

硕士学位论文

(专业学位论文)

基于大语言模型的医疗知识图谱
扩充与应用

**EXPANSION AND APPLICATION OF
MEDICAL KNOWLEDGE GRAPHS
BASED ON LARGE LANGUAGE MODELS**

姚行志

哈尔滨工业大学

2025 年 1 月

国内图书分类号: TP391.1
国际图书分类号: 004.8

学校代码: 10213
密级: 公开

硕士学位论文

基于大语言模型的医疗知识图谱 扩充与应用

硕士研究生: 姚行志

导师: 关毅教授

申请学位: 工程硕士

学科或类别: 计算机技术

所在单位: 计算学部

答辩日期: 2025 年 1 月

授予学位单位: 哈尔滨工业大学

Classified Index: TP391.1

U.D.C: 004.8

Dissertation for the Master's Degree

EXPANSION AND APPLICATION OF MEDICAL KNOWLEDGE GRAPHS BASED ON LARGE LANGUAGE MODELS

Candidate: Yao Xingzhi

Supervisor: Prof. Guan Yi

Academic Degree Applied for: Master of Engineering

Specialty: Computer Technology

Affiliation: Faculty of Computing

Date of Defence: January, 2025

Degree-Confering-Institution: Harbin Institute of Technology

摘 要

大语言模型在医疗领域的应用正推动着诊断和治疗方式的革新，加速医疗数字化转型，并提升诊疗效率和患者体验。然而，它们生成的回复仍可能存在不准确的信息，即“幻觉”现象。这在医疗领域中尤为严重，可能会直接危及患者的健康。因此，为了确保大语言模型的安全和高效应用，解决幻觉问题至关重要。在此背景下，知识图谱作为一种结构化的信息表示，成为缓解“幻觉”问题的有效手段。通过组织节点和边构建知识网络，知识图谱为大语言模型提供更准确的事实支持，从而提高回复的可靠性与精准性。然而，由于医学知识庞大复杂，知识图谱规模不足可能限制其效用。因此，不断扩大知识图谱的规模对提高大语言模型在医疗领域的应用效果发挥着不可忽视的作用。

本课题首先探讨了如何利用大语言模型从医学文本中挖掘关系三元组，并基于所设计的框架，在新的医学文本语料中抽取关系三元组。随后，本文进一步研究如何将抽取到的高质量关系三元组与现有医疗知识图谱进行有效融合。基于上述研究内容，本文提出了一个融合动态关系三元组示例和自反思机制的关系抽取框架，旨在高效完成医疗领域的关系抽取任务。通过在人工标注数据集上进行实验，结果表明，所提方法的准确率较直接利用大语言模型抽取提升了 15.12%，验证了该框架在关系抽取任务中的有效性。此外，本文还设计了基于实体对齐和关系一致性检查的知识图谱扩充算法，有效避免了重复的关系三元组被融合进现有知识图谱中，从而提升知识图谱的质量和一致性。为了验证所提框架的实际效果，本文选取了中文医学书籍作为数据源，利用所提出的关系三元组抽取框架，成功抽取到 6374 个高质量的关系三元组，并与现有医疗知识图谱进行融合。通过持续收集医学文本语料并应用本文提出的关系抽取框架和知识图谱扩充算法，可以在一定程度上缓解医疗知识图谱规模不足的问题。

本课题的核心是将知识图谱与大语言模型相结合，应用于医疗领域的下游任务。本文提出了一种融合向量知识库和医疗知识图谱的应用框架。该框架首先根据用户查询从向量知识库中检索相关的外部知识，然后将用户查询与外部知识融合后输入给大语言模型，以生成初步结果。随后，基于大语言模型的输出结果，从医疗知识图谱中检索相关知识子图进行校正，以提升最终结果的准确性。实验结果表明，所提框架在 MedQA 中文数据集上的准确率较零样本提示方法提高了 2%；在 CMB-Exam 数据集上的准确率提升了 2.92%。这些结果说

明本文所提出的框架显著提升了大语言模型在医疗应用中的准确性。

总的来说，本文围绕医疗知识图谱展开，深入研究了利用大语言模型扩大医疗知识图谱规模以及知识图谱在医疗任务中的应用，实验结果证明本文提出的框架在关系抽取任务和下游应用任务上均取得了显著提升。我们期待随着医疗知识图谱的不断完善与扩充，智慧医疗将在提高医疗效率、降低误诊率和优化患者体验方面发挥越来越重要的作用，从而推动医疗行业的数字化转型与持续发展。

关键词：大语言模型；医疗知识图谱；关系抽取；检索增强；自反思机制

Abstract

Large language models (LLMs) are driving innovations in diagnosis and treatment within the healthcare sector, accelerating digital transformation, and enhancing both diagnostic efficiency and patient experience. However, the responses generated by these models may still contain inaccurate information, known as "hallucinations," a phenomenon that is particularly critical in healthcare, as it can directly impact patient health. Therefore, addressing the hallucination issue is crucial for ensuring the safe and effective deployment of LLMs. In this context, knowledge graphs, as a structured form of information representation, have emerged as an effective solution to mitigate hallucinations. By organizing nodes and edges to construct a knowledge network, knowledge graphs provide more accurate factual support for LLMs, thereby improving the reliability and precision of their responses. However, due to the vast and complex nature of medical knowledge, the limited scale of knowledge graphs may restrict their utility. Therefore, continuously expanding the scale of knowledge graphs is essential for enhancing the application of LLMs in the healthcare field.

We first explore how to utilize LLMs to extract relationship triples from medical texts. Based on the designed framework, relationship triples are then extracted from new medical text corpora. Subsequently, we further investigate how to effectively integrate the extracted high-quality relationship triples with the existing medical knowledge graph. To achieve this, we propose a relationship extraction framework that combines dynamic relationship triple examples with a self-reflection mechanism, aiming to efficiently perform relationship extraction tasks in the medical domain. Experiments on manually annotated datasets demonstrate that the proposed method improves accuracy by 15.12% compared to directly using a large language model for extraction, thereby validating the effectiveness of the proposed framework in relationship extraction tasks. In addition, we design a knowledge graph expansion algorithm based on entity alignment and relationship consistency checking, effectively preventing redundant relationship triples from being integrated into the existing knowledge graph, thus enhancing the quality and consistency of the knowledge graph. To validate the practical effectiveness of the proposed framework, we select Chinese medical books as the data source and successfully extracts 6,374 high-quality

relationship triples using the proposed framework, which are then integrated into the existing medical knowledge graph. By continuously collecting medical text corpora and applying the proposed relationship extraction framework and knowledge graph expansion algorithm, the issue of insufficient scale of medical knowledge graphs can be alleviated to some extent.

The core focus of this study is to combine knowledge graphs with LLMs for downstream tasks in the healthcare domain. We propose an application framework that integrates vector-based knowledge repositories with medical knowledge graphs. The framework first retrieves relevant external knowledge from the vector knowledge base based on the user's query. It then combines the user's query with the external knowledge and inputs them into LLMs to generate preliminary results. Subsequently, based on the output of LLMs, relevant subgraphs are retrieved from the medical knowledge graph for correction, enhancing the accuracy of the final result. Experimental results demonstrate that the proposed framework improves accuracy by 2% over zero-shot prompting methods on the MedQA Chinese dataset, and by 2.92% on the CMB-Exam dataset. These results indicate that the framework significantly enhances the accuracy of large language models in medical applications.

In summary, we focus on medical knowledge graphs and explore the use of LLMs to expand the scale of medical knowledge graphs, as well as their application in healthcare tasks. Experimental results demonstrate that the proposed framework achieves significant improvements in both relation extraction tasks and downstream application tasks. We anticipate that as medical knowledge graphs continue to be refined and expanded, intelligent healthcare will play an increasingly important role in enhancing medical efficiency, reducing misdiagnosis rates, and optimizing patient experience. This will, in turn, drive the digital transformation and sustained development of the healthcare industry.

Keywords: Large Language Model, Medical Knowledge Graph, Relation Extraction, Retrieval Augmented, Self Reflection

目 录

第 1 章 绪论.....	1
1.1 课题研究背景及意义.....	1
1.2 国内外研究现状.....	3
1.2.1 大语言模型研究现状.....	3
1.2.2 医疗知识图谱研究现状.....	5
1.2.3 基于大语言模型的关系抽取方法研究现状	6
1.2.4 基于大语言模型的检索增强技术研究现状	9
1.3 本文研究内容及结构安排	11
第 2 章 相关理论基础	14
2.1 引言.....	14
2.2 任务介绍.....	15
2.2.1 基于大语言模型的医疗知识图谱扩充	15
2.2.2 基于大语言模型的医疗知识图谱应用	16
2.3 大语言模型相关技术.....	16
2.4 检索增强生成相关技术.....	21
2.4.1 向量知识库和知识图谱相关技术.....	21
2.4.2 外部知识库检索策略与方法.....	24
2.5 任务评价指标.....	26
2.6 本章小结.....	28
第 3 章 基于大语言模型的医疗知识图谱扩充研究	29
3.1 引言.....	29
3.2 融合动态提示和自反思机制的关系抽取算法	31
3.3 基于实体对齐和关系一致性检查的知识图谱扩充算法	34
3.4 实验与分析.....	36
3.4.1 实验数据集构建与分析.....	36
3.4.2 实验设置.....	37
3.4.3 基于大语言模型的命名实体识别验证实验	37
3.4.4 基于大语言模型的关系三元组抽取验证实验	38
3.4.5 基于大语言模型的医疗知识图谱扩充实验	39
3.5 本章小结.....	40
第 4 章 基于大语言模型的医疗知识图谱应用	42
4.1 引言.....	42
4.2 医疗向量知识库的构建与检索	43
4.3 基于医疗知识图谱的后验矫正	45

4.4 实验与分析.....	47
4.4.1 实验数据集构建.....	47
4.4.2 实验设置与结果分析.....	47
4.4.3 示例分析.....	50
4.5 本章小结.....	51
结论.....	52
参考文献.....	54
附录 A 提示词模版.....	59

第 1 章 绪论

1.1 课题研究背景及意义

随着人工智能技术的飞速发展，大语言模型在医疗健康领域的应用正逐步成为学术研究和行业实践中的重要热点。近年来，以 ChatGPT^①、Gemini^②为代表的大语言模型在自然语言处理领域取得了突破性进展，展现出前所未有的语言理解和生成能力。这些模型不仅能够精准理解各种文本形式的输入，还具备处理复杂推理任务的能力。中国政府及国内相关企业一直致力于推动人工智能技术在医疗领域的创新应用，积极构建智能医疗生态系统。这些努力不仅加速了医疗行业数字化转型的进程，还为医疗服务的智能化、精细化和个性化发展奠定了坚实的基础。在 2024 年，李强总理在《政府工作报告》^③中明确指出，要加快推动大数据、人工智能等前沿技术的研发和应用，进一步促进科技创新与经济发展的深度融合，要实施“人工智能+”行动计划，推动人工智能在各个行业和领域的广泛应用，以提升国家竞争力和经济发展质量。医疗作为人民群众生活中最为重要的民生保障之一，其直接关系到社会的整体健康水平和国家的长远发展。因此，将人工智能技术充分应用于医疗领域，既是顺应科技进步的必然要求，也是提升医疗服务质量和效率、解决“看病难、看病贵”问题的迫切需要。

人工智能在医疗领域中应用的主要手段是通过高效的数据处理生成精准的诊断结果和个性化的治疗方案，从而提升医疗服务的质量。然而，尽管人工智能在医疗领域展现出巨大的潜力，但要确保其真正发挥应有的价值，最关键的一点就是准确性。医疗决策直接关系到患者的生命健康，任何细微的偏差或错误都可能带来严重的后果。因此，人工智能技术在医疗领域中的应用必须具备高度的可靠性。只有确保其提供的诊断、治疗建议有坚实的依据，并且与临床实际紧密结合，才能真正保障患者的安全和治疗效果。

人工智能在医疗领域的广泛应用离不开对数据的依赖，其中文本数据尤为重要。典型的医疗文本数据包括病人的电子病历、医学教科书、医学考试题等。随着医学数据的急剧增长和不断更新，数据的存储方式多种多样，质量参差不

① <https://chatgpt.com/>

② <https://gemini.google.com/>

③ https://www.gov.cn/yaowen/liebiao/202403/content_6939153.htm

齐,这使得从海量数据中提取有效信息的效率日益下降。因此,如何有效组织和利用这些庞大的文本数据,并从中挖掘有价值的信息,成为一个亟待解决的重要课题。研究人员将目光聚焦于各类结构化知识库的构建上,如 Freebase^[1]、WordNet^[2]、Yago^[3] 等。这些结构化知识库的建立促进了人工智能的发展,提供的结构化知识为众多下游任务提供了支持,如问答系统、搜索引擎等智能应用。随着知识源的不断发展与更新,带来的关键问题是:如何有效表示这些知识,以准确反映客观世界的事实;以及如何构建合理的知识表示方法,支持更深层的语义理解。2012 年,谷歌基于网络结构的知识表示形式提出了知识图谱(Knowledge Graph, KG)这一概念,知识图谱的特点在于使用图结构来表示和存储知识,其中节点代表实体,边表示节点之间的关系,较为出名的知识图谱有 DBpedia^[4]、Wikidata^[5] 等。

知识图谱主要由实体、属性和关系三部分构成,通常通过(头实体,关系,尾实体)形式的三元组进行存储。在构建知识图谱的过程中,如何从海量的非结构化文本中提取有效信息是一个关键挑战。通常,自动化构建知识图谱的过程可分为两个主要步骤:命名实体识别(Named Entity Recognition, NER)和关系抽取(Relation Extraction, RE)。命名实体识别任务是指从文本中识别出具有特定意义的实体。关系抽取任务旨在从非结构化文本中自动抽取实体之间的语义关系。目前,知识图谱构建技术主要分为以下几类:1. 基于监督学习的方法;2. 基于无监督学习的方法;3. 基于大语言模型的方法。基于监督学习的命名实体识别模型和关系抽取模型虽然具有较高的准确率,但其主要缺点是依赖于大量的人工标注数据集,并且缺乏领域迁移能力,会耗费大量的人力和时间。与监督学习不同,基于无监督学习的知识图谱构建方法不依赖人工标注数据。它通过从大规模文本中挖掘潜在的模式和结构,自动识别实体及其关系。尽管这种方法不需要大量的标注数据,但其抽取效果通常不如监督学习方法。近年来,随着深度学习的发展,基于大量无监督文本训练出的大语言模型展现出强大的上下文理解能力,大语言模型通过预训练阶段已经掌握了丰富的语言知识,使得其在特定任务上可以不再依赖大量标注数据,同时,大语言模型强大的推理能力使其能够处理更为复杂的推理任务。因此,如何利用大语言模型的预训练知识,在无需大量人工标注数据的情况下,从非结构化文本中自动抽取高质量的关系三元组,已成为当前知识图谱构建的重要研究方向。借助大语言模型的强大语义理解和推理能力,不仅能够有效提升知识图谱的构建效率和准确性,还为知识图谱的应用带来新的机遇。

在医疗领域,构建高质量的医疗知识图谱具有至关重要的意义。知识图谱

作为一种高效的知识组织与表示方式，能够系统化地整合和组织医疗领域的各种知识，为人工智能系统提供丰富的背景信息和结构化的数据支持，从而为模型的训练和推理奠定坚实的基础。医疗知识图谱通过将医学知识以图结构的形式展现，不仅有助于清晰解释各类医学实体之间的复杂关系，还能为大语言模型提供精准的上下文信息。这使得大语言模型在医学领域能够更好地理解并推理医学实体之间的相互作用，从而提升推理和决策的准确性。总的来说，引入知识图谱的优势在于，它使得人工智能在医疗领域的应用能够更加依赖真实的医学知识，避免过度依赖模型的黑箱推理，确保系统的科学性与可靠性。通过结合知识图谱和大语言模型，能够更准确地支持疾病诊断和治疗方案的制定，进一步推动个性化医疗的发展，提升诊疗效率，并确保医疗实践中的安全性与有效性。

基于上述背景，本课题主要研究如何利用大语言模型扩充现有的医疗知识图谱并将其应用于下游任务中。具体而言，本课题设计了一个关系抽取框架，能够从海量非结构化文本数据中自动挖掘关系三元组。同时，通过引入自反思机制，确保提取的关系三元组具有较高的置信度。在此基础上，通过关系一致性判断，筛选出不重复的关系三元组并将其加入现有的知识图谱，从而有效解决知识图谱稀疏性和语义表达能力有限的问题。通过这一方法，医疗知识图谱的规模将不断扩展，进而为大语言模型提供更加丰富的结构化知识支持。扩充后的医疗知识图谱将帮助大语言模型进行更加精准的推理，同时提升推理过程的可解释性，从而在医疗决策中发挥更大的作用。

1.2 国内外研究现状

1.2.1 大语言模型研究现状

预训练语言模型是大语言模型的前身，它是一种在大规模未标注文本数据上进行预训练，从中学习语言的潜在规律和语义信息的模型。这种方法的核心思想是利用海量的文本数据进行无监督学习，捕捉文本中的上下文信息，从而获得通用的文本向量表示。早期的预训练语言模型，如 ELMo (Embeddings from Language Models, ELMo)^[6] 采用了双向长短时记忆网络 (Bidirectional Long Short-Term Memory Network, biLSTM)^[7]，通过在大规模文本上进行预训练，生成融合上下文语义信息的嵌入向量。与传统的词向量表示方法不同，ELMo 能够根据上下文的变化动态调整词向量的表示，从而有效地提高了在多个自然语言处理任务中的表现。随后基于 Transformer 架构的 BERT (Bidirectional Encoder Represen-

tations from Transformers)^[8] 模型,进一步推动了预训练语言模型的发展。**BERT** 的核心创新在于其双向编码器架构,它通过自注意力机制来捕捉输入文本中的长距离依赖关系。与传统的单向语言模型不同,**BERT** 在预训练阶段通过同时关注文本的左右上下文信息,能够全面理解每个词在句子中的含义。此外,**BERT** 还设计了两种特定的预训练任务:掩码语言模型和下一句预测任务在大规模未标注文本数据上进行预训练。掩码语言模型通过随机遮蔽句子中的部分单词并要求模型预测这些被遮蔽的词,从而帮助模型学习上下文信息;下一句预测任务则训练模型理解句子间的关系和连贯性。通过这些任务的训练,**BERT** 在多个自然语言处理任务中实现了显著的性能提升,尤其在文本分类、问答、命名实体识别等任务上表现出了卓越的能力。

随着预训练语言模型的发展,以及模型规模和训练数据的不断扩大,研究者们开始探索更大规模的语言模型。由此,逐渐提出了大语言模型(**Large Language Model, LLM**)的概念。大语言模型如 **GPT**^[9] 系列、**PaLM**^[10] 等,不仅具备更强的语言理解和生成能力,而且能够处理更复杂的任务,涵盖更广泛的应用场景。它们通过在更大规模的文本数据上进行训练,学习更加细致和深层次的语义规律,从而在各种自然语言处理任务中展现出更高的性能和更强的推理能力。大语言模型不仅在自然语言处理任务中取得了显著进展,还表现出了一定的“涌现能力”,可以在没有特定预训练的情况下通过提示学习解决一系列复杂任务。其中,美国的 **OpenAI** 公司发布的 **ChatGPT** 最引人关注,其强大的推理能力,为研究人员带来极大的便利。在国内,各大互联网公司也紧随其后,积极追赶大语言模型的浪潮。首先,百度推出的文心一言(**Ernie Bot**)是国内领先的大语言模型,在中文语言理解、生成以及对话能力上取得显著进展,并在多个领域得到了广泛应用。字节跳动推出的豆包是一款大语言模型产品,独特之处在于它在交互过程中加入了联网搜索功能,从而保证了大语言模型上下文提示的时效性,提升了大语言模型输出的准确性。此外,阿里巴巴推出的通义千问(**Qwen**)^[11] 是另一款广泛应用于电商、金融、医疗等领域的大语言模型,并且支持下载各个系列(如:**Qwen-Coder**、**Qwen-VL**等)的模型权重,促进了学术界和行业的进一步探索与发展。

随着大语言模型的广泛应用,它们不仅在通用任务中表现出惊人能力,还逐渐渗透到医疗、金融、法律等垂直领域。由于这些领域的任务通常是知识密集型的,大语言模型凭借其强大的数据处理、理解和推理能力,成为当前研究和重要方向。如:在法律领域有 **DISC-LawLLM**^[12]、夫子·明察司法大模型^[13] 等领域大语言模型。金融领域有轩辕^[14]、**FinGPT**^[15]、**FLANG**^[16] 等领域大

模型，由此可见，大语言模型在各个垂直领域的应用已是遍地开花。在医疗领域，大语言模型同样展现出了巨大的潜力。医疗领域的知识庞大且复杂，涵盖了大量的专业术语、临床经验和最新的研究成果。传统的医疗辅助工具往往面临着知识更新速度慢、理解深度不足等问题，而大语言模型的出现则为这些问题提供了有效的解决方案。通过对医学文献、临床病例、药品信息等海量数据的学习，大语言模型能够帮助医生更准确地诊断、制定治疗方案，并为患者提供个性化的健康建议。Qiu^[17] 等人使用 ChatGPT 作为文本改写工具，将单轮长文本的心理咨询对话转换为多轮共情对话，更好地模拟了真实世界中求助者与支持者之间的多轮对话交流。并选用了 ChatGLM^{[18][19]} 模型作为基础模型，使用 LoRA^[20] 进行指令微调。最终，实验结果表明，经过微调后的模型在共情、倾听和安慰方面的能力得到了显著提升，从而实现了具备心理咨询功能的人工智能心理医生角色。香港中文大学团队发布了 HuaTuoGPT^[21]，通过结合 ChatGPT 蒸馏数据与医生数据进行微调，同时引入混合反馈强化学习进行模型优化，使得其在医疗咨询中的表现超过了现有开源大模型。IVYGPT^[22] 由澳门理工大学发布，IVYGPT 基于 LLaMA^[23] 模型，通过高质量的医学问答实例和基于人类反馈的强化学习进行训练和微调，旨在提升模型在医学问答中的表现。在训练过程中，IVYGPT 使用了真实的医患对话数据，结合了 HuaTuoGPT 发布的数据集，使用 QLoRA 进行微调训练。实验结果表明，IVYGPT 在与真实医生回答的语义相似度比较中得分最高，表明其能够更好地捕捉和表达医学问答中的语义相关性。

综上所述，大语言模型在医疗领域展现出广泛的应用前景，但仍面临一些挑战。医疗领域对准确性和时效性的要求非常高，而大语言模型的预训练知识存在时间滞后性。如何解决大语言模型预训练知识过时的问题，已成为当前研究的一个关键挑战。同时，研究人员也在积极探索如何提升大语言模型在医疗领域推理的可靠性，确保其能够在复杂且高风险的医疗决策中提供稳定、可信的支持。

1.2.2 医疗知识图谱研究现状

医疗知识图谱在现代医学研究与临床实践中具有至关重要的作用。因此，越来越多的研究者集中精力于医疗知识图谱的构建。国际上，SNOMED CT (Systematized Nomenclature of Medicine-Clinical Terms)^[24] 是全球广泛使用的医学术语系统，涵盖了大量医学概念及其关系，是医疗领域中最全面和复杂的知识图谱之一，广泛用于临床记录、医疗决策支持系统、医学研究等任务。UMLS (Uni-

fied Medical Language System, 统一医学语言系统)^[25] 是由美国国立医学图书馆开发并维护的一套医学术语系统, 旨在为医疗健康信息提供统一的语言基础。通过整合多个医学领域(如: 临床医学、内科学等)的术语、标准和知识体系, 为医疗领域的自然语言处理应用提供了重要资源。PrimeKG^[26] 是由哈佛医学院 Zitnik 实验室开发的一个综合性知识图谱, 通过整合了 20 个高质量的生物医学资源, 涵盖了 17080 种疾病, 并挖掘出 4050249 个关系。同时, PrimeKG 还提供了药物和疾病的临床指南文本描述, 以支持多模态分析。在国内, 上海曙光医院利用文本抽取、关系数据转换以及数据融合等技术, 构建了中医药知识图谱^[27], 并实现了中医药知识图谱的智能应用。杨锦锋^[28] 等人构建了中文电子病历标注语料库, 并提出了适用于中文电子病历的实体识别和关系抽取标注体系, 具有重要的应用价值。CMeKG (Clinical Medicine Knowledge Graph)^[29] 是一个面向临床医学领域的知识图谱, 整合了大量医学知识, 广泛支持临床决策、医疗信息检索、医学研究等多种应用。杨洋^[30] 等人定义了中文医学文本的知识表示体系, 并为中文医学实体识别与关系抽取提供了相关语料支持。同时, 他们对《诊断学》一书进行了标注, 构建了监督数据集, 并利用该数据集训练深度学习模型, 进而构建了 WiMedKG 医疗知识图谱, 旨在为医疗领域提供更好的服务。另外, 为了应对中文医学知识的匮乏以及现有跨语言知识库中实体关系不足的问题, Sheng^[31] 等人创建了 CLMed 平台, 整合了跨语言的医学数据, 成功生成了一个大规模的跨语言医疗知识图谱, 以提升跨语言医学数据的处理能力和应用价值。

综上所述, 国内外医疗知识图谱的研究已取得显著进展, 并且以 UMLS 为代表的医疗知识图谱已经在临床实践中得到广泛应用。然而, 国内在医疗知识图谱构建方面的工作仍显不足, 尤其是在中文医疗领域, 缺乏自动化构建知识图谱规模的有效手段, 以融入新的医学知识。因此, 未来需要在中文医疗知识图谱的构建上深入研究, 填补这一空白, 推动医疗知识图谱的进一步发展。

1.2.3 基于大语言模型的关系抽取方法研究现状

关系抽取 (Relation Extraction, RE) 是知识图谱构建中的核心任务, 旨在从非结构化文本中自动识别实体之间的语义关系。传统的关系抽取通常采用机器学习方法, 基于特征工程来构建模型。这些方法的主要思路是通过提取实体对之间的上下文特征, 然后使用分类模型来预测实体之间的关系, 如使用决策树^[32]、支持向量机 (Support Vector Machine, SVM)^[33]、随机森林^[34] 等方法。随着人工智能技术的不断发展, 关系抽取任务的处理方法发生了显著变化, 传统

的基于特征工程和机器学习模型的关系抽取方法逐渐被深度学习方法所取代,深度学习模型通过自动学习特征表示,能够有效地捕捉更加复杂的语义关系和上下文信息,如使用循环神经网络(Recurrent Neural Network, RNN)和长短期记忆网络(Long Short-Term Memory, LSTM)完成关系抽取任务,并且在实际应用中取得了显著的效果。然而,尽管使用深度学习模型在关系抽取任务中带来了显著的性能提升,但对大规模标注数据的依赖仍然是亟待解决的挑战。

为了解决这一挑战,研究者们提出了几种可能的解决方案。弱监督学习作为一种重要方法,利用部分标注或间接的监督信号。例如,远程监督方法通过将已有知识库中的实体对和关系自动映射到文本中生成训练数据,从而有效减少对大规模标注数据的依赖,同时在一定程度上保持了模型的高性能。其次,迁移学习也为解决标注数据不足的问题提供了有效途径,通过使用大规模语料库进行预训练,并将预训练得到的语义表示迁移到关系抽取任务中,迁移学习能够显著提高模型的性能,尤其是在标注数据稀缺的情况下也能获得较好的性能。除了迁移学习之外,少样本学习(Few-shot Learning)^[35]也被提出作为应对标注数据不足的另一种方法。少样本学习通过优化模型,使其能够从少量样本中快速学习到有效的特征表示,确保模型在数据稀缺条件下也能有不错的表现。

随着大语言模型不断发展,研究人员逐渐将其应用于关系抽取任务。大语言模型的核心在于其自注意力机制,自注意力机制使模型在处理文本时,能够捕捉到长距离词汇之间的依赖关系,从而理解更复杂的上下文信息。Trajanoska^[36]等人在 ChatGPT 发布后首先将大语言模型应用于关系抽取任务上,通过对非结构化文本进行实体识别和关系抽取,并将抽取结果进行实体链接的后处理步骤,以规范化实体,提升了关系抽取结果的规范性。Zhang^[37]等人通过定义 Extract-Define-Canonicalize 的框架自动化构建知识图谱。但这样的抽取方式对模式检索器的要求较高,对特定领域的关系抽取任务并不适用。Zhu^[38]等人通过设置多智能体协作来完成知识图谱构建任务,智能体会根据任务需求分配角色,并通过智能体之间的对话协作,利用大语言模型的内部知识和外部资源来构建知识图谱。Carta^[39]等人提出了基于大语言模型构建知识图谱的流程,主要分为三个阶段:第一阶段是从给定的文本中提取实体和三元组,并为实体提供描述和类型,为三元组提供谓词的描述。第二阶段是实体和谓词解析,这一阶段目的是消除实体和谓词之间的歧义问题,将提及同一实体的不同表达形式合并为单一实体,并将不同表达形式的同一关系合并为单一关系。第三阶段是自动推断知识图谱的模式,即定义知识图谱中实体类型和关系的组织结构,这种方法不需要外部知识库和人工干预,能够处理大规模数据集,并适用于不同的垂直领域。

GPT-RE^[40] 利用大语言模型的上下文学习能力来完成知识图谱构建任务，通过实体嵌入向量进行提示并通过少样本示例的方法来提升关系抽取任务的准确性。

总的来说，基于大语言模型完成关系抽取任务有以下三种方式：(1) 微调大语言模型以适应领域关系抽取任务：微调方法是指在预训练的大语言模型基础上，通过利用特定关系抽取任务的数据集进行参数调整，使模型能够更准确地识别和分类文本中实体之间的关系类型。然而，这种方法也面临一些挑战，尤其是需要大量的标注数据和较高的计算资源，这可能在实际应用中增加成本和复杂性。总体而言，微调大语言模型以应用于特定任务是一种常用且有效的技术，广泛应用于垂直领域中的各种任务。(2) 提示工程：提示工程是基于大语言模型进行关系抽取的另一种重要方法。它通过设计特定的自然语言提示，来引导大语言模型执行关系抽取任务，而无需对模型进行微调。该方法的主要优势在于显著减少了对标注数据的依赖，仅依靠少量示例或思维链等方式，借助大语言模型强大的上下文理解能力，便能取得较好的效果。总体而言，提示工程结合了大语言模型的生成能力与灵活性，在资源有限的情况下，仍能实现高效且准确的关系抽取。(3) 智能体流式抽取：在智能体流式抽取框架中，关系抽取任务通常被划分为两个相互关联且逐步推进的子任务，即命名实体识别与关系抽取。具体而言，整个过程可以分为两个阶段：第一阶段通过提示学习策略，引导大语言模型从文本中识别并提取出相关实体。在此阶段，重点是让模型准确捕捉文本中的关键信息，并为后续的关系抽取奠定基础。第二阶段则基于第一阶段提取的实体，通过提示进一步引导大语言模型识别实体之间可能存在的关系。这种分阶段的处理方式降低了直接进行端到端关系抽取的复杂性，使得模型能够更专注于单一子任务，从而提升整体抽取效率。然而，这种方法也引入了潜在的误差传递问题：如果第一阶段的实体识别结果存在误差，这些错误信息将不可避免地传递到第二阶段的关系抽取中，进而影响最终的结果。因此，研究者需要进一步探索有效的机制，以减少误差积累、改进提示策略或引入后处理步骤，从而提升多阶段关系抽取的整体质量。

综上所述，利用大语言模型完成关系抽取任务不仅有效减少了对标注数据的依赖，还凭借强大的预训练知识展现了良好的性能。然而，如何高效执行关系抽取任务，并对抽取出的关系三元组进行置信度检验，仍然是关系抽取任务的难点。在医疗领域，医学文本通常包含高度专业化的术语和复杂的句法结构，这使得关系抽取任务更加具有挑战性。

1.2.4 基于大语言模型的检索增强技术研究现状

大语言模型,如 ChatGPT、文心一言等,通常依赖于预训练的文本语料和微调阶段的监督数据来生成内容。然而,这种基于静态数据的训练方式也带来了一些问题,尤其在回复的时效性和准确性方面。由于生成模型的预训练数据是固定的,它的内部知识只能反映出训练数据中的信息。这意味着,若模型的预训练知识是基于某一时间点的语料库,那么它就无法了解该时间点之后发生的事件。此外,大语言模型的输出完全依赖于训练数据的质量。在面对其未曾接触过的问题时,模型往往会生成包含错误的回答,这使得模型在执行知识密集型任务时显得推理能力不足。检索增强技术 (Retrieval-Augmented Generation,RAG) 是一种将信息检索应用到生成式模型的创新方法,旨在提升自然语言处理任务中的模型推理能力。早期,关^[41]等人提出了一种个性化知识子图构建方法,并设计了基于预训练模型和知识子图联合推理的疾病诊断框架,这是检索增强技术在预训练语言模型中的一种应用方式。zhao^[42]等人提出了在大模型时代使用检索增强技术的基础框架,如图1-1所示。具体而言,用户的输入可以是文本、代码、图像或语音等多种形式,然后通过不同的检索方式(如稀疏检索、稠密检索等),从检索源(如:文档、视频、网站)中获取相关信息,最后将检索到的信息与用户查询相结合输入到生成器,通过生成器输出最终的结果。




图 1-1 检索增强的一般性框架

在大模型时代,许多研究者专注于检索增强生成技术的研究。Lin^[43]等人在 2023 年提出一种名为 RA-DIT 的框架,该框架首先通过微调检索器以返回与

用户查询更相关的结果，同时微调语言模型以更好地使用检索到的信息，实验结果在知识密集型任务上，显著优于各种基于上下文的检索增强方法。Yoran^[44]等人提出，在检索过程中检索到的不相关信息可能对语言模型产生误导，因此他们设计了一个自然语言推理模型，能够从检索结果中根据约束条件筛选出相关信息。此外，在训练过程中，他们采用了将相关信息与无关信息混合的提示方式。实验表明，这种方法能帮助语言模型判断何时应充分利用外部知识，何时应屏蔽外部知识并依赖内部知识。Xu 等人^[45]通过将检索到的文档压缩成文本摘要的形式，减轻了语言模型在长文档中识别相关信息的负担，同时降低了计算成本。Asai 等人^[46]提出了 self-RAG 框架，旨在通过检索增强和自反思机制来提高大语言模型的生成质量和事实准确性，self-RAG 框架通过添加特殊标记，使语言模型能够根据需求自适应地检索相关段落，并反思检索到的段落是否与问题相关，从而生成更准确的内容。

检索增强技术在大语言模型应用于医疗领域中同样至关重要。由于医疗领域涉及大量专业知识和快速更新的信息，单纯依赖模型的内部知识和预训练数据往往难以满足实时性和准确性的需求。但大语言模型拥有强大的上下文学习能力，可以通过检索到的外部知识提示大语言模型提高其输出结果的准确性和可靠性。Wu^[47]等人提出了 MedKP 框架，旨在提高大语言模型在医疗对话生成任务中的应用效果。MedKP 框架通过整合外部知识模块和内部临床路径编码来提升大语言模型在医疗对话时的准确性和可靠性。Xiong^[48]等人提出了 MedRAG 的工具包，对不同语料库、检索器和大语言模型的 41 种组合进行了大规模的实验，实验发现，不同医学语料库和检索器的组合能够取得最佳性能，并且还发现了模型性能与检索片段数量之间的对数线性关系。Wu^[49]等人提出了 Med-GraphRAG 框架，利用大语言模型将检索到的相关信息组织为图结构的形式，来为大语言模型提供外部知识，可以更好地加强模型对外部知识的理解能力，从而增强其回复的可靠性和准确性。

在检索增强生成技术中，知识图谱作为一种结构化的信息存储形式，已经在医疗领域得到了广泛应用，特别是在疾病诊断任务中，作为外部知识源，它能够显著提升模型的性能。通过提供系统化的医学知识，知识图谱有效弥补了大语言模型在医学领域的知识盲点，并增强了其推理能力。Gao^[50]等人提出了一种创新的方法，将知识图谱 UMLS 应用于疾病诊断任务。他们设计了一个图神经网络模型，用于定位 UMLS 知识图谱中的关键节点，并识别出有助于诊断的关键知识路径。这些路径被重构为半结构化的表示形式，并通过提示词模板引导大语言模型进行有效推理。研究结果表明，结合知识图谱的模型相比于单

纯依赖语言模型，显著提高了疾病诊断任务的准确性和可解释性，尤其在处理复杂病例和多变量推理任务时，展现出了明显的优势。此外，Wen^[51]等人提出了MindMap这一新型提示流水线方法，进一步探讨了知识图谱在医疗领域的应用。该方法通过融合基于路径探索的知识子图和基于邻居探索的知识子图，为大语言模型提供了更多的外部知识信息，在多个医疗领域问答数据集上表现出更优的效果，尤其是在面对复杂病例时，能够有效减少模型幻觉现象的发生。他们还提出了当检索到的知识与任务不匹配时，如何通过合理的推理机制和知识图谱的结构化数据减少幻觉现象，提高模型输出的可靠性。由此可见，知识图谱作为外部知识源，在医疗疾病诊断任务中发挥了重要作用。它不仅能够为大语言模型提供丰富、结构化的先验知识，还能为模型的输出结果提供可解释性。这些研究成果为智能医疗的发展提供了新的思路和方法，也为未来医疗诊断领域的技术发展奠定了坚实的基础。

综上所述，大语言模型在医疗领域的应用愈发广泛，其在疾病诊断、药物推荐等任务上有着卓越表现。然而，当前大语言模型在医疗领域的推理效果仍有待提高。在这种背景下，将检索增强技术融入医疗大语言模型的应用当中具有重要意义。首先，检索增强技术为模型提供了接入外部可靠医学知识库的途径。通过实时查询权威的医疗文献、指南、数据库和临床实践案例，大语言模型得以生成更加准确、全面和可信的回答。其次，外部知识库可以不断地迭代和更新，从而快速适应最新医学发现、药物治疗方案与诊疗规范的演变，使模型无需重新训练也具备动态更新的能力。因此，将检索增强技术引入到医疗领域大语言模型的研究与应用，不仅有助于提升其诊断分析、临床决策支持的精度与可靠性，更为相关领域的发展奠定了坚实基础，对推动智能医疗生态的成熟与普及具有深远的实践价值和研究意义。

1.3 本文研究内容及结构安排

基于上述研究背景与现状，本课题的研究内容主要包括两大部分，如图1-2所示。第一部分是：设计并实现一套基于大语言模型的医疗知识图谱扩充框架，旨在提升医疗知识图谱的知识覆盖范围和语义表达能力。具体而言，利用大语言模型构建实体识别和关系抽取框架，自动识别并提取医疗文本中出现的实体及其关系，并通过自反思机制对提取出的关系三元组进行置信度评估，以确保抽取结果的高质量和可靠性。同时，利用人工标注的专业书籍语料对实体识别方法和关系抽取方法的准确性进行严格验证，并利用所设计框架从新医疗

语料中挖掘高质量的三元组知识，持续扩充和优化医学知识图谱，解决其稀疏性和语义表达不足的问题。第二部分是：将医疗知识图谱应用于评估和提升大语言模型生成回复的质量。具体来说，首先，利用检索增强技术从权威医学教科书中检索与用户查询相关的文档片段，为大语言模型提供丰富的外部知识支持。这些外部知识可以帮助大语言模型在生成回复时更好地依赖实际的医学知识，而不仅仅是基于预训练知识推断。在此基础上，进一步对大语言模型生成的回复进行实体识别，识别出其中包含的医学实体。接着利用实体对齐技术将医学实体链接到医疗知识图谱上，构建相应的知识子图。通过验证大语言模型生成回复与知识图谱中的关系三元组之间的一致性，可以有效评估生成内容的准确性与可靠性。同时，这一过程赋予模型自反思的能力，使其能够通过对比生成的内容与知识图谱的关系进一步提升回复的质量和最终结果的准确性。通过上述研究，本课题旨在设计一套知识图谱扩充框架提升医疗知识图谱的规模，并利用扩充后的医疗知识图谱全面提升大语言模型在医疗领域中的应用表现，推动大语言模型在医疗领域的创新应用。




图 1-2 论文研究内容的结构框架

本文的文章结构安排如下：

(1) 第 1 章：绪论

本章首先概述了智慧医疗的发展趋势，并分析了在医疗领域构建知识图谱的重要性。通过引出本文的研究内容，阐明了智慧医疗中基于大语言模型的技术

术应用背景和研究动机。接下来，深入讨论了大语言模型、医疗知识图谱、基于大语言模型的关系抽取方法，以及基于大语言模型的检索增强技术的研究现状。最后，概括了当前研究中的主要难点与挑战，为后续的研究方向提供了必要的分析。

(2) 第2章：相关理论基础

本章首先对基于大语言模型的医疗知识图谱扩充任务和应用任务进行了详细的形式化定义。然后，深入探讨了大语言模型的相关技术理论，重点介绍了 **Transformer** 架构，详细阐述了预训练、微调等技术的原理和方法。紧接着，本章还介绍了常用的检索增强生成技术理论，分析了外部知识库构建和检索方法。最后，提出了本课题研究任务的相关评价指标，为后续的实验设计和结果分析提供了标准化的依据。

(3) 第3章：基于大语言模型的医疗知识图谱扩充

本章研究了面向医学书籍文本的医疗知识图谱扩充方法。首先，详细描述了本课题设计的基于大语言模型的关系抽取框架，介绍了框架的构建过程及其在关系抽取任务的应用。随后，通过使用标注数据集对框架的关系抽取性能进行了评估，并在新的医疗文本语料上进行了关系抽取实验，进一步扩充了现有医学知识图谱。最后，本章对多种不同方案的实验结果进行了分析，验证了提出的关系抽取框架的有效性，并对实验结果进行了详细的讨论。

(3) 第4章：基于大语言模型的医疗知识图谱应用

本章研究了利用检索增强技术进一步提高大语言模型的推理能力。其中详细介绍了本课题所选用的外部知识源、向量知识库构建方法以及检索方法。随后，介绍了如何从大语言模型的输出结果中构建相关知识子图，以及如何利用知识子图提示大语言模型进行自反思。随后，进行了相关的实验并对结果进行了分析，验证了本文提出的知识图谱后验方法的有效性。

第2章 相关理论基础

2.1 引言

本文的核心目标是设计一个基于大语言模型的关系抽取框架，通过在新医疗文本语料上进行知识挖掘，扩充现有的医疗知识图谱，并结合扩充后的知识图谱与大语言模型，提升解决医疗任务的能力。在医疗知识图谱扩充任务中，重点是通过设计有效的算法提取高质量的关系三元组，从而丰富和完善知识图谱中的内容。在医疗知识图谱应用任务中，知识图谱作为外部知识源，能够通过提示大语言模型，帮助其生成更准确、更可靠的响应结果。前者主要关注医学知识的挖掘与扩充，属于医疗领域应用的上游任务；而后者则是医疗领域应用的下游任务，着重于利用扩充后的知识图谱提升大语言模型在实际医疗任务中的表现。

医疗知识图谱的扩充任务主要依赖于大语言模型，通过从大量医疗文本中自动提取关系三元组，以扩充现有的知识图谱。大语言模型具有强大的自然语言理解和生成能力，能够有效地从非结构化文本中识别出医疗实体（如疾病、症状、药物、治疗方法等）及其之间的关系（如“治疗”关系、“导致”关系等）。通过这种方式，模型能够从医学文献、电子病历、医学教科书等数据源中挖掘出有价值的知识，并将其结构化为知识图谱中的关系三元组。本文设计了一套融合动态提示和自反思机制的关系抽取框架，以确保关系抽取任务的高可靠性。该框架的核心思想是在传统的关系抽取过程中引入动态提示和自反思机制，从而在自动化抽取医学知识的过程中，提升模型的推理能力和输出结果的准确性。

医疗知识图谱的应用是医疗领域中的下游任务，旨在通过将已构建的知识图谱与大语言模型结合，增强大语言模型的医疗任务处理能力。在这一任务中，知识图谱不仅作为外部知识源提供支持，还在推理过程中发挥着重要作用。具体而言，知识图谱中的结构化知识可以编辑成半结构化的形式，用作知识源提示大语言模型，从而为模型提供准确的背景信息，增强其生成结果的专业性和准确性。另一方面，知识图谱中的结构化知识在推理过程中还加强了大语言模型的可解释性。通过明确的实体、关系和属性，知识图谱能够为模型提供透明的、系统化的知识框架，帮助模型更好地理解不同知识之间的关联，并提高其推理过程的逻辑性。在医疗任务中，尤其是在疾病诊断、治疗建议等任务中，可

解释性对于模型的可信度至关重要，它能够帮助医生和用户更清晰地理解模型的推理过程和生成依据。为了进一步提升生成结果的质量和可靠性，本文设计了一套基于知识图谱的自反思校验框架，旨在通过反馈机制增强大语言模型的推理能力和结果的准确性。首先，通过在向量知识库中进行检索，从中提取相关的外部知识，这些知识将作为提示输入到大语言模型中，以便模型根据这些信息生成初步的结果。该步骤确保了生成内容能够依据真实的医学知识进行构建，提升了结果的专业性和准确性。在生成初步结果之后，利用生成结果中的医学实体进一步在知识图谱中检索相关的知识子图。这些知识子图包含了与问题相关的医学知识，通过与初步生成的结果进行对比，能够帮助大语言模型识别出潜在的错误。

综上所述，本课题围绕医疗知识图谱，聚焦于两个核心任务：一是基于大语言模型的医疗知识图谱扩充，二是基于大语言模型的医疗知识图谱应用。本章将对两个任务进行形式化定义并详细探讨其中涉及的相关理论基础，为后续的研究提供理论支撑。其中包括大语言模型的原理、医疗知识图谱理论、检索增强生成技术在大语言模型中的应用，以及实验所应用到的相关评价指标等内容。通过对这些理论基础的系统梳理和深入剖析，本章为后续的研究工作奠定了坚实的理论框架，帮助更好地理解 and 解决医疗知识图谱扩充与应用过程中可能遇到的各类问题。

2.2 任务介绍

2.2.1 基于大语言模型的医疗知识图谱扩充

本课题的研究目标是通过构建基于大语言模型的关系抽取框架，在新的医学文本上完成医疗知识图谱扩充任务。首先，本文设计了一套融合动态提示和自反思的关系抽取框架。随后，在已标注数据集 $D = \{(s_i, r_i, o_i)\}_{i=1}^N$ 上验证关系抽取框架的有效性，其中 s_i 和 o_i 分别表示实体， r_i 表示它们之间的关系，并通过计算准确率和 $F1$ 值等指标，确保所设计的框架在关系抽取任务中的有效性。接着，本文在未挖掘的语料库 $C = \{c_j\}_{j=1}^M$ 上执行关系抽取任务，生成候选三元组集 $T = \{(s_k, r_k, o_k)\}_{k=1}^K$ ，并通过知识图谱融合算法 F 将这些候选三元组整合到现有知识图谱 G 中，这一过程将包括实体对齐，关系一致性检查等更新步骤，旨在提升知识图谱的完备性和准确性。通过自动化地抽取关系三元组并将其纳入医疗知识图谱，本课题的最终目标是构建一个更加丰富和精确的医疗知识图谱，为下游应用如疾病诊断、药物推荐、医学智能问答等提供更加坚实的知识

基础。这一扩充过程不仅能够提高知识图谱的覆盖度，还能增强其在实际医疗场景中的实用性与可靠性。

2.2.2 基于大语言模型的医疗知识图谱应用

医疗知识图谱通过结构化的方式将疾病、症状、药物、治疗方法等各类医学实体有机地关联起来，为疾病诊断等下游任务提供结构化的知识支持。本课题的研究思路主要是基于医学问题，在向量知识库中检索出相关文本作为先验提示，进而引导大语言模型生成初步诊断结果，并通过检索与该结果相关的知识子图进行自反思矫正。具体而言，首先，给定病人的病状、体征等相关信息作为输入，系统将在向量知识库中检索出与病人情况相关的外部知识，并作为先验文本提示，指导大语言模型生成初步的诊断结果。接下来，基于大语言模型生成的初步诊断结果，系统将在医疗知识图谱中检索出相关的知识子图，用于验证和补充模型的输出。在知识子图的基础上，模型将进行自反思校正。通过对比生成的结果与知识图谱中的结构化信息，模型将进行推理验证，并在必要时进行矫正，修正可能的错误和遗漏。这样，经过自反思矫正后的输出结果将更为准确。同时，推理过程也能够得到合理的解释，从而确保输出结果不仅准确，而且具备良好的可解释性。最终，经过自反思矫正的模型输出将作为最终的输出结果，确保系统的决策过程透明、可靠，且能够为临床提供更加精准和可信的诊断支持。

该问题可以形式化为以下问题定义公式：

$$P = \text{RetrieveText}(T, V), \quad D = f_{\text{LLM}}(T, P) \quad (2-1)$$

其中， T 是输入文本， V 是向量知识库， P 是检索得到的先验提示， D 是大语言模型的初步生成结果。

$$S = \text{RetrieveSubgraph}(D), \quad D' = f_{\text{Self-Reflect}}(D, S) \quad (2-2)$$

其中， S 是与诊断结果 D 相关的知识子图， D' 是经过自反思矫正后的最终诊断结果。

2.3 大语言模型相关技术

大语言模型的核心架构是 Transformer，Transformer 的提出彻底改变了自然语言处理领域的技术和方法，使得模型处理长文本和捕捉语义关联的能力得到了显著提升。作为一种强大的生成模型，Transformer 通常用于序列到序列的任

务（如机器翻译、文本生成等），其特点之一是自回归生成。在自回归生成过程中，模型逐步生成序列中的每个元素（如词或字符），每次生成的元素都会作为输入反馈给模型，用于生成下一个元素，从而实现逐步构建输出的过程。**Transformer** 架构的核心是自注意力机制，其不同于传统的循环神经网络（RNN）和长短时记忆网络（LSTM），它摒弃了递归结构，采用全局依赖关系建模的自注意力机制来处理输入数据。这一设计使得 **Transformer** 在捕捉远距离依赖关系时，比传统模型更加高效和精准。由于自注意力机制能够并行处理输入序列，**Transformer** 在并行计算方面具有显著优势，尤其在处理长序列时，能够有效避免递归结构带来的梯度消失或梯度爆炸问题，从而大大提升了训练效率和模型稳定性。**Transformer** 主要由编码器（Encoder）和解码器（Decoder）两部分组成，每部分由多个相同的层堆叠而成，具体形式如图2-1所示。




图 2-1 Transformer 结构图

输入嵌入 (Input Embedding) 和位置编码 (Positional Encoding) 是两个核心组件, 彼此协同工作, 共同为模型提供输入序列的表示和顺序信息。首先, 输入嵌入将离散的词汇映射到一个高维的连续向量空间中, 使模型能够处理这些词汇的语义关系。每个词汇通过嵌入矩阵转换为一个固定维度的向量, 这些嵌入向量构成了 Transformer 模型的输入。由于 Transformer 结构本身不直接考虑词汇在序列中的顺序信息, 因此需要引入位置编码来提供位置信息。位置编码通过正弦和余弦函数生成与词汇位置相关的向量, 以确保模型能够理解词汇在序列中的相对位置。通过这种方式, 位置编码使得模型能够区分不同位置的词汇, 并有效捕捉长距离依赖关系。最终, 输入嵌入和位置编码逐元素相加, 形成最终的输入表示。这一结合使得模型能够同时利用词汇的语义信息和位置信息, 从而高效处理各种序列任务, 如机器翻译、文本生成等。Transformer 的核心思想是自注意力机制, 自注意力机制的关键思想是: 对于输入序列中的每个词, 它会根据其他所有词的特征对自己进行加权组合, 从而生成一个更加丰富的表示。自注意力机制的核心是查询 (Query)、键 (Key) 和值 (Value) 这三个概念, 它们是由输入的嵌入向量通过不同的线性变换得到的。对于每个输入词, 会计算其查询与所有其他词的键之间的相似度, 然后通过 *softmax* 函数将这些相似度转化为一个概率分布, 表示当前词对其他词的关注程度。最后, 这些相似度权重被用来对序列中所有词的值进行加权求和, 从而得到一个加权后的输出表示。其计算公式如2-3所示。

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-3)$$

Transformer 中的多头注意力 (Multi-Head Attention) 是自注意力机制的扩展, 它通过并行计算多个注意力“头”来捕捉不同的语义关系。每个注意力头使用不同的查询、键和值进行计算, 从而学习到不同的注意力模式。最终, 所有头的输出会被拼接在一起, 并通过线性变换合并成一个最终的输出。多头注意力的优势在于, 它能够从多个不同的子空间同时关注输入序列的不同部分, 从而捕捉更多的上下文信息。这种机制使得模型能够在多个维度上对输入进行深度理解, 提升了其表达能力和信息处理的多样性。在每个编码器中, 前馈神经网络是自注意力机制后的第二个主要模块。它由两个线性变换和一个激活函数构成, 为每个位置的表示提供非线性变换, 进一步增强了模型的表达能力。与自注意力机制不同, 前馈神经网络对每个位置的输入进行独立处理, 不考虑其他位置的信息。这种独立处理使得前馈神经网络能够提供额外的非线性变换, 从而提升模型在处理复杂模式时的表现。

Transformer 的解码器与编码器的主要区别在于，它不仅能够处理输入的上下文信息，还需要生成目标序列。在解码器中，每一层包含几个核心组件，确保其能够高效且稳定地生成目标序列。首先，解码器中的掩码自注意力机制（Masked Self-Attention）允许每个位置仅关注当前词及其前面的词，避免泄漏未来的信息，从而保证模型的自回归特性。其次，编码器-解码器注意力机制（Encoder-Decoder Attention）使得解码器能够在生成目标序列的过程中，充分利用来自编码器的上下文信息。解码器的每一层还包含一个前馈神经网络，用于对每个位置的表示进行非线性变换，增强模型的表达能力。此外，解码器中的每一层都采用了残差连接和层归一化，前者有助于缓解梯度消失问题，后者则提升了训练的稳定性与收敛速度。最后，解码器的输出通过一个线性变换和 *softmax* 层，生成每个位置的词汇分布，最终形成目标序列。通过这些组件的协同作用，解码器能够在生成目标序列时充分利用编码器提供的上下文信息，同时保证生成过程的稳定性与高效性。

在 Transformer 架构的基础上，许多先进的大语言模型采用了 decoder-only 架构，而非传统的 encoder-decoder 架构。这一设计选择主要基于几个关键原因。首先，decoder-only 架构简化了模型结构，只需训练解码器部分，从而优化了训练过程和推理效率，减少了计算资源的消耗。在生成任务中，解码器能够通过自回归机制逐步生成文本，每次生成的词语依赖于前文信息，这使得模型能够高效地生成连贯且语法正确的内容。此外 decoder-only 架构非常适合于预训练任务和少样本学习，通过大规模的无监督预训练，模型可以灵活适应各种任务，而无需特定的编码部分来处理输入，解码器本身就能处理生成和理解任务。与 encoder-decoder 架构相比，解码器的自回归特性使得生成任务更加直接高效，并且能够在推理时快速生成内容，而不需要复杂的编码步骤。通过这种设计，大语言模型能够高效地处理生成、翻译、问答等多种任务，并且能够在少样本或零样本的情况下展现强大的迁移学习能力。因此，decoder-only 架构在当前的大语言模型中得到了广泛应用，成为其核心设计理念之一。

在介绍了大语言模型的基础架构后，接下来将深入探讨大语言模型的训练过程。大语言模型的训练通常包括以下几个关键步骤：

(1) 无监督预训练：大语言模型的训练过程首先从无监督预训练阶段开始。在这一阶段，模型通过海量的文本数据进行学习，掌握基本的语法结构和语义关系。预训练通常采用自回归方法，目标是预测给定上下文中的下一个词。通过这种无监督的训练方式，模型能够深入理解上下文之间的关联，逐步积累广泛的语言知识，奠定了其在后续任务中的基础能力。

(2) 微调监督训练: 在这一阶段, 预训练后的大语言模型将在特定的监督数据集上进行微调, 以使其能够适应具体的任务或应用场景。监督数据集通常包含已标注的样本, 这些数据能够提供模型训练所需的目标输出。通过最小化交叉熵损失函数, 模型的参数会在监督数据上进行调整, 从而提升其在特定任务中的表现和准确性。为了防止过拟合, 微调过程还会引入正则化技术, 以限制模型的复杂度, 减少对训练数据的过度依赖。此外, 早停策略也是常用的技术, 它通过监控验证集上的性能变化, 在模型表现不再提升时提前停止训练, 从而有效避免过拟合并保证模型的泛化能力。通过这些技术, 微调后的模型不仅能在特定任务上表现出色, 还能够保持良好的泛化能力, 适应未见过的输入数据。

(3) 训练奖励模型: 在微调模型后, 需要通过偏好数据训练一个奖励模型, 用于评估生成文本的质量。奖励模型的训练目标是通过学习如何区分优质和劣质响应, 来指导后续的生成过程。奖励模型的训练损失函数如公式2-4所示, 其中, θ 表示奖励模型的参数, D 是包含输入 x 、优质响应 y_w 和劣质响应 y_l 的偏好数据集。 $r_\theta(x, y)$ 是奖励模型对输入 x 和响应 y 的评分函数。具体来说, 损失函数的设计通过最大化优质响应相对于劣质响应的概率, 来训练奖励模型。这意味着, 模型将被优化为在相同输入下, 能够给出优质响应更高的评分, 并对劣质响应给予较低的评分。这一过程能够有效帮助奖励模型学习区分不同质量的生成文本, 并为后续的优化过程提供有力的反馈信号。通过这一过程, 奖励模型不仅能够评估文本质量, 还能够为生成任务提供进一步优化的方向, 确保生成的文本更加符合预期的质量标准。

$$\text{loss}(\theta) = -\mathbb{E}_{(x, y_w, y_l) \sim D} [\log(\sigma(r_\theta(x, y_w) - r_\theta(x, y_l)))] \quad (2-4)$$

(4) 强化学习优化: 在这一阶段, 通过结合奖励模型, 利用强化学习算法进一步优化监督训练模型, 以提升生成高质量响应的能力。强化学习优化的目标是调整生成策略, 使得模型在生成过程中能够更好地满足预期的质量标准。强化学习优化的目标函数如2-5所示, 其中, ϕ 表示强化学习策略的参数, $\pi_\phi^{RL}(y|x)$ 是经过强化学习优化后的策略模型, $\pi_\phi^{SFT}(y|x)$ 是经过监督微调后的模型, $r_\theta(x, y)$ 是奖励模型对生成响应的评分, β 和 γ 是用于平衡不同损失项的超参数。具体而言, 目标函数包括两个主要部分: 一方面, 模型通过最大化奖励模型对生成响应的评分 (即 $r_\theta(x, y)$) 来优化生成的内容, 确保响应的质量尽可能高; 另一方面, 强化学习通过正则化项 $\log\left(\frac{\pi_\phi^{RL}(y|x)}{\pi_\phi^{SFT}(y|x)}\right)$, 鼓励优化后的策略与经过监督微调的策略保持一致, 避免过度偏离预训练阶段的知识。进一步地, 为了保证模型在生成过程中不失去原有的预训练能力, 目标函数还加入了一个额外的项

$\mathbb{E}x \sim D_{\text{pretrain}} \left[\log \left(\pi_{\phi}^{RL}(x) \right) \right]$, 该项确保生成的内容在某种程度上仍然符合预训练阶段学到的语言模式和知识。通过采用策略梯度方法（如 Proximal Policy Optimization, PPO），模型在奖励信号的引导下不断调整生成策略，以实现高效且稳定的优化过程。最终，强化学习优化帮助模型提升了生成质量，且能够在多种应用场景下展现出更强的适应性和可靠性。

$$\text{objective}(\phi) = \mathbb{E}_{(x,y) \sim D_{\pi_{\phi}^{RL}}} \left[r_{\theta}(x,y) - \beta \log \left(\frac{\pi_{\phi}^{RL}(y|x)}{\pi^{SFT}(y|x)} \right) \right] + \gamma \mathbb{E}_{x \sim D_{\text{pretrain}}} \left[\log \left(\pi_{\phi}^{RL}(x) \right) \right] \quad (2-5)$$

2.4 检索增强生成相关技术

2.4.1 向量知识库和知识图谱相关技术

在检索增强生成技术中，向量知识库和知识图谱作为关键的外部知识源，能够有效支持大语言模型的推理和生成任务。向量知识库通过将医学文献、医学教科书等专业资料转化为向量表示，能够实现高效的语义检索。知识图谱则通过结构化的方式将医学实体及其关系表示出来，为任务提供精准的知识支持。这两者在医疗领域的结合，能够极大提升信息检索的准确性和效率。

构建向量知识库通常包括多个关键步骤，如图2-2所示。首先，系统从权威数据库（如：医学文献库、医学教科书等）中收集数据。随后，对文本数据进行预处理，包括去除无关字符、特殊符号和 HTML 标签等，确保数据的结构一致性和质量。接下来，在文本分割阶段，根据不同类型的文本数据，可以采用多种分割策略，以确保文本被有效且合理地拆分。常见的分割策略包括：（1）CharacterTextSplitter：根据字符数量进行简单分割，适用于较短的文本，能够快速拆分并提取关键信息；（2）MarkdownHeaderTextSplitter：通过文档中的 Markdown 标题进行分割，特别适合结构化较强的文档，如技术文档或报告，能够有效识别和分割章节内容；（3）RecursiveCharacterTextSplitter：递归地根据文本的自然段落和语义结构进行分割，适合处理更复杂且内容丰富的长文本，能够保留更多的上下文信息；（4）SpacyTextSplitter：结合自然语言处理工具，进行基于句法结构的分割，适用于需要深入语法分析的文档，能够识别并分割复杂句子。这些分割方法可以显著提高文本向量化的质量，确保每个文本片段在语义层面上保持连贯性。随后，使用嵌入模型将分割后的每个文本片段转化为高维向量。常见的嵌入模型包括 Jina Embedding、Text-Embedding-ADA、BGE 和 m3e-base 等，它们能够有效地将文本信息转化为可进行数学运算的向量表示。最后，将这些高

维向量存储到向量数据库中，以便进行高效的相似性检索。通过这种方式，系统能够快速识别与查询内容最相关的文本片段，极大提高检索效率。总的来说，向量知识库能够实现基于语义的精准检索，避免传统关键词匹配的局限性，极大提升医学信息检索的效率和准确性。这不仅帮助研究人员和医生快速获取相关资料，还能为临床决策和科学研究提供强有力的支持。




图 2-2 构造向量知识库基本框架

本课题采用哈尔滨工业大学关毅教授团队构建的 WiMedKG 医疗知识图谱，并在其原有基础上进行扩展，以支持医疗任务的应用。WiMedKG 医疗知识图谱主要依托于临床诊断指南和电子病历等医学文本资源，结合疾病诊断和健康预测任务对常识性知识及经验性知识的需求，在专业医生的指导下，构建了医学领域的概念和关系分类体系。该知识图谱通过人工标注与模型自动抽取相结合的

方式,构建了以医学实体为节点、实体关系为边的结构化知识图谱。在 WiMedKG 医疗知识图谱中,主要采用了以下三类数据源:(1)医学书籍和文献(2)电子病历(3)专业医学网站的文本数据。自建立以来, WiMedKG 医疗知识图谱不断更新与优化,并在医学专家的协助下逐步完善了知识体系,当前已预定义了 28 种医学实体类型和 107 种医学关系类型,这些实体与关系覆盖了广泛的医学领域知识。本研究在此基础上,筛选出与医学领域疾病诊断任务密切相关的医学实体类型和关系类型,作为主要研究对象。图2-3展示了 WiMedKG 中各实体类型的数量,图2-4展示了 WiMedKG 中主要关系类型的数量。




图 2-3 医疗知识图谱 WiMedKG 实体分布统计




图 2-4 医疗知识图谱 WiMedKG 关系分布统计

综上所述, 向量知识库和医疗知识图谱为医学信息检索提供了强大的支持。向量知识库通过高效的语义检索与快速相似度匹配, 能够迅速提供与查询相关的医学资料, 而医疗知识图谱则通过结构化的知识表示与深入的语义理解, 确保检索结果的准确性和全面性。两者均为现代医疗研究、临床决策支持及实践中的知识发现提供了重要支撑, 成为推动医疗领域智能化发展的不可或缺的技术基础。

2.4.2 外部知识库检索策略与方法

在构建高效的检索系统时, 根据不同类型的检索源, 可以采用多种检索策略和方法, 以确保准确且高效地获取用户所需的相关信息。对于文本形式的知识源、向量数据库、垂直领域的特定数据以及知识图谱检索, 每种数据类型都有其独特的检索方法和技术。这些方法能够针对不同的数据结构和应用场景, 提供最优的检索效果, 满足不同需求, 提升信息检索的效率和准确性。

在传统的文本检索中, **BM25 (Best Matching 25)** 是最常用的检索方法之一, 广泛应用于大规模文档检索系统, 尤其适用于基于关键词的检索。**BM25** 算法源自概率检索模型, 主要依赖两个核心概念: 词频 (**TF**) 和逆文档频率 (**IDF**)。其中, 词频衡量查询词在单个文档中的出现频率, 而逆文档频率则反映了查询词在整个文档库中的稀有程度。**BM25** 通过结合这两个因素, 计算每个文档与查询词的匹配度, 从而返回与查询最相关的文档。**BM25** 的显著优势是通过文档长度归一化, 避免长文档因包含更多关键词而不公平地获得较高的排名, 确保了检索结果的公正性和准确性。此外, **BM25** 不仅适用于简单的关键词匹配, 它还能够处理部分模糊查询和词语变体, 尽管其基于词汇层面的检索方法, 但在处理结构化与非结构化文本时都表现出较好的效果。因此, 对于文本形式的知识源, **BM25** 是一种快速且高效的检索策略, 能够在海量数据中迅速筛选出与查询最相关的信息, 广泛应用于医疗领域的的数据检索与信息提取任务中。

与传统的基于关键词的检索方法不同, 向量数据库通过计算向量相似度来实现检索, 这种方法突破了关键词匹配的局限, 能够深入挖掘文本中的语义关系。具体来说, 向量数据库将文本数据转化为高维向量表示, 通过计算查询向量与数据库中存储的向量之间的相似度, 从而进行精准的检索。在这种检索模式下, 文本数据首先需要通过嵌入模型转换为向量表示, 每个文本片段会被表示为一个高维向量, 这些向量随后被存储在向量数据库中, 如 **Faiss**、**Pinecone** 等。当用户进行查询时, 查询文本同样会被转换为一个向量表示。接着, 检索系统通过计算查询向量与数据库中各个存储向量之间的相似度来找到最相关的文档,

常用的相似度计算方法包括余弦相似度、欧几里得距离和曼哈顿距离等。其中，余弦相似度是最常用的度量方法，它通过计算向量之间的夹角来评估它们的语义相似度，特别适合处理稀疏向量数据。与传统的基于关键词的检索方式相比，向量相似度匹配的优势在于能够捕捉更深层次的语义相关性，克服了同义词、上下文变化等问题。例如，在医疗领域，向量检索可以准确识别与疾病、症状、治疗方法等相关的文献或资料，返回更为相关和精确的信息，极大提升了医学知识检索的效率与准确性。因此，向量数据库不仅能够提供比传统关键词匹配更高效的检索方式，还能够支持更为复杂的检索需求。

在垂直领域应用检索增强技术时，标准的预训练嵌入模型往往无法充分捕捉到领域特有的术语和语义关系。因此，针对特定领域的嵌入模型进行微调成为一种常见且有效的策略。特别是在医疗领域，像 MedCPT^[52] 这样的嵌入模型，通过在医学语料 PubMed 上进行微调，从而优化了模型对医学知识的理解与表示。与通用的预训练嵌入模型相比，经过微调的领域特定模型在处理医学术语、疾病名称、药物名称及临床用语等复杂的领域知识时，展现出更高的准确性和相关性。这是因为微调后的模型能够在训练过程中学习并调整对医学领域特有概念的表示，从而更好地捕捉到领域的深层次语义。在检索过程中，微调后的嵌入模型仍然依赖于向量相似度匹配来进行检索，但与标准嵌入模型相比，它能够更精准地理解和区分医疗领域内的语义差异。这种微调技术在医学领域的应用尤为重要，因为医学知识的复杂性和专门性要求检索系统能够处理大量细致的领域术语和关系。通过这种方法，医生和研究人员面对海量医学信息时，可以显著提高检索效率和准确性，帮助他们更快速地获取最新的研究成果、治疗方案或临床指南，进而支持医疗决策和科学研究的深入推进。总之，微调后的领域特定嵌入模型，尤其是在医疗领域，提供了比通用模型更为精准和实用的检索能力，成为了现代医疗信息系统中不可或缺的技术基础。

在基于知识图谱的检索中，知识以图结构的形式存储，其中每个节点代表一个实体，而边则表示这些实体之间的关系。知识图谱通过这种结构化的方式，将复杂的领域知识有机地组织起来，使得检索过程中能够更加精确地捕捉到实体之间的语义关联。在知识图谱的检索过程中，核心任务是从用户的查询中准确识别出相关实体，并基于图谱中已存储的关系，提取出相应的关系三元组。三元组是知识图谱中的基本单元，它通过简洁明了的方式展示了不同实体之间的关系，便于快速查找和理解。整个检索过程通常包括以下几个步骤：（1）实体识别：系统需要从用户查询中提取出关键实体，可以通过大语言模型来自动识别查询中的重要关键词。（2）实体链接：将识别出的实体与知识图谱中的实

体进行匹配。实体链接的目的是确保系统能够精确定位到图谱中的实体，避免不同的实体名称或同义词带来的歧义。(3) 关系检索：利用已识别的实体，系统可以从知识图谱中检索出与之相关的三元组。这些三元组直接提供了实体间的关系。通过这种基于知识图谱的检索方式，信息的查询和检索过程得以更加精准且直观地进行。不同于传统的基于关键词的检索方法，知识图谱能够通过图结构展示实体之间的深层次关联，避免了关键词检索中可能出现的模糊性和信息过载的问题。

综上所述，本章探讨了构建高效检索系统的多种策略和方法，涵盖了不同类型的检索源，包括文本数据、向量数据库、垂直领域数据和知识图谱。对于文本数据，BM25 算法作为经典的基于关键词的检索方法，能够快速且高效地返回相关文档。与传统方法相比，向量数据库通过计算语义相似度，不仅能捕捉更深层次的语义关系，还能处理复杂的查询需求，特别适用于医疗等领域。针对垂直领域，经过微调的领域特定嵌入模型，能够更精确地理解和应用领域特有的术语和语义，从而提升检索准确性。在知识图谱的应用中，结构化的图表示能够直观地展示实体间的关系，提高检索的精度和效率，尤其是在处理复杂的领域知识时表现出明显优势。

2.5 任务评价指标

在机器学习任务中，评估模型的性能至关重要。常用的评估指标包括准确率 (Accuracy)、精确率 (Precision)、召回率 (Recall) 和 F1 分数 (F1-Score) 等，这些指标的计算通常基于混淆矩阵。混淆矩阵通常与以下四个计算指标相关：(1) 真正例 (True Positives, TP)：模型成功地将实际为正类的样本分类为正类的数量。(2) 假正例 (False Positives, FP)：模型错误地将实际为负类的样本误分类为正类的数量。(3) 真负例 (True Negatives, TN)：模型成功地将实际为负类的样本正确地预测为负类的数量。(4) 假负例 (False Negatives, FN)：模型错误地将实际为正类的样本误分类为负类的数量。

准确率的计算公式为：

$$\text{Acc} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2-6)$$

精确率的计算公式为：

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2-7)$$

召回率的计算公式为：

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2-8)$$

F1 分数的计算公式为:

$$\text{F1-Score} = 2 * \frac{\text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2-9)$$

在介绍了混淆矩阵及其相关指标后, 接下来需要考虑如何在多分类任务中评估模型的性能。对于多分类问题, 通常会采用微平均 (Micro-Average) 和宏平均 (Macro-Average) 这两种方法来计算整体性能。这两种方法通过不同的方式聚合各个类别的评估指标, 从而为多分类模型提供全面的性能评估。微平均 (Micro-Average) 是通过将所有类别的 TP、FP、TN 和 FN 加总后, 计算整体的精确率、召回率和 F1 分数。

微平均精确率的计算公式为:

$$\text{Precision}_{\text{micro}} = \frac{TP_{\text{micro}}}{TP_{\text{micro}} + FP_{\text{micro}}} \quad (2-10)$$

微平均召回率的计算公式为:

$$\text{Recall}_{\text{micro}} = \frac{TP_{\text{micro}}}{TP_{\text{micro}} + FN_{\text{micro}}} \quad (2-11)$$

微平均 F1 分数的计算公式为:

$$\text{F1-Score}_{\text{micro}} = 2 * \frac{\text{Precision}_{\text{micro}} * \text{Recall}_{\text{micro}}}{\text{Precision}_{\text{micro}} + \text{Recall}_{\text{micro}}} \quad (2-12)$$

宏平均首先分别计算每个类别的精确率、召回率和 F1 分数, 然后对所有类别的这些指标取平均。它适用于类别分布均衡的情况, 能够反映模型在各个类别上的一致性表现。

宏平均精确率 (Precision_macro) 计算公式为:

$$\text{Precision}_{\text{macro}} = \frac{1}{N} \sum_{i=1}^N \text{Precision}_i \quad (2-13)$$

宏平均召回率 (Recall_macro) 计算公式为:

$$\text{Recall}_{\text{macro}} = \frac{1}{N} \sum_{i=1}^N \text{Recall}_i \quad (2-14)$$

宏平均 F1 分数 (F1-Score_macro) 计算公式为:

$$\text{F1-Score}_{\text{macro}} = \frac{1}{N} \sum_{i=1}^N \text{F1}_i \quad (2-15)$$

2.6 本章小结

本章详细阐述了本课题研究的核心任务：一是基于大语言模型的医疗知识图谱扩充，二是将知识图谱与大语言模型相结合应用于下游任务。首先，介绍了这两个任务的研究背景与目标，并进一步探讨了它们在医疗领域中的潜在价值与实际应用。接下来，本章详细讲解了本课题相关的理论基础。其中系统地介绍了大语言模型的基本原理，重点分析了 **Transformer** 架构的核心概念与技术实现，以及当前主流的大语言模型训练流程。然后，本章进一步探讨了医疗知识图谱和检索增强技术的相关理论。最后，本章明确了本课题实验任务的评价指标，包括准确率、精确率、召回率、F1 分数等，以便为后续的实验分析和结果评估提供标准。通过这些指标，能够全面衡量实验系统的性能，并为优化方案的选择提供依据。后续章节将在本章的理论基础上展开，结合具体实验任务，进一步丰富研究内容并进行实验验证。

第3章 基于大语言模型的医疗知识图谱扩充研究

3.1 引言

在医疗领域，数据规模庞大且结构复杂，涉及临床记录、医学文献、医学教科书等多种来源的信息。这些海量数据的有效整合与利用对于疾病诊断、制定治疗方案以及医学研究具有重要意义。知识图谱作为一种能够将多源异构数据有机关联起来并进行展示的工具，已被广泛应用于医疗辅助系统中。然而，现有的医疗知识图谱往往存在知识量不足的问题，这在一定程度上限制了其在医疗领域的应用。因此，扩充医疗知识图谱规模，提升其全面性，对于推动人工智能医疗领域的发展至关重要。构建一个高质量的医疗知识图谱通常依赖于大量的人力进行数据标注，这不仅耗费大量时间和人力资源，而且难以满足快速增长的数据需求。因此，利用大语言模型开发自动化抽取关系三元组的框架显得尤为重要。这种自动化方法不仅能够显著提升构建和扩充知识图谱的效率，还能确保其在医疗环境中的准确性和实用性，从而推动医疗领域的智能化发展。

随着深度学习的不断发展，卷积神经网络（CNN）、循环神经网络（RNN）、长短时记忆网络（LSTM）等模型已被广泛应用于关系抽取任务。这些模型通过学习文本的上下文表示，减少了对手工特征工程的依赖，提升了模型在关系抽取任务中的性能。然而，传统深度学习模型在灵活性和可扩展性方面存在一定局限，尤其是在应对动态变化的实体类型和关系类型时，传统模型的适应能力较差。当预定义的实体类型或关系类型发生变化时，传统深度学习模型通常需要进行大规模的重新训练，并且常常需要手动调整模型架构或特征设计。这意味着传统模型需要通过重新标注数据和进行全面训练来进行适配，工作量非常庞大。与传统深度学习模型相比，预训练模型（如 BERT、RoBERTa、T5 等）在关系抽取任务中展现了更高的灵活性和可扩展性。预训练模型通过在大规模语料上进行预训练，已经学会了丰富的语义表示，并能通过少量的微调快速适应新任务。当实体类型或关系类型发生变化时，预训练模型可以通过在新的数据上微调，而无需重新设计模型架构。这种灵活性使得预训练模型能够更高效地应对领域变化和任务变化。

尽管预训练模型相较于传统深度学习模型在灵活性和可扩展性上具有显著优势，但大语言模型（如 ChatGPT 等）在处理关系抽取任务时，展现出了更为

卓越的适应性和扩展能力。通过在更大规模的语料库上进行训练，大语言模型能够在不同领域之间进行迁移学习，捕捉更复杂的语义关系，从而迅速适应新的任务和需求。同时，大语言模型在处理上下文信息时表现出色，能够灵活应对垂直领域中的预定义实体类型和关系类型的变化。与传统模型不同，大语言模型能够通过上下文学习有效完成关系抽取任务，而无需依赖大量标注数据。这使得它能够在数据稀缺的场景下依靠对语言的深刻理解和推理能力，自动识别并抽取关键信息。除此之外，大语言模型通常无需额外的特征工程，就能完成从文本到关系三元组的端到端抽取，从而显著提高了应用的效率和灵活性。

本课题将重点研究句子级别的关系抽取方法，旨在通过动态向大语言模型提供实体和关系三元组示例，充分利用其强大的上下文理解能力，以提升大语言模型对医疗实体和关系三元组的理解。与此同时，结合自反思机制，帮助模型在抽取过程中进行自我优化和调整，进一步提升实体识别和关系抽取结果的准确性。随后，本课题通过使用《诊断学》书籍的人工标注数据集，对本文所提出的框架进行测试，实验结果验证了本文所提出框架的有效性。验证完成后，利用该自动化关系抽取框架进一步挖掘新语料中的关系三元组，并基于实体对齐和关系一致性检查方法对现有的医疗知识图谱 WiMedKG 进行扩充，通过这种方式，进一步提升了知识图谱的完整性和准确性。具体框架如图3-1所示。




图 3-1 融合动态提示和自反思机制的大语言模型知识图谱扩充框架

3.2 融合动态提示和自反思机制的关系抽取算法

在第一章的国内外研究现状中,本文深刻阐述了几种基于大语言模型的关系抽取方案。针对智能体流式抽取框架,关系抽取过程一般被划分为两个相关联的阶段。然而,在实际应用中,该框架在关系抽取任务中仍面临诸多困难和挑战,主要体现在以下几个方面:(1)错误的累积传递:关系抽取任务的第一阶段通常是命名实体识别,实体识别结果的准确性直接影响到后续的关系抽取任务。如果实体识别阶段出现错误,错误将会被传递到关系抽取阶段,导致最终抽取结果的不准确。(2)预定义类型的复杂结构难以理解:在关系抽取过程中,预定义的实体和关系类型通常具有复杂的结构和多样的语义表达形式。大语言模型在处理这些复杂的类型时,可能难以准确区分和理解不同语义之间的差异。(3)无法保证抽取结果的准确性:尽管大语言模型在自然语言处理任务中表现出色,但在关系抽取任务中,无法完全确保最终抽取结果的准确性。由于大语言模型依赖于整段文本的语义信息进行推理,而不是专注于局部的、精准的关系表达,这种全局语义的抽取方式可能会导致对语义的误解和与预训练知识的冲突,进而影响抽取结果的精确性。

基于以上问题,本课题在智能体流式抽取框架的基础上进行改进,设计了一个结合动态提示和自反思机制的大语言模型关系抽取框架。首先,针对每种实体和关系类型,从现有的知识图谱中挑选相关示例,构建成一个类比示例池。通过将实体、关系三元组及其文本表示在不同阶段作为提示输入给大语言模型,旨在增强模型对语义信息的理解能力,从而提高实体识别和关系抽取的准确性。同时,本文在大语言模型的抽取结果上,通过自反思机制验证抽取结果是否与预训练知识相冲突,以确保结果的准确性。通过上述方法,不仅能够有效缓解错误的累积传递问题,还能保证最终关系抽取结果的准确性和可靠性。本研究将关系抽取任务分为两个主要阶段:命名实体识别和关系抽取。




图 3-2 基于大语言模型的实体识别框架

在命名实体识别阶段，本文将任务细分为两个步骤，流程如图3-2。首先，模型需要识别文本中可能出现的医学实体类型，从整体上把握文本的语义信息，并明确文本中可能涉及的实体类型。这一步骤有助于为后续的实体抽取提供必要的结构支持，并确保模型能够从全局视角理解文本内容，公式如下：

$$E_p = f_{LLM}(T, E) \quad (3-1)$$

其中 T 代表输入的医学文本， E 代表预定义的医学实体类型列表， E_p 代表文本中存在的实体类型。

接下来，根据文本中存在的医学实体类型，模型将专注于抽取该类型的具体实体名称，公式如下：

$$N_e = \sum_{i=1}^P f_{LLM}(T, E_i, F_{e_i}), \quad F_{e_i} \in F_e \quad (3-2)$$

其中 E_i 代表要抽取的实体类型， F_{e_i} 代表这一类型的实体示例， N_e 代表识别出的实体结果。

通过这种分步策略，模型可以更加精准地识别特定类型的实体，避免同时处理实体类型和名称所带来的混淆和复杂性，从而提高识别的准确性。因此，将命名实体识别任务拆分为两个阶段，有助于降低难度，提高每个阶段的准确率和效率。然而，实体识别的准确性直接影响后续关系抽取的效果。为了确保高质量的实体识别并减少错误对关系抽取的干扰，本文引入了自反思机制 $N_{e_s} = f_{LLM}(N_e)$ ，其中 N_{e_s} 代表自反思后的实体识别结果。该机制基于大语言模型的预训练知识，自动验证实体识别结果。在初步识别完成后，自反思机制模拟标注验证环节，重新审视识别结果的合理性与一致性。通过充分利用预训练知识和推理能力，自反思机制能够识别并修正由于上下文理解不充分所导致的错误。总的来说，自反思机制不仅能提升实体识别的准确性，还能为关系抽取阶段提供更可靠的输入，从而提升整体框架的性能。

在关系抽取阶段，本文创新性地将三元组类比示例池与自反思机制融合，以显著提升大语言模型对关系类型的理解能力和抽取结果的置信度，完整框架图如图3-3所示。在实际应用中，我们发现大语言模型有时难以准确理解预定义关系类型的具体含义，导致抽取出的关系三元组出现头尾实体顺序错误、关系类型误判等问题。为了解决这一挑战，本研究提出了一种结合三元组类比示例池与自反思机制的方法。三元组类比示例池通过从知识图谱中精心筛选出与当前待抽取关系类型一致的三元组集合。这些三元组不仅包含明确的医学实体之间的关系，而且可以通过类比示例的方式增强模型对目标关系的认知。




图 3-3 基于大语言模型的关系抽取

首先每种关系类型的头尾实体受到特定实体类型的限制，我们首先根据命名实体识别结果中的实体类型，筛选出文本中医学实体之间可能存在的关系类型，公式如下：

$$R_p = S(R, N_{e_s}) \quad (3-3)$$

其中， R 是预定义的关系类型列表， N_{e_s} 是实体识别的结果， S 是根据关系的头实体类型和尾实体类型进行规则筛选的函数。

接着，通过遍历每一种可能存在的关系类型，从三元组类比示例池中选取相应的示例，并将这些三元组转化为文本形式，以供模型参考。这一过程使得大语言模型能够通过具体的类比示例，深入理解不同语义关系下各关系类型的具体表现，从而更清晰地掌握关系类型的具体含义，减少抽取过程中的错误，公式如下：

$$N_r = \sum_{i=1}^p f_{LLM}(T, N_{e_s}, R_i, F_{r_i}), \quad F_{r_i} \in F_r \quad (3-4)$$

其中， T 是需要识别的文本， R_i 是要抽取的关系类型， F_r 是关系三元组的示例， N_r 是初步关系抽取结果。

在完成关系抽取任务之后，该框架引入了自反思机制以进一步提升抽取结

果的置信度。具体而言，模型会将抽取出的关系三元组与其预训练知识进行对比和验证。自反思机制将每个抽取出的三元组进行分类标记：标记为 1 表示该三元组与大语言模型的预训练知识吻合且一致；标记为 -1 则表示该三元组与预训练知识存在冲突，即被判定为错误的关系三元组，公式如下：

$$N_{r_s} = f_{LLM}(N_r) \quad (3-5)$$

其中， N_{r_s} 是自反思后的关系抽取结果。

通过这一机制，能够有效过滤掉低置信度或错误的抽取结果，确保最终输出的关系三元组具有高度的准确性和可靠性。

综上所述，三元组类比示例池的引入显著增强了大语言模型对关系类型的理解深度，使其能够更准确地识别和抽取关系三元组；而自反思机制的应用则保障了抽取结果的高置信度，确保了最终关系三元组的准确性和可信度。这两者的有机结合，为关系抽取任务提供了一种更加精准和可靠的解决方案，极大地提升了大语言模型在复杂关系抽取中的表现。

3.3 基于实体对齐和关系一致性检查的知识图谱扩充算法

知识图谱扩充任务旨在通过从新语料中进行命名实体识别和关系抽取，生成高质量的实体识别结果和关系三元组，并将这些三元组合并到已有的知识图谱中。在上一小节中，本文深刻阐述了基于大语言模型的实体识别和关系抽取操作，以及通过三元组类比示例池和自反思机制得到置信度高的关系三元组。本课题聚焦于医疗知识图谱的扩充，旨在将从新语料中抽取的实体和关系与现有知识图谱有效整合。在这一过程中，主要包括两个步骤：实体对齐和关系一致性检查，确保新增知识与现有医疗知识图谱之间不重复。

在实体对齐过程中，本课题提出了基于词频的 BM25 方法和基于语义相似度的 BERT 模型构建候选实体，然后通过大语言模型进行进一步判断的方法。BM25 算法是一种广泛应用于信息检索领域的排序算法，用于评估文档与查询之间的相关性，BM25 的基础思想是根据词频和文档长度等因素来评估文档与查询的相关性。BM25 算法的计算公式如下：

$$BM25(q, D) = \sum_{i=1}^n idf(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{avgdl}\right)} \quad (3-6)$$

其中 q 是查询， D 是文档， $f(q_i, D)$ 是词项 q_i 在文档 D 中的出现次数， k_1 是一个调节词频加权的超参数， b 是一个调节文档长度对评分影响的超参数， $|D|$

是文档长度, $avgdl$ 是文档集合中的平均文档长度, $1 - b + b \cdot \frac{|D|}{avgdl}$ 是归一化项用于调整文档长度的影响, $idf(q_i)$ 表示词项 q_i 的逆文档频率, 用于衡量该词项在文档集合中的稀有性, 其计算公式如下:

$$idf(q_i) = \log \left(\frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} + 1 \right) \quad (3-7)$$

其中 N 是文档集中的总文档数, $n(q_i)$ 是包含词项 q_i 的文档数。如果词项 q_i 出现频繁, 即 $n(q_i)$ 较大, 则其对应的 IDF 值较小, 频繁出现的词项在被检索中通常信息量较少, 因为它们在大多数文档中都有出现, 对文档的区分度较低。如果词项 q_i 很少出现在文档集中的文档中, 即 $n(q_i)$ 较小, 那么其 IDF 值会较大。这是因为稀有的词项通常具有更高的区分能力。

基于语义相似度主要是通过将抽取出的实体和现有医疗知识图谱的实体均转化为高维向量, 使用余弦距离来判断彼此之间的相似程度, 公式如下:

$$\text{sim}(T, C_i) = \frac{M_e(T) \cdot M_e(C_i)}{\|M_e(T)\| \|M_e(C_i)\|} \quad (3-8)$$

其中 M_e 是中文嵌入向量模型, $\|M_e()\|$ 指的向量的欧几里得长度。

总的来说, 通过基于语义相似度的 BERT 模型和基于词频的 BM25 方法从知识图谱中召回 Top-K 个候选实体, 然后通过大语言模型判断每个候选实体与待对齐实体是否是同一实体, 以确定它们是否代表同一实体, 具体流程如3-4所示。这种方法充分利用大语言模型的预训练知识, 还有效地避免了实体冗余, 确保知识图谱的完整性和一致性。




图 3-4 基于大语言模型的实体对齐框架

在合并过程中, 关系一致性检查是确保新增关系与现有知识图谱中关系三元组是否重复的关键步骤。本课题采用基于向量相似度的方法对关系进行一致性检查, 首先, 利用预训练的嵌入模型将新抽取的关系和知识图谱中已有的关

系进行向量化表示，然后计算这些向量之间的相似度，通过设定相似度阈值来判断新关系是否与已有关系在语义上相似或相同，流程如图3-5所示。与传统的基于规则的完全匹配方法相比，向量相似度能够捕捉关系之间的语义相似性，有效匹配同义词、近义词以及表达方式不同但含义相近的关系，从而在一定程度上减轻实体对齐任务的难度。而规则匹配通常只能识别完全相同的关系表达，缺乏足够的灵活性。其次，向量相似度方法具有更好的扩展性和适应性，能够处理复杂多变的关系类型，减少因规则编写不全而导致的漏匹配或误匹配情况。此外，基于向量的相似性检查能够在大规模知识图谱中高效运行，提高了关系一致性检查的效率。因此，采用向量相似度进行关系一致性检查，不仅提升了知识图谱扩充过程中的语义精度，还增强了系统对多样化关系表达的适应能力。




图 3-5 基于向量相似度的关系一致性检查

通过上述方法，本课题实现了从新语料中高效、准确地抽取并合并实体和关系到医疗知识图谱中，显著丰富了知识图谱的内容，提升了其覆盖范围和深度。未来，随着技术的进一步发展，知识图谱扩充将在更多领域展现其广泛的应用潜力和价值。

3.4 实验与分析

3.4.1 实验数据集构建与分析

为了对现有医疗知识图谱进行有效扩充，首先需要验证本课题提出的关系抽取框架的有效性。本课题选择《诊断学》第一章中的常见症状部分作为文本数据，进行关系抽取验证实验。《诊断学》由医学专家编写，内容基于前沿的医学理论和临床实践，具有高度权威性和系统性，适合作为构建医疗知识图谱的基础。教科书语言结构化、语义联系紧密，有助于模型在关系抽取时更好地捕捉实体间的关联，提升抽取准确性。在本研究中，为了确保抽取的实体和关系与疾病诊断密切相关，实体和关系类型的选择依据 WiMedKG 中已有的定义进行，相关内容在第二章已经介绍过，这里不再赘述。医疗知识图谱扩充实验选用收集的医学教科书作为数据源，并不断输入医学文本进行抽取。

3.4.2 实验设置

本课题选择使用 **GPT-4o** 模型来进行医疗关系三元组抽取任务，而非使用一些经过监督微调后的医疗专用模型，主要是因为医疗大语言模型通常是使用问答数据集进行微调的，这使得它们更擅长于回答问题和进行对话，但在处理关系抽取任务时存在一定的局限性。问答任务和关系抽取任务的核心差异在于，前者侧重于理解问题并给出答案，而后者则要求模型能够准确识别和提取文本中实体之间的复杂关系。虽然经过监督微调过的医疗大语言模型能够理解医疗领域的常见问题，但它们往往缺乏对文本中细粒度关系的抽取能力，因此难以精准识别并提取医学文本中的三元组关系。通过以香港中文大学的 **Huatuo2-13B** 模型为例进行测试，尽管该模型通过医疗数据进行监督微调过，但仍无法有效解决实体识别和关系抽取问题，会输出“对不起，我无法完成此任务”或“对不起，由于没有给出具体的医疗文本进行分析和处理，我无法生成相应的结果”类似的结果。

与此不同，**GPT-4o** 作为一个通用大语言模型，虽然没有专门针对医疗领域的微调，但它在大规模、跨领域的语料库上进行了预训练，能够捕捉到复杂的语义关系和长距离依赖。即使是在医疗领域，**GPT-4o** 也能够通过上下文推理灵活地识别和抽取实体及其关系。更重要的是，**GPT-4o** 在关系抽取任务中能够利用其强大的推理能力，结合上下文信息，在没有大量标注数据的情况下，通过上下文学习完成有效的关系抽取。因此，**GPT-4o** 在医疗关系三元组抽取任务中，能够提供更高的准确性和灵活性，尤其是在处理医疗文本中的复杂语义关系时，表现得更为出色。所以，本实验选用 **GPT-4o** 作为实验模型完成实体识别和关系抽取任务。

3.4.3 基于大语言模型的命名实体识别验证实验

在实体识别任务实验中，主要对比了两种方法在命名实体识别任务中的表现：第一种是采用思维链机制的实体识别方法，第二种是引入自反思机制的两阶段识别方法，第一阶段识别实体类型，第二阶段针对实体类型识别具体的实体名称。实验结果如下表所示。

表 3-1 基于大语言模型的实体识别结果

方法	macro-p	macro-r	macro-f1	micro-p	micro-r	micro-f1
GPT-4o + 思维链	57.25	67.62	0.62	55.4	69.37	0.62
GPT-4o + 两阶段识别	60.82	61.01	0.61	58.99	58.16	0.59

从表中可以看出，GPT-4o 结合两阶段的识别方法在精确率方面有所提升，而召回率则有所下降。宏观精确率（macro-precision）从 57.25% 提升至 60.82%，微观精确率（micro-precision）从 55.41% 提升至 58.99%。精确率的提高意味着模型在识别出的实体中，正确识别的比例增加了。这表明引入自反思机制后，模型在生成结果时更加谨慎，减少了错误实体的生成，从而提升了整体识别的准确性。宏观召回率（macro-recall）从 67.62% 下降至 61.01%，微观召回率（micro-recall）从 69.37% 下降至 58.16%。召回率的降低意味着模型在识别所有真实实体时的覆盖率有所减少，可能漏掉了一部分实体。这是因为自反思机制倾向于生成更精确的结果，会牺牲部分召回以换取更高的精确率。

综上所述，在两阶段命名实体识别过程中，第一阶段生成包含的实体类型，第二阶段通过自反思机制对实体识别结果进行验证和修正。这一过程减少了错误实体的生成，从而提高了精确率。然而，严格的验证过程可能导致部分真实实体被误判为不相关，导致召回率下降。但知识图谱作为知识表示工具，其质量直接影响在下游任务应用中的准确性。因此，本研究更看重精确率，以确保模型输出结果的可靠性，减少错误信息的传播。这一策略在实际应用中更符合医疗行业对信息准确性的高要求。

3.4.4 基于大语言模型的关系三元组抽取验证实验

在本章节中，我们选取了《诊断学》教材第一章中的人工标注数据集作为实验基础。该数据集由哈尔滨医科大学的资深医疗专家团队，利用专业的标注工具，进行了详尽且准确的标注工作，确保了数据的高质量和可靠性。这一数据集不仅具有丰富的医学知识，而且涵盖了广泛的实体类型和多样化的关系，适用于验证关系抽取算法的有效性和准确性。

为了进行关系三元组抽取的验证实验，本课题选用 GPT-4o 作为实验模型。GPT-4o 是 OpenAI 最新发布的 GPT 系列模型，具备卓越的上下文理解和生成能力，能够处理复杂的语言任务。在实验评估过程中，主要选用了三个主要评价指标：准确率（Accuracy）、微平均 F1-Score（Micro-average F1-Score）和宏平均 F1-Score（Macro-average F1-Score）。这些指标能够全面衡量模型在不同维度上的表现，确保评价结果的全面性和客观性。关于这些评价指标的具体计算方法，已在本文第二章中详细阐述，此处不再赘述。

在本实验中，我们设计了四组不同的试验方法，以全面评估所提出的关系三元组抽取框架的性能。每组实验在基础模型的基础上，逐步引入不同的增强策略，以探究其对关系抽取效果的影响。第一组实验采用了 OpenAI 最新发布

的 GPT-4o 模型，结合思维链技术进行关系抽取任务。思维链是一种增强模型推理能力的方法，通过引导模型进行多步逻辑推理，从而提高其在复杂任务中的表现。第二组实验在基础方法（GPT-4o + 思维链）的基础上，本组实验引入了关系三元组示例池。示例池包含预先标注的高质量关系三元组，用于指导模型在抽取过程中参考和学习，从而提升抽取的准确性。第三组实验在基础方法（GPT-4o + 思维链）的基础上，增加了关系三元组自反思机制。自反思使模型能够对已抽取的关系三元组进行自我检查和优化，进一步提升抽取结果的质量和可靠性。最后一组实验是综合前两种增强策略的组合方法，即同时使用关系三元组示例池和自反思机制。本组实验旨在结合关系三元组示例池和自反思机制，最大化模型在关系抽取任务中的性能提升，具体实验结果如下表所示。

表 3-2 关系三元组验证实验结果

方法	Acc(%)	Macro-F1	Micro-F1
GPT-4o + 思维链	25.12	0.35	0.32
GPT-4o + 思维链 + 关系三元组示例池	35.19	0.45	0.4
GPT-4o + 思维链 + 关系三元组自反思	36.94	0.42	0.42
GPT-4o + 思维链 + 关系三元组示例池 + 自反思	40.26	0.53	0.48

我们可以观察到不同方法在关系抽取任务中的表现差异。首先，使用“GPT-4o + 思维链”的方法时，准确率为 25.12%，macro-F1 值为 0.35，micro-F1 值为 0.32，表明该方法在基本任务上表现较为一般。在加入“关系三元组示例池”后，性能有所提升，准确率、macro-F1 值、micro-F1 值均有提升。这表明示例池能有效帮助模型更好地理解 and 抽取关系，提升了整体性能。进一步引入“关系三元组自反思”机制后，准确率进一步提升，反映出自反思机制在纠正错误识别对优化关系抽取结果具有一定的作用。最后，结合“关系三元组示例池”和“自反思机制”后，模型的表现得到了显著提升，准确率达到 40.26%，macro-F1 值为 0.53，micro-F1 值为 0.48。综合来看，二者的结合显著提高了模型的性能，证明了本课题提出框架的有效性。

3.4.5 基于大语言模型的医疗知识图谱扩充实验

由于文本语料量较大，且不断输入到本课题设计的框架中，截止目前，关系三元组抽取的实验结果如表3-3所示。

在本实验中，我们对现有医疗知识图谱进行了扩充，主要目标是通过从新

语料中提取新的实体和关系类型，从而丰富现有的知识图谱。扩充后的实体和关系为模型提供了更多的语义信息，进一步提升了知识图谱的覆盖度和精准度。值得注意的是，随着医学领域信息的不断更新和迭代，会出现更多新的症状和疾病实体描述。从实验结果来看，我们识别出了多个新的实体，其中“症状”和“疾病”是最为频繁出现的实体类型，分别出现了 1018 次和 808 次。在关系类型方面，我们也识别出了多种新的关系三元组，其中“导致”和“伴随”最为频繁。

表 3-3 知识图谱扩充结果

实体类型	出现次数	关系类型	出现次数	关系类型	出现次数
症状	1018	导致	1689	合并症	664
疾病	808	伴随	933	并发症	826
微生物	15	有发生部位	820	是诊断依据	67
人体部位	1018	是临床表现	553	可使用检查	64
检查	71	是风险因素	733	其他	25
健康危险因素	537				

3.5 本章小结

本章围绕基于大语言模型的医疗知识图谱扩充研究展开，系统探讨了如何利用先进的自然语言处理技术，特别是 OpenAI 最新的 GPT-4o 模型，来提升医疗知识图谱的构建效率与准确性。首先，本章指出了现有医疗知识图谱在知识量和覆盖范围上的不足，强调了自动化关系三元组抽取在解决这一问题中的重要性。

为了应对传统方法在累积错误传递和处理复杂关系的局限性，本研究提出了一种融合动态提示和自反思机制的关系抽取框架。该框架通过引入关系三元组示例池，增强了模型对关系类型的理解能力；同时，通过自反思机制，提升了抽取结果的准确性和可靠性。这一创新性的方法有效缓解了错误累积传递的问题，确保了知识图谱扩充过程中的信息质量。

在实验部分，研究选用了《诊断学》第一章的人工标注数据集，由哈尔滨医科大学的医疗专家团队精心标注，确保了数据的高质量和可靠性。通过一系列对比实验，验证了所提出框架在命名实体识别和关系抽取任务中的优越性能。实验结果表明，结合示例池和自反思机制的方法显著提升了模型在准确率和 F1 分数上的表现，充分证明了该框架的有效性和实用性。

综上所述，本章通过理论分析与实验证实，基于大语言模型的自动化关系抽取框架在医疗知识图谱扩充中展现出显著的优势。该方法不仅提升了知识图谱的构建效率和覆盖范围，还确保了信息的准确性和一致性，为医疗领域的智能化发展提供了坚实的技术支持。未来，随着大语言模型和知识图谱技术的不断进步，预计这一研究方向将在更多医疗应用场景中发挥更大的作用，推动临床决策支持和医学研究的智能化水平迈上新台阶。

第4章 基于大语言模型的医疗知识图谱应用

4.1 引言

在当今自然语言处理领域，大型语言模型凭借其强大的文本生成能力，已在诸多应用场景中展现出卓越的性能。例如，在自动摘要、机器翻译、智能客服以及内容创作等方面，大语言模型都表现出了令人瞩目的效果。然而，随着大语言模型在实际应用中的广泛部署，越来越多的问题也逐渐显现出来，其中“幻觉”现象尤为突出。所谓“幻觉”现象，指的是大语言模型在根据用户查询生成回复时，可能会包含不准确、无依据或与事实不符的信息。这种现象在医疗领域尤为严重，因为医疗决策直接关系到患者的健康和生命安全。医疗领域对信息的准确性和可靠性要求极高，任何不准确或误导性的内容都可能导致严重的后果。因此，如何有效减少大语言模型在医疗应用中的幻觉现象，成为当前研究的一个重要热点。

为了解决上述问题，本研究提出在先验文本形式的提示基础上将知识图谱引入作为后验知识验证的工具，以进一步提升大语言模型的推理效果。首先，知识图谱中的知识以结构化的关系三元组形式存在，虽然它能够展现清晰的医学关系，但由于其高度结构化的特性，需要与特定的医学实体进行匹配，检索时必须依赖于这些关系三元组中的实体。然而，如果在检索过程中仅使用医学问题和选项中的实体来查找相关的知识子图，可能无法全面覆盖所有相关的医学信息。因此，知识图谱作为先验知识往往不能充分满足大语言模型在生成回答时对语境和细节的需求。另一方面，如果使用向量知识库作为先验提示，虽然其可以通过检索相关文档和资料，为大语言模型提供丰富的背景信息，进而引导其生成更多相关的专业内容。但是，这种方式也存在一定的局限性。如果检索过程未能精准地提取相关知识，可能会导致模型生成的回答因缺乏必要的医学信息而出现错误。此外，由于向量知识库中的信息通常呈现为自然语言文本，语义表达较为模糊或不够明确，可能会导致模型理解上的偏差，尤其在一些细节要求较高的医学场景中，容易产生语义不一致或误导。因此，单独依赖向量知识库作为先验提示并不足以完全解决问题。

本课题提出了将知识图谱应用于后验矫正的框架。在生成初步回答后，我们可以根据大语言模型的输出中的医学信息，进一步提取更为全面和精准的知

识子图。这种后验矫正能够有效补充或修正模型生成的内容，确保生成结果更加准确且符合实际医学知识，从而提高模型的整体可靠性和准确性。通过将先验提示与后验矫正相结合，本框架能够充分发挥向量知识库和知识图谱各自的优势，提升大语言模型在复杂领域问题上的表现。具体而言，本研究的方法包括以下几个步骤：1. 利用外部知识库提示大语言模型生成初步的回答结果。2. 对大语言模型生成的回答进行中文医学实体识别，提取出与解决问题有关的关键医学实体。3. 基于识别出的医学实体，从知识图谱中检索出相应的关系三元组。这些三元组包含了解决问题的结构化知识，为后续的自我反思验证提供了知识依据。4. 利用检索到的关系三元组，对生成的内容进行验证和反思，确保其与知识图谱中的事实相符，从而有效减少幻觉现象的发生。

因此，本研究旨在深入探讨基于大语言模型的医疗知识图谱应用，通过第三章扩充后的完备知识图谱，结合先进的检索增强技术，系统性地解决大语言模型在医疗领域应用中存在的幻觉问题。并通过实验验证其在医疗诊断任务中的有效性和实用性，从而为医疗人工智能的发展提供坚实的理论基础和技术支持。最终，期望能够为医疗行业带来更为智能化、精准化的信息服务，推动医疗技术和服务水平的全面提升。

4.2 医疗向量知识库的构建与检索

向量知识库的构建与检索是现代自然语言处理和信息检索领域中的关键技术，尤其在大语言模型的应用中具有重要意义。构建医疗向量知识库的第一步是数据收集与预处理，包括从多种来源如：医学文献、电子健康记录、临床指南等获取大量结构化数据，并进行清洗、去重和标准化处理，以确保数据质量和一致性。接下来，利用先进的文本嵌入模型将文本内容转化为高维向量表示，这些向量能够捕捉文本的语义信息和上下文关系。生成的向量随后被存储在专门优化的向量数据库中，这些数据库支持高效的向量索引和快速相似性搜索，能够在大规模数据集上实现实时检索。在检索过程中，当用户提出查询时，同样通过嵌入模型将查询转换为向量，然后在向量知识库中进行相似性搜索，常用的相似性度量方法包括余弦相似度、欧氏距离或内积等，以找到与查询最相近的向量及其对应的原始数据。这种基于向量的检索方法相比传统的关键词匹配，能够更好地理解和捕捉查询的语义意图，提高检索结果的相关性和准确性。为了进一步优化向量知识库的性能，常采用分布式存储和并行计算技术，以处理海量数据和高并发访问需求。

本课题选取了 24 本权威医学教科书作为基础医疗语料，涵盖病理学、外科学、传染病学等多个重要领域，确保语料库的广泛性和专业性。为了有效管理和利用这些海量文本数据，我们首先对语料库进行预处理，包括数据清洗、去重和标准化处理。随后，采用文本切割技术将整个语料库利用 **LangChain** 工具划分为若干个较小的文本块，每本数据的统计信息如表4.2所示。在文本切割完成后，利用 **BGE** 中文嵌入模型将每个文本片段转化为高维向量表示。这一过程通过将文本内容嵌入到高维向量空间中，保留了文本的语义信息和上下文关系。生成的高维向量随后被存储在 **FAISS** 索引中，完成了医疗向量知识库的构建工作。**FAISS** 是一种高效的向量检索库，专为大规模向量数据的快速相似性搜索而设计，能够显著提升检索速度和准确性。构建完成的医疗向量知识库不仅存储了大量的医学知识，还通过向量化表示实现了对文本语义的深度理解。这为后续的知识检索和大语言模型的应用提供了坚实的基础。

表 4-1 向量知识库数据介绍

书籍名称	段落数量	书籍名称	段落数量	书籍名称	段落数量
病理生理学	417	人体寄生虫学	417	医学伦理学	345
病理学	526	神经病学	668	医学免疫学	294
传染病学	658	生理学	667	医学生物学	345
儿科学	715	生物化学与分子生物学	733	医学微生物学	520
耳鼻咽喉头颈外科学	566	外科学	1122	医学细胞生物学	630
法医学	318	卫生法	568	医学心理学	422
妇产科学	655	卫生学	651	医学遗传学	369
精神病学	546	系统解剖学	387	医学影像学	498
局部解剖学	317	药理学	753	预防医学	731
临床药理学	814	医患沟通	392	诊断学	724
内科学	1321	医学导论	357	组织学与胚胎学	305

在医疗向量知识库构建完成后，检索过程成为实现知识应用的关键环节。当用户提出查询时，系统首先通过 **BGE** 中文嵌入模型将查询文本转化为高维向量表示。这一向量表示同样保留了查询文本的语义信息，使其能够在向量空间中与知识库中的向量进行有效匹配。接下来，利用 **FAISS** 索引结构对查询向量进行快速相似性搜索。**FAISS** 通过高效的索引算法和优化的数据结构，能够在海量的向量数据中迅速找到与查询向量最相似的若干个向量，并返回对应的文本片段，这个方法能够有效评估查询与知识库中各文本片段之间的语义相关性。检索到的文本片段作为背景知识，输入到大语言模型中，辅助模型理解用户查询的具体内容，并生成更为准确和相关的回答。这一过程不仅提升了回答

的准确性，还通过提供上下文信息，有效缓解了大语言模型在生成内容时可能出现的“幻觉”现象。特别是在面对复杂或专业性强的医疗问题时，向量知识库的高效检索能力能够迅速定位相关信息，确保模型输出的内容具有高度的专业性和可靠性。

4.3 基于医疗知识图谱的后验矫正

在本章的研究中，主要聚焦于医疗领域的下游任务，提出了一种基于知识图谱的自反思框架。随着大语言模型在医疗诊断等下游任务中的广泛应用，如何提高模型在医疗决策中的准确性和可靠性，成为了亟待解决的重要问题。为此，本课题提出的框架旨在通过结合知识图谱与自反思机制，进一步增强模型的推理能力与准确性，特别是在面对复杂和模糊的医学问题时。该框架主要包括两个关键步骤。首先，基于病人的病状、体征等相关信息，检索相关文本并作为先验提示，引导大语言模型生成初步的诊断结果。接着，利用生成结果中的医学实体链接到知识图谱，检索相关的知识子图进行自反思矫正，修正可能存在的错误或遗漏，从而提高诊断结果的准确性。具体而言，通过将用户查询转换为高维嵌入向量，在向量知识库中检索相关的医学文本以得到先验提示。先验提示为大语言模型提供了背景知识，帮助模型获取与用户查询相关的上下文信息。这些先验提示能够引导模型理解具体的医学上下文，生成初步的诊断结果。然而，检索到的文本可能存在噪声、偏差或过时的信息，尤其是在医疗领域，新的治疗方法和医学发现不断更新，检索到的信息可能不完全准确或不符合最新的标准。此外，大语言模型在推理过程中可能面临语义差异、上下文丧失等问题。因此，仅依赖先验提示并不足以保证推理的准确性和合理性。

为此，本课题设计的框架引入了后验矫正机制。模型能够通过初步生成的诊断结果链接到医疗知识图谱中的结构化信息，对生成的结果进行推理验证。这一机制有助于识别推理中的潜在错误，并结合知识图谱中的知识对模型的生成结果进行纠正，从而确保最终输出的结果更加准确、合理，自反思机制的核心优势在于它能够根据知识图谱中的子图进行反向审视。当生成的初步诊断结果可能包含误差或缺失时，模型可以通过检索与生成结果相关的知识子图补充缺失的上下文，或对推理过程进行优化，纠正潜在的错误。例如，在诊断某种疾病时，如果生成结果中遗漏了与该疾病相关的症状或治疗方法，模型可以通过知识图谱中的结构化信息来补充这一部分内容。此外，当面对复杂的医学问题时，结构化的知识图谱信息可以帮助模型更好地理解问题，弥补上下文的空

白，从而避免生成错误的答案或不合理的推理。框架如图4-1所示。




图 4-1 基于大语言模型的知识图谱自反思校正框架

具体而言，以下是框架中各步骤的数学表示：

$$P = R_e(Q, K) \quad (4-1)$$

其中 P 是检索到的外部知识， R_e 是检索器， Q 是用户输入的医学问题， K 是向量知识库。

$$A_{\text{fake}} = f_{\text{LLM}}(Q, P) \quad (4-2)$$

其中 A_{fake} 是模型根据检索出的文本片段生成的初步结果。

$$E = f_{\text{LLM}}(A_{\text{fake}}, Q), \quad G_s = R_G(E) \quad (4-3)$$

其中 E 是从生成结果中检索出的医学实体， G_s 是检索到的知识子图， R_G 是知识图谱检索算法。

$$A_{\text{final}} = f_{\text{LLM}}(Q, A_{\text{fake}}, G_s) \quad (4-4)$$

其中 A_{final} 是模型根据关系三元组后验提示校正后的输出结果。

4.4 实验与分析

4.4.1 实验数据集构建

本课题选用的实验数据集包括两个与医疗任务相关的开源数据集: MedQA 数据集和 CMB-Exam 数据集。MedQA 数据集包括中文数据集和英文数据集两个版本, 本课题选用中文数据集版本, MedQA 测试集中的内容主要围绕疾病诊断、临床症状和治疗方案等方面展开, 适合作为验证知识图谱在下游任务中应用的数据, 因计算资源和成本有限, 本课题选用 MedQA 测试集中的 1500 条作为本部分实验数据集。CMB-Exam 数据集的测试集中包含 11200 条数据, 涵盖了广泛的医学领域知识。为了确保实验的针对性, 我们使用大语言模型 qwen2.5-14b-instruct 对 CMB-Exam 数据集进行了预处理和筛选。本课题通过设计 prompt 从选择题中筛选与疾病诊断任务相关的数据, 与疾病诊断任务相关的数据往往包含病人的具体病例信息, 提示词模版详见附录。通过大语言模型的辅助筛选, 将那些包含患者病历描述和疾病诊断相关信息的条目保留下来, 形成了最终用于实验的 1500 条疾病诊断数据集。

由于 MedQA 和 CMB-Exam 数据集中的题目形式均为选择题, 每个问题存在多个可能的选项, 并且其中一个是正确答案。所以本课题选用准确率作为唯一的评价指标, 其计算公式如下:

$$\text{Accuracy} = \frac{\text{Number of Correct Predictions}}{\text{Total Number of Predictions}} \quad (4-5)$$

4.4.2 实验设置与结果分析

本课题选用了三种先进的大语言模型, 分别为 Qwen2.5-14B-Instruct、ChatGLM4-9B-Chat 以及 GPT-3.5。这些模型各具特色, 涵盖了生成式预训练、对话优化以及多任务处理等多方面的能力, 能够满足课题中多样化的应用需求。

Qwen2.5-14B-Instruct 是一个功能强大的生成式预训练语言模型, 基于先进的架构设计, 具备卓越的自然语言理解与生成能力。Qwen2.5-14B-Instruct 支持多种智能体应用场景, 能够高效处理复杂任务, 如长文本解析、数据预测与趋势分析、代码生成等。其在多任务学习中的表现尤为出色, 能够在不同领域之间实现知识迁移, 提升整体模型的适应性和泛化能力。

ChatGLM4-9B-Chat 是智谱 AI 推出的最新一代预训练模型 GLM-4 系列中的开源版本。该模型在语义理解、数学推理、逻辑分析、代码生成以及知识问

答等多个维度的评测中，均展现出超越 Llama-3-8B 的卓越性能。除了支持多轮对话功能外，ChatGLM4-9B-Chat 还具备网页浏览、代码执行、自定义工具调用 (Function Call) 以及长文本推理 (支持最大 128K 上下文) 的高级功能。该版本模型进一步增强了多语言支持能力，覆盖包括日语、韩语、德语在内的 26 种语言，显著提升了其在全球化应用中的适应性。

ChatGPT 由 OpenAI 开发，是基于 Transformer 架构的先进人工智能语言模型。ChatGPT 具备强大的自然语言理解和生成能力，广泛应用于对话系统、内容创作、翻译、编程辅助等多个领域。通过海量数据的训练，ChatGPT 拥有丰富的知识储备和深厚的语言理解能力，能够与用户进行流畅且智能的互动交流。无论是在日常生活中的信息查询，还是在专业领域中的复杂问题解答，ChatGPT 都能提供高效且精准的支持，极大地提升了人们的工作和生活效率。鉴于本课题中需要处理较长的输入上下文，选择了 GPT-3.5-turbo-16k 版本，以充分发挥其在长文本处理方面的优势。

在本课题的研究中，我们在两个不同的数据集上，针对不同模型采用了多种实验方案进行对比分析。这些实验方案包括基于零样本提示的实验、基于思维链推理的实验、基于外部知识库混合检索的先验提示实验，以及融合外部知识库先验提示与知识图谱后验校正的综合实验。通过这些多样化的实验设计，本课题全面评估各大语言模型在不同任务和应用场景下的表现。最终的实验结果如下表所示，详细展示了各模型与策略的具体表现，进一步验证了所选模型在本课题中的适用性和优势。

表 4-2 医疗知识图谱应用实验

大语言模型	方法	MedQA-ZH	CMB-Exam
Qwen2.5 (14B-Instruct)	零样本提示	88.32	84.73
	思维链	85.57	82.64
ChatGLM4 (9B-Chat)	零样本提示	77.54	80.06
	思维链	76.72	72.88
GPT-3.5 (turbo)	零样本提示	60.48	48.81
	思维链	59.64	50.75
GPT-3.5 (turbo-16k)	思维链 + 向量知识库	61.81	51.33
	思维链 + 向量知识库 + 知识图谱	62.48	51.73

根据表中的实验结果，我们对所选用的大语言模型在医疗领域两个 Benchmark 数据集上的表现进行了详细分析。Qwen2.5-14B-Instruct 在所有测试方法中表现最为优异。在 MedQA-ZH 数据集上，零样本提示达到了 88.32% 的准确率，而在 CMB-Exam 数据集上也取得了 84.73% 的准确率。ChatGLM4-9B-Chat 的表现次之。在 MedQA-ZH 数据集上，零样本提示达到了 77.54% 的准确率，CMB-Exam 数据集上为 80.06% 的准确率。本课题在基础性实验中，尝试使用 qwen2.5-14b-instruct 模型和 chatglm4-9b-chat 模型进行基础实验，但在实验过程中发现 qwen2.5 模型和 chatglm4 模型在医疗测试集上在零样本提示下都达到了极高的准确率，但在医疗任务中是需要更强的推理能力，我们发现在这两个模型上使用思维链进行推导，实验结果均有下降，我们猜测这其中可能存在数据泄露问题，即在 Benchmark 上的测试数据被收集到模型预训练语料当中造成，Ni^[53] 等人在论文中进行了详细地实验介绍。所以，本实验主要以 ChatGPT 作为主要实验模型。根据实验结果表中的数据，GPT-3.5-turbo 模型在两个医疗领域的基准数据集（MedQA-ZH 和 CMB-Exam）上的表现存在一定差异。在 MedQA-ZH 数据集中，采用零样本提示方法时达到 60.48% 的准确率，而使用思维链方法略降至 59.64%，表明在处理直接的中文医疗问答任务时，思维链方法未能显著提升模型性能，甚至略有下降。相较之下，在 CMB-Exam 数据集中，思维链方法的得分为 50.75%，高于零样本提示的 48.81%，显示出思维链方法在需要更复杂推理和综合知识的考试题目中具有一定的优势。对于 GPT-3.5-turbo-16k 模型，引入向量知识库后，在 MedQA-ZH 和 CMB-Exam 数据集上的得分分别提升至 61.81 分和 51.33 分，接下来，针对 GPT-3.5-turbo-16k 模型，首先引入思维链和向量知识库的方法后，在 MedQA-ZH 数据集上的得分提升至 61.81 分，CMB-Exam 数据集则提升至 51.33 分。这表明，向量知识库的引入为模型提供了额外的相关信息，增强了其在处理医疗问答任务时的知识储备和理解能力，从而显著提升了整体表现。进一步结合知识图谱后，GPT-3.5-turbo-16k 在 MedQA-ZH 上的得分进一步提升至 62.48 分，在 CMB-Exam 上达到 51.73 分。这一结果显示，知识图谱的引入通过提供结构化的知识关系，进一步增强了模型在理解和回答复杂医疗问题时的能力，尤其是在需要多步骤推理和深度理解的任务中，知识图谱显著提升了模型的解答质量。综合比较可见，GPT-3.5-turbo-16k 在引入向量知识库和知识图谱的辅助下，在两个数据集上的表现均有所提升，尤其是在处理复杂和长文本任务时表现更为出色。具体而言，向量知识库的引入显著增强了模型的知识获取能力，而知识图谱的结合则进一步校验了模型输出结果，二者协同作用下，模型在 MedQA-ZH 和 CMB-Exam 上的得分分别提升了约 1 分和 0.92

分。这表明，结合向量知识库和知识图谱，能够有效提升模型的整体性能和适应性。

4.4.3 示例分析

在医疗领域，基于大语言模型的应用日益广泛，其在临床决策支持、医学文献检索和患者咨询等方面展现出巨大的潜力。这些模型能够快速处理和生成大量医疗信息，辅助医生和患者做出更为精准和高效的决策。然而，随着这些模型在关键医疗任务中的深入应用，其决策过程的透明性和可解释性成为确保其可靠性和安全性的关键因素。以一个具体示例说明，如图4-2所示，有一道题目询问急性肾小球肾炎的产生原因：“急性肾小球肾炎是一种免疫复合物性肾小球肾炎，往往与（ ）有关。”大语言模型在生成初步响应时，包含相关的医学实体如“急性肾小球肾炎”、“链球菌感染”等。接着，利用这些医学实体作为封闭实体集合，在医疗知识图谱中检索具有一阶关系的三元组，检索结果为：“链球菌感染-导致-急性肾小球肾炎”。然后，将关系三元组转化为文本提示，反馈给大语言模型，使其能够进行自反思和验证，从而矫正初步响应，生成最终准确的答案。通过这种结合外部知识图谱的可解释性分析方法，不仅提升了模型回答的准确性和相关性，还揭示了其决策依据和推理路径。这一过程展示了可解释性分析在基于大语言模型的医疗任务中的重要作用，确保了模型在复杂和高风险医疗决策中的可靠应用。




图 4-2 基于知识图谱的自反思示例

4.5 本章小结

本章围绕大型语言模型在医疗领域应用中普遍存在的“幻觉”问题，系统性地探讨了通过应用医疗知识图谱来提升模型输出准确性和可靠性的研究方法。为有效缓解“幻觉”现象，本研究引入了检索增强技术，通过构建高效的医疗向量知识库，利用先进的文本嵌入模型和相似性搜索机制，从海量医学数据中精准检索相关知识，辅助大语言模型生成更加准确和信息丰富的回答。此外，进一步将结构化的医疗知识图谱整合进来，作为后验知识验证工具，通过中文医学实体识别和关系三元组检索，对模型生成的初步结果进行验证与反思，确保输出内容与医学知识的一致性，以解决外部知识源中内容过多，导致模型不能充分利用外部知识解决问题的问题。

在实验部分，通过选取两个开源医学数据集 MedQA 和 CMB，对比分析了在引入向量知识库和知识图谱后的性能提升情况。实验结果表明，结合检索增强技术和知识图谱显著提升了模型在医疗诊断任务中的准确率，尤其在处理复杂和专业性强的医疗问题时，表现尤为突出。这不仅验证了所提方法的有效性，也展示了知识图谱在增强模型理解和推理能力方面的潜力，更强调了扩充医疗知识图谱完备性的必要性。

综上所述，本章通过构建医疗向量知识库和引入结构化知识图谱，提出并验证了一种综合性的解决方案，显著提升了大语言模型在医疗应用中的表现，减少了“幻觉”现象的发生。研究成果为医疗人工智能的发展提供了坚实的理论基础和技术支持，推动了医疗信息服务的智能化和精准化，具有重要的实际应用价值和广阔的发展前景。

结 论

本文的主要研究围绕医疗知识图谱展开。首先，针对医疗知识图谱的扩充任务，本文设计了一个融合动态提示和自反思机制的关系抽取框架，用于从医疗文本中挖掘现有知识图谱中缺失的医学关系三元组，从而扩充知识图谱。随后，本文将扩充后的关系三元组应用于医疗领域的下游任务，为大语言模型提供外部知识进行结果校验，同时提升模型推理的可解释性。在全面调研国内外研究现状的基础上，结合大语言模型的强大推理能力，本文提出了相应的算法框架，并进行了充分的实验验证。实验结果表明，所设计的框架在医疗知识图谱扩充和下游应用两个核心任务中均取得了较为优异的表现。

具体来说，本文贡献主要包括以下三个方面：

(1) 设计了融合动态提示和自反思机制的关系抽取框架。本课题分析了当前使用大语言模型进行医疗关系抽取时面临的难题和挑战，并设计了一种关系抽取框架。通过引入三元组类比示例池，利用大语言模型的上下文理解能力，提升了对关系类型的理解深度，从而实现了更准确的关系三元组识别和抽取。同时，自反思机制的引入确保了抽取结果的高置信度，进一步提升了最终关系三元组的准确性和可信度。

(2) 利用所提出的关系抽取框架在新医疗文本语料上进行抽取，完成对现有医疗知识图谱的扩充。本课题基于所提出的关系抽取框架，在新的医疗文本语料上进行了关系三元组抽取，并成功完成了对现有医疗知识图谱的扩充。具体而言，我们利用设计的框架从新的医疗文本中自动提取出尚未涵盖在现有图谱中的医学实体和关系三元组，通过知识挖掘补充和扩展了图谱的内容。这一过程不仅增强了知识图谱的深度和广度，还为后续的下游任务提供了更加丰富的知识支持。为了确保新增的实体和关系信息能够高效地整合到现有知识图谱中，课题还引入了实体对齐和关系一致性检查机制。实体对齐通过对比新旧实体的语义相似性，确保不同来源的相同或相似实体能够统一标识，避免重复和歧义；关系一致性检查则通过验证新提取关系与已有关系的语义一致性，去除了冗余的关系三元组，保证了知识图谱中关系的准确性和一致性。通过这一系列的优化和校验措施，课题有效地避免了知识图谱扩充过程中可能出现的数据冗余问题，确保了最终扩充后的知识图谱不仅更加全面，而且具备更高的质量和可靠性。

(3)提出基于向量知识库先验提示和医疗知识图谱后验矫正的应用框架。该框架旨在解决当前医疗领域中大语言模型推理准确性和可解释性不足的问题,通过结合外部知识库和结构化知识图谱的优势,显著提升了医学任务中模型的诊断准确性和推理可靠性。具体而言,框架的工作流程分为两个主要步骤:首先,利用向量知识库作为先验提示,为大语言模型提供与输入医疗文本相关的背景知识。通过检索与用户输入相匹配的外部知识,向量知识库能够为大语言模型提供语义丰富的上下文信息,帮助其在生成初步结果。然而,尽管先验提示能够为大语言模型提供丰富的上下文信息,但在实际应用中,向量知识库的检索结果可能存在噪声、过时或不完整的情况,这可能影响模型的推理质量。因此,本框架引入了医疗知识图谱的后验矫正机制,在模型生成初步结果后,基于知识图谱对推理过程进行验证和修正。具体而言,通过在知识图谱中检索与初步结果相关的医学实体和关系子图,模型可以对比生成的推理结果与知识图谱中的结构化信息,识别可能的错误或遗漏。在后验矫正阶段,模型通过自反思机制进一步优化推理过程。自反思机制不仅帮助模型发现初步结果中的潜在问题,还能够基于知识图谱的结构化信息进行推理修正。最终,经过先验提示的引导和后验矫正的优化,框架能够输出更为准确、合理的医疗决策,同时提高了推理过程的透明度和可解释性。这种结合了动态检索和自我校正的机制,使得大语言模型在医疗领域中的应用更加稳健,并且在实际临床应用中更具实用性。

总体而言,本文的研究在利用大语言模型进行医疗知识图谱扩充以及将知识图谱应用于医疗任务方面取得了显著进展。实验结果验证了所提出的方法在医疗知识图谱扩展和实际应用中的有效性。尽管本文在医疗知识图谱扩充和应用方面取得了显著进展,但仍存在一些需要进一步解决的问题。首先,尽管引入了动态提示和自反思机制以提高关系抽取的准确性,但在面对更加复杂和多样化的医疗关系时,现有框架的鲁棒性和适应性仍需加强。其次,随着医学领域的不断发展和新的医学实体的不断涌现,如何确保知识图谱能够及时更新并有效整合新的信息,避免数据冗余和信息不一致,仍然是一个亟待解决的挑战。此外,尽管知识图谱为模型提供了更为结构化的推理支持,但在复杂任务情况下,如何有效利用知识图谱中的多跳关系,仍然需要更多的探索和改进。

参考文献

- [1] BOLLACKER K, EVANS C, PARITOSH P, et al. Freebase: a collaboratively created graph database for structuring human knowledge[C]//Proceedings of the 2008 ACM SIGMOD international conference on Management of data. 2008.
- [2] MILLER G A. Wordnet: a lexical database for english[J]. Communications of the ACM, 1995.
- [3] SUCHANEK F M, KASNECI G, WEIKUM G. Yago: a core of semantic knowledge [C]//Proceedings of the 16th international conference on World Wide Web. 2007.
- [4] LEHMANN J, ISELE R, JAKOB M, et al. Dbpedia—a large-scale, multilingual knowledge base extracted from wikipedia[J]. Semantic web, 2015.
- [5] VRANDEČIĆ D, KRÖTZSCH M. Wikidata: a free collaborative knowledgebase [J]. Communications of the ACM, 2014, 57(10): 78-85.
- [6] PETERS M, NEUMANN M, IYYER M, et al. Deep contextualized word representations[C]//Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers). 2018.
- [7] GRAVES A, SCHMIDHUBER J. Framewise phoneme classification with bidirectional lstm and other neural network architectures[J]. Neural networks, 2005, 18 (5-6): 602-610.
- [8] KENTON J D M W C, TOUTANOVA L K. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of naacL-HLT. Minneapolis, Minnesota, 2019.
- [9] OUYANG L, WU J, JIANG X, et al. Training language models to follow instructions with human feedback[J]. Advances in neural information processing systems, 2022.
- [10] CHOWDHURY A, NARANG S, DEVLIN J, et al. Palm: Scaling language modeling with pathways[J]. Journal of Machine Learning Research, 2023.
- [11] BAI J, BAI S, CHU Y, et al. Qwen technical report[A]. 2023. arXiv: 2309.16609.
- [12] YUE S, LIU S, ZHOU Y, et al. Lawllm: Intelligent legal system with legal reasoning and verifiable retrieval[C]//International Conference on Database Systems for Advanced Applications. Springer, 2024: 304-321.

- [13] DENG W, PEI J, KONG K, et al. Syllogistic reasoning for legal judgment analysis [C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 13997-14009.
- [14] ZHANG X, YANG Q. Xuanyuan 2.0: A large chinese financial chat model with hundreds of billions parameters[C]//Proceedings of the 32nd ACM International Conference on Information and Knowledge Management, CIKM 2023, Birmingham, United Kingdom, October 21-25, 2023. 2023: 4435-4439.
- [15] YANG H, LIU X Y, WANG C D. Fingpt: Open-source financial large language models[J]. FinLLM Symposium at IJCAI, 2023.
- [16] SHAH R S, CHAWLA K, EIDNANI D, et al. When flue meets flang: Benchmarks and large pretrained language model for financial domain[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing (EMNLP). Association for Computational Linguistics, 2022.
- [17] QIU H, HE H, ZHANG S, et al. SMILE: Single-turn to multi-turn inclusive language expansion via ChatGPT for mental health support[C]//Findings of the Association for Computational Linguistics: EMNLP 2024. Association for Computational Linguistics, 2024: 615-636.
- [18] DU Z, QIAN Y, LIU X, et al. Glm: General language model pretraining with autoregressive blank infilling[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2022: 320-335.
- [19] ZENG A, LIU X, DU Z, et al. Glm-130b: An open bilingual pre-trained model[C]//The Eleventh International Conference on Learning Representations. 2023.
- [20] HU E J, YELONG SHEN, WALLIS P, et al. LoRA: Low-rank adaptation of large language models[C]//International Conference on Learning Representations. 2022.
- [21] ZHANG H, CHEN J, JIANG F, et al. HuatuoGPT, towards taming language model to be a doctor[C]//Findings of the Association for Computational Linguistics: EMNLP. 2023.
- [22] WANG R, DUAN Y, LAM C, et al. Ivygpt: Interactive chinese pathway language model in medical domain[C]//CAAI International Conference on Artificial Intelligence. Springer, 2023: 378-382.
- [23] TOUVRON H, LAVRIL T, IZACARD G, et al. Llama: Open and efficient foundation language models[A]. 2023. arXiv: 2302.13971.

- [24] DONNELLY K, et al. Snomed-ct: The advanced terminology and coding system for ehealth[J]. Studies in health technology and informatics, 2006, 121: 279.
- [25] BODENREIDER O. The unified medical language system (umls): integrating biomedical terminology[J]. Nucleic acids research, 2004, 32(suppl_1): D267-D270.
- [26] CHANDAK P, HUANG K, ZITNIK M. Building a knowledge graph to enable precision medicine[J]. Scientific Data, 2023.
- [27] 阮彤, 孙程琳, 王昊奋, 等. 中医药知识图谱构建与应用[J]. 医学信息学杂志, 2016, 37(4): 8-14.
- [28] 杨锦锋, 关毅, 何彬, 等. 中文电子病历命名实体和实体关系语料库构建[J]. 软件学报, 2016, 27(11): 2725-2746.
- [29] 奥德玛, 杨云飞, 穗志方, 等. 中文医学知识图谱 CMeKG 构建初探[J]. 中文信息学报, 2019, 33(10): 1-7.
- [30] 杨洋, 关毅, 李雪, 等. 中文医学细粒度知识表示体系与标注语料库构建[J]. 中文信息学报, 2023, 37(06): 52-66.
- [31] SHENG M, ZHANG H, ZHANG Y, et al. Clmed: a cross-lingual knowledge graph framework for cardiovascular diseases[C]//Web Information Systems and Applications: 16th International Conference, WISA 2019, Qingdao, China, September 20-22, 2019, Proceedings 16. Springer, 2019: 512-517.
- [32] HUNTE B, MARIN J, STONE P J. Experiments in induction.[M]. Academic press, 1966.
- [33] CORTES C. Support-vector networks[J]. Machine Learning, 1995.
- [34] BREIMAN L. Random forests[J]. Machine learning, 2001.
- [35] WANG Y, YAO Q, KWOK J T, et al. Generalizing from a few examples: A survey on few-shot learning[J]. ACM computing surveys (csur), 2020.
- [36] TRAJANOSKA M, STOJANOV R, TRAJANOV D. Enhancing knowledge graph construction using large language models[A]. 2023. arxiv: 2305.04676.
- [37] ZHANG B, SOH H. Extract, define, canonicalize: An llm-based framework for knowledge graph construction[C]//AL-ONAIZAN Y, BANSAL M, CHEN Y. Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing, EMNLP 2024, Miami, FL, USA, November 12-16, 2024. Association for Computational Linguistics, 2024: 9820-9836.
- [38] ZHU Y, WANG X, CHEN J, et al. Llms for knowledge graph construction and reasoning: Recent capabilities and future opportunities[J]. World Wide Web, 2024.

- [39] CARTA S, GIULIANI A, PIANO L, et al. Iterative zero-shot llm prompting for knowledge graph construction[A]. 2023. arxiv: 2307.01128.
- [40] WAN Z, CHENG F, MAO Z, et al. GPT-RE: in-context learning for relation extraction using large language models[C]//BOUAMOR H, PINO J, BALI K. Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, EMNLP 2023, Singapore, December 6-10, 2023. Association for Computational Linguistics, 2023: 3534-3547.
- [41] 关昌赫. 融合外部知识的智能疾病诊断研究[D]. 哈尔滨工业大学, 2023.
- [42] ZHAO P, ZHANG H, YU Q, et al. Retrieval-augmented generation for ai-generated content: A survey[A]. 2024. arxiv: 2402.19473.
- [43] LIN X V, CHEN X, CHEN M, et al. RA-DIT: Retrieval-augmented dual instruction tuning[C]//The Twelfth International Conference on Learning Representations. 2024.
- [44] YORAN O, WOLFSON T, RAM O, et al. Making retrieval-augmented language models robust to irrelevant context[C]//The Twelfth International Conference on Learning Representations. 2024.
- [45] XU F, SHI W, CHOI E. RECOMP: Improving retrieval-augmented LMs with context compression and selective augmentation[C]//The Twelfth International Conference on Learning Representations. 2024.
- [46] ASAI A, WU Z, WANG Y, et al. Self-RAG: Learning to retrieve, generate, and critique through self-reflection[C]//The Twelfth International Conference on Learning Representations. 2024.
- [47] WU J, WU X, ZHENG Y, et al. Medkp: Medical dialogue with knowledge enhancement and clinical pathway encoding[A]. 2024. arXiv: 2403.06611.
- [48] XIONG G, JIN Q, LU Z, et al. Benchmarking retrieval-augmented generation for medicine[C]//Findings of the Association for Computational Linguistics, ACL. 2024.
- [49] WU J, ZHU J, QI Y, et al. Medical graph rag: Towards safe medical large language model via graph retrieval-augmented generation[A]. 2024. arXiv: 2408.04187.
- [50] GAO Y, LI R, CASKEY J, et al. Leveraging a medical knowledge graph into large language models for diagnosis prediction[A]. 2023. arXiv: 2308.14321.

- [51] WEN Y, WANG Z, SUN J. Mindmap: Knowledge graph prompting sparks graph of thoughts in large language models[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), ACL. Association for Computational Linguistics, 2024.
- [52] JIN Q, KIM W, CHEN Q, et al. Medcpt: Contrastive pre-trained transformers with large-scale pubmed search logs for zero-shot biomedical information retrieval[J]. Bioinformatics, 2023.
- [53] NI S, KONG X, LI C, et al. Training on the benchmark is not all you need[A]. 2024. arXiv: 2409.01790.

附录 A 提示词模版

提示词模版-疾病诊断数据筛选

你是一名医学专家，你的任务是回答给定的医学问题是否与疾病诊断任务相关，疾病诊断问题往往包含患者的性别、症状等详细信息，请你一步步思考并给出你的最终答案。请以JSON格式输出你的最终结果。
示例如下：{"思考过程": "", "判断结果": "是/否"}

这是给定的医学问题：
{question}

请一步步思考，并以JSON格式输出你的结果。

图 A-1 疾病诊断数据筛选提示词模版

提示词模版-实体类型识别模版

system

你是一名医学专家，你的任务是判断给定的医学文本中包含预定义实体类型列表中的哪些医学实体类型，请先一步步思考，然后确定所包含的医学实体类型，请以JSON格式输出你的结果，示例如下：
{"思考过程": "", "医学实体类型列表": []}

user

这是给定的医学文本：
{text}

预定义的医学实体类型为{entity_type_list}

请一步步思考并将你的结果以JSON格式输出：

图 A-2 实体类型识别提示词模版

提示词模版-命名实体识别模版

```
## system
你是一名医学专家，你的任务是从给定的医学文本语
料中识别中文医学实体，请一步步思考和分析，然后
输出对应的中文医学实体。请以JSON格式输出你的结
果，示例如下：
{"思考过程": "", "实体名称": []}

## user
这是给定的医学文本:
{text}

你需要抽取的医学实体类型为{entity_type}

请一步步思考并将你的结果以JSON格式输出:
```

图 A-3 命名实体识别提示词模版

提示词模版-基于零样本提示的思维链模版

```
## system
你是一名医学专家，你的任务是为医学选择题选择正
确的答案。请一步步思考和分析并以JSON格式输出你
的结果，示例如下：
{"思考过程": "", "答案": " A/B/C/D/E"}

## user
这是给定的医学问题:
{text}

这是问题的选项:
{options}

请一步步思考并将你的结果以JSON格式输出:
```

图 A-4 基于思维链的提示词模版

提示词模版-基于外部知识的思维链模版

```
## system
你是一名医学专家，你的任务是结合外部知识为医学
选择题选择正确的答案。请先判断外部知识是否与问
题相关，然后一步步思考和分析并以JSON格式输出你
的结果，示例如下：
{"思考过程": "", "答案": " A/B/C/D/E"}

## user
这是提供的外部知识:
{knowledge}

这是给定的医学问题:
{text}

这是问题的选项:
{options}

请一步步思考并将你的结果以JSON格式输出:
```

图 A-5 基于外部知识的提示词模版

提示词模版-基于关系三元组的思维链模版

```
## system
你是一名医学专家，你的任务是基于关系三元组的内
容，判断医学问题的可能答案是否正确，如果不正确
请进行修正。然后一步步思考和分析并以JSON格式输
出你的结果，示例如下：
{"思考过程": "", "答案": " A/B/C/D/E"}

## user
这是给定的医学问题:
{text}

这是问题的选项:
{options}

这是提供的关系三元组内容:
{knowledge}

这是医学问题的可能答案:
{history_response}

请一步步思考并将你的结果以JSON格式输出:
```

图 A-6 基于关系三元组的后验矫正模版