

分类号_____

学校代码 10487

学号 M202276601

密级_____

华中科技大学

硕士学位论文

(学术型☐ 专业型☒)

基于检索增强大语言模型的病案质检 方法研究

学位申请人：刘览

学 科 专 业：软件工程

指 导 教 师：区士颀 讲师

答 辩 日 期：2025 年 4 月 29 日

**A Dissertation Submitted in Partial Fulfillment of the Requirements
for the Professional Master Degree**

**Research on Medical Record Quality Control Methods
Based on Retrieval-Augmented Large Language Models**

Candidate : Liu Lan
Major : Software Engineering
Supervisor : Dr. Ou Shiqi

Huazhong University of Science and Technology
Wuhan 430074, P. R. China
May, 2025

摘要

电子病历作为医疗信息的主要载体，其质量控制是医院质量管理的重要环节。传统病案质量控制主要依靠人工终末检查，工作量大且效率低。近年来，随着大语言模型在自然语言处理领域的突破，病历质控正逐步向智能化转型。然而，现有开源大语言模型在医学领域的适配不足，难以准确理解和分析医学问题，同时还面临知识更新滞后和幻觉生成等挑战。开展基于检索增强大语言模型的病案质检方法研究，对提升医疗质量管理水平具有重要意义。

针对上述问题，开展基于检索增强大语言模型的病案质检方法研究。主要研究内容包括：（1）提出了面向病案质检任务的医疗大模型构建方法，有效解决了通用领域大语言模型在病案质检任务中适配不足的问题。该方法通过构建面向多种医学任务、多阶段的指令微调数据集，全面激发大语言模型的基础医学能力和复杂病历分析能力，并在此基础上构建了具备丰富且准确医学知识、在复杂病历数据处理任务中表现出色的垂域大语言模型。（2）提出了基于知识图谱检索增强的病案质检方法，有效缓解了大语言模型在实际应用中存在的知识更新滞后、幻觉生成以及知识相关性不足等问题。该方法通过构建外部知识库，为模型提供可靠的医学知识，并基于知识图谱挖掘实体关系，提高检索知识与用户输入之间的相关性。（3）实现了一个基于大语言模型和检索增强生成技术的病案质量检测系统。该系统支持用户上传病历数据，并通过可视化界面调用在线推理服务，实现对病历质量问题的自动化检测。

实验结果表明，与其他开源大语言模型相比，所构建的医疗大模型在医学专业能力和病历分析能力方面表现突出。在公开医学测评集的性能对比中，该模型相较于基座模型，在多类别的医学选择题准确率上提升了 7.4%，在复杂病历处理任务中的得分提升了 2.9%。引入基于知识图谱检索增强的病案质检方法后，在真实病历测试集的性能对比中，模型在病案质检任务中的综合能力得分提升了 3.5%。综上所述，提出的方法有效提升了大语言模型在病案质检任务中的表现。

关键词： 大语言模型；病案质检；指令微调；检索增强生成；知识图谱

Abstract

As the primary carrier of medical information, Electronic Health Records (EHRs) play a crucial role in hospital quality management. Traditionally, quality control of medical records relies heavily on manual end-point reviews, which are labor-intensive and inefficient. In recent years, with the breakthroughs of large language models (LLMs) in natural language processing, medical record quality control has been gradually transitioning toward intelligent automation. However, existing open-source LLMs lack sufficient adaptation to the medical domain, making it difficult for them to accurately understand and analyze medical issues. Moreover, challenges such as outdated medical knowledge and hallucination generation persist. Therefore, research on quality control solutions for medical records based on retrieval-augmented LLMs is of great significance for enhancing the level of healthcare quality management.

To address these issues, this study proposes a retrieval-augmented LLM-based approach for medical record quality control. The main contributions are as follows:(1) A method for constructing medical-domain LLMs tailored to EHR quality control tasks is proposed, effectively overcoming the limitations of general-domain LLMs in this context. This approach involves building instruction-tuning datasets for various medical tasks and stages, fully activating the model's fundamental medical knowledge and its capability to analyze complex records. On this basis, a domain-specific LLM is developed, characterized by rich and accurate medical knowledge and strong performance in complex EHR analysis tasks.(2) A knowledge graph-based retrieval-augmented method for EHR quality control is introduced to alleviate issues such as outdated knowledge, hallucinations, and insufficient knowledge relevance in practical applications. This method constructs an external knowledge base to provide reliable medical information, and utilizes entity-relation mining based on knowledge graphs to enhance the relevance between retrieved knowledge and user input.(3) A quality control system for EHRs is implemented, integrating LLMs and retrieval-augmented generation techniques. The system supports uploading EHR data and provides an interactive visualization interface for automated quality issue detection via online inference services.

Experimental results show that compared to other open-source LLMs, the proposed

medical model demonstrates outstanding performance in both medical expertise and EHR analysis capabilities. On public medical evaluation datasets, the model achieved a 7.4% improvement in accuracy on multi-category medical multiple-choice questions and a 2.9% score increase in complex EHR processing tasks compared to the base model. After introducing the knowledge graph-based retrieval-augmented quality control framework, the model's overall performance on real-world EHR test sets improved by 3.5%. In summary, the proposed approach significantly enhances the performance of LLMs in EHR quality control tasks.

Key words: Large Language Model, Medical Record Quality Control, Instruction Fine-Tuning, Retrieval-Augmented Generation, Knowledge Graph

目 录

1 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.3 研究工作内容.....	6
2 相关技术介绍	7
2.1 Transformer 架构.....	7
2.2 大语言模型训练流程.....	10
2.3 参数高效微调.....	13
2.4 检索增强生成.....	16
2.5 知识图谱.....	19
2.6 本章小结.....	20
3 面向病案质检任务的医疗大模型构建方法	21
3.1 大语言模型病案质检适配问题分析	21
3.2 医疗大模型构建方法整体框架	22
3.3 指令数据集构建策略.....	23
3.4 数据预处理.....	25
3.5 指令微调策略.....	28
3.6 本章小结.....	31
4 基于知识图谱检索增强的病案质检方法	32
4.1 医疗大模型应用问题分析	32
4.2 病案质检方法整体框架.....	33
4.3 知识库构建策略.....	35
4.4 知识图谱构建策略.....	38
4.5 知识融合策略.....	43
4.6 本章小结.....	45
5 实验结果与分析	46
5.1 指令微调实验结果与分析	46
5.2 检索增强实验结果与分析	50
5.3 系统展示.....	54
5.4 本章小结.....	60
6 总结与展望.....	61
6.1 总结.....	61
6.2 展望.....	62
参考文献.....	63

1 绪论

1.1 研究背景与意义

随着我国医疗卫生事业的迅速发展,人民群众的健康意识不断提高,医疗诊疗和护理服务需求日益增加,这对医院的医疗质量管理提出了更高的要求^[1]。病案质检作为规范医疗服务行为、保障医疗安全的重要手段,通过对患者住院期间形成的病历文书进行系统化的质量评估,为医院整体医疗水平的持续提升提供了有力支持^[2]。

当前医疗环境下,病案质检面临着诸多挑战。首先,传统的病案质量检查主要依赖于终末病案检查,以人工抽查为主,存在质控覆盖面窄、时效性不足、效率低下以及质控标准不统一等一系列问题^[3]。其次,由于出院病案数量庞大,传统的人工质控方式只能采取抽检的形式,这导致质控覆盖面狭窄,难以保证质控结果一致性,还大幅增加了人工成本。此外,随着医疗数据的不断积累,电子病历已成为医疗信息的主要载体,全面记录了患者从入院到出院的疾病发生、发展和转归的全过程,为医疗管理和临床研究提供了宝贵的信息资源^[4]。然而,由于实际工作中电子病历数据常存在错误、无效、不完整、不一致、异构等问题^[5],严重影响了其在医疗管理和临床科研中的二次利用和深度挖掘。

近年来,信息技术和医疗科学的快速发展为解决上述问题带来了新的契机。特别是自然语言处理(Natural Language Processing, NLP)技术的进步,使得对自由文本进行结构化处理成为可能^[6]。医学自然语言处理进一步将这一技术应用于医学领域,能够从病历文本中提取结构化数据并结合机器学习、知识图谱等技术训练医学语义理解模型^[7,8]。这些技术的发展为人工智能病历质控系统的应用奠定了坚实的基础,使其在医院管理工作中展现出广阔的应用前景。

在此背景下,大语言模型(Large Language Model, LLM)作为一项新兴的人工智能技术,凭借其强大的语言理解和生成能力在自然语言处理领域取得了显著成就。大语言模型通常由数十亿至数千亿参数构成,采用自监督或半监督的学习方法在海量未标注文本语料上进行预训练,因而能够深入挖掘语言的内在规律,并将所学知识迁

移应用于多种下游任务。随着模型规模的不断扩展，其在阅读理解、对话交互、文本生成等任务上的表现持续提升^[9]，并在多项自然语言处理任务中取得了卓越成效。

与此同时，大语言模型已在医疗健康领域展现出广阔的应用前景^[10]。相关研究表明^[11]，GPT-4 不仅在常规自然语言处理任务中展现出卓越性能，在专业领域和各类标准化学术测评中也表现出接近人类的水平。例如，GPT-4 在美国医学执照考试（USMLE）中取得了 90.7% 的整体正确率，在医学图像解析等任务中的表现也已超越 ABOSS 平台上 70% 的医学生^[12]。尽管如此，将通用大语言模型有效迁移至医学领域仍面临诸多挑战。一方面，通用大模型的训练语料主要来源于互联网，缺乏针对医学语言体系和专业医学知识的系统训练；另一方面，医学场景复杂多变，往往涉及长上下文理解、推理及领域知识融合生成等一系列关键技术问题^[13]。

1.2 国内外研究现状

1.2.1 医疗大模型

近年来，国内外学者在医学大模型领域取得了诸多突破，基于大语言模型的各类应用不断涌现，为提升医疗服务的智能化水平和临床决策支持能力提供了新的技术路径。

在中文医疗大模型的研究领域，已有诸多成果取得了显著进展。例如，本草大模型^①借助中文医学知识图谱 CMeKG^②构建医学指令微调数据集，并联合 GPT-3.5 对多个基础模型进行指令微调，显著提升了模型在医疗问答任务中的效果表现^[14,15]。QizhenGPT^③则采用模板的方式，基于知识图谱构建指令问答数据，并分别在 Chinese-LLaMA-Plus-7B、ChatGLM-6B、CaMA-13B 等模型上进行精调，同时邀请专业医学人员评估模型回答的准确性。华佗大语言模型^[16]在训练过程中融合了来自 ChatGPT 的精炼样本与真实临床数据，并引入强化学习策略以优化其在医疗应用场景下的能力。神农大模型^④作为首个聚焦中医药领域的语言模型，基于 LLaMA 架构，在

① <https://github.com/SCIR-HI/Huatuo-Llama-Med-Chinese>

② https://github.com/king-yyf/CMeKG_tools

③ <https://github.com/CMKRG/QiZhenGPT>

④ <https://github.com/michael-wzhu/ShenNong-TCM-LLM>

ChatGPT 的协助下,利用中医药知识图谱生成指令数据,并结合实体驱动的指令设计与低秩适配微调(low-rank adaptation, Lora)技术,提升了模型对中医知识问答的适应性与准确性。扁鹊大模型^①围绕主动性、预防性、精准性、个性化、共建共享和自律性六大健康理念,利用千万级中文健康对话数据进行指令微调,推动了其在慢性病管理和心理咨询等多个子领域的实际应用^[17]。孙思邈大模型^②则整合了来自教材、期刊、多科室临床数据、问诊对话及病历分析等多元医学信息,借助 GPT-4 自动生成训练语料,力图打造一个安全可靠、覆盖面广、以中医为核心的智能医疗系统。张仲景大模型^③构建了涵盖预训练、监督微调、强化学习及人类反馈的完整训练流程,其在部分真实医患交流任务中展现出近似专业医生的对话水平^[18]。此外,由中国医学科学院医学信息研究所与清华大学 OpenDE 团队联合开发的 AiMed^④大模型,凭借出色的语义理解和信息检索能力,为医学科研人员提供高效的知识问答、文献获取与文献阅读支持^[19]。此外,中国医学科学院基础医学研究所将复杂医疗场景拆分为多个特定的“小世界”,构建了全景数据采集-知识精炼-算法增强的“小世界增强”技术框架,并研发了兼具高专业度和共情支持的导诊大模型,成功推向临床试验,获得高级别的循证医学支持证据^[20]。

在国际研究方面,斯坦福大学与 DataBricks 研究团队合作推出了 BioMedLM^⑤,这是一种专门针对生物医学文本设计的预训练语言模型。该模型在生物医学专业术语和概念的语义理解方面具有突出表现,其应用效果在命名实体识别、关联关系挖掘、学术文献检索以及智能问答系统等多个下游任务中得到验证^[21]。微软研究院开发的 BioGPT^⑥是面向生物医学领域的生成式预训练模型,基于 Transformer 架构构建,在医疗咨询应答和科研文献自动摘要生成等应用场景中展现出卓越性能^[22]。Google 研发的 Med-PaLM^⑦以 PaLM 为基础架构,经过领域适应性训练后,在医学问答系统和临床辅助决策支持方面的表现已达到接近专业医师的水平^[23]。此外,在生物医学

① <https://github.com/scutcyr/BianQue>

② <https://github.com/X-D-Lab/Sunsimiao>

③ <https://github.com/pariskang/CMLM-ZhongJing>

④ <https://github.com/dujh22/AiMed>

⑤ <https://huggingface.co/stanford-crfm/BioMedLM/tree/main>

⑥ <https://github.com/microsoft/BioGPT>

⑦ <https://github.com/kyegomez/Med-PaLM>

等专业领域，由于存在海量未标注文本数据，从头进行预训练得到的大语言模型效果优于对通用语言模型进行持续微调的方法。PubMedBERT^①基于此观点提出了针对生物医学领域的语言理解评估体系，为领域专用预训练提供了基准^[24]。佛罗里达大学开发的 GatorTron^②模型利用电子健康记录中的超过 900 亿词汇训练数据，构建了包含 89 亿参数的超大规模临床语言模型。实验表明，该模型在五项临床自然语言处理任务中的表现均取得了显著提升，特别是在医疗咨询问答和医学术语关系抽取等方面表现突出^[25]。在结合知识增强方面，ChatDoctor^[26]和 DoctorGLM^[27]在指令微调的基础上进一步融合了外部知识检索机制。它们通过实时检索医学知识库中的相关信息作为补充上下文，不仅显著提升了回答的专业性和准确性，还有效抑制了大语言模型可能产生的幻觉现象，使系统能够更精准地理解患者诉求并提供专业医疗建议。Veen 等^[28]的研究进一步表明，经过参数高效微调的大语言模型在临床文本摘要任务中表现优于部分医疗专家，显示出其在改善临床工作流程、减轻医务人员文档负担方面的潜力。

尽管当前医疗大模型在医学问答等任务中已取得显著进展，其内容融合了大量专业医学术语与复杂的时序信息，语义结构更为严谨。要将大语言模型应用于病案质检任务，仍面临诸多挑战。病历记录往往以患者入院、检查、诊断、治疗到出院等流程为线索，信息前后关联密切，错误往往隐含在跨段落、跨模块的信息不一致中，将通用的医疗对话大模型直接应用于病案质控任务，难以充分理解病历中的时序关系与医学逻辑。基于此，如何在现有开源大语言模型的基础上，深入挖掘病历文本的结构特点，提升模型对医学知识的深度建模与临床事件的时序理解能力，成为推动智能化病案质控发展的关键所在。

1.2.2 电子病历质量控制研究

在国际医疗信息化的进程中，病历质量控制的专项研究相对有限，但其重要意义与日俱增。国外发达国家的电子病历质控系统通过优化传统医疗服务模式，有效解决

① <https://huggingface.co/microsoft/BiomedNLP-BiomedBERT-base-uncased-abstract-fulltext>

② <https://github.com/uf-hobi-informatics-lab/GatorTron>

了传统医疗中的诸多问题，为患者提供了更加安全、高效、及时、经济且公平的医疗服务^[29]。这些系统能够有效存储患者的历史诊疗信息，帮助医护人员全面了解患者病史，从而提高诊疗效率和医疗决策质量^[30]。此外，许多国家在电子病历系统中嵌入了智能质量监控模块，实现了对病历记录全过程的动态监控与评估。例如，美国国家卫生信息技术协调办公室(ONC^①)推动电子病历系统集成临床决策支持系统(CDSS)、药物相互作用与过敏预警模块、患者身份验证等功能，有效提升了医疗服务质量与患者安全水平。

目前，我国电子病历质控系统的市场规模十分可观。电子病历评级标准的逐步完善以及大数据和人工智能技术的发展，进一步推动了电子病历应用的研究。依据《电子病历系统应用水平分级评价管理办法（试行）及评价标准（试行）》的要求，国家对电子病历应用的评级分为九级，其中零到三级仅具备基础的搜索和查询功能，而四级及以上则需要支持医疗决策^[31]。然而，我国电子病历质控系统的普及率和智能化水平相较于发达国家仍有差距。针对这一问题，刘晓东等^[32]提出，应改进现有的电子病历质控内容与流程，通过逻辑判断规范医学术语的使用，并确保病历项目的完整性，从而提升病历的整体合格率。吴文健等^[33]则结合当前电子病历质控的现状与智能化质量管理的关键点，详细分析了质控中存在的问题与挑战，并建议借助人工智能技术进一步提升电子病历的质量。沈鑫^[34]、吴骋^[35]和刘祉呈^[36]等也提出了利用机器学习方法对电子病历进行质量控制，可以有效识别和纠正病历中的错误与不规范现象。此外，郝安琪^[37]等提出基于自然语言处理技术构建高度结构化的病历数据库，并借助病历质控引擎实现对病历文书的内涵质控，从而达到电子病历全覆盖、全自动、全过程质控的目标。

尽管国内外在电子病历质量控制领域已取得了一定的进展，现有系统仍主要依赖于规则驱动方法或基于传统机器学习的技术路径。这类方法通常依赖人工预设的规则库或提取有限的统计特征，虽在结构化数据的校验中具有一定成效，但在处理实际临床环境中大量存在的非结构化自由文本时，表现出明显的局限性。具体而言，这

① <https://www.healthit.gov/playbook/quality-and-patient-safety/>

类方法难以识别潜藏于文本中的隐性错误，如术语误用、信息矛盾或医学因果冲突等问题，也难以全面理解病历叙述中所蕴含的复杂语义关系与时序逻辑。由于缺乏对病历自由文本内容的深入语义建模与上下文分析能力，系统在面对表达方式多样、主观性强、上下文依赖性大的文本时，往往难以及时发现潜在的重要质量问题。

1.3 研究工作内容

以面向病案质检任务的医疗大模型为主要研究对象，开展基于检索增强大语言模型的病案质检方法研究，主要研究内容包括如下三个方面：

（1）提出了一个面向病案质检任务的医疗大模型构建方法，有效解决了通用领域大语言模型在病案质检任务中适配不足的问题。该方法通过构建面向多种医学任务、多阶段的指令微调数据集，全面激发大语言模型的基础医学能力和复杂病历分析能力，并在此基础上构建了具备丰富且准确医学知识、在复杂病历数据处理任务中表现出色的医疗大模型。通过在公开医学测试集上开展详细实验，验证了该方法的有效性。

（2）提出了基于知识图谱检索增强的病案质检方法，有效缓解了大语言模型在实际应用中存在的知识更新滞后、幻觉生成以及知识相关性不足等问题。该方法通过引入外部医学知识库，为模型提供权威、可靠的专业知识，从而缓解模型幻觉问题。同时，知识库易于更新的特点，也有效解决了大语言模型知识更新滞后的问题。此外，基于该知识库构建的知识图谱，通过挖掘实体与实体之间的多层次关系，提升了检索结果与用户输入的相关性，从而优化模型的整体表现。通过在真实电子病历数据集上开展详细实验，验证了该方法的有效性。

（3）实现了一个基于大语言模型和检索增强生成技术的病案质量检测系统。该系统支持用户上传病历数据，并通过可视化界面调用在线推理服务，实现对病历质量问题的自动化检测。同时，系统引入反馈机制，持续收集用户偏好，为后续模型优化提供数据支持，为大模型在医疗领域的应用探索了新的方向。

2 相关技术介绍

本章介绍了大语言模型在面向病案质检任务进行适配时涉及到的技术理论，包括 Transformer 架构、大语言模型训练流程、参数高效微调方法、检索增强生成和知识图谱，为后续研究工作奠定了理论基础。

2.1 Transformer 架构

Transformer^[38]是由多层的多头自注意力（Multi-head Self-attention）模块堆叠而成的神经网络模型。原始的 Transformer 模型如图 2-1 所示，由编码器和解码器两个部分构成，且这两个部分可以独立使用，例如基于编码器架构的 BERT^[39]模型和解码器架构的 GPT^[40]模型。




图 2-1 Transformer 架构^[38]

2.1.1 输入层

在 Transformer 模型中，输入的词元序列首先经过一个输入嵌入模块转化成词向

量序列。具体来说，为了捕获词汇本身的语义信息，每个词元在输入嵌入模块中被映射成为一个可学习的、具有固定维度的词向量。由于 Transformer 的编码器结构本身无法识别序列中元素的顺序，因此引入位置编码（Position Embedding, PE）来表示序列中的位置信息。给定一个词元，位置编码根据其在输入中的绝对位置分配一个固定长度的嵌入向量。然后，将每个词元对应的词向量和位置向量相加，生成了最终的输入嵌入序列，并且被传入到后续层中。Transformer 的位置编码通过以下公式计算得到：

$$PE_{(pos,2i)} = \sin\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}}\right) \quad (2-1)$$

$$PE_{(pos,2i+1)} = \sin\left(\frac{pos}{10000^{\frac{2i+1}{d_{model}}}}\right) \quad (2-2)$$

其中，pos 代表单词在句子中的位置， d_{model} 表示位置编码的维度（和词向量相同）， $2i$ 表示偶数维度， $2i+1$ 表示奇数维度。

2.1.2 多头自注意力机制

多头自注意力是 Transformer 模型的核心创新技术。能够直接建模任意距离的词元之间的交互关系。多头自注意力机制通常由多个自注意力模块组成。自注意力模块接收词元序列作为输入，并将其分别转换为查询（Query）、键（Key）和值（Value）矩阵，以支持后续的注意力权重计算过程。然后，对于每个查询，将和所有没有被掩盖的键之间计算点积。这些点积值进一步除以 $\sqrt{d_k}$ 进行缩放（ d_k 是键对应的向量维度），被传入到 softmax 函数中用于权重的计算。进一步，这些权重将作用于与键相关联的值，通过加权求和的形式计算得到最终的输出。上述过程可以用如下公式表示：

$$Q = XW^Q \quad (2-3)$$

$$K = XW^K \quad (2-4)$$

$$V = XW^V \quad (2-5)$$

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-6)$$

与单头注意力相比，多头注意力机制的主要区别在于它使用了 h 组结构相同但映射参数不同的自注意力模块。输入序列首先通过不同的权重矩阵被映射为一组查询、键和值。每组查询、键和值的映射构成一个“头”，并独立地计算自注意力的输出。最后，不同头的输出被拼接在一起，并通过一个权重矩阵进行映射，产生最终的输出。数学公式如下：

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h)W^O \quad (2-7)$$

$$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \quad (2-8)$$

其中参数矩阵 $W_i^Q \in \mathbb{R}^{d_{model} \times d_k}$, $W_i^K \in \mathbb{R}^{d_{model} \times d_k}$, $W_i^V \in \mathbb{R}^{d_{model} \times d_v}$ 以及 $W^O \in \mathbb{R}^{hd_v \times d_{model}}$ 。

在 Transformer 中，多头注意力机制采用的是 $h = 8$ 层自注意力层，对于每一层使用 $d_k = d_v = d_{model}/h = 64$ ，以保证最后的输出维度为 512。

2.1.3 前馈网络层

为了学习复杂的函数关系和特征，Transformer 模型引入了一个前馈网络层(Feed-Forward Netwok, FFN)，对于每个位置的隐藏状态进行非线性变换和特征提取。具体来说，给定输入 x ，Transformer 中的前馈神经网络由两个线性变换和一个非线性激活函数 ReLU 组成：

$$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2 \quad (2-9)$$

通过在前馈网络中使用激活函数实现非线性映射，模型的表示能力得以增强，从而更好地捕获复杂的交互关系。

2.1.4 编码器

在 Transformer 模型中，编码器(Encoder)的主要功能是将每个输入词元转换为包含上下文语义信息的表示向量。整个编码器由六个结构一致的层级堆叠构成，每一层包含两个主要子模块：其一为多头自注意力机制，其二为前馈全连接网络。为增强模型训练过程的稳定性，在每个子模块之后均引入了残差连接与层归一化机制。残差连接通过将子层的输入与其输出相加，形成跨层的信息通路，有效缓解了梯度爆炸和梯度消失等问题，从而促进了深层网络的高效训练。而层归一化则对数据进行重新放

缩，提升模型的训练稳定性。其数学表示为，若子层的输入为 x ，子层内部的实现函数为 $Sublayer(x)$ ，那么每个子层的输出为 $LayerNorm(x + Sublayer(x))$ 。

2.1.5 解码器

Transformer 中的解码器结构与编码器类似，均由六个结构相同的层组成，其区别于编码器之处在于每层包含三个子层。第一层是掩码多头注意力机制（Masked Multi-Head Attention），用来在计算注意力分数的时候掩盖当前位置之后的词，以保证生成目标序列时不依赖于未来的信息。第二层和第三层分别为多头注意力机制与前馈全连接网络，与编码器中的结构一致。与编码器类似，在每个模块之后，Transformer 解码器也采用了层归一化和残差连接。

2.2 大语言模型训练流程

大语言模型是指在海量无标注文本数据上进行预训练得到的大型预训练语言模型，是一种基于 Transformer 结构的神经网络模型。与传统的机器学习模型相比，大语言模型具有更大规模的参数，且构建过程涉及更为复杂的训练方法，进而展现出了强大的自然语言理解能力和复杂任务求解能力，一般来说，这个训练过程可以分为大规模预训练、指令微调和人类偏好对齐三个阶段。

2.2.1 预训练

预训练是指使用无标签的大规模文本数据来训练语言模型，数据通常与下游任务无关，模型会根据输入的文本序列来预测下一个词的概率分布，然后使用预测的结果来计算损失函数，通过反向传播算法来更新模型参数。通过这一过程，模型能够逐步学习并理解语言的结构、语法及其所承载的语义信息。为了预训练大语言模型，需要准备大规模的文本数据，并且进行严格的清洗，去除掉可能包含有毒有害的内容，最后将清洗后的数据进行词元化（Tokenization），并且切分成批次，用于大语言模型的预训练。由于大语言模型的能力基础主要来源于预训练数据，因此数据的收集与清洗对于模型性能具有重要的影响，收集高质量、多源化的数据以及对于数据进行严格的清洗是构建大语言模型关键能力的重中之重。预训练这一过程对于算力需求量极

高，一般来说训练百亿模型至少需要百卡规模的算力集群（如 A100-80G）联合训练数月时间，而训练千亿模型则需要千卡甚至万卡规模的算力集群。

2.2.2 指令微调

经过大规模数据预训练后的语言模型已经具备较强的模型能力，能够编码丰富的世界知识，但是由于预训练任务形式所限，通用的大语言模型能够在传统自然语言处理任务（如生成和推理）以及日常生活任务（如头脑风暴）上取得较好的效果，然而它们在特定领域中（如医学、法律和金融等）的表现与领域专用模型的效果仍有一定差距。因此，当预训练结束后，通常需要对于大语言模型进行微调与对齐，使之更好地被用于任务求解。

目前来说，比较广泛使用的微调技术是“指令微调”（也称为有监督微调，Supervised Fine-tuning, SFT），语言模型的指令微调（Instruction Tuning）是一种用于微调预训练语言模型以适应特定任务的方法，通过使用任务输入与输出的配对数据进行训练，模型会根据有标签数据的损失函数进行参数的更新，可以使得语言模型较好地掌握通过问答形式进行特定任务求解的能力。一般来说，指令微调很难教会大语言模型预训练阶段没有学习到的知识与能力，它主要起到了对于模型能力的激发作用，而不是知识注入作用。指令微调使大语言模型显著提高了遵循指令的能力，进而具备了在零样本学习条件下解决多类下游任务的潜力。与预训练相比，指令微调通常来说需要的指令实例数据规模要小的多，对于算力资源的需求也更小。相关研究表明，不同规模的语言模型（参数量规模从 77M 到 540B）都可以从指令微调中受益^[41,42]，提升的性能随着参数规模的增加而提升^[43]。此外，经过指令微调的小模型甚至可以比没有经过微调的大模型表现得更出色，进一步凸显了指令微调的有效性^[41,44]。

2.2.3 人类偏好对齐

经过大规模的预训练和指令微调，大语言模型具备了解决各种任务的通用能力和指令遵循能力，但是同时也可能生成有偏见的或事实错误的文本内容。这些潜在的有害行为，可能在下游应用中产生严重的影响与危害。因此，除了提升任务的解决能力外，还需要将大语言模型与人类的期望、需求以及价值观对齐，这对于大模型的部

署与应用具有重要的意义。OpenAI 在 2022 年初发布了 InstructGPT^[45]的学术论文，系统地介绍了如何将语言模型进行人类对齐。具体来说，主要引入了基于人类反馈的强化学习对齐方法 RLHF（Reinforcement Learning from Human Feedback），在指令微调后使用强化学习加强模型的对齐能力。




图 2-2 基于人类反馈的强化学习工作流程^[46]

RLHF 的整体训练框架主要分为监督微调、奖励模型训练和强化学习三个阶段，如图 2-2 所示。具体来说，首先语言模型需要先通过监督微调获得较好的指令遵循能力。随后，使用语言模型针对任务指令生成一定数量的候选输出，并人工对输出文本进行偏好标注。进一步，使用人工标注的偏好数据进行奖励模型的训练，使其能够建模人类偏好。而在最后的强化学习阶段中，待对齐语言模型担任策略实施者的角色，接收提示并生成文本，其动作空间由整个词汇表构成，状态则为已生成的词元序列。奖励模型则根据当前语言模型的状态提供相应的奖励分数，用于指导策略模型的优化。为了避免当前训练轮次的语言模型明显偏离初始的语言模型，通常会在原始优化目标中加入一个惩罚项（如 KL 散度）。例如，InstructGPT 使用近端策略优化（Proximal Policy Optimization, PPO）算法^[47]来优化待对齐语言模型以最大化奖励模型的奖励。对于每个输入提示，InstructGPT 计算当前语言模型与初始语言模型生成结果之间的 KL 散度作为惩罚项。KL 散度越大，意味着当前语言模型越偏离初始语言模型。这个对齐过程可以进行多次迭代，从而更好地对齐大语言模型。

此外，尽管 RLHF 已被证明是一种较为有效的语言模型对齐技术，但也存在着一些局限性，如需要同时维护和更新多个模型，导致占用大量内存资源等。为了克服

这些问题，学术界的研究人员提出了一系列直接基于监督微调的对齐方法。直接偏好优化（Direct Preference Optimization, DPO）算法^[48]是其中一种具有代表性的监督对齐算法，DPO 可以通过与有监督微调相似的复杂度实现模型对齐，不再需要在训练过程中针对大语言模型进行采样，同时超参数的选择更加容易。

2.3 参数高效微调

参数高效微调（Parameter-efficient Fine-tuning）旨在在大幅度降低微调参数规模的前提下，仍能使模型在下游任务中的表现接近于传统的全量微调，以解决全参数微调时消耗算力资源较大的问题。

2.3.1 低秩适配微调方法

大语言模型中包含大量的线性变换层，其中参数矩阵的维度通常很高。研究人员发现模型在针对特定任务进行适配时，参数矩阵往往是过参数化的，其存在一个较低的内在秩。为了解决这一问题，低秩适配（Low-Rank Adaptation, LoRA）^[49]微调方法通过在预训练权重矩阵中引入低秩分解矩阵，以近似各层参数更新，从而在保证性能的前提下显著减少下游任务的可训练参数，如图 2-3 所示。给定一个参数矩阵 W ，其更新过程可以一般性地表达为以下形式：

$$W = W_0 + \Delta W \quad (2-10)$$

其中， W_0 是原始参数矩阵， ΔW 是更新的梯度矩阵。LoRA 的基本思想是冻结原始矩阵 $W_0 \in \mathbb{R}^{H \times H}$ ，通过低秩分解矩阵 $A \in \mathbb{R}^{H \times R}$ 和 $B \in \mathbb{R}^{R \times H}$ 来近似参数更新矩阵 $\Delta W = A \cdot B^T$ ，其中 R 远小于 H 是减小后的秩。在微调期间，原始的矩阵参数 W_0 不会被更新，低秩分解矩阵 A 和 B 则是可训练参数用于适配下游任务。在前向传播过程中，原始计算中间状态 $h = W_0 \cdot x$ 的公式修改为：

$$h = W_0 \cdot x + A \cdot B^T \cdot x \quad (2-11)$$

训练结束后，将原始参数矩阵 W_0 和训练得到的权重 A 和 B 进一步进行合并： $W = W_0 + A \cdot B^T$ 得到更新后的参数矩阵。因此，LoRA 微调得到的模型在解码过程中不会增加额外的开销。




图 2-3 LoRA 示意图^[49]

在原始的 LoRA 实现中，每个低秩矩阵的低秩参数 R 都被设置为固定且相同的数值，并且在训练过程中无法进行调整，这种设定忽略了不同的秩在微调任务中可能产生的差异化影响。因此，通过这种方式训练得到的低秩矩阵往往并非最优解。AdaLoRA^[50]讨论了如何更好地进行秩的设置。它引入了一种动态低秩适应技术，在训练过程中动态调整每个参数矩阵需要训练的秩同时控制训练的参数总量。具体来说，模型在微调过程中通过损失来衡量每个参数矩阵对训练结果的重要性，重要性较高的参数矩阵被赋予比较高的秩，进而能够更好地学习到有助于任务的信息。相对而言，不太重要的参数矩阵被赋予比较低的秩，来防止过拟合并节省计算资源。

QLoRA^[51]将原始的参数矩阵量化为 4 比特，而低秩参数部分仍使用 16 比特进行训练，在保持微调效果的同时进一步节省了显存开销。

2.3.2 适配器微调

适配器微调 (Adapter Tuning)^[52]通过在 Transformer 架构中嵌入小型神经网络模块（即适配器）来实现参数高效微调。为构建这些模块，研究者采用了瓶颈式网络设计：先将输入特征向量降维，再通过激活函数进行非线性映射，最后再将其投射回原始维度。形式化地，可以通过以下公式进行表达：

$$\hat{h} = h + \sigma(h \cdot W^d) \cdot W^u \quad (2-12)$$

其中 $W^d \in \mathbb{R}^{H \times R}$ ， $W^u \in \mathbb{R}^{R \times H}$ ，且 R 远小于 H 。通常来说，适配器模块将会被集成到 Transformer 架构的每一层中，使用串行的方式分别插入在多头注意力层和前馈网

络层之后、层归一化之前，如图 2-4 所示。微调时，适配器模块会依据具体任务需求进行更新，而原始语言模型的参数则不会发生变化。通过这种方式，可以在微调过程中有效减少需要训练参数的数量。




图 2-4 Adapter Tuning 示意图^[52]

2.3.3 前缀微调

受到 Prompt 思想的启发，前缀微调（Prefix Tuning）^[53]提出在语言模型的每个多头注意力层中都添加一组前缀参数。这些前缀参数组成了一个可训练的连续矩阵，可以视为为每个输入增加一组连续的、与任务相关的嵌入向量（continuous task-specific embedding vectors），它们会根据特定任务进行学习，如图 2-5 所示，训练时只训练连续嵌入向量。




图 2-5 Prefix Tuning 示意图^[53]

2.3.4 提示微调

与前缀微调不同，提示微调仅在输入嵌入层中加入可训练的提示向量。在离散提示方法的基础上，提示微调首先在输入文本端插入一组连续嵌入数值的提示词元，这些提示词元可以增强输入文本，用于解决特定的下游任务。在具体实现中，只需要将可学习的特定任务提示向量与输入文本向量结合起来一起输入到语言模型中。Prompt Tuning^[54]以前缀形式添加提示，直接在输入前拼接连续型向量。在提示微调的训练过程中，只有提示的嵌入向量会根据特定任务进行监督学习。P-tuning^[55]提出了使用自由形式来组合输入文本和提示向量，通过双向 LSTM 来学习软提示词元的表示，它可以同时适用于自然语言理解和生成任务。P-tuning v2^[56]与 P-tuning 的不同之处在于将只在第一层嵌入加入提示向量修改为在许多层都插入提示向量，层与层质检的提示向量是相互独立的。图 2-6 展示了提示微调算法的示意图。




图 2-6 提示微调示意图

2.4 检索增强生成

检索增强生成（Retrieval-Augmented Generation, RAG）^[57]是一种融合了信息检索与生成模型的技术，旨在通过引入外部知识库中的相关内容，为大语言模型提供补充信息，从而生成更准确且上下文相关性更强的回答。这使得 RAG 既具有灵活性又易于扩展，便于在不同模型中实现多种用途的应用。此外，RAG 检索到的信息来源于现实世界，由人类编撰，这不仅简化了生成过程，还提升了生成答案的可靠性。

2.4.1 RAG 工作流程

RAG 的基础工作流程始于创建一个包含外部资源的索引。该索引是基于特定查询通过检索模型检索相关信息的基础。最终步骤涉及一个生成模型，它结合检索到的信息和查询内容，以产生期望的输出。RAG 框架的基本工作流程包含索引建立、信息检索和文本生成三个阶段，如图 2-7 所示。

索引建立：这一阶段包括文本标准化过程，如分词、词干提取和停用词的移除，以提高文本适合索引的程度。接着，文本段落会被组织成句子或段落，以便进行更有针对性的搜索，确保能够精确找到含有关键词的内容。深度学习技术的融入彻底革新了索引建立过程，通过预训练的语言模型生成文本的语义向量表示，这些向量存储后能够实现对海量数据集的快速精确检索，极大提升了检索效率。

信息检索：传统的信息检索方法，如 BM25 算法，主要依据术语的频率和出现来对文档进行排序，但往往忽略了查询的语义内容。现代策略则利用了如 BERT 这样的预训练语言模型，这些模型能够更有效地捕捉查询的语义内涵。它们通过考虑同义词和短语结构，提高搜索的精确度，进而通过语义相似性检测来优化文档的排序。这通常是通过计算文档和查询之间的向量距离来实现的，将传统的检索指标与语义理解相结合，以获得既相关又符合用户意图的搜索结果。

文本生成：生成阶段的任务是创造出既与查询相关又能反映检索文档信息的文本。常见的做法是将查询内容与检索到的信息结合起来，然后输入到一个大型语言模型中进行文本生成。生成的文本应准确传达检索文档的信息，与查询的意图保持一致，同时也应具有一定的灵活性，能够引入检索数据中未明确包含的新观点或视角。




图 2-7 RAG 框架基本工作流程^[58]

2.4.2 图检索增强生成

尽管 RAG 已取得显著成果并在多个领域得到广泛应用，但在实际场景中仍存在以下局限性：

（1）忽视实体间关系信息

在实际应用中，文本内容通常是相互关联、交织在一起的。然而，传统 RAG 方法仅依赖语义相似性来捕捉信息，难以识别和利用那些无法仅通过语义相似性表达的重要结构化关系知识。以论文引用网络为例，论文之间通过引用关系相互连接，而传统 RAG 方法往往侧重于根据查询定位相关论文，而忽略了论文之间潜在的重要引用联系。

（2）冗余信息

RAG 在以文本片段的形式拼接为提示时，常常出现内容重复的问题，导致生成的上下文信息过于冗长，从而引发“中间信息丢失”的困境。

（3）缺乏全局信息

由于 RAG 只能检索到部分文档，其在整体信息的把握上存在局限，难以全面捕捉全局信息，因此在诸如查询聚焦型摘要等任务上表现不佳。

图检索增强生成（Graph Retrieval-Augmented Generation, GraphRAG）^[59]是解决上述挑战的一项创新方法。与传统的 RAG 方法不同，GraphRAG 通过预先构建的图数据库，针对给定查询检索包含关系知识的图元素。GraphRAG 考虑了文本之间的相互关联，从而能够更准确、全面地检索关系信息。此外，图数据（如知识图谱）能够对文本数据进行抽象和概括，从而显著缩短输入文本的长度，缓解内容冗长的问题。通过检索子图或图社群，可以捕捉图结构中更广泛的上下文和内在联系，有效应对查询聚焦型摘要任务。GraphRAG 的工作流程主要分为以下三个步骤：

（1）图索引

图索引是 GraphRAG 的第一步，其核心在于构建并索引知识图谱。该阶段旨在建立高效的索引结构，以便后续能够迅速检索到相关信息。具体而言，首先通过从外部数据源提取结构化数据来构建知识图谱；随后，采用多种索引技术（如图索引、文本索引和向量索引）对图谱进行索引，以提高查询与检索效率。

（2）图检索

图检索阶段的目标是从知识图谱中提取与用户查询高度相关的信息片段。首先，将用户的查询转换为图谱能够理解的形式，这通常涉及自然语言处理技术，例如实体链接和查询扩展。接着，利用检索算法（包括基于规则和基于模型的方法）对知识图谱进行搜索，筛选出最符合查询需求的信息。

（3）图生成

图生成阶段侧重于利用检索到的信息生成准确、相关且富有意义的文本响应。首先，需要将图检索结果转换为大语言模型能够理解的格式，这通常借助图编码或图嵌入技术实现。随后，采用适当的文本生成算法（如基于语言模型或图神经网络的方法）生成最终响应，在生成过程中充分利用检索信息以提高文本的相关性与准确性。

2.5 知识图谱

知识图谱（Knowledge Graph）是一种用于组织和表示结构化知识的图形化数据模型，它通过图的形式将现实世界中的实体（如人物、地点、事件等）及其相互之间的关系（如属性、关联、联系等）进行直观表示。其核心目标是构建一个完整、准确且可扩展的知识库，以模拟人类对知识的组织方式，为机器提供可理解和可操作的知识表示，从而支持语义搜索、智能问答和推荐系统等多种智能应用。

知识图谱主要包括实体、属性、关系和语义表示四个部分。实体表示现实世界中的各种事物，如人物、地点和组织等。每个实体在知识图谱中都有一个唯一标识符，用于识别和检索。属性描述了实体的特征或性质，用于对不同实体之间的差异进行进一步区分。属性通常采用键值对的形式表示，其中键表示属性名称或类型，值表示属性的具体取值，如姓名、年龄或地理坐标等。关系表示实体之间的关联或联系，描述它们之间的语义关系或属性关系。关系通常以有向边或无向边的形式连接两个实体，例如“拥有”、“属于”、“位于”或“相关”等。语义表示是对实体、属性和关系的语义化描述，能够使得知识图谱具备语义丰富性和推理能力。语义表示通常基于本体、分类体系或语义标签，用于提升知识理解和表达的能力，以支持更智能化的知识管理和应用。

知识图谱在架构上可以分为逻辑架构和技术架构。其中，逻辑架构主要包括模式层和数据层两部分，数据层使用三元组（实体-关系-实体）的形式存储真实的数据，而模式层作为知识图谱的核心，用来储存知识图谱的数据结构，约束数据层的具体表现形式。

知识图谱的技术架构主要包括知识抽取、知识融合以及知识加工三个部分，如图 2-8 所示。其中，知识抽取是知识图谱的关键，包括实体抽取、关系抽取和属性抽取。实体抽取又被称为命名实体识别（Named Entity Recognition, NER），旨在对数据集中的各类实体进行自动化地识别。实体抽取质量的高低决定了知识图谱构建的效率和质量，是整个知识抽取体系中的关键和基础。关系抽取旨在通过从语料库中识别实体间的关联，构建实体之间的关系网络。属性抽取的任务则是从不同的数据源获取实体的具体特征信息，如药物的疗效、生产日期和副作用等。




图 2-8 知识图谱技术架构图

2.6 本章小结

本章主要介绍了大语言模型在面向病案质检任务进行适配时涉及到的技术理论。首先介绍了大语言模型的底层架构 Transformer 模型以及大语言模型的训练过程。其次介绍了几种大语言模型的参数高效微调方法和检索增强生成方法的基本工作流程以及图检索增强生成方法，最后介绍了知识图谱的相关理论知识。

3 面向病案质检任务的医疗大模型构建方法

面向通用领域大语言模型在病案质检任务中适配不足的问题，提出了面向病案质检任务的医疗大模型构建方法，为后续工作奠定了基础。该方法主要包括数据预处理、指令微调数据集的构建和模型训练三个阶段。本章将对开源大模型进行病案质检任务适配时所面临的相关问题进行详细分析，并依次介绍医疗大模型构建方法的整体框架、指令数据集的构建策略、数据预处理的具体流程以及模型训练阶段应用的指令微调策略。

3.1 大语言模型病案质检适配问题分析

大语言模型的迅速发展已对多个领域产生深远影响，其在医疗等众多领域的表现已接近人类水平。随着大语言模型在医疗领域的应用不断深入，它将成为诊疗辅助的关键工具，进而显著减轻医生的临床负担。然而，在将大语言模型应用于病案质检时仍面临诸多挑战，主要体现在以下两方面：

（1） 医疗领域适配的复杂性

医学领域的专业术语和语境理解对大语言模型提出了较高的要求。虽然通用领域的大语言模型在多个领域具备丰富的知识储备，但在高度专业化的医学领域，模型的针对性训练仍显不足。在临床场景中，医患交互数据具有高度专业化和多样化的特征，而这类真实交互语料在通用模型的预训练数据中往往很少覆盖，且医疗相关数据的比例偏低，这限制了模型对医学知识的理解深度与应用能力。

如何有效利用医学语料构建高质量的医学领域数据集，并将准确的医学知识有效注入大语言模型，以提升其在医学领域的专业知识，依然是一个亟待解决的难题。此外，在构建医疗垂直领域指令数据集后，如何通过指令微调优化模型性能（包括数据比例选择、超参数调整等技术细节）也需要进一步探索与实践。

（2） 复杂病历数据分析的挑战

尽管经过医学领域适配的大语言模型已经积累了大量医学知识，但由于临床医学应用的复杂性及其场景的多样性，仅作为医学知识库的语言模型仍难以完全满足

医学领域的实际任务需求。电子病历（Electronic Health Records, EHR）的质检工作主要分为形式质检与内涵质检两大方面，形式质检包含病历书写的完整性、时效性等要求，而内涵质检则侧重于书写规范性、前后一致性、诊疗合理性等要求。目前，许多质控工作仍依赖于预定义的质控规则，虽然这种方法简单直接，但在处理复杂病例或非标准化数据时存在明显局限性。在此背景下，如何充分发挥大语言模型的优势，将其与传统质控规则相结合，实现更精细、更智能的电子病历质量检测，成为一个值得深入探讨的重要方向。

3.2 医疗大模型构建方法整体框架

从上述问题分析出发，提出了一种基于开源大语言模型实现病案质检任务高效适配的方法，主要包括数据预处理、指令微调数据集的构建和模型训练三个阶段，整体技术框架如图 3-1 所示。




图 3-1 面向病案质检任务的医疗大模型构建方法技术框架

具体来说，分别收集了来自医院的电子病历数据以及公开的医学领域知识，作为

指令数据集的数据源，以增强模型的基础医学能力和复杂病历分析能力。在数据预处理阶段，主要针对两类数据进行相应处理，为后续指令数据集的构建奠定基础。指令数据集构建阶段的重点在于如何有效整合医学相关语料以及电子病历数据，并围绕医患对话、医学知识理解、复杂医学问题分析以及复杂病历分析四个维度，构建高质量的医学领域指令微调数据集。而在模型训练阶段，则聚焦于如何有效利用参数高效的指令微调方法，结合合适的训练策略，提升大语言模型在病案质检任务中的表现。

3.3 指令数据集构建策略

为全面提升大语言模型在医疗领域，尤其在病案质检任务中的应用能力，提出了一种面向多种医学任务、多阶段的指令微调数据集构建方案。该方案根据不同实际应用场景，制定具有针对性的指令数据，以更充分地激发模型在医学领域的专业潜力。第一阶段侧重于通过医患对话、医学知识问答与复杂医学任务三类数据，为模型提供系统而专业的医学知识；第二阶段则聚焦真实电子病历及其潜在错误信息，构建高质量的病案质检指令数据，进一步提升模型在病案质检场景下的分析与处理能力。图 3-2 展示了指令微调数据集构建策略整体框架。




图 3-2 指令微调数据集构建策略整体框架

阶段一：面向基础医学知识注入的数据集构建

为了提升模型处理病案质检任务时的表现，需要先增强模型的基础医学能力，作为模型在处理病案质检任务时的医学知识大脑。本文采用了以下三部分数据：

（1）医患对话数据

该部分数据来源于真实临床场景下的医患对话，包含丰富的医学专业知识以及医生分析和解决临床问题的思维过程。引入这些数据的目的是在为模型注入医学知识的同时，引导其学习医生在实际情境下的分析方法和问题解决策略，使模型能够根据患者相关信息，提供相应建议并检索医学知识。数据来源为 HuatuoGPT2 指令微调阶段的训练数据集 HuatuoGPT2-SFT^①，通过系统抽样的方式共抽取四万条数据。

（2）医学知识问答

医学知识图谱将分散的医学信息进行系统化整合，并以结构化的方式对疾病特征、药理作用等多维度知识进行有序组织。其构建数据源自临床指南、医学文献、电子病历及医疗数据库等多种渠道。医学知识图谱通过深度解析医学概念间的语义关联，构建出一个高度关联的知识网络，有效增强了医学实体间复杂关系的可解释性，并为疾病诊断、临床决策支持以及病案质检等医学任务提供了坚实的知识基础。为了进一步增强大模型的医学知识储备，采用了来自于医学知识库收集整理的真实医患知识问答数据，数据来源为 Qizhen^②，总样本数量共两万条。

（3）复杂医学任务

鉴于医学专业问题的复杂性和临床医学场景的多样性，单纯的医学知识注入难以满足大语言模型在实际医学领域中的应用需求。模型不仅需要具备丰富的医学知识，还应具备灵活理解和运用这些知识的能力。为此，进一步引入了基于复杂医学自然语言处理任务构建的指令微调数据集，重点提升大语言模型对多样化的复杂医学推理任务的分析和处理能力，从而增强其临床应用中的灵活性与决策合理性。数据集基于 PromptCBLUE^③中的训练数据构建，涵盖了医学文本信息抽取（实体识别、关系抽取、事件抽取）、医学术语标准化、医学文本分类、医学句子语义相关性判定和医

① <https://huggingface.co/datasets/ticoAg/HuatuoGPT2-SFT-GPT4-140K>

② <https://github.com/CMKRG/QiZhenGPT/blob/main/data/train/sft-20k.json>

③ <https://huggingface.co/datasets/Juvenilecris/CHIP2023-PromptCBLUE-peft>

学对话理解与生成五大类医疗信息处理任务，共涵盖十四个子任务，本文采用系统抽样的方式共选用一万条 PromptCBLUE 训练集中的数据。

阶段二：面向复杂病历分析能力强化的数据集构建

病历中不仅含有专业的医学知识，还蕴含着丰富的时序信息。为使大语言模型在病案质检场景中发挥更高效、更精准的作用，收集了来自真实世界的电子病历数据，数据涵盖某医院 2023 年 1 月至 2024 年 5 月期间的住院病历数据及其相关错误信息。将其转换为指令微调数据格式后共得到 63106 条数据，并通过进一步处理与高质量筛选，构建了高质量的病案质检数据集。该数据集旨在增强模型对复杂电子病历数据的分析与处理能力，进一步提升大语言模型在病案质检任务中的表现。

3.4 数据预处理

数据预处理环节是指令微调数据集构建的基础，直接关系到最终数据集的质量与有效性。在该阶段，主要对原始病历数据进行了格式转换、数据清洗以及敏感信息脱敏处理，并构建了一份高质量的病案质检数据集，作为指令微调数据集的重要组成部分。以下详细介绍病历数据集的具体处理流程。

3.4.1 数据格式转换

本文基于 LLaMA Factory 框架进行指令微调，该框架支持的指令微调数据样例格式如图 3-3 所示。其中，“instruction”列对应人类指令，“input”列对应人类输入，“output”列则为模型的回答。

```
{  
  "instruction": "请你作为一名医学领域专家，回答以下问题",  
  "input": "亚叶酸钙注射液的药物相互作用是？",  
  "output": "本品较大剂量与巴比妥、扑米酮或苯妥英钠同用，可影响抗癫痫作用。"  
},
```

图 3-3 LLaMA Factory 指令微调数据集样例

原始病案数据以表格形式保存，为满足大模型指令微调需求，需先将数据转化为框架支持的格式。接下来分别介绍 Instruction、Input 和 Output 三部分的处理流程，最终得到的数据格式示例如图 3-4 所示。

(1) Instruction（指令部分）

为适配病案质检任务，从模型角色定位、所需技能以及任务规则三个方面构建了提示词（prompt），作为指令数据中的指令部分。这一设计旨在明确模型的任务目标及执行标准。

Instruction

```
## 角色
- 作为一位专业的医疗记录质检专家，你的任务是对电子病历进行质量检查，确保所有必要的信息都被准确无误地记录下来。你需要具备对病历内容的深入理解，以及识别病历中潜在错误的能力，并给出专业的修改意见。

## 技能：
- 熟练掌握病历书写规范和标准。
- 具有专业的医疗知识储备。
- 能够准确地分析病历内容，找出其中可能存在的问题。
- 对于发现的问题，能够给出具体的定位、描述和修改建议。

## 规则：
- 输入的数据为包含多个病历记录的JSON数组，每个记录包括“病历名称”、“书写时间”和“病历内容”。
- 输出应为一个JSON数组，其中包含发现的错误的“错误字段”及“错误详情”。对于每个错误字段，需提供具体的错误实例位置和描述。对于无误的病历可以返回空数组。
- 错误类型可以包括但不限于：病历信息不一致、术语使用不当等。
- 在处理过程中，应注重保护患者隐私，避免泄露敏感信息。
```

Input

```
[
  {"病历名称": "入院记录", "书写时间": "2023/2/1 00:00:00", "病历内容": "..."},
  {"病历名称": "首次病程记录", "书写时间": "2023/2/1 01:00:00", "病历内容": "..."},
  {"病历名称": "出院记录", "书写时间": "2023/2/2 00:00:00", "病历内容": "..."}
]
```

Output

```
[
  {"错误字段": "入院记录", "错误详情": "..."},
  {"错误字段": "出院记录", "错误详情": "..."}
]
```

图 3-4 病案质检指令数据格式示例

（2）Input（输入部分）

原始病历数据以表格形式存储，属性包括病历编号、就诊号码、病历名称、书写时间及病历内容等。其中，同一就诊号码表同一患者在一次住院期间产生的多条病历。首先，需要删除冗余的列，只保留就诊号码、病历名称、书写时间以及病历内容。其次，对于具有相同就诊号码的病历数据，将其整合为一个 JSON 对象，并存入数组中，作为指令数据中的输入部分。该 JSON 对象中包含病历名称、书写时间和病历内

容三个键值对。

(3) Output（输出部分）

病历错误信息的处理方式与病历数据类似。原始错误信息同样以表格形式存储，其属性包括就诊号码、错误字段和错误详情等，其中就诊号码作为外键与病历数据关联。处理这部分数据时，首先，删除冗余列，仅保留就诊号码、错误字段和错误详情。其次，将相同就诊号码的错误信息整合为一个 JSON 对象，并存入数组中，作为指令数据中的输出部分；该 JSON 对象包含错误字段和错误详情两个键值对。最后，利用就诊号码字段将错误信息与病历数据关联，确保每一条输入均能对应唯一的输出。

3.4.2 数据清洗

为确保指令数据的高质量，对原始病历数据进行了严格清洗与筛选。首先，剔除了“就诊号码”不足六位、病历数组（指令数据输入部分）条数少于三条、存在字段缺失或字段类型非字符串的测试及异常样本；其次，鉴于所收集数据时间跨度为 2023 年 1 月至 2024 年 5 月，为确保每条病历均可完整追溯至入院到出院的全过程，若病历数组中任一病历条目的书写时间早于 2023 年 2 月或晚于 2024 年 4 月，则剔除该条数据；最后，本文使用 Qwen2.5-7B 模型进行指令微调，基于该模型的分词器对病历数据的 token 数进行了统计（见图 3-5）。结果显示，绝大多数样本的 token 数低于 16000。综合考虑实际算力资源，设置单条数据最大 token 数为 16384，并删除超过该阈值的数据，以避免训练过程中的截断处理破坏数据完整性。




图 3-5 病历数据 token 区间统计

3.4.3 数据脱敏

数据脱敏旨在对敏感信息进行去隐私化处理，从而防止数据泄露。所收集的原始数据中涉及身份证号、手机号等敏感信息，为防止患者隐私泄漏，基于正则匹配和命名实体识别模型实现数据脱敏处理。首先，通过编写正则表达式匹配敏感信息字符串，并将匹配到的内容用‘*’替换；其次，对于正则表达式未能匹配到的敏感信息，加载中文命名实体识别模型进一步脱敏。具体脱敏规则如下：

- (1) 对于身份证号码，将身份证号码的第七位至第十四位替换为‘*’。
- (2) 对于患者、医生、手术者以及助手等姓名，全部替换为同等长度的‘*’。
- (3) 对于手机号，将四至七位用‘*’代替。
- (4) 对于固定电话号码，将‘-’符号后的四位用‘*’代替。
- (5) 对于住院号、病案号、床号以及表单编号，全部替换为同等长度的‘*’。
- (6) 对于地址信息，仅保留至市/县，并将省、市/县前的字符替换为‘*’。
- (7) 对于医院名称，全部替换为同等长度的‘*’。

3.5 指令微调策略

本节将系统地探讨指令微调的整体策略，依次阐述基座模型的选择、数据配比方案以及微调技术框架，为后续研究奠定基础。

3.5.1 基座模型选型

在进行指令微调训练前，基座模型（即预训练大语言模型）的选择是决定最终模型性能的关键环节，直接关系到微调后模型在特定任务中的表现。基座模型的选型需要从多个角度进行综合考虑，主要包括以下几个方面：

(1) 模型性能

在选择基座模型时，需要评估其在大规模无监督预训练阶段的表现，以及在各种自然语言处理任务中的综合效果。通常，在多类自然语言处理任务上均能获得良好表现的模型往往泛化能力更强，更能高效地适配于下游任务，从而提升整体性能。本文侧重于使用具备较长上下文处理能力、较强语义理解能力和逻辑推理能力的大模型，

因此主要关注模型在 MMLU^[60]、BBH^[61]、Hellaswag^[62]、MATH^[63]和 GSM8K^[64]等多个基准测试中的得分和表现。

(2) 参数规模

参数规模是衡量模型表达能力和学习复杂度的重要指标。通常，参数量越大的模型能够捕捉更多的信息，并具有更强的表达和推理能力。然而，参数规模的增加也会带来更高的计算资源消耗和训练时间成本。因此，选型时需要在模型能力与实际资源限制之间找到平衡点，综合考虑训练数据量、下游任务复杂度以及计算资源限制，来确定适宜的参数规模。

(3) 开源与社区支持

一个活跃的社区和丰富的资源对于模型复现和后续优化至关重要。开源基座模型不仅能提供大量学习和使用的资源，还能够借助社区的不断优化与反馈，实现模型性能的持续提升。

对参数量为 7~9B 的几款主流大模型在上述基准测试中的表现进行了比较，涵盖了 Qwen2.5-7B^[65]、Mistral-7B^[66]、Llama3-8B^[67]、Gemma2-9B^[68]和 Qwen2-7B^[69]，其具体比较结果如表 3-1 所示。

表 3-1 主流大语言模型（7~9B）在各类基准测试中的表现

模型	MMLU	BBH	Hellaswag	MATH	GSM8K	上下文
Qwen2.5-7B	74.2	70.4	80.2	49.8	85.4	128k
Mistral-7B	64.2	56.1	83.3	10.2	36.2	32k
Llama3-8B	66.6	57.7	82.1	20.5	36.2	8k
Gemma2-9B	71.3	68.2	81.9	37.7	70.7	8k
Qwen2-7B	70.3	62.3	80.7	43.5	80.2	128k

经过综合评估和比较，最终选择了 Qwen2.5-7B 模型作为基座模型，主要基于以下理由：

(1) 该模型在多达 18T tokens 的大规模数据集上进行了预训练，该数据集中包含了丰富的医学专业知识，为模型提供了坚实的医学知识基础。

(2) 该模型在多个权威数据集上的基准测试中取得了优异成绩，表现出较强的泛化能力和跨任务适应性，这为后续指令微调阶段的高效适配奠定了基础。

(3) 该模型在指令执行、生成文本（超过 8k 标记）、理解结构化数据（如表格数据）以及生成结构化输出（特别是 JSON 格式）方面取得了显著改进^[65]，这些特性使得该模型在处理病案质检任务时具有更高的适应性和优势。

3.5.2 数据配比方案

为缓解大模型在指令微调阶段潜在的灾难性遗忘问题，在构建指令微调数据集时，有针对性地引入了一定比例的通用指令数据。这一策略旨在确保模型在经过指令微调后，仍能保持其原有的通用知识和对话能力，从而避免因专注于特定任务而导致的整体性能下降。所采用的通用指令微调数据来源于斯坦福 alpaca^①模型的训练数据。这些数据经过 GPT-4 高质量翻译以适应中文环境，并采用随机采样的方式从中选取了一万条数据。

此外，考虑到病历数据中病历质量类别分布失衡可能会对模型性能产生的负面影响，提出了基于临床真实场景的数据重构策略。为了提升数据集的代表性，并确保模型能够更好地学习到病案质检的实际需求，对病历数据集进行了划分和重构。首先，将数据集分为两部分：一部分包含所有被标记为存在质量问题的病历及其对应的错误描述，另一部分则由没有发现任何质量问题的病历组成。随后，根据医院实际环境中这两类病历的真实分布比例，对这两部分数据进行了精心的筛选和采样。通过这种方法，最终构建了一个包含两万条记录的数据集，这些记录尽可能贴近真实的医院状况，同时精心筛选出了五百条高质量病历数据作为测试集用于后续评估模型性能。

综上所述，最终构建的指令微调数据集共计十万条，各类型数据具体配比详情如表 3-2 所示。

表 3-2 指令微调数据配比策略

数据集类型	数据来源	样本数量
医患对话数据	HuatuoGPT2-SFT	40k
医学知识问答	Qizhen	20k
复杂医学任务	PromptCBLUE	10k

① <https://huggingface.co/datasets/shibing624/alpaca-zh>

通用指令数据	alpaca-gpt4-zh	10k
病案质检数据	某医院	20k

3.5.3 微调技术框架

本文基于 LLaMAFactory 框架，采用 LoRA 技术对 Qwen2.5-7B 模型进行了参数高效的指令微调，训练在四张 A6000-48GB 显卡上完成。为尽可能地节省计算资源，训练过程中采用了 fp16 精度，并结合 DeepSpeed 的 ZeRO-3 + offload 策略实现高效的分布式训练。实验设置方面，将训练轮次数设置为 2，初始学习率设置为 $1e-5$ ，并采用余弦退火策略动态调整学习率，以防止模型因过度拟合训练数据而导致灾难性遗忘问题的出现。实验过程中取 10% 的训练数据作为验证集，并记录训练和验证 loss 曲线，具体训练参数如表 3-3 所示。

表 3-3 微调训练参数

参数	取值
r	8
lora_alpha	16
lora_dropout	0
epoch	2
learning_rate	$1e-5$
per_device_train_batch_size	1
gradient_accumulation_steps	16

3.6 本章小结

本章面向提升开源大语言模型在病案质检任务上的表现所面临的相关挑战，提出了面向病案质检任务的医疗大模型构建方法。针对通用领域大语言模型在基础医学知识储备和病历分析能力方面的不足，提出了一种面向多种医学任务、多阶段的指令微调数据集构建方案。该方案旨在面向不同应用场景构建针对性指令数据，从而充分激发大语言模型在医学领域的专业能力。同时，章节还介绍了数据集构建过程中涉及的数据预处理流程，以及在模型训练阶段应用的指令微调策略，为后续医疗大模型的构建提供了坚实基础。

4 基于知识图谱检索增强的病案质检方法

本章基于前文构建的面向病案质检任务的医疗大模型，提出了一种基于知识图谱检索增强的病案质检方法，并在此基础上构建了相关医学知识库，以增强大语言模型在医学任务中的生成，缓解其知识更新滞后与幻觉生成等问题。相较于传统的使用向量数据库检索语义相似文本的检索增强生成方法，本方法融合知识图谱以增强检索效果，使模型在处理复杂医学问题时能够获得更准确的知识。本章将从大语言模型应用于医学领域特定下游任务的问题分析出发，依次介绍病案质检方法的整体框架、医学知识库与知识图谱的构建策略，最后阐述如何基于检索结果将相关知识注入大语言模型，以提升其在病案质检任务中的表现。

4.1 医疗大模型应用问题分析

大语言模型在经过指令微调后，能够掌握丰富的医学知识，并更加适配于下游任务。然而，单纯依赖模型自身的知识仍存在一定局限性。为此，本章引入基于知识图谱检索增强的病案质检方法，通过引入外部知识对大语言模型的知识体系进行补充，从而弥补模型自身存在的局限性，并进一步适配病案质检下游任务。具体而言，大语言模型在应用于医学领域下游任务时，主要面临以下三个关键问题：

（1）知识更新滞后问题

经过微调的大语言模型虽然具备丰富的专业知识，但其学习到的知识是静态的，存在明显的知识更新滞后的问题。考虑到大模型训练所需的高昂成本（包括数据准备、算力资源和训练时间等方面），通过频繁微调来实现知识更新的方案在实际应用中并不可行。这种知识更新的滞后限制了模型在特定领域的应用，在医学领域中，信息的准确性至关重要，模型必须能够迅速适应新的知识。

为解决这一问题，RAG 技术将传统的生成式语言模型与实时信息检索系统相融合，使模型能够动态访问外部知识库。其核心优势在于能以较低成本实现知识库的快速更新，并通过检索将相关信息注入模型输入。在病案质检任务中，RAG 能够实时提取知识库中的相关医学知识，辅助大语言模型做出更为精准的判断。这种方法不仅

提高了模型在病案质检任务上的表现，还降低了模型更新知识的成本。

（2）幻觉问题

生成模型在回答问题时，常常会产生与事实不符的内容，这种现象被称为“幻觉”。由于生成模型依赖于其内在知识（权重），无法完全摆脱幻觉问题，而医学领域对模型的准确性要求极为严格，且对用户的理解门槛较高，用户难以识别模型输出中的错误信息。与微调相比，RAG 技术通过引入经过验证的外部知识作为生成依据，显著提高了回答的可信度。具体而言，模型在生成响应前会先检索相关知识库，确保输出的内容建立在可靠的信息基础之上，从而有效抑制了幻觉现象的发生。

（3）知识相关性问题

RAG 的效果很大程度上取决于检索内容与任务的相关性。低相关性的检索结果不仅无法提供有效支持，反而可能引入噪声干扰模型的判断。不同于传统的使用向量数据库检索语义相似文本的 RAG，本文通过知识图谱增强检索效果，获取与输入文本高度相关的内容。在此基础上，大语言模型结合检索到的专业知识进行分析推理，最终实现更精准的病案质量评估。

4.2 病案质检方法整体框架

针对上述问题，提出了基于知识图谱检索增强的病案质检方法。本小节将依次介绍该方法的整体框架、知识库构建策略、知识图谱构建策略以及知识融合策略。

本方法旨在通过引入外部知识库，充分利用大语言模型的上下文理解能力，将检索到的相关医学知识与用户输入进行拼接，并结合提示工程进一步激发模型能力。具体来说，本方法主要基于病案质检任务相关的医学语料构建外部知识库，并从中挖掘实体和关系，以构建相应的知识图谱。基于从用户输入中识别出的实体，通过知识图谱从外部知识库中检索出高度相关的知识，再结合提示工程，将用户指令与检索出的知识文本进行合理拼接，形成新的输入序列，以作为大模型对病历进行质检的依据。该方法将知识图谱抽象为一个超大规模的词表，将其中的实体与关系视作词汇单元，在检索过程中实现对实体与实体间关系的联合建模。整体框架如图 4-1 所示，具体包括如下四个步骤：

（1）知识库构建

以病历相关语料为核心构建了一个外部知识库，通过对文本进行切片与分块处理，提升其嵌入效果，随后借助嵌入模型将文本转换为向量形式，并存入本地的向量数据库中。




图 4-1 基于知识图谱检索增强的病案质检方法整体框架

（2）知识图谱构建

为了增强所检索出知识的相关性，在语料库进行分块后利用大语言模型强大的语义理解能力识别并提取文本块中所有实体、实体间关系以及文本中的关键声明（即关于实体的陈述信息），并根据这些信息构建知识图谱，最后使用聚类算法对初始知识图谱执行分层聚类，将每个实体分配到社区中，并自下而上为每个社区生成摘要。

（3）知识融合

在病案质检任务执行时，首先利用知识图谱中的实体关系和社区摘要，从向量数据库中检索出相关性较高的文本，再将检索出的知识片段与用户输入进行拼接，形成新的输入序列，最后根据提示工程构建合适的提示词，引导大模型更好地理解 and 利用拼接后的输入序列，提高病案质检的准确性和效率。

(4) 大模型推理与生成

利用经过指令微调后的大语言模型对拼接后的输入序列进行内容分析，提取关键信息并进行逻辑推理，最终得到结果。

4.3 知识库构建策略

外部知识库作为本文提出的检索增强方法的核心基础，其质量直接影响着与病历内容之间的知识相关性，进而对检测效果产生显著影响。构建一个高质量、系统化的知识库不仅能提高大模型在病案质检任务中的判断精度，还能有效降低因知识缺失或信息幻觉带来的误判风险。本节将依次介绍知识库构建的整体框架、质控规则构建以及数据预处理。

4.3.1 知识库构建整体框架

在知识库构建过程中，所选用的数据源如表 4-1 所示，包括病案相关代表性政策文件、地方性评价指标、权威医学知识以及质控规则四部分。

表 4-1 知识库数据源

数据类型	数据来源
代表性政策文件	病历书写基本规范
	病案管理质量指标（2021 年版）
	电子病历应用管理规范
	三级医院评审标准（2022 年版）
	三级医院评审标准（2022 年版）实施细则
	医疗机构病历管理规定
地方性评价指标	湖北省病历质量考核评分标准（2016 版）
权威医学知识	CMeKG
质控规则	根据相关政策文件构建

结合上述数据，构建了一个专用于病案相关任务的综合知识库，整体框架如图 4-2 所示。具体而言，病案处理不仅涉及患者的诊疗过程，也反映医院整体的医疗水平。各项政策文件均明确规定了医院在处理病案时应遵循的具体细则，将这些条款纳入知识库后，可为大模型提供严格的行为约束，确保其在执行质检任务时严格依照标准

进行判断。同时，地方性病案评价指标详细说明了各项病历内容在实际操作中的重要性，这不仅为质检任务提供了明确的评价标准，还帮助大模型准确捕捉病案填写中的关键细节，从而提升判断的针对性和准确性。引入专业医学知识则大大增强了大模型的专业背景，降低了因知识盲区而产生幻觉问题的风险。且权威医学数据的不断更新也为模型提供了实时的医学信息，从而保证在复杂案例判断中的科学性与准确性。




图 4-2 知识库构建策略整体框架

在知识库构建过程中，采用 CMeKG（Chinese Medical Knowledge Graph）中的部分数据作为医学知识的基础。CMeKG 是一种中文医学知识图谱，结合自然语言处理与文本挖掘技术，在大规模医学文本数据的基础上，以人机协作方式构建而成。其构建过程中参考了 ICD、ATC、SNOMED、MeSH 等权威国际医学标准，以及大量来源多样、结构复杂的临床指南、行业规范、诊疗标准和医学百科等医学资料。

4.3.2 质控规则构建

为确保大语言模型在执行病案质检任务中具备明确的判断依据与操作标准，基于《病历书写基本规范》等具有代表性的病案政策文件以及《湖北省病历质量考核评分标准（2016 版）》等地方性病案评价指标文件，系统梳理并归纳了相关规范要点，最终共构建了 177 条适用于病案质检任务的规则。这些规则从结构完整性、内容准确性、时间连续性以及逻辑一致性等多个维度，对病案书写过程中的关键环节进行约束，覆盖了从入院记录、病程记录到手术相关记录、出院记录的完整病案书写流程，

具体如表 4-2 所示。

表 4-2 质检规则详情

规则类型	规则示例	规则数量
病历基本要求	病历书写内容与客观事实不一致	13
病案首页	出院时间记录与病历记录不一致	17
入院记录	无入院记录（或再次/多次入院记录）或 24 小时内入出院（死亡）记录	22
病程记录	无首次病程记录	59
手术相关记录	手术无术前小结	35
出院（死亡）记录	出院记录或死亡记录未在患者出院（死亡）后 24 小时内完成	12
知情同意书	自费项目无患者本人（委托人或法定代理人）签名的知情同意书	10
辅助检查	辅助检查、检验的相关医嘱、报告单不完整，或医嘱、报告单与病程不一致	3
医嘱	无长期医嘱单	6

4.3.3 数据预处理

本文基于 GraphRAG^[70]框架对大模型的响应进行检索增强。该框架支持 txt 和 csv 两种文件格式，本文主要使用 txt 纯文本文件。针对知识源数据的多源异构特征，在数据预处理阶段需要对不同格式的原始数据进行统一的格式转换与清洗，以确保后续工作能够顺利进行并达到预期效果，处理前后相关文件字符数如表 4-3 所示。

表 4-3 文件处理前后字符数

文件名	处理前字符数	处理后字符数
病历书写基本规范	9041	8706
病案管理质量指标（2021 年版）	5873	5469
电子病历应用管理规范	3104	2973
三级医院评审标准（2022 年版）	36444	31436
三级医院评审标准（2022 年版）实施细则	81874	74054
湖北省病历质量考核评分标准（2016 版）	15639	14824
医疗机构病历管理规定	3874	3615

具体来说,收集的数据主要来源于 pdf 和 doc 两种文件格式。针对 pdf 文件,主要使用 PyMuPDF 库进行文本内容提取,将原始 pdf 文件转换为 txt 格式文本。完成格式转换后,需要对文本数据进行系统的清洗工作。由于原始数据中可能包含诸如页眉页脚、广告、无关标记以及其他噪声信息,采用基于正则表达式的匹配和替换方法,对文本数据进行清洗。具体而言,首先利用正则规则过滤掉无效字符、特殊符号和非结构化信息,确保文本内容更加纯净;接着对文本中的空格、换行符和标点符号等元素进行规范化处理,将多余的连续空格和换行符合并,过滤非段落性换行,并将标点符号统一为中文,从而增强数据的一致性与可读性;最后,对清洗后的文本进行完整性校验,确保数据未被误删,同时验证文本结构是否完整。

4.4 知识图谱构建策略

在知识库构建完成后,下一步便是基于该知识库构建知识图谱。本文基于 GraphRAG 框架进行知识图谱的构建。GraphRAG 是一种结构化的、分层的检索增强生成方法,而不是使用纯文本片段的语义搜索方法。与使用向量数据库检索语义相似文本的基本 RAG 不同,GraphRAG 通过结合知识图谱来增强 RAG。

GraphRAG 工作流程包括索引和查询两个阶段,在索引构建阶段对原始文本进行实体和关系提取,从而构建知识图谱。本节将依次介绍 GraphRAG 框架中的索引构建以及在知识图谱构建过程中所采用的优化策略。

4.4.1 GraphRAG 索引构建

索引构建的工作流程如图 4-3 所示,主要包含以下步骤:

(1) 文本单元分割

整个输入语料库被划分为多个文本单元(文本块)。这些文本块是最小的可分析单元,可以是段落、句子或其他逻辑单元。通过将长文档分割成较小的文本块,可以提取并保留有关输入数据的更详细信息。

(2) 提取实体(Entity)、关系(Relationship)和声明(Claim)

GraphRAG 使用大语言模型识别并提取每个文本单元中的所有实体(人名、地点、组织等)、实体之间的关系以及文本中表达的关键声明,并使用这些提取的信息构建

初始知识图谱。

(3) 层次聚类

GraphRAG 使用 Leiden 技术对初始知识图谱执行分层聚类。Leiden 是一种社区检测算法，能够有效地发现图中的社区结构。每个聚类中的实体被分配到不同的社区，以便进行更深入的分析。

(4) 生成社区 (Community) 摘要

GraphRAG 使用自下而上的方法为每个社区及其中的重要部分生成摘要。这些摘要包括社区内的主要实体、实体的关系和关键声明。这一步为整个数据集提供了概览，并为后续查询提供了有用的上下文信息。




图 4-3 索引构建工作过程示意图

在索引构建过程中，为了提升对知识库文本中实体、关系等关键信息的提取效果，需要对相关参数进行合理配置。表 4-4 展示了在构建索引阶段所采用的主要参数及其取值。其中，将温度系数设置为 0，可确保大语言模型输出结果的确定性，从而避免因生成内容过于随机而影响后续知识图谱的构建质量。

表 4-4 索引构建主要参数

参数（均省略前缀 GRAPHRAG_）	描述	取值
LLM_MAX_TOKENS	最大标记数	4000
LLM_TEMPERATURE	使用生成的温度	0
LLM_TOP_P	用于抽样的 top_p 值	1
EMBEDDING_BATCH_SIZE	一次嵌入的文本数量	16
EMBEDDING_BATCH_MAX_TOKENS	每批的最大标记数	8191
CHUNK_SIZE	用于文本分块分析窗口 的标记数的块大小	1200
CHUNK_OVERLAP	用于文本分块分析窗口 的标记数的重叠	100

4.4.2 知识图谱构建提示词优化

GraphRAG 框架主要面向通用场景以及英文环境，其在中文医学领域应用时，原始提示词存在语言不匹配、实体类别单一等缺陷。针对这些问题，对知识图谱构建过程中所涉及到的提示词（见表 4-5）进行了系统优化，具体步骤如下：

（1）语言适配

利用大语言模型将原始英文提示词翻译为中文，从而满足中文文本处理的需求，并确保提示词在语义和表达上的准确性。

（2）实体类型扩展

在进行实体提取任务时，原始提示词仅支持机构、人物、地理位置和事件四类实体。为提升其在中文医学领域的适用性，结合已构建的医学知识库，利用大语言模型多轮提取知识库片段中的实体（见图 4-4）。最终，将支持的实体类型扩展至包括药品、症状等在内的 16 种类别，确保后续能从知识库片段中精准提取各类医学实体。

（3）示例优化

基于 few-shot 学习方法，利用大语言模型并结合知识库文本，为实体提取任务提示词构建了格式规范的高质量示例（见图 4-5），以进一步提高模型在医学文本上的抽取效果。




图 4-4 实体提取示例



图 4-5 提示词示例构建

表 4-5 GraphRAG 提示词文件描述

文件名	作用
entity_extraction	提取实体及实体间关系
claim_extraction	提取关键声明
community_report	创建社区报告
summarize_description	概括社区报告

为评估提示词优化对知识图谱构建的影响，设计并开展了消融实验，对比优化前后所生成知识图谱在节点数量、边数量及社区数量等指标上的变化，具体实验结果如表 4-6 所示。实验结果表明，随着各项优化策略的逐步引入，知识图谱的结构复杂度显著提升。其中，实体类型扩展对图谱规模的增长贡献尤为显著，节点数量由 1439 跃升至 5374，表明在特定领域引入细粒度实体类型有助于挖掘更多领域相关实体，增强知识图谱的表达能力。

表 4-6 消融实验结果

优化方法	节点数	边数	社区数
未优化	1291	793	47
语言适配	1439	1843	50
语言适配+实体类型扩展	5374	7154	133
语言适配+实体类型扩展+示例优化	6276	9357	142

4.4.3 知识图谱可视化策略

在完成知识图谱的构建后，进一步借助 Gephi 软件对其进行可视化分析。Gephi 是一款基于网络科学方法的开源网络分析与可视化工具，能够对关系型数据进行深入处理与解析，且支持多种图布局算法，可用于展示图结构的整体形态。

在知识图谱可视化的过程中，根据社区划分对图谱中的节点进行着色，以突出不同社区的结构特征。同时，为了反映节点的重要性，设定节点的大小与其 PageRank 值存在比例关系，即 PageRank 值越大的节点，其显示尺寸也越大。PageRank 是一种基于网络结构的节点重要性排序算法，用于衡量图中特定节点的全局影响力或权威性。其计算公式如公式 4-1 所示。

$$PR(P_i) = \frac{1-d}{N} + d \sum_{p_j \in M(p_i)} \frac{PR(p_j)}{L(p_j)} \quad (4-1)$$

其中, $d \in (0,1)$ 为阻尼因子, 通常取值为 0.85; N 为图中节点总数; $M(p_i)$ 表示指向节点 p_i 的节点集合; $L(p_j)$ 为节点 p_j 的出度。

4.5 知识融合策略

在完成知识图谱构建后, 下一步工作是基于该图谱检索相关知识, 并通过高质量的提示词将其有效地与原始病历数据融合, 从而提升大语言模型在病案质检任务中的效果。

本文基于 GraphRAG 的查询工作流程, 将检索到的知识有效注入至大语言模型的生成过程中。该框架支持全局搜索和本地搜索两种查询流程, 并根据查询类型进行优化。全局搜索方法通过整合全部社区摘要生成答案, 注重于对知识库的整体理解; 而本地搜索方法则通过结合知识图谱中的相关数据和原始文档的文本块来生成答案, 这种方法适用于需要理解文档中提到的特定实体的问题。考虑到病案质检任务中更侧重于对特定实体及其关系的理解, 使用本地搜索方法实现知识融合, 相关工作流程如图 4-6 所示。




图 4-6 本地搜索工作过程示意图

具体知识融合流程如下:

(1) 用户查询: 用户提交患者病历数据, 系统通过将病历转换为指令微调数据集 (见图 3-4) 中输入部分的 JSON 格式, 并结合病案质检任务提示词, 共同构成模型的初始输入。

(2) 搜索相似实体：使用向量数据库，通过文本语义相似性搜索从知识图谱中识别出与用户所提交病历内容相关的一组实体。

(3) 实体-文本单元映射：将图谱中的医学实体与文本单元进行映射，同时移除冗余的原始文本信息。

(4) 实体信息融合：围绕检索到的医学实体，进一步整合多维度信息，包括实体间的关系信息、关联的实体声明以及相关社区报告等，并对这些信息进行过滤和优先级排序。

(5) 生成响应：将初始输入结合经过过滤和排序的实体信息，共同组织为如图 4-7 所示的提示词中的数据表（context_data）部分。模型根据提示词，综合已有知识与输入信息，生成符合任务目标、格式规范且具有数据支持的回答内容。

```
Prompt:
——角色——
你是一位乐于助人的助手，专门回答有关所提供数据表中数据的问题。
——目标——
生成一个符合目标长度和格式的回答，回答用户的问题，同时总结所有适用于该回答长度和格式的输入数据表中的信息，并结合任何相关的通用知识。
如果你不知道答案，请直接说不知道。不要凭空捏造信息。
数据支持的观点应按照如下方式列出数据引用：
“这是一个由多个数据引用支持的示例句子[Data: <数据集名称> (记录ID); <数据集名称> (记录ID)]。”
在单个引用中不要列出超过5个记录ID。相反，应列出最相关的前5个记录ID，并添加“+more”以表示还有更多记录。
例如：
“糖尿病患者常合并高血压，其发生率可高达60%以上[Data: Sources (15, 16), Reports (1), Entities (5, 7); Relationships (23); Claims (2, 7, 34, 46, 64, +more)]。”
其中15、16、1、5、7、23、2、7、34、46和64表示相关数据记录的ID（而非索引）。
不要包含没有数据支持证据的信息。
——目标回答长度和格式——
{response_type}
——数据表——
{context_data}
——目标——
生成一个符合目标长度和格式的回答，回答用户的问题，同时总结所有适用于该回答长度和格式的输入数据表中的信息，并结合任何相关的通用知识。
如果你不知道答案，请直接说不知道。不要凭空捏造信息。
数据支持的观点应按照如下方式列出数据引用：
“这是一个由多个数据引用支持的示例句子[Data: <数据集名称> (记录ID); <数据集名称> (记录ID)]。”
在单个引用中不要列出超过5个记录ID。相反，应列出最相关的前5个记录ID，并添加“+more”以表示还有更多记录。
例如：
“糖尿病患者常合并高血压，其发生率可高达60%以上[Data: Sources (15, 16), Reports (1), Entities (5, 7); Relationships (23); Claims (2, 7, 34, 46, 64, +more)]。”
其中15、16、1、5、7、23、2、7、34、46和64表示相关数据记录的ID（而非索引）。
不要包含没有数据支持证据的信息。
——目标回答长度和格式——
{response_type}
根据回答的长度和格式，适当地添加章节和评论。
```

图 4-7 知识融合提示词

4.6 本章小结

本章面向大语言模型在实际应用中存在的不足，提出了一种基于知识图谱检索增强的病案质检方法。该方法通过构建外部知识库对大语言模型的生成进行增强，从而缓解其知识更新滞后和幻觉生成的问题。同时，通过构建基于外部知识库的知识图谱，并深入挖掘其中的实体关系，进一步提升了检索知识与用户输入之间的相关性。

5 实验结果与分析

本章围绕提出的面向病案质检任务的医疗大模型构建方法以及基于知识图谱检索增强的病案质检方法分别展开详细的实验研究与结果分析。通过与其他基线模型的对比实验，验证所提出方法的有效性。此外，实现了一个融合大语言模型与检索增强技术、交互性强的病案质量检测系统，为实际应用提供有力支持。

5.1 指令微调实验结果与分析

5.1.1 实验环境

实验环境具体软硬件配置如表 5-1 所示。该环境为大语言模型的训练与微调提供了坚实的基础，保障了模型在训练过程中的稳定性与高效性。

表 5-1 实验环境配置

配置名称	配置参数
GPU	NVIDIA RTX A6000 × 4
运行显存	48G × 4
CUDA	12.4
操作系统	Ubuntu 20.04
开发语言	Python 3.11
深度学习框架	Pytorch 2.6.0

在硬件方面，实验所使用的 NVIDIA RTX A6000 GPU 拥有强大的浮点计算能力与高速显存，单卡配备 48GB 显存，可高效支持大规模参数模型的训练与推理。本实验配置了 4 张 A6000 显卡，通过多卡并行训练机制进一步提升了训练速度和效率。

在软件环境方面，使用的操作系统为 Ubuntu 20.04，具有良好的稳定性和兼容性，适合部署深度学习相关的软件栈。开发语言采用 Python 3.11，该版本兼顾了语言性能与社区支持，适用于构建复杂的机器学习任务流程。深度学习框架选用 PyTorch 2.6.0，具备丰富的生态资源和灵活的计算图机制，支持动态图与静态图的高效切换，并与 CUDA 12.4 深度集成，有效发挥了 GPU 的并行计算能力。

5.1.2 模型训练

训练过程中通过 swanlab 平台对训练进程进行实时监控，损失函数变化如图 5-1 所示。从图中可以看出，模型在训练初期（约前 0.2 个 epoch）损失值迅速下降，表明模型较快地捕捉到了训练数据中的特征，具备良好的学习能力。随着训练的进行，损失曲线逐渐趋于平稳，并在后续阶段维持在较低水平，表明模型已逐步收敛。在整个训练过程中，验证损失基本与训练损失保持一致，说明模型在验证集上的表现良好，未出现过拟合现象。此外，尽管训练损失曲线存在一定程度的局部波动，但整体趋势仍然稳定下降，符合预期。




图 5-1 指令微调损失曲线

5.1.3 评价指标

本文旨在通过构建高质量指令微调数据集，实现大语言模型对病案质检任务的高效适配。具体而言，需要提升模型在医学领域的理解与推理能力，同时增强其对复杂病历数据的分析与处理能力，因此从这两个方面对模型进行系统评估。

CMB^[71]是一个中文医学评估标准，该评估标准包括了两个部分：CMB-Exam 和 CMB-Clin，具体如图 5-2 所示。

该部分利用资格考试作为数据来源,具有客观且通常准确的基准,涵盖了医师考试、护理考试、药师考试、医技考试、专业知识考试和医学考研 6 个类别,共 176 个子类,280839 道题目。其中标准测试集包括 11200 题,题型涵盖单项选择题和多项选择题,且测试数据量较为充足。

该部分由 74 例医学专家基于临床诊断教材构建的病历咨询问题组成。这些问题基于真实的、复杂的病例，并由医学领域专家共同确定正确的答案，以评估模型面对复杂病历数据时综合运用医学知识进行推理和分析的能力。

CMB-Exam

Physician

Technician

Pharmacist

Nurse

Disciplines

CMB-Clin

Medical History

Summary:
Tian XX, female, 61 years old, upper abdominal pain...

Chief Complaint
Upper abdominal pain for 1 month, worsening for 3 days

Physical Examination
Self-chosen position, clear consciousness, slight yellowing of the sclera...

Auxiliary Examination:

- (1) Laboratory Examination ...
- (2) Doppler Ultrasound ...
- (3) CT Examination ...

Analyze the patient's medical history, physical examination, and auxiliary examination.

1. Medical History Analysis: The medical history of...
2. Physical Examination Analysis: In terms of ...
3. Auxiliary Examination Analysis: In this case, laboratory examination of liver function...

Summarize the diagnosis and basis for diagnosis of this patient, and the key points of differential diagnosis.

1. Diagnosis: Multiple stones in the common bile ...
2. Diagnostic Basis: (1)Upper abdominal pain (2)Physical examination...(3)Laboratory tests...
3. Differential Diagnosis: (1)Right kidney stones: Urinary system ultrasound can differentiate...

Briefly describe the treatment principles for this patient.

Considering the patient in this case has multiple common bile duct stones with a larger diameter, surgical treatment is chosen. During the surgery, it is necessary to remove all the stones as much as possible to relieve the biliary obstruction, and postoperatively maintain the smooth drainage of bile....

为了进一步验证提出方法的有效性，选用了多个大语言模型作为实验的基线模

型，包括通用领域和医疗领域的基线模型。

面向通用领域的基线模型选取了 GPT-4^[72]、Yi-34B-Chat^[73]、Baichuan2-13B-chat^[74]、ChatGLM3-6B^[75]、Internlm-Chat-20B^[76]、Mixtral-8x7B^[77]、Qwen2.5-7B。

面向医疗领域的基线模型选取了经过医学领域适配的 HuatuoGPTII-34B、Bentsao、ChatGLM-Med。

表 5-2 展示了模型在 CMB-Exam 数据集上的测评结果，分别从医师考试、护理考试、药师考试、医技考试、专业知识考试和医学考研六个维度评估各个模型的综合医学能力。

表 5-2 CMB-Exam 测评结果

模型名称	平均分	医师	护理	药师	医技	专业知识	医学考研
Ours	76.56	74.38	83.25	76.84	77.13	72.34	75.42
GPT-4	59.46	59.90	69.31	52.19	61.50	59.69	54.19
Yi-34B-Chat	69.17	71.10	77.56	73.16	66.56	52.94	68.00
Baichuan2-13B-Chat	48.87	49.55	56.75	49.41	50.08	48.25	39.19
ChatGLM3-6B	40.00	42.55	47.31	39.56	41.08	37.44	32.06
Internlm-Chat-20B	38.17	39.35	45.44	38.53	37.92	38.13	29.63
Mixtral-8x7B	36.37	39.00	41.87	33.12	39.50	36.44	28.25
Qwen2.5-7B	71.27	73.25	78.69	74.19	69.33	66.19	66.00
HuatuoGPTII-34B	76.80	75.65	82.31	76.81	76.17	74.38	75.56
Bentsao	20.39	21.67	19.99	21.07	22.85	19.83	16.93
ChatGLM-Med	21.56	23.59	23.37	22.67	21.85	19.83	16.93

表 5-3 展示了模型在 CMB-Clin 数据集上的测评结果，分别从模型回答的流畅性、相关性、完整性和医学知识专业性四个维度衡量各个模型面对复杂病历数据时的综合运用医学知识进行推理和分析的能力。

实验结果表明，与选取的基座模型 Qwen2.5-7B 相比，经过高质量数据集指令微调的大模型在医师考试、护理考试、药师考试、医技考试、专业知识考试、医学考研六个方面的得分上分别提升了 1.5%，5.8%，3.6%，11.3%，9.3%，14.3%，平均分上升了 7.4%，总体性能接近于参数量级更大的医疗模型 HuatuoGPTII-34B，且相较于其他通用领域和医学领域的大语言模型存在明显优势。同时，该模型在复杂病历数据的处理方面，其回答的流畅性、相关性、完整性以及医学知识专业性得分分别提升了

1.0%，3.3%，1.9%，5.1%，平均分上升了 2.9%。其中，模型在回答的相关性和医学知识专业性方面具备明显优势，总体性能也超过了其他面向通用领域和医学领域的大语言模型。

表 5-3 CMB-Clin 测评结果

模型名称	平均分	流畅性	相关性	完整性	医学知识专业性
Ours	4.69	4.98	4.73	4.32	4.72
GPT-4	4.67	4.95	4.71	4.35	4.66
Yi-34B-Chat	4.67	4.99	4.69	4.34	4.64
Baichuan2-13B-Chat	4.43	4.93	4.41	4.03	4.36
ChatGLM3-6B	4.25	4.92	4.11	3.74	4.23
Internlm-Chat-20B	4.05	4.90	3.91	3.25	4.14
Mixtral-8x7B	2.35	2.53	2.28	1.54	3.04
Qwen2.5-7B	4.56	4.93	4.58	4.24	4.49
HuatuoGPTII-34B	4.60	4.96	4.61	4.31	4.53
Bentsao	2.55	3.88	2.05	1.71	2.58
ChatGLM-Med	2.38	3.55	1.97	1.61	2.37

综上所述，实验结果验证了提出的面向病案质检任务的医疗大模型构建方法的有效性。通过面向多种医疗场景构建高质量的指令微调数据集，可以为大语言模型注入丰富的医学知识，有效提升了大语言模型推理分析复杂医学问题的能力和分析处理复杂病历数据的能力。

5.2 检索增强实验结果与分析

5.2.1 实验环境

本实验的实验环境具体配置与上一节中的指令微调实验配置相同，其中 GraphRAG 版本为 0.4.1。

5.2.2 知识图谱构建

本文基于 GraphRAG 框架开展了知识图谱的索引构建工作，并在此基础上对得到的图谱文件进行可视化展示，图 5-3 展示了索引构建成功后的实验界面截图，清晰地呈现了执行索引构建任务时的主要步骤与结果。索引构建完成后得到了一系列知

识图谱相关文件，具体文件及其说明如表 5-4 所示。

```
GraphRAG Indexer
Loading Input (InputFileType.text) - 9 files loaded (0 filtered) 100% 0:00:00 0:00:00
create_base_text_units
create_base_entity_graph
create_final_covariates
create_final_entities
create_final_nodes
create_final_communities
create_final_relationships
create_final_text_units
create_final_community_reports
create_final_documents
generate_text_embeddings
All workflows completed successfully.
```

图 5-3 索引构建成功示意图

表 5-4 索引构建文件表

文件名	说明
clustered_graph.0.graphml	社区 0 的子图，除社区 0 外还包含多个社区
merged_graph.graphml	所有社区合并后的完整知识图谱
summarized_graph.graphml	对完整图做摘要/抽样后得到的精简概览图
create_final_communities.parquet	严格分层的社区列表
create_final_community_reports.parquet	各社区报告汇总列表
create_final_covariates.parquet	协变量列表，保存关于实体的陈述信息
create_final_documents.parquet	文档列表
create_final_entities.parquet	实体汇总表
create_final_nodes.parquet	节点汇总表
create_final_relationships.parquet	关系汇总表
create_final_text_units.parquet	文本块汇总表
stats.json	构建过程统计

在索引构建完成后，进一步使用 Gephi 软件对得到的 merged_graph 图谱文件进行处理与可视化展示。根据第 4.5 节中提出的知识图谱可视化策略，首先对图中的节点按照其所属社区进行分类，并采用不同的颜色进行标注，使得各类社区结构在整体图谱中呈现出较强的区分度。同时，为了增强知识图谱中节点重要性的直观表现，设定节点的大小与其 PageRank 值比例关系，使得在图谱中具有更高影响力或连接度的节点在视觉上更加突出。最终，通过上述处理得到了如图 5-4 所示的知识图谱可视化结果。



为了全面验证本方法在病案质控任务中的有效性与实用性，基于第三章中构建的真实电子病历测试集，设计并开展了多维度的评估实验。通过从多个维度对模型生成结果的系统性评价，分析其在实际应用中的表现。

为了获得高质量的评估结果，采用提示工程方法构建精确引导的评估提示词，结合 GPT-4 模型作为评估主体进行回答质量的自动化评分。图 5-5 展示了用于进行评估的提示词示例，确保模型在评估过程中理解任务意图，生成具有一致性和可参考性的评分结果。在评分方式上，为每个维度设置 1 至 5 分的分值范围，分数越高代表模型在该维度上的表现越优异。每条生成结果均由模型在四个维度上分别进行打分，最终得到对模型在病案质控任务中的综合评估结果。

Prompt:

你是一个专门评估其他语言模型回答质量的AI评估员。你的主要任务是根据以下四个指标对模型的回答进行评分：准确性、全面性、相关性和语言质量。请使用以下评分标准来评价每个指标：

准确性:

- 1: 存在严重事实错误或矛盾陈述
- 2: 大部分信息不准确，有明显错误
- 3: 基本准确，但有一些小错误或不精确之处
- 4: 高度准确，只有轻微细节上的偏差
- 5: 完全符合医学事实与逻辑

全面性:

- 1: 极其不完整，缺少关键信息
- 2: 很不完整，提供的信息非常有限
- 3: 提供了大部分相关信息但缺乏细节
- 4: 比较完整，仅缺失少量非关键信息
- 5: 完全详尽，所有相关信息都已提供

相关性:

- 1: 完全偏离病历内容
- 2: 与病历有些许关联，但大部分不相关
- 3: 相关，但缺乏关键细节
- 4: 紧扣病历本身但存在冗余
- 5: 精准聚焦于病历问题核心

语言质量:

- 1: 存在严重语法错误和逻辑断裂
- 2: 基本达意但表达生硬，难以理解
- 3: 语句通顺但表达简单
- 4: 语言流畅，能够清晰传达复杂思想
- 5: 达到人类水平的语言流畅度和表达能力

你将会得到以下格式的信息：

...

请确保仅以JSON格式提供你的评估结果，并分别为上述提到的每个标准提供评分，如下例所示：

```
{"accuracy": 3, "comprehensiveness": 3, "relevance": 3, "language_quality": 3}
```

图 5-5 模型评估提示词

5.2.4 实验结果

为进一步验证本方法的有效性，引入了本文构建的医疗大模型进行对比实验，同时选取了多个参数量与本研究基座模型相近的开源大语言模型作为实验的基线模型，包括通用领域和医疗领域的基线模型。

面向通用领域的基线模型包括 Baichuan2-13B-chat、ChatGLM3-6B、Internlm-Chat-20B、Qwen2.5-7B。

面向医疗领域的基线模型包括 Bentsao 和 ChatGLM-Med。

表 5-5 展示了详细的实验结果，其中平均分为模型回答在准确性、全面性、相关性和语言质量四个维度上的评分均值。相比于本文构建的医疗大模型，使用本文提出的方法执行病案质检任务时，模型得到的回答在准确性、全面性、相关性和语言质量方面分别提升了 3.9%、5.1%、4.6%和 0.8%，平均上升了 3.5%。相比于基座大模型 Qwen2.5-7B，使用本文提出的方法执行病案质检任务时，模型得到的回答在准确性、全面性、相关性和语言质量方面分别提升了 7.6%、1.8%、9.1%和 0.8%，平均分数上升了 4.8%。

表 5-5 实验结果

模型名称	平均分	准确性	全面性	相关性	语言质量
Ours(RAG)	4.40	4.23	3.91	4.54	4.90
Ours	4.25	4.07	3.72	4.34	4.86
Baichuan2-13B-Chat	3.86	2.97	3.57	3.92	4.96
ChatGLM3-6B	3.35	2.51	2.64	3.31	4.92
Internlm-Chat-20B	3.76	3.43	2.91	3.81	4.89
Qwen2.5-7B	4.20	3.93	3.84	4.16	4.86
Bentsao	3.50	3.52	2.80	3.76	3.92
ChatGLM-Med	3.32	2.75	3.62	3.42	3.47

该实验数据表明，提出的基于知识图谱检索增强的病案质检方法有效提升了大语言模型在病案质检任务中的表现。相较于基座模型，使用本文提出的方法得到的回答在准确性和相关性两方面提升较大；相比于其他通用领域和医疗领域的大语言模型，本方法同样具有明显优势。

5.3 系统展示

本文实现了一个具备高交互性与良好用户体验的、基于大语言模型和检索增强技术的病案质量检测系统。该系统整合了适配于病案质检任务的大语言模型，以及外部医学知识库和知识图谱，并向用户提供了一个直观、便捷的访问接口，使用户能够

通过上传病历数据，借助大语言模型的强大分析能力对病历进行高效的质量检测。

设计的基于检索增强大语言模型的病案质量检测系统的整体功能层次结构如图 5-6 所示，系统包含用户验证、数据管理、问题识别、模型服务管理以及数据可视化五个模块，主要功能的具体实现细节如下：




图 5-6 系统功能层次

(1) 数据管理模块

病历数据上传页面如图 5-7 所示，支持通过上传病历文件或提交表单两种方式上传数据。用户上传文件后，系统调用 PyMuPDF 等库提取文件中的文本信息，并调用大语言模型的服务自动识别文本中的字段，将从文件中识别出的病历信息自动填入表单中，用户也可对自动生成的病历表单内容进行手动修改。表单支持通过“添加病历”按钮同时上传多条病历记录。最终，在用户提交病历数据时，系统会为上传的病历文件和相应的病历记录生成统一的分组 ID。数据存放情况如图 5-8 所示，其中红色框内为加密数据，蓝色框内为病历文件和病历记录共享的分组 ID。上传完成后，用户可在“我的病历”页面查看所有上传的病历数据，并可查看详情或更新数据，如图 5-9 所示。



图 5-7 病历数据上传示例

id	record_name	record_date	record_content	user_id	group_id	createdAt	updatedAt
17	U2FsdGVkX1/7dZgx6Eyl	2025-01-31 16:00:00	U2FsdGVkX1+LQHF	1	2eedfeb7-f510-4eaf-a2f6	2025-03-20 03:07:39	2025-03-20 03:07:39
18	U2FsdGVkX19hX9JI8Wju7	2025-02-01 16:00:00	U2FsdGVkX1+OAYf	1	2eedfeb7-f510-4eaf-a2f6	2025-03-20 03:07:39	2025-03-20 03:07:39

A EHR记录表提交数据

id	file_name	file_path	user_id	group_id	createdAt	updatedAt
1	1.csv	uploads\medical-records\	1	c15a61b1-c628-4f2c-937b	2025-02-09 06:40:57	2025-02-09 06:40:57
2	测试数据.json	uploads\medical-records\	1	bc3334d5-522c-463d-856	2025-02-09 14:16:59	2025-02-09 14:16:59
3	测试数据.pdf	uploads\medical-records\	1	61e916b9-bcc0-4337-a43	2025-02-22 08:49:10	2025-02-22 08:49:10
4	测试数据.pdf	uploads\medical-records\	1	94f4038e-553a-4b45-af2c	2025-03-20 03:05:50	2025-03-20 03:05:50
5	测试数据.pdf	uploads\medical-records\	1	2eedfeb7-f510-4eaf-a2f6	2025-03-20 03:07:39	2025-03-20 03:07:39


B EHR文件表提交数据

图 5-8 MySQL 中的数据存放

（2）问题识别模块

问题识别模块主要基于构建的医疗大模型和外部知识库进行实现。病案质量问题识别界面如图 5-10 所示。用户可以通过勾选表格中的病案记录，批量选择后点击“开始质检”按钮，启动病历质量问题识别任务。该模块主要依赖于后台部署的大语言模型提供的在线推理服务，同时结合知识图谱从外部知识库中检索相关知识，以增强模型的输出效果。模型推理服务的部署采用了 vllm 框架，实现了对大语言模型的高效推理调度；服务接口则基于 FastAPI 库构建，保证了系统响应的实时性和稳定性。质检任务完成后，用户可查看病案质检结果，界面如图 5-11 所示。该页面中展示了患者病历记录的错误详情信息，错误字段名与用户上传的病历记录中的病历名

称字段对应。此外，用户还可在该页面中通过点赞、点踩或提交文字反馈的方式对检测结果进行偏好反馈。这些反馈数据将作为后续模型调优的重要依据，有助于系统在持续运行过程中不断优化输出效果，更好地对齐用户的实际偏好。



A 我的病历页面



B 病历详情页面

图 5-9 查看或修改上传病历数据




图 5-10 问题识别页面




图 5-11 质检结果示例

(3) 模型服务管理模块

模型服务管理页面如图 5-12 所示，仅对系统管理员开放，保障模型服务的安全性与可控性。该页面主要功能包括模型的上下线管理、超参数控制以及运行日志展示。管理员可以在该页面对模型的温度系数、采样阈值以及最大输出长度等关键超参数进行动态调整，从而影响模型输出的多样性和精确度，优化用户交互体验。此外，运行日志的展示便于管理员及时发现异常并进行问题定位与处理，提高系统稳定性。



图 5-12 模型服务管理页

(4) 数据可视化模块

数据可视化页面如图 5-13 所示，旨在提供直观的质检结果统计分析。该页面主要对当前登录用户上传的所有病历数据所得到的质检结果进行统计分析，并通过柱状图和表格的形式进行可视化呈现，帮助用户直观了解病历数据质检结果的分布情况和质量状况。其中柱状图按检测结果的错误字段进行分类展示，表格中则完整展示了该用户所上传的全部病历数据的质量情况。




图 5-13 数据可视化页面

5.4 本章小结

本章基于公开医学测评集和真实电子病历数据集, 设计并开展了详细的实验, 并与通用领域和医学领域的基线模型进行对比分析, 从而验证了所提出方法的有效性。此外, 本章详细介绍了基于检索增强语言模型的病案质量检测系统的实现细节, 为大模型在医疗领域的应用探索了新的方向。

6 总结与展望

6.1 总结

针对大语言模型在医疗领域应用中所面临的挑战,结合实际医疗场景需求,围绕如何有效训练面向病案质检任务的医疗大模型并利用外部知识库增强模型生成效果这一核心问题,提出了面向病案质检任务的医疗大模型训练方法和基于知识图谱检索增强的病案质检方法,并基于这些工作实现了一个病案质量检测系统。主要工作内容包含以下三个部分:

(1) 面向病案质检任务的医疗大模型构建

提出了一个面向病案质检任务的医疗大模型训练方法。针对通用领域开源大语言模型在病案质检任务中适配不足的问题,提出了面向多种医学任务、多阶段的高质量指令微调数据集构建方法,并在此基础上构建了具备丰富且准确医学知识、在复杂病历数据处理任务中表现出色的垂域大语言模型。此外,通过在公开医学测试集上进行实验,验证了该方法的有效性。

(2) 基于知识图谱检索增强的病案质检方法研究

为缓解大语言模型在实际应用中存在的知识更新滞后、幻觉生成以及知识相关性不足等问题,提出了基于知识图谱检索增强的病案质检方法。该方法利用外部知识库为模型提供可靠的医学知识,从而有效缓解幻觉问题。同时,知识库易于更新的特点,也有效解决了大语言模型知识更新滞后的问题。此外,基于外部知识库构建的知识图谱,通过挖掘实体关系,进一步提高了检索知识与用户输入之间的相关性,从而优化了模型的整体表现。通过在真实电子病历数据集上进行实验,验证了该方法的有效性。

(3) 病案质量检测系统的实现

实现了一个基于大语言模型和检索增强生成技术的病案质量检测系统。该系统支持用户上传病案数据,并通过可视化界面调用在线推理服务,实现对病案质量问题的自动化检测。同时,系统引入反馈机制,持续收集用户偏好,为后续模型优化提供数据支持,为大模型在医疗领域的应用探索了新的方向。

在上述工作内容中，创新与新颖之处主要体现在：提出了面向多种医学任务、多阶段的高质量指令微调数据集构建方法。该方法通过分别面向医患对话、医学知识问答、医疗信息处理任务及病案质检任务构建高质量指令数据集，全面激发模型的基础医学能力和复杂病历分析能力。提出了基于知识图谱检索增强的病案质检方法。该方法通过构建病案质检任务相关的外部知识库为模型提供可靠知识，并将知识图谱的深度语义关联特性与大语言模型的推理能力相结合，有效提升了模型在病案质检任务中的表现。

6.2 展望

本文围绕如何有效利用大语言模型提升病案质检任务性能展开了一系列探索，但工作仍然存在许多不足之处和未来可以进一步探索的空间。未来的工作可从以下几个方向进一步深入和完善：

（1） 模型训练所用电子病历数据主要依赖单一机构的病案资料，数据分布的单一性限制了模型的泛化能力。未来可以引入更多复杂、多样的医学任务数据，并在其中引入更完整的逻辑推理链条，或融合多模态数据（如医学影像等）构建更全面的指令微调数据集。

（2） 现有知识库主要依赖人工构建与定期更新，未来可探索构建自动化的知识更新机制，以进一步提升知识库的时效性与完整性，从而更好地支撑模型的动态知识需求。

（3） 当前系统主要聚焦于病案质量问题检测，未来可进一步拓展至临床决策支持。例如，通过 API 接口与医院现有电子病历系统进行对接，实现病案质检的实时嵌入，并自动提供病历修正建议，及时为医生提供修改方案。同时，通过强化用户反馈机制，形成“检测—反馈—优化”的闭环，不断提升模型性能和系统实用性。

参考文献

- [1] 左海霞. 智能化病案质量控制系统的构建与应用. 中国病案, 2021, 22(8): 40-43
- [2] 徐帆, 舒婷. 高级别医院电子病历系统数据质量评价及对策研究. 中国卫生质量管理, 2022, 29(12): 6-9
- [3] 任牡丹, 杨柳, 殷杰, 吴义熔. 电子病历数据质量研究的国内外差异. 中国卫生事业管理, 2023, 40(4): 268-274
- [4] 卫生健康委办公厅. 关于进一步推进以电子病历为核心的医疗机构信息化建设工作通知. 中华人民共和国国家卫生健康委员会公报, 2018, 8: 106-108
- [5] 李萍. 医疗数据质量的问题探索和解决模式. 计算机应用与软件, 2013, 30(8): 217-219
- [6] 阮彤, 高炬, 冯东雷, 钱夕元, 王婷, 孙程琳. 基于电子病历的临床医疗大数据挖掘流程与方法. 大数据, 2017, 3(5): 83-98
- [7] 胡海洋, 赵从朴, 马琰, 姜会珍, 张晶, 朱卫国. 基于膨胀卷积神经网络的中文医疗命名实体识别研究. 医学信息学杂志, 2021, 42(9): 39-44
- [8] M. Afshar, D. Dligach, B. Sharma, X. Cai, J. Boyda, S. Birch, et al. Development and application of a high throughput natural language processing architecture to convert all clinical documents in a clinical data warehouse into standardized medical vocabularies. Journal of the American Medical Informatics Association, 2019, 26(11): 1364-1369
- [9] 胡振生, 杨瑞, 朱嘉豪, 廖芝美, 方立, 周毅. 大语言模型在医学领域的研究与应用发展. 人工智能, 2023, 4: 10-19
- [10] 王耀祖, 李擎, 戴张杰, 徐越. 大语言模型研究现状与趋势. 工程科学学报, 2024, 46(8): 1411-1425
- [11] C. Wu, J. Lei, Q. Zheng, W. Zhao, W. Lin, X. Zhang, et al. Can gpt-4v (ision) serve medical applications? case studies on gpt-4v for multimodal medical diagnosis. ArXiv abs/2310.09909 (2023): 1-178
- [12] Z. Yang, Z. Yao, M. Tasmin, P. Vashisht, W. S. Jang, F. Ouyang, et al. Performance of Multimodal GPT-4V on USMLE with Image: Potential for Imaging Diagnostic Support

- with Explanations. medRxiv. 2023.10.26.23297629 (2023): 1-31
- [13]阮彤, 卞侯昂, 余广涯, 徐捷. 医学大语言模型研究与应用综述. 中国卫生信息管理杂志, 2023, 20(6): 853-861
- [14]H. Wang, C. Liu, N. Xi, Z. Qiang, S. Zhao, B. Qin, et al. Huatuo: Tuning llama model with chinese medical knowledge. ArXiv abs/2304.06975 (2023): 1-6
- [15]H. Wang, S. Zhao, Z. Qiang, Z. Li, C. Liu, N. Xi, et al. Knowledge-tuning large language models with structured medical knowledge bases for trustworthy response generation in Chinese. ACM Transactions on Knowledge Discovery from Data, 2025, 19(2): 1-7
- [16]H. Zhang, J. Chen, F. Jiang, F. Yu, Z. Chen, J. Li, et al. Huatuogpt, towards taming language model to be a doctor. ArXiv abs/2305.15075 (2023): 1-21
- [17]Y. Chen, Z. Wang, X. Xing, Z. Xu, K. Fang, J. Wang, et al. Bianque: Balancing the questioning and suggestion ability of health llms with multi-turn health conversations polished by chatgpt. ArXiv abs/2310.15896 (2023): 1-10
- [18]S. Yang, H. Zhao, S. Zhu, G. Zhou, H. Xu, Y. Jia, et al. Zhongjing: Enhancing the chinese medical capabilities of large language model through expert feedback and real-world multi-turn dialogue, in: Proceedings of the AAAI Conference on Artificial Intelligence, Washington, DC, USA, 20-27 Feb. 2024, Proceedings of the AAAI, 2024: 19368-19376
- [19]J. Du, X. Li, Z. Jiang, Y. Liu, H. Yin, H. Liu. AiMed: Artificial intelligent large language model for Medicine in China, in: IEEE International Conference on Medical Artificial Intelligence (MedAI), Shanghai, China, 15-17 Nov. 2024, Proceedings of the IEEE, 2024: 360-365
- [20]P. Wan, Z. Huang, W. Tang, Y. Nie, D. Pei, S. Deng, et al. Outpatient reception via collaboration between nurses and a large language model: a randomized controlled trial. Nature Medicine, 2024, 30(10): 2878-2885
- [21]E. Bolton, A. Venigalla, M. Yasunaga, D. Hall, B. Xiong, T. Lee, et al. Biomedlm: A 2.7 b parameter language model trained on biomedical text. ArXiv abs/2403.18421 (2024): 1-23
- [22]R. Luo, L. Sun, Y. Xia, T. Qin, S. Zhang, H. Poon, et al. BioGPT: generative pre-trained

- transformer for biomedical text generation and mining. Briefings in Bioinformatics, 2022, 23(6): 1-11
- [23] K. Singhal, S. Azizi, T. Tu, S. S. Mahdavi, J. Wei, H. W. Chung, et al. Large language models encode clinical knowledge. Nature, 2023, 620(7972): 172-180
- [24] Y. Gu, R. Tinn, H. Cheng, M. Lucas, N. Usuyama, X. Liu, et al. Domain-specific language model pretraining for biomedical natural language processing. ACM Transactions on Computing for Healthcare (HEALTH), 2021, 3(1): 1-23
- [25] X. Yang, A. Chen, N. PourNejatian, H. C. Shin, K. E. Smith, C. Parisien, et al. A large language model for electronic health records. NPJ digital medicine, 2022, 5(1): 194-203
- [26] Y. Li, Z. Li, K. Zhang, R. Dan, S. Jiang, Y. Zhang. Chatdoctor: A medical chat model fine-tuned on a large language model meta-ai (llama) using medical domain knowledge. Cureus, 2023, 15(6): 1-12
- [27] H. Xiong, S. Wang, Y. Zhu, Z. Zhao, Y. Liu, L. Huang, et al. Doctorglm: Fine-tuning your chinese doctor is not a herculean task. ArXiv abs/2304.01097 (2023): 1-10
- [28] D. Van Veen, C. Van Uden, L. Blankemeier, J. B. Delbrouck, A. Aali, C. Bluethgen, et al. Adapted large language models can outperform medical experts in clinical text summarization. Nature medicine, 2024, 30(4): 1134-42
- [29] 唐雄, 张巨发, 徐传新. 依托电子病历的病区护理质控管理系统的开发及应用. 医疗卫生装备, 2012, 33(7): 52-53
- [30] 解锦锦. 电子病历质控管理系统的设计与实现[硕士学位论文]. 济南: 山东大学, 2018
- [31] 杨蓉. 中国电子病历正从初级智能化向中高级智能化迈进. 计算机与网络, 2021, 47(14): 6
- [32] 刘晓东, 宋俊. 结构化电子病历质量控制新模式实践与探讨. 中国医疗设备, 2018, 33(9): 168-171
- [33] 吴文健, 季国忠, 金培生, 刘颖, 孙晖. 关于电子病历智能化质量控制管理及思考. 江苏卫生事业管理, 2020, 31(9): 1181-1184
- [34] 沈鑫, 李晓晴, 徐翠香, 王一波, 易智, 段降龙. 基于人工智能的电子病历实时质

- 量控制探索. 中华医院管理杂志, 2020, 36(3): 206-209
- [35] 吴骋, 王志勇, 徐蕾, 周全. 基于人工智能的电子病历数据质量控制. 解放军医院管理杂志, 2021, 28(2): 134-135
- [36] 刘祉呈, 陈爱芬, 黄颂列. 基于 AI 技术的电子病历质控系统构建与实践. 医院管理理论论坛, 2021, 38(8): 83-84
- [37] 郝安琪, 沈洁. 基于自然语言处理的智能病历质控系统的设计与应用. 中国医疗设备, 2024, 39(12): 71-77
- [38] Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, et al. Attention Is All You Need. ArXiv abs/1706.03762 (2017): 1-15
- [39] J. Devlin, M. W. Chang, K. Lee, K. Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. ArXiv abs/1810.04805 (2018): 1-16
- [40] Radford, K. Narasimhan, T. Salimans, I. Sutskever. Improving language understanding by generative pre-training. OpenAI, 2018, 1: 1-12
- [41] H. W. Chung, L. Hou, S. Longpre, B. Zoph, Y. Tay, W. Fedus, et al. Scaling instruction-finetuned language models. Journal of Machine Learning Research, 2024, 25(70): 1-53
- [42] S. Longpre, L. Hou, T. Vu, A. Webson, H. W. Chung, Y. Tay, et al. The flan collection: Designing data and methods for effective instruction tuning, in: International Conference on Machine Learning, Honolulu, HI, USA, 23-29 Jul. 2023, Proceedings of the PMLR, 2023: 22631-22648
- [43] N. Muennighoff, T. Wang, L. Sutawika, A. Roberts, S. Biderman, T. L. Scao, et al. Crosslingual generalization through multitask finetuning. ArXiv abs/2211.01786 (2022): 1-119
- [44] V. Sanh, A. Webson, C. Raffel, S. H. Bach, L. Sutawika, Z. Alyafeai, et al. Multitask prompted training enables zero-shot task generalization. ArXiv abs/2110.08207 (2021): 1-216
- [45] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. Wainwright, P. Mishkin, et al. Training language models to follow instructions with human feedback. Advances in neural information processing systems, 2022, 35: 27730-27744
- [46] W. X. Zhao, K. Zhou, J. Li, T. Tang, X. Wang, Y. Hou, et al. A survey of large language models. ArXiv abs/2303.18223 (2023): 1-140

- [47]J. Schulman, F. Wolski, P. Dhariwal, A. Radford, O. Klimov. Proximal policy optimization algorithms. ArXiv abs/1707.06347 (2017): 1-12
- [48]R. Rafailov, A. Sharma, E. Mitchell, C. D. Manning, S. Ermon, C. Finn. Direct preference optimization: Your language model is secretly a reward model. Advances in Neural Information Processing Systems, 2023, 36: 53728-53741
- [49]E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, et al. Lora: Low-rank adaptation of large language models. ICLR, 2022, 1(2): 3-23
- [50]Q. Zhang, M. Chen, A. Bukharin, N. Karampatziakis, P. He, Y. Cheng, et al. AdaLoRA: Adaptive budget allocation for parameter-efficient fine-tuning. ArXiv abs/2303.10512 (2023): 1-17
- [51]T. Dettmers, A. Pagnoni, A. Holtzman, L. Zettlemoyer. Qlora: Efficient finetuning of quantized llms. Advances in neural information processing systems, 2023, 36: 10088-10115
- [52]N. Houlsby, A. Giurgiu, S. Jastrzebski, B. Morrone, Q. De Laroussilhe, A. Gesmundo, et al. Parameter-efficient transfer learning for NLP, in: International Conference on Machine Learning, Long Beach, CA, USA, 9-15 Jun. 2019, Proceedings of the PMLR, 2019: 2790-2799
- [53]X. L. Li, P. Liang. Prefix-tuning: Optimizing continuous prompts for generation. ArXiv abs/2101.00190 (2021): 1-15
- [54]B. Lester, R. Al-Rfou, N. Constant. The power of scale for parameter-efficient prompt tuning. ArXiv abs/2104.08691 (2021): 1-15
- [55]X. Liu, Y. Zheng, Z. Du, M. Ding, Y. Qian, Z. Yang, et al. GPT understands, too. AI Open, 2024, 5: 208-215
- [56]X. Liu, K. Ji, Y. Fu, W. L. Tam, Z. Du, Z. Yang, et al. P-tuning v2: Prompt tuning can be comparable to fine-tuning universally across scales and tasks. ArXiv abs/2110.07602 (2021): 1-8
- [57]P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, et al. Retrieval-augmented generation for knowledge-intensive nlp tasks. Advances in neural information processing systems, 2020, 33: 9459-9474
- [58]Y. Huang, J. Huang. A Survey on Retrieval-Augmented Text Generation for Large Language Models. ArXiv abs/2404.10981 (2024): 1-37

- [59]B. Peng, Y. Zhu, Y. Liu, X. Bo, H. Shi, C. Hong, et al. Graph retrieval-augmented generation: A survey. ArXiv abs/2408.08921 (2024): 1-41
- [60]D. Hendrycks, C. Burns, S. Basart, A. Zou, M. Mazeika, D. Song, et al. Measuring massive multitask language understanding. ArXiv abs/2009.03300 (2020): 1-27
- [61]M. Suzgun, N. Scales, N. Schärli, S. Gehrmann, Y. Tay, H. W. Chung, et al. Challenging big-bench tasks and whether chain-of-thought can solve them. ArXiv abs/2210.09261 (2022): 1-49
- [62]R. Zellers, A. Holtzman, Y. Bisk, A. Farhadi, Y. Choi. Hellaswag: Can a machine really finish your sentence?. ArXiv abs/1905.07830 (2019): 1-14
- [63]D. Hendrycks, C. Burns, S. Kadavath, A. Arora, S. Basart, E. Tang, et al. Measuring mathematical problem solving with the math dataset. ArXiv abs/2103.03874 (2021): 1-22
- [64]K. Cobbe, V. Kosaraju, M. Bavarian, M. Chen, H. Jun, L. Kaiser, et al. Training verifiers to solve math word problems. ArXiv abs/2110.14168 (2021): 1-22
- [65]Yang, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, et al. Qwen2.5 technical report. ArXiv abs/2412.15115 (2024): 1-26
- [66]A. Q. Jiang, A. Sablayrolles, A. Mensch, C. Bamford, D. S. Chaplot, D. de las Casas, et al. Mistral 7b. ArXiv abs/2310.06825 (2023): 1-9
- [67]A. Grattafiori, A. Dubey, A. Jauhri, A. Pandey, A. Kadian, A. Al-Dahle, et al. The llama 3 herd of models. ArXiv abs/2407.21783 (2024): 1-92
- [68]G. Team, M. Riviere, S. Pathak, P. G. Sessa, C. Hardin, S. Bhupatiraju, et al. Gemma 2: Improving open language models at a practical size. ArXiv abs/2408.00118 (2024): 1-21
- [69]A. Yang, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, et al. Qwen2.5 technical report. ArXiv abs/2412.15115 (2024): 1-26
- [70]D. Edge, H. Trinh, N. Cheng, J. Bradley, A. Chao, A. Mody, et al. From local to global: A graph rag approach to query-focused summarization. ArXiv abs/2404.16130 (2024): 1-26
- [71]X. Wang, G. H. Chen, D. Song, Z. Zhang, Z. Chen, Q. Xiao, et al. Cmb: A comprehensive medical benchmark in chinese. ArXiv abs/2308.08833 (2023): 1-22
- [72]J. Achiam, S. Adler, S. Agarwal, L. Ahmad, I. Akkaya, F. L. Aleman, et al. Gpt-4

- technical report. ArXiv abs/2303.08774 (2023): 1-100
- [73] A. Young, B. Chen, C. Li, C. Huang, G. Zhang, G. Zhang, et al. Yi: Open foundation models by 01.ai. ArXiv abs/2403.04652 (2024): 1-26
- [74] A. Yang, B. Xiao, B. Wang, B. Zhang, C. Bian, C. Yin, et al. Baichuan 2: Open large-scale language models. ArXiv abs/2309.10305 (2023): 1-28
- [75] T. GLM, A. Zeng, B. Xu, B. Wang, C. Zhang, D. Yin, et al. Chatglm: A family of large language models from glm-130b to glm-4 all tools. ArXiv abs/2406.12793 (2024): 1-19
- [76] I. Team. Internlm: A multilingual language model with progressively enhanced capabilities. Aminer (2023): 1-19
- [77] A. Q. Jiang, A. Sablayrolles, A. Roux, A. Mensch, B. Savary, C. Bamford, et al. Mixtral of experts. ArXiv abs/2401.04088 (2024): 1-13