

分类号_____

U D C _____

密级_____

编号 10736

西北师范大学

硕士学位论文

(专业学位)

基于知识图谱和大语言模型的医疗
辅助诊断系统

研究生姓名: 高福财

指导教师姓名、职称: 何廷年 副教授

实践指导教师姓名、职称: 刘晓光 高级工程师

专业学位类别: 电子信息

专业学位领域: 计算机技术

专项计划: _____

二〇二五年五月

Medical-Assisted Diagnosis System Based on Knowledge Graphs and Large Language Models

A Thesis Submitted to
Northwest Normal University
in partial fulfillment of the requirement
for the degree of
Master of Electronic Information

by

Gao Fucai

Supervisor : Associate Professor He Tingnian

Supervisor for Practice Guiding: Senior Engineer Liu Xiaoguang

May, 2025

摘要

随着医疗技术的不断进步和医疗数据的爆炸式增长,疾病诊断的精准度和效率得到了极大提升,但同时也面临着如何从海量数据中有效提取关键信息等新的挑战。大语言模型(LLMs)凭借其强大的推理能力和对大规模文本语料的学习,能够处理复杂的医疗数据并生成上下文相关的信息,从而为医疗诊断提供支持。但LLMs在医疗应用中也面临着诸多挑战,如幻觉问题(生成不准确或虚假信息)、缺乏可解释性、计算效率低等,这些问题限制了其在高可靠性要求医疗场景中的应用。针对上述问题进行了如下工作:

(1)大型语言模型(LLMs)中的幻觉、专业领域知识不足等问题可通过引入外部知识图谱来缓解。但现有方法在知识获取中精度不足且检索速度缓慢。因此提出了一种新的知识增强信息检索方法——全局修剪检索(Global Pruning Retrieval, GPR)。为从知识图谱中获取知识,通过广度优先搜索(BFS)检索相关关系及实体,并以全局视角修剪提取高度相关的关系及实体形成实体子图。同时将获得的多个实体子图通过最短路径进行关系连接。将关系及实体转化为提示词推送到LLMs,引导LLMs推理生成结果。在多个普通文本问答数据集上的实验结果表明GPR方法在Hits@1可提高5%左右,医疗文本数据集上Bert-score可提高1%左右。

(2)LLMs的幻觉问题和错误信息传播的风险可对患者的健康造成严重威胁,因此事实核查是确保LLMs输出内容具有真实性和可靠性的关键环节。现有方法通常只从声明分解或对比论证一个方面进行工作,性能不足。因而提出了一种新的快速事实核查方法。通过聚合生成支持和反驳对比论证进行独立核查的方法,以及将复杂的声明分解为若干原子事实,并对每个原子事实进行独立核查的方法对声明的真实性进行分级。运用模型参数高效微调方法(PEFT)对Flan-T5-Large模型进行微调,模型在医疗文本分类任务上展现出高准确率,Micro-F1可提高3%左右。

(3)实现了一种基于知识图谱和大语言模型进行辅助的医疗诊断系统,通过输入患者患病情况,采用改进的知识图谱检索算法精准快速地检索相关知识并提示给LLMs,使得LLMs综合分析患者的病情,给出患者的病情报告及可行的治疗方案,再次经过事实核查模块,进行事实核查确保LLMs推理结果真实有效,将结果和推理过程呈现到使用者面前,供其进行参考以达到辅助诊断的目的。

关键词: 知识图谱; 大语言模型; 事实核查; 辅助诊断

Abstract

With the continuous advancement of medical technology and the explosive growth of healthcare data, the accuracy and efficiency of disease diagnosis have been greatly improved. However, new challenges have emerged, such as how to effectively extract key information from massive data. Large Language Models (LLMs), with their powerful reasoning capabilities and training on large-scale textual corpora, can handle complex medical data and generate context-relevant information, thus providing support for medical diagnosis. Nevertheless, LLMs face numerous challenges in medical applications, such as hallucination (generating inaccurate or false information), lack of interpretability, and low computational efficiency, which limit their application in high-reliability medical scenarios. To address these problems, the following work has been carried out:

(1) The issues of hallucination and insufficient domain-specific knowledge in Large Language Models (LLMs) can be alleviated by incorporating external knowledge graphs. However, existing methods suffer from low accuracy in knowledge retrieval and slow retrieval speed. Therefore, a novel knowledge-enhanced information retrieval method—Global Pruning Retrieval (GPR)—is proposed. To retrieve knowledge from knowledge graphs, relevant relations and entities are retrieved through Breadth-First Search (BFS), and highly relevant relations and entities are extracted with a global pruning strategy to form an entity subgraph. Multiple entity subgraphs are then connected via shortest paths. The resulting relations and entities are transformed into prompts and fed into LLMs to guide their reasoning and generation. Experimental results on several general text-based QA datasets show that the GPR method improves Hits@1 by approximately 5%, and on medical text datasets, it improves BERTScore by about 1%.

(2) The hallucination problem and the risk of misinformation in LLMs can pose serious threats to patient health. Therefore, fact verification is a key step to ensure the truthfulness and reliability of LLM-generated content. Existing methods usually work from only one aspect, such as claim decomposition or comparative argumentation, resulting in limited performance. Hence, a new rapid fact verification method is proposed. This method combines two approaches: one that aggregates the independent verification of generated supportive and refutative arguments, and another that decomposes complex claims into several atomic facts for independent verification. These approaches together

provide a graded assessment of claim veracity. By applying Parameter-Efficient Fine-Tuning (PEFT) to the Flan-T5-Large model, the system achieves high accuracy on medical text classification tasks, improving Micro-F1 by approximately 3%.

(3) A medical diagnosis system based on knowledge graphs and large language models is implemented. By inputting the patient's condition, the system uses an improved knowledge graph retrieval algorithm to quickly and accurately retrieve relevant knowledge and provide it as prompts to LLMs. LLMs then perform a comprehensive analysis of the patient's condition, generate a medical report and feasible treatment plan. The output is passed through the fact verification module to ensure the reasoning result is factual and valid. Finally, both the result and the reasoning process are presented to users for reference, achieving the goal of assisting in diagnosis.

Keywords: Knowledge Graphs; Large Language Models; Fact-Checking; Diagnostic Support

目 录

第 1 章 绪论.....	1
1.1 研究背景和意义.....	1
1.2 国内外研究现状.....	2
1.2.1 知识图谱增强大语言模型.....	3
1.2.2 事实核查模型.....	4
1.3 本文研究内容.....	5
1.4 论文结构安排.....	6
第 2 章 相关技术	8
2.1 知识图谱技术概述.....	8
2.1.1 知识图谱的定义与结构.....	8
2.1.2 知识图谱的构建.....	8
2.2 大语言模型架构与推理过程	9
2.2.1 大语言模型的架构.....	9
2.2.2 大语言模型的训练过程.....	11
2.2.3 大语言模型的推理过程.....	12
2.3 事实核查技术.....	13
2.3.1 事实核查技术概述.....	13
2.3.2 事实核查的核心技术与方法.....	13
2.4 评估指标.....	14
2.5 本章小结.....	14
第 3 章 知识图谱全局检索增强辅助诊断	15
3.1 全局修剪检索.....	15
3.2 知识图谱实体关系树挖掘	15
3.2.1 实体关系树检索.....	15
3.2.2 实体关系树全局修剪.....	17
3.2.3 实体间路径检索.....	19
3.3 多实体关系树融合及推理	19
3.3.1 多实体关系树融合.....	19
3.3.2 实体关系网络图的 LLMs 推理.....	19
3.4 实验及分析.....	20
3.4.1 普通文本知识问答.....	20
3.4.2 医疗知识问答.....	22
3.5 本章小结.....	25
第 4 章 核查辅助诊断内容事实模型	26

4.1 多任务学习的事实核查模型	26
4.2 事实核查增强方法.....	27
4.2.1 事实核查的证据增强方法.....	27
4.2.2 事实核查的声明分解方法.....	27
4.3 事实核查模型.....	28
4.4 实验及分析.....	29
4.4.1 实验数据	29
4.4.2 微调模型	30
4.4.3 生成论证和声明分解数据.....	32
4.4.4 事实核查模型训练.....	32
4.5 本章小结.....	34
第5章 检索增强的大语言模型辅助诊断系统	35
5.1 系统分析.....	35
5.1.1 功能需求分析.....	35
5.1.2 非功能需求分析.....	37
5.2 系统设计.....	37
5.2.1 系统整体框架.....	37
5.2.2 系统功能框架.....	39
5.2.3 系统业务流程设计	39
5.3 系统数据库设计.....	40
5.3.1 逻辑结构设计.....	40
5.3.2 存储结构设计.....	41
5.4 系统实现.....	43
5.4.1 患者信息端模块.....	43
5.4.2 系统管理端模块.....	46
5.4.3 知识图谱数据库.....	46
5.4.4 大语言模型诊断建议生成模块.....	47
5.4.5 核查证据检索模块.....	48
5.4.6 事实核查模块.....	49
5.4.7 系统功能测试.....	50
5.5 本章小结.....	50
结论.....	52
参考文献.....	54

第1章 绪论

1.1 研究背景和意义

随着科学技术的发展,医疗诊断技术也在不断发展。传统的医疗诊断主要依赖医生的经验和专业知识,但这种方法在面对大量的病例和医疗数据时往往存在局限性。为了提高诊断的准确性和效率,辅助诊断系统应运而生。辅助诊断系统(Assisted Diagnosis System)利用计算机技术、人工智能算法和医学知识对患者的医疗数据进行分析和处理为医生提供诊断建议和决策支持^[1]。

早期的辅助诊断系统主要依赖专家经验和规则引擎,通过预定义的规则、逻辑或基于病例数据库的相似性推理来生成诊断建议。这些系统在处理简单、规则明确的病例时表现出色,但在面对复杂、不确定性的病例时其性能往往不尽人意,且这类传统系统往往面临知识更新滞后、处理能力有限和可扩展性差等问题^[2,3]。

随着大型语言模型(LLMs)的发展,医疗辅助诊断系统迎来了新的机遇^[4]。大语言模型有着强大的推理能力,人工智能(AI)在医疗保健中的应用正在增加。LLMs与预测性AI不同,LLMs利用对大型文本语料库的广泛预训练,以及在特定的医学数据集上进行微调,以实现医学语言和概念的深入理解^[5]。LLMs能够处理大量的医疗数据,将其综合分析并生成上下文高度相关的信息^[6]。通过学习大量的医疗数据可自动提取特征和模式,可以生成更加准确的诊断决策^[7]。可根据最新的医学文献推荐个性化治疗计划,提供实时的决策支持,并在提高诊断效率、降低医疗错误、优化医疗资源配置等方面发挥作用^[8,9],这可改善医疗服务,简化临床的工作流程。这是LLMs在医疗系统中应对日益复杂和资源限制的一个重要优势。

在实际应用中,国内的华佗GPT、仲景、扁鹊等中文医疗大模型以及国外的IBM watsonx Assistant和Microsoft Cloud for Healthcare等医疗平台都利用人工智能进行疾病预测、影像分析和医疗决策支持,极大地提高了诊断的精度和效率。其中ChatGPT在被认为在临床决策^[10,11]、诊断^[12]和症状评估方面有着很好的准确性。

我国“十四五”规划中明确“聚焦人工智能、生物医药组建一批国家实验室,瞄准人工智能、生命健康等前沿领域,实施一批具有前瞻性、战略性的国家重大科技项目”^[13]。由此可见人工智能和生命健康领域在中国国民经济规划中的地位正在不断提高。AI医疗是中国医疗行业转型升级的发展重点,为更好地规范和促进中国医疗卫生事业的发展,国家及相关主管部门制定了一系列的支持、指导和规范

类政策，旨在完善 AI 医疗应用标准体系，同时更大力度地探索人工智能辅助诊疗和人工智能远程医疗应用。除了中共中央、国务院等部门颁布一系列政策外，各省市同样出台了一些举措来指导 AI 医疗行业的发展。主要方向为促进 AI 大数据模型的医疗场景应用，推动 AI 医疗在基层医疗领域覆盖等。因此通过对智慧医疗方面的应用研究可响应国家政策，促进智慧医疗行业的发展。

随着技术的不断进步和政策的持续引导，大型语言模型在医疗辅助诊断中将进一步提升诊断的准确性和效率，优化医疗资源配置，推动医疗行业的智能化升级，将成为智慧医疗发展的重要方向，为临床诊疗提供更强有力的支持。

1.2 国内外研究现状

尽管基于人工智能大语言模型的辅助诊断系统在医疗领域已经取得了显著的进展，但现有的系统仍存在一些局限性。大模型主要依靠在训练时所能记忆的知识，这些知识是非即时的，数据中也可能包含错误、偏见或不准确的信息，在回答问题时 LLMs 需要回忆相关知识，在某些情况下 LLMs 可能会产生与事实知识相冲突的不真实信息，这被称为幻觉问题^[14,15]。在自然语言生成领域（Natural Language Generation, NLG）中幻觉问题阻碍模型的性能发挥，且引发现实应用中的安全问题。在医疗应用中，对患者的信息生成摘要，幻觉问题可能会对患者的安全构成威胁^[16]。关于病情、治疗或药物相互作用的不准确信息也可能导致有害的医疗决策^[17]。同时 LLMs 作为黑盒模型，在生成医疗诊断建议时，缺乏透明度和可解释性，难以对其回答进行解释和验证。这些问题使得 LLMs 在医疗诊断等某些高风险的场景下的应用受限。且现有的系统在处理大规模医疗数据时，计算效率较低，难以满足实际医疗场景中的实时性要求^[18]。

目前幻觉及可解释性问题可通过指令调优、整合外部知识库和改进提示技术、事实核查等策略来大幅度缓解^[19]，而安全性方面主要靠电子护栏进行防护。指令调优可以显著提高下游任务的性能并缓解幻觉问题^[20]。指令调优可以使模型更真实地表示不确定的回答有助于减少幻觉，但对提高事实性帮助不大，与知识图谱相比，语言模型在事实知识方面仍存在不足，需要用微调和知识图谱联用的混合方式进行解决^[21]。简单微调对于特定领域的任务来说可能是次优的，因为它们不能涵盖所有领域的知识^[22]。

而知识图谱（Knowledge Graphs, KG）可以提供丰富的结构化知识事实来帮助大语言模型更好地理解语言，知识图谱中的信息实体可以增强模型的语言表达^[23]，也可以通过增强的外部知识为推理过程提供指导来提高模型性能^[24]。

电子护栏中的事实核查模块可通过对 LLMs 的输出内容进行事实性核查评估，

提高其可信度与事实性^[25]。同时电子护栏还可解决 LLMs 中越狱问题和安全漏洞问题，防止操纵模型绕过内置的保护措施，从而生成有害、不适当内容^[26]。

因此本章节主要介绍知识图谱与大语言模型的结合及事实核查模型的研究现状。

1.2.1 知识图谱增强大语言模型

随着人工智能、自然语言处理（NLP）和大数据技术的快速发展，医疗辅助诊断系统在全球范围内得到了广泛的研究与应用。国内外的研究者围绕智能化医疗系统的构建和应用，尤其是知识图谱与大语言模型（LLMs）的结合，取得了许多显著成果。

在自然语言处理和人工智能领域，知识图谱作为一种结构化的知识表示方式，包含了丰富的实体、属性和关系信息，可以为语言模型提供丰富的语义知识，从而提升模型在各种任务中的性能，因而知识图谱与语言模型相结合已经成为了研究的热点之一^[27,28]。随着 LLMs 的发展及 LLMs 缺陷的发现，研究人员开始探索如何将知识图谱与最先进的语言模型相结合，通过信息增强的方式以进一步提高自然语言处理系统的效果^[29]。

一些工作探索了如何通过修改结构将知识图谱与语言模型进行融合，以及如何将知识图谱中的实体和关系信息融入到语言模型的训练过程中，以增强其语义表示能力^[23,30]。这些方法通常是将知识图谱中的实体和关系映射到语言模型的词嵌入空间中，将语言实体经过编码器进行编码，并利用图神经网络进行信息汇聚，获得相关信息的嵌入表示并通过语言模型的推导获得最终表示。通过这种方式，语言模型可以更好地理解输入文本中涉及到的实体和关系，从而提高其在各种任务中的性能。在 KEPLER（Knowledge Embedding and Pretrained Language Representation）方案中对查找的三元组中头尾实体和关系分别进行编码并嵌入语言模型，提高了模型对于实体间关系的理解^[31]。但在信息汇聚的过程会导致图关系信息及结构信息的丢失。

如何利用知识图谱中的外部知识来引导语言模型的生成过程，以生成更加准确和连贯的文本。这些方法通常会利用知识图谱中的实体和关系信息来指导语言模型生成文本的过程，从而使得生成的文本更加符合语义逻辑和常识推理^[32]。这种方法在文本生成、问答系统等任务中取得了一定的效果，为进一步提高语言模型的生成能力提供了新的思路。

对于图上信息检索，Baek 等人提出根据输入文本的表征相似性直接从 KG 中检索事实的框架 Di-FaR（Direct Fact Retrieval），通过语言模型将 KG 中的所有事

实嵌入到密集的嵌入空间中,然后根据输入文本提供最接近的事实^[33]。Luo 等人提出一种关系感知子图检索 RASR (Relation-Aware Subgraph Retrieval) 方法根据关系语义进行初始化和子图修剪,并提出一个关系感知推理网络 RARN (Relation-Aware Reasoning Network) 用于问题语义理解的文本推理和主题实体和答案之间拓扑结构的挖掘^[34]。

LLMs 有着强大的推理能力,为能够充分检索信息,Jiang 等人则是通过 SQL 语句在图数据库中进行搜索与问题中实体相连的关系及实体,并将其线性化为 LLMs 可以理解的文本句子,使得 LLMs 根据提供的信息进行推理^[35]。但是问题相关的三元组数量通常太大,无法在 LLMs 中转发,此外,它们中的大多数与问题无关,误导 LLMs 生成不相关的答案。KAPING (Knowledge-Augmented language model PromptING) 方案中则是通过查找给定问题相关的前 K 个相似的三元组进行查找,有效地防止 LLMs 因计算效率生成不相关的答案^[36]。

受信息检索的启发,Baek J 等人根据问题及其相关实体间的语义相似性从知识图中检索相关实体,并以提示的形式将检索到的信息添加到输入问题中,将其转发给 LLMs 以生成答案^[37]。Sun 等人提出的 ToG (Think-on-Graph) 方案,通过 LLMs 进行边推理边筛选的方式,以贪婪算法搜索并修剪语义相似性低的枝杈,确保了所搜索信息的质量。这种方法虽然能够充分利用数据,但其搜索过程需要多次调用 LLMs,耗时较长,且面对多实体问题时并未有更好的方法进行联系推理^[38]。Wen 等人的 MindMap 方案则是通过构建思维导图,使得 LLMs 在该思维导图上进行推理并生成答案,该方案增加了多实体间的联系。该方法在知识子图邻居节点信息检索中采用了与 ToG 相似的策略,但同样面临效率低的问题^[39]。

1.2.2 事实核查模型

医疗 LLMs 中的幻觉、偏见传播和错误信息所带来的挑战需要精确的评估方案来确保安全性和可靠性。因 LLMs 的自我验证可能会使成本增加一个数量级^[40],所以通常另外建立一个事实核查模型。近年来事实检查器通常首先将文档分解为一组原子声明,然后根据检索到的证据逐一验证该声明是真是假,确认独立主张的典型事实与对话中提出的主张是否存在矛盾。

Gupta 等人提出在标记的对话数据上微调这些模型^[41]。然而为每个用例创建单独的模型是不切实际的,微调对话模型会导致典型事实检查的性能不佳。为了克服这一挑战,Chamoun 提出检索适应和转换对话输入相关技术,能够使用相同的模型进行对话和典型的事实检查,以便能够在独立主张上的模型准确预测^[42]。但是模型的功效仅在一个数据集上表现出了很高的准确性。医疗辅助诊断中对话环境

是复杂的，泛化性过低不能胜任这项任务。

因此 Yang 等人则提出了一种标签自适应的自我理性化方法，通过对模型进行微调以学习真实性预测，并再次微调以学习自我理性化的同时使用相同的标签和额外的注释解释^[43]。这种方法允许模型更有效地适应新领域。在 PubHealth 和 AVeriTec 数据集上标签自适应方法显著提高了真实性预测性能，超过了 GPT-4 模型。通过使用大型语言模型生成少量合成解释可有效减少对标注解释的依赖。但在处理具有不同标签方案的现实世界事实核查时，直接应用自我理性化方法可能会导致性能下降。

Yue 等人则提出了 RAFTS (Retrieval Augmented Fact Verification by Synthesizing Contrastive Arguments) 框架，该框架通过检索相关文档并基于检索到的证据形成对比论证（支持或反驳），利用嵌入模型识别信息性示例并通过上下文提示生成预测和解释^[44]。该方法有效地检索相关文档并从不同角度评估论点进行决策。在多个基准数据集上表现出色，即使使用较小的 7B LLM 也能超越基于 GPT 的方法。通过结合信息性上下文示例，RAFTS 能够生成高质量的解释。但其完全靠 LLMs 总结概括导致部分论点上可靠性不足。

Tang 等人则通过使用 GPT-4 构建合成训练数据创建具有挑战性的事实错误实例训练，MiniCheck 模型检查每个事实并识别跨句子的信息合成^[45]。MiniCheck 在新的统一基准 LLM-AGGREFACT 上表现可与 GPT-4 相当，但成本可低 400 倍。该文章提出了两种合成数据生成方法解决了基于文档的事实核查中的挑战。其中 LLM-AGGREFACT 数据集统一了所有设置下的人工标注模型响应，并在事实检查器的评估表现中 MiniCheck 在性能和成本效益方面均优于其他方法，但 MiniCheck 在处理复杂或模糊的声明时可能会出现性能下降的情况。

因此在知识图谱增强大语言模型方面如何更好更快地计算关系及实体与问题的语义相似性和筛选路径是两个重要问题。而事实核查在处理复杂声明方面及处理速度上有着改进空间。

本文提出一种基于知识图谱和大语言模型的辅助诊断系统，通过知识图谱全局检索增强和电子护栏事实核查技术，旨在提高诊断准确性、可解释性、内容事实性和计算效率，为医疗诊断提供更全面、更准确、更可靠的解决方案。

1.3 本文研究内容

(1) 提出了一个新的知识增强的信息检索方案 GPR，该方案在检索过程中使用 BFS 搜索形成实体关系树，并以全局视角通过语义相似性进行修剪，即从整棵实体关系树进行评估，选取最相关的部分实体，去除多于信息，使其信息更加精简。

在面对多个实体的查询时，多个单实体关系树相互连接成更大的树，能够提示 LLMs 进行更加有效的推理。并在多个普通文本问答数据集和医疗文本问答数据集上进行验证。实验结果表明，GPR 方案相较于其他方案具有更高的检索精度和检索速度，可快速精准地检索 LLMs 需要的相关知识。

(2) 提出了一种多任务学习的高效事实核查模型。首先增强论证，在检索证据的基础上生成对比论证，进行事实核查。其次是对声明进行分解，分解成原子事实，对原子事实进行事实核查。最终将对比增强和声明分解的结果进行合并。使用多个数据集进行微调训练并评估了这种核查方法的有效性。该事实核查方法可有效提高实施核查可靠性和准确性，减少错误信息的发生风险。

(3) 实现了一种基于知识图谱和大语言模型的辅助诊断系统。该系统首先通过输入患者患病情况，经过(1)(2)两模块的处理将结果和推理过程呈现到使用者面前，供其进行参考以达到辅助诊断的目的。并完成相关系统的前端页面和后端其他组件编写，形成一个相对完整的辅助诊断系统。

1.4 论文结构安排

本文从基于知识图谱和大语言模型的辅助诊断系统研究现状出发，重点针对知识图谱知识检索算法展开了研究与应用。论文结构安排如下：

第 1 章 绪论。本章探讨了人工智能(AI)在医疗辅助诊断研究中的背景和意义，尤其是在大语言模型(Large Language Models, LLMs)结合知识图谱的广泛应用背景下系统地梳理了当前针对大语言模型在辅助诊断领域的各类研究工作，并对这些研究进行了深入分析与评述。在总结现有研究成果与局限的基础上明确了本文的研究目标和重点，为后续章节的深入探讨奠定了理论基础。最后阐述了本论文主要工作和结构安排。

第 2 章 相关技术。本章详细介绍了大语言模型辅助诊断系统中使用的相关技术，其中涉及知识图谱的基本理论与关键技术、大语言模型的架构和推理以及事实核查技术。该部分为后续章节的模型构建与优化提供了理论基础。

第 3 章 知识图谱全局检索增强辅助诊断。本章提出了一种基于知识图谱和大语言模型的检索方案。在知识图谱中存储医疗领域的知识，通过检索和修剪方案实现了对有关知识的提取并提示到大语言模型。最后详细介绍了相关的实验配置和实验数据集，并对所提出的优化方案进行评估。

第 4 章 核查辅助诊断内容事实模型。本章重点探讨了如何利用事实核查模块对 LLMs 输出进行核查。通过综合分析结合现有工作，融合事实声明分解和证据增强两种方案，使用多任务学习方案提高了模型的精确性和稳定性。最后介绍了实

验相关的实验方案、实验结果和评估改进方法的有效性。

第5章 医疗辅助诊断系统实现。本章结合先前两章节的研究成果进行整合构建了一个结合知识图谱进行辅助增强的大语言模型，通过大语言模型综合分析患者情况获得患者身体情况的报告。该系统实现了相关方案并进行实际应用。系统通过对患者病情的历史信息综合了解能够更准确地推理出患者的问题并推荐合适的治疗方案，从而提高医生诊断的效率。

结论。对本文的研究工作进行分析总结，并对未来人工智能在辅助诊断领域的工作进行了展望。

图 1-1 对论文结构进行了详细展示。




图 1-1 论文结构安排

第2章 相关技术

本章主要介绍了与本文研究内容相关的技术。由于本文的工作内容围绕知识图谱、大语言模型、事实核查计算展开，因此本章将分别介绍相关概念及其研究成果。

2.1 知识图谱技术概述

知识图谱（Knowledge Graph, KG）是一种结构化的语义知识库，其主要用于描述实体及其之间的关系。知识图谱通过图结构表示知识，其中节点代表实体，边代表实体之间的关系。知识图谱的核心在于将复杂的知识以一种易于理解和处理的方式表示出来，从而为各种应用提供丰富的语义信息和上下文关系。

2.1.1 知识图谱的定义与结构

知识图谱是由实体（Entities）、关系（Relations）和属性（Attributes）组成的图结构。实体是知识图谱中的基本单元，实体代表现实世界中的对象，如人、地点、组织、疾病、药物等。关系表示实体之间的语义联系，例如“属于”、“位于”、“治疗”等。属性则描述实体的特征，如人的年龄、地点的坐标、药物的副作用等。以本研究所使用的知识图谱为例：

- （1）实体：肺气肿、小支气管粘膜水肿、纵隔浊音界扩大等。
- （2）关系：诊断检查、常用药品、并发症、可能患有疾病、症状等。
- （3）属性：id、name 等。

这个图谱不仅描述了实体本身，还通过关系和属性提供了丰富的上下文信息，使得大语言模型能够更好地理解和处理这些知识。

2.1.2 知识图谱的构建

知识图谱的构建通常包括以下几个步骤：

- （1）知识获取：从各种数据中提取知识，比如结构化数据（如数据库）、半结构化数据和非结构化数据。常见的知识获取方法包括爬虫技术、文本挖掘和数据清洗。

- （2）实体识别：从文本中识别实体通常使用自然语言处理技术，如命名实体

识别（Named Entity Recognition, NER）。例如从句子“使用感冒灵颗粒治疗感冒”中识别出实体“感冒灵颗粒”和“感冒”。

（3）关系抽取：识别实体之间的关系通常使用关系抽取技术，如基于规则的方法、机器学习方法和深度学习方法。例如从句子“使用感冒灵颗粒治疗感冒”中抽取关系“治疗”。

（4）知识融合：将从不同数据源获取的知识进行整合用于解决实体和关系的歧义问题。例如将不同数据源中表示同一实体的条目合并为一个唯一的实体。

（5）知识存储：将构建好的知识图谱存储在图数据库中，例如 Neo4j 等数据库。这些数据库专门用于存储和查询图结构数据，能够高效地处理复杂的图查询。Neo4j 数据库中存储的知识图谱数据如图 2-1 所示。




图 2-1 Neo4j 数据库知识图谱图展示

2.2 大语言模型架构与推理过程

2.2.1 大语言模型的架构

大语言模型（Large Language Models, LLMs）是基于深度学习的自然语言处理（NLP）技术，其能够理解、生成和推理人类语言。随着模型规模的不断扩大和数据量的激增，LLMs 在多个领域展现了显著的优势，尤其是在文本生成、机器翻译、文本理解和问答等任务中取得了重要进展。大语言模型通常基于 Transformer

架构，其核心在于自注意力机制能够使模型高效地处理长文本的依赖关系。

(1) Transformer 架构^[46]

Transformer 架构是大语言模型的基础，首次由 Vaswani 等人在 2017 年提出。与传统的循环神经网络 (RNN)^[47]和长短期记忆网络 (LSTM)^[48]不同，Transformer 通过自注意力机制 (Self-Attention) 使得每个输入元素都能同时与其他所有元素进行交互，这种机制解决了 RNN 和 LSTM 处理长序列时出现的梯度消失和计算效率低下的问题。Transformer 模型架构如图 2-2 所示。

Transformer 模型由两个主要部分组成：编码器 (Encoder) 和解码器 (Decoder)。编码器负责对输入序列进行编码，捕捉词与词之间的语义关系。编码器通过自注意力机制来处理输入数据中的长程依赖关系并输出一个向量表示。在生成任务中解码器逐步生成输出序列。在每一步中解码器都会基于前一时刻的输出和编码器提供的上下文信息来生成当前词。

在大多数大语言模型中通常只使用 Transformer 的编码器或解码器的一个部分。例如 GPT 系列采用了基于自回归的解码器架构，BERT 则使用了基于自注意力的编码器架构。




图 2-2 Transformer 模型架构

(2) 自注意力机制

自注意力机制 (Self-Attention) 是 Transformer 架构的关键创新。它通过计算输入序列中每个词与其他词之间的注意力得分来捕捉词之间的上下文关系。自注意力机制具有并行化处理、长距离依赖和灵活的表示能力等优点, 如式 2-1 及式 2-2 所示。

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right)\mathbf{V} \quad (2-1)$$

$$\begin{aligned} \text{MultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) &= \text{Concat}(\text{head}_1, \dots, \text{head}_h)\mathbf{W}^O \\ \text{where } \text{head}_i &= \text{Attention}(\mathbf{Q}\mathbf{W}_i^Q, \mathbf{K}\mathbf{W}_i^K, \mathbf{V}\mathbf{W}_i^V) \end{aligned} \quad (2-2)$$

公式 2-1 和公式 2-2 中同时在一组查询上计算注意力函数, 并将其填充到矩阵 $\mathbf{Q}$ 中。键和值也被填充到矩阵 $\mathbf{K}$ 和 $\mathbf{V}$ 中, 参数矩阵 $\mathbf{W}_i^Q \in \mathbb{R}^{d_{\text{model}} \times d_k}$ 、 $\mathbf{W}_i^K \in \mathbb{R}^{d_{\text{model}} \times d_k}$ 、 $\mathbf{W}_i^V \in \mathbb{R}^{d_{\text{model}} \times d_v}$ 和 $\mathbf{W}^O \in \mathbb{R}^{hd_v \times d_{\text{model}}}$, h 为平行的注意力层的层数, $d_k = d_v = d_{\text{model}} / h$ 。

传统的 RNN 需要逐步处理序列中的每个元素, 而自注意力机制能够同时处理所有输入, 极大提高了计算效率。自注意力机制能够直接捕捉序列中任何两个位置之间的依赖关系, 尤其是对于长文本或复杂句子的处理能够更好地理解上下文。且自注意力机制通过计算不同词之间的加权关系能够灵活地捕捉到语言中的复杂语义关系。

2.2.2 大语言模型的训练过程

大语言模型的训练通常分为两个阶段: 预训练 (Pre-training) 和微调 (Fine-tuning)。这两个阶段的结合使得模型能够从大规模的未标注数据中学习通用语言知识并通过微调来适应具体的应用任务。

(1) 预训练阶段

在预训练阶段模型通过无监督学习从大量的文本数据中学习语言的基本知识。常见的预训练目标包括: 自回归语言模型 (Autoregressive Model)、掩码语言模型 (Masked Language Model, MLM) 和去噪自编码 (Denoising Autoencoder)。

常见自回归语言模型, 例如 GPT 系列模型根据前文生成下一个词。在训练时模型通过最大化给定上下文的条件概率来学习生成文本的能力。

掩码语言模型有 BERT 系列模型, 模型通过掩盖输入文本中的一些词, 并让模型预测这些被掩盖的词来训练。与自回归模型不同, BERT 采用的是双向上下文, 能够同时考虑左右两个方向的信息。

去噪自编码, 例如一些变种模型如 T5, 使用去噪自编码任务来训练模型, 通过扰动输入文本并要求模型恢复原始内容来进行训练。

预训练通常使用海量的语料库，模型通过处理这些数据来学习语言的基本结构，包括语法、语义以及词汇的搭配等。这一阶段不依赖于人工标注数据，能够利用大量的开放文本数据进行训练。

（2）微调阶段

在微调阶段，模型会根据具体的任务进行有监督学习。在这个阶段，模型会使用标注数据来进一步调整参数，以适应特定的应用场景。例如，针对医学诊断任务，可以用标注的病历数据进行微调，使得模型能够更准确地理解和生成与医疗相关的文本。

微调的目标是让模型能够将其在预训练阶段学到的语言知识迁移到具体任务中，使得它能够更好地处理领域特定的任务，例如疾病诊断、医学文献分析、患者问答等。

2.2.3 大语言模型的推理过程

大语言模型的推理过程指的是模型在训练完成后，基于输入数据生成输出的过程。推理过程包括以下几个步骤：

（1）输入处理

首先输入文本通过嵌入层（Embedding Layer）转化为词向量或子词向量。大语言模型通常采用词级或子词级的嵌入方式，将输入序列中的每个词转化为一个高维向量表示，例如 Word2Vec、BERT 的 WordPiece 或 GPT 的 Byte Pair Encoding。

（2）上下文编码

经过自注意力机制的处理，模型能够计算输入序列中每个词与其他词之间的相关性。这一过程是通过自注意力层完成的，模型通过对输入的每个词赋予不同的权重，从而捕捉到上下文信息。

通过多层自注意力和前馈神经网络的堆叠，Transformer 能够对输入数据中的复杂关系进行建模，最终输出每个词的上下文表示。

（3）输出生成

对于文本生成、问答系统等生成任务，模型根据当前的上下文信息逐步生成输出。GPT 等自回归模型通过每次生成一个新的词，并将生成的词与当前的上下文信息一起输入模型，以此类推直到生成完整的输出序列。

在情感分析、医学诊断分类等分类任务中，大语言模型通过计算每个类别的概率分布，选择概率最高的类别作为输出结果。

（4）推理优化

推理过程中，大语言模型的生成结果常常通过一些优化技巧进行调整，例如：

束搜索（Beam Search）通过同时探索多个生成路径来提高生成文本的质量。温度调节（Temperature Scaling）通过控制生成过程中的随机性来调整输出的多样性和创造性。Top-K 采样和 Top-P 采样控制生成词汇的选择，避免生成过于单一或常见的词。

2.3 事实核查技术

2.3.1 事实核查技术概述

事实核查技术是指通过对数据、文本或知识图谱的分析，验证问答结果是否符合真实、可信的信息来源的一种技术方法。在医疗辅助诊断场景下，其主要作用包括：

（1）输出答案的真实性验证：确保 LLMs 输出的诊断建议符合权威医学指南和已知医疗知识。

（2）错误信息的识别与过滤：避免因错误信息导致误导性诊断建议，提高系统的鲁棒性。

（3）结果解释性增强：通过事实核查为输出提供可溯源的依据，提升问答系统的可信度和用户信任感。

事实核查（Fact Verification）技术在医疗辅助诊断问答系统中具有重要作用，尤其是当大语言模型（LLMs）作为问答核心时，模型生成的自然语言答案可能因数据偏差或泛化能力不足而出现事实不准确、推理错误等问题。因此，使用事实核查技术对 LLMs 的输出进行评估，确保回答的准确性。

2.3.2 事实核查的核心技术与方法

针对 LLMs 输出结果的事实核查，一般可以分为以下几个技术环节：

（1）知识图谱驱动核查

首先知识图谱构建，基于权威医学文献、疾病数据库和电子病历（EHR），构建涵盖病因、症状、治疗方案等内容的医疗知识图谱。而后三元组验证，将 LLMs 的输出转化为结构化三元组，在知识图谱中进行匹配验证。最终进行语义一致性分析，通过嵌入模型计算三元组的语义相似度，判断输出的可信度。

（2）基于证据的核查

首先检索相关证据，利用信息检索技术，从医学文献、临床指南或数据库中进行检索与问答内容相关的文献和证据。然后证据对齐与验证，通过自然语言处理技

术（如 BERT、T5）对输出与证据进行语义对齐，验证答案是否符合已知证据。

（3）推理增强的核查

首先进行逻辑推理验证，结合因果推理模型或基于规则的推理方法，验证 LLMs 输出内容是否在逻辑上与医学知识一致。而后对因果关系建模，通过构建因果图验证诊断建议是否符合病因与症状之间的因果关联。

2.4 评估指标

在检索中，检索精度使用精确匹配（Hits@1）进行评价，生成的句子使用 Bert Score 进行评价。事实核查中预测标签性能主要使用 Micro F1 分数、Accuracy 等指标评估模型在标签预测任务上的性能。

2.5 本章小结

本章通过对研究中使用的技术进行全面解释，首先介绍了知识图谱，包括知识图谱的定义、机制及知识图谱的构建。之后阐述了大语言模型相关的架构及推理过程。最后介绍了事实核查方面的定义及作用，为后续章节的深入研究奠定了理论基础。

第3章 知识图谱全局检索增强辅助诊断

通过国内外研究现状中的分析可知，需要重点解决计算关系及实体与问题的语义相似性和筛选路径两个问题。为加快计算语义相似性时的速度，GPR 采用词嵌入技术将文本转换为向量，以实现文本相似性的高效批量计算。对于路径的筛选，GPR 首先以 BFS 方式检索，检索到的相关路径仍旧繁多复杂，因而再通过整体计算并修剪，留下少部分的关键信息由 LLMs 进行路径推理寻找答案。

3.1 全局修剪检索

在图 3-1 中展示了 GPR 的框架，该框架以一个医疗问题解释说明该框架的工作流程，主要包含三部分：实体关系挖掘，实体关系树融合，实体关系树的 LLMs 推理。并最终得到对该问题推理的结果。三个主要组件具体如下：

实体关系树挖掘：一个问题中的所有实体组成实体集 V_q ，通过对问题实体集中的每一个实体 $\{e | e_i \in V_q, i = 1, 2, 3, \dots\}$ 查询 KG 数据源以构建实体关系树 T_e 。以一个完整的实体关系树 T_e 作为视角，通过关系筛选去除语义相似性较低的关系及实体，进一步简化实体关系树得到简化版的实体关系树 T_e^c 。

实体关系树融合：检索问题中实体间的关系路径，融合多个实体关系树 T_e^c 为完备的实体关系图 G_m 。

实体关系树的 LLMs 推理：最终将实体关系网络图转换为易于 LLMs 理解的提示词，LLMs 整合构建的提示词及其隐含知识来生成答案，并根据实体关系网络图对推理结果进行解释。

3.2 知识图谱实体关系树挖掘

3.2.1 实体关系树检索

在实体关系树的挖掘任务中，定义知识源知识图谱为：

$$T = \{ \langle v, r, v' \rangle | v, v' \in V, r \in R, v \neq v' \} \quad (3-1)$$

由实体集 V 和关系集 R 构成，其中 v, v' 是不同的实体， r 是实体关系。

定义实体关系树 $T_e = (V_s, R_s)$ 是从知识图谱中提取的一个结构，其中 V_s 是从选定的根节点 v_0 出发，通过唯一的无环路径到达的实体子集：

$$V_s = \{v \in V \mid \exists \text{ 唯一路径 } P = (v_0, v_1, \dots, v) \text{ 使得 } \forall i, \langle v_i, r, v_{i+1} \rangle \in T \text{ 或 } \langle v_{i+1}, r, v_i \rangle \in T\} \quad (3-2)$$

R_s 定义为连接这些实体的直接父子关系集:

$$R_s = \{r \in R \mid \exists v, v' \in V_s : \langle v, r, v' \rangle \in T \text{ 且 } v \text{ 是 } v' \text{ 的直接子节点}\} \quad (3-3)$$

实体关系树挖掘过程中主要任务分两部分: 搜索和修剪。每一层的任务又分为关系挖掘和实体挖掘两部分。整个部分以广度优先搜索 (BFS) 算法形式展开。




图 3-1 总体框架

如图 3-2 所示,在关系挖掘中首先进行关系搜索,在第 D 层首先通过进行关系搜索,对 $D-1$ 层获取的实体 $v_{D-1,i}$ 进行查找其一阶邻居实体间的所有关系作为候选关系 $R_{s,D}^{cand}$ 。之后通过语义相似性计算进行关系上的初步修剪,通过语义模型计算获取关系与问题的语义相似性分数并过滤相似性分数较低的关系,便是需要的第 D 层中实体 $v_{D-1,i}$ 扩展关系,经 $D-1$ 层所有实体进行关系扩展组成 D 层的关系集 $R_{s,D}$ 。

实体挖掘在第 D 层修剪后的关系集 $R_{s,D}$ 上进行,例如在 D 层获取的关系 $r_{D,i}$,根据 $\langle v, r, v' \rangle$ 的关系可通过 $\langle v_{D-1}, r_{D,i}, v' \rangle$ 进行查找 v' ,在同一种关系中可能对应多个尾部实体 v' ,一个关系所对应的所有尾部实体组成为候选实体集 $V_{s,D,i}^{cand}$,为了能够更好的筛选出有关实体,我们将关系与尾部实体进行组合成为一个句子,以便模型更好理解实体含义。在此基础上进行实体筛选,通过语义模型计算获取关系—实体组合与问题的语义相似性分数并过滤相似性分数较低的组合,即为需要的第 D 层中实体,经 D 层所有关系扩展筛选的实体组成 D 层的实体集 $V_{s,D}$ 。

经过 N 层的查询扩展形成实体关系树 T_e 。




图 3-2 搜索策略（将一个实体作为根节点进行搜索语义相似性较高的邻居节点过程。）

3.2.2 实体关系树全局修剪

如图 3-3 所示,在实体关系树挖掘过程中得到目前图中的所有关系子集候选集 $R_{s,T}^{cand}$,对整个子集进行筛选,获得 $Top-N$ 的筛选关系集 $R_{s,T}^c$,由实体关系树的最外层进行逐步剔除,若遇到 $R \in R_{s,T}^c$,该关系所连的两实体直至中心实体 V_{cen} 所经过的实体及关系整条路径进行保留,以便形成实体关系推理链路。经过层层剔除,获得最终由核心关系组成的实体关系树 T_e^c 。如算法 3-1 所示。




图 3-3 全局修剪策略 (对一颗由问题中实体作为根节点的完整实体关系树进行修剪, 通过比较整棵树中关系的语义相似性, 进行大幅度的修剪。)

算法 3-1: 子图修剪

输入: entities, relations, prune_set

输出: 更新后的 entities 和 relations

1. 函数 prune_subgraph(entities, relations, prune_set)
2. $idx \leftarrow \text{length}(\text{entities}) - 1$
3. 当 $idx > 0$ 时 循环
4. $\text{rel_idx}, \text{key_loc} \leftarrow \text{locate_relation}(\text{relations}, idx)$
5. $\text{rel} \leftarrow \text{relations}[\text{rel_idx}][\text{key_loc}]$
6. $\text{entity} \leftarrow \text{entities}[idx]$
7. 如果 rel 不在 prune_set 中
8. 如果 relations[idx] 的长度为 0
9. 删除 entities[idx]
10. 删除 relations[idx]
11. 从 relations[rel_idx] 中移除 rel
12. 结束 如果
13. 结束 如果
14. $idx \leftarrow idx - 1$
15. 结束 循环
16. 返回 entities, relations
17. 结束

3.2.3 实体间路径检索

当有多个实体时,通过实体关系树进行查询形成多个实体关系树 T_e^c ,为 LLMs 能够更好理解多实体间的关系,将实体之间的关系路径进行描述,在一个问题 N 个实体只需查询 $N-1$ 条路径 $P_{i,j}$,每条都是可推理的,且与关系树同种形式,以便提示 LLMs 进行深刻理解。

3.3 多实体关系树融合及推理

3.3.1 多实体关系树融合

将多个关系树 T_e^c 进行融合,以关系路径 P 进行连接,将其定义为:

$$G_m = \{T_{e,1}, T_{e,2}, T_{e,3}, P_{1,2}, P_{2,3}, \dots\} \quad (3-4)$$

其中 $T_{e,i}, i=1,2,3,\dots$ 为问题中每个实体经实体邻居检索所形成的实体关系树。 $P_{i,i+1}, i=1,2,3,\dots$ 为问题中两相邻实体经实体间路径检索所形成的实体关系路径。为了简化处理过程加速回复速度,并未进行真正意义上的融合,而是在构造提示词的过程进行此操作。

3.3.2 实体关系网络图的 LLMs 推理

将实体关系图 G_m 按照 BFS 的方式进行转化为提示词,由中心节点 v 逐阶扩展,按照“实体-关系->实体”的方式进行编写提示词,以便于 LLMs 易于理解并生成内容。首先对一个问答中多个实体节点的实体关系树 T_e^c 进行转化,而后通过提示词将实体之间的关系再进一步说明从而构造融合的实体关系图 G_m 的提示词。

在 LLMs 中自身含有大量的知识,且 LLMs 可以理解并提取自然语言描述的实体关系图 G_m 中的知识进行推理。因此在提示词中鼓励 LLMs 在推理中利用自身隐含的知识及提供的外部知识共同推理。如图 3-1 中 Answer 所示,LLMs 可以识别上下文实体关系提示信息的关系连接,从而实现思维导图并产生新的见解。整体方法如算法 3-2 所示。

算法 3-2: 基于知识图谱的子图搜索与修剪

输入: depth_limit, relation_num, entity_num, subg_rel_num, path_num

输出: 查询响应 result

1. question, topic_entity $\leftarrow$ 获取问题及主题实体
2. 如果 topic_entity 为空:
3. result $\leftarrow$ response_without_TopicEntity(question)

4. 继续下一轮循环
5. $(relations, entities, rels) \leftarrow RGsearch.bfs_get_relations_sparql(question, topic_entity, depth_limit)$
6. $pruned_rels \leftarrow RGsearch.relation_prune(question, relations, subg_rel_num)$
7. $(entities, rels) \leftarrow RGsearch.prune_subgraph(entities, rels, pruned_rels)$
8. $prompt \leftarrow RGsearch.graph_construction_one_prompt(\{entities, rels\})$
9. 遍历 $topic_entity$, 获取 $entities, relations$
10. 计算 $pruned_rels$ 并修剪子图
11. 计算 $topic_entity$ 之间的最短路径
12. $prompt \leftarrow RGsearch.graph_construction_mul_prompt(entities, relations)$
13. $result \leftarrow response_with_TopicEntity(question, prompt)$
14. 返回 $result$
15. 结束

3.4 实验及分析

3.4.1 普通文本知识问答

(1) 数据集

为了测试 GPR 在多跳知识密集型推理任务上的能力, 针对一系列需要复杂推理和领域知识的问答任务评估了提出的方法, 并将其与基于检索的基线进行了比较。在 4 个 KBQA 数据集 (3 个多实体和 1 个单实体) 上对 GPR 进行了评估: CWQ^[49]、WebQSP^[50]、GrailQA^[51]、Simple Questions^[52]。此外还准备了一个开放域 QA 数据集 WebQuestions^[53]; 对于这些数据集, 以 ToG 提供的样本中抽取 200 样例进行简单测试。使用了 FreeBase KG^[54], 以支持 KG 增强的方法。

(2) 语言模型

为了验证框架在大型语言模型上的性能, 使用了两种不同大小的 LLMs。具体而言, 使用 GPT-3.5^[55]的 API 和 Mixtral-8x7B-Instruct-v0.1^[56]来作为推理模型测试提出的方法。

(3) 基准及实验方案

在普通文本任务实验中以 ToG、ToG-bm25、ToG-sentence、GPT-3.5 和 GPT-4 作为基线。ToG 完全以 GPT 运行, ToG-bm25 和 ToG-sentence 在语义相似性计算中分别使用 Bm25 算法和 Bert 语义模型进行计算, RPG-vector 和 RPG-sentence 在语义相似性计算中分别使用 Glove 的 vector 和 Bert 语义模型进行计算, 在通用的问答数据集对比中, 因专门针对这些数据训练的方法与基于无需训练的提示

的方法相比,评估的数据集通常具有本质上的优势,但牺牲了对其他数据的灵活性和泛化能力。因此,分别比较了所有基于提示的方法中的先前 SOTA,与基于标准的精确匹配 (Hits@1) 评估的方法进行对比。

(4) 评估具体设置方案

考虑到 GPR 的即插即用便利性,在实验中尝试了两种 LLMs 作为推理模型。使用 OpenAI API 来调用 ChatGPT (GPT-3.5-turbo)。Mixtral-8x7B-Instruct-v0.1 在半精度量化的情况下以 8 块 A30-24G 运行,Python3.10, CUDA: 12.1, 其中 temperature 参数对于勘探过程设置为 0.4, 最大令牌长度设置为 256, 将实体关系树深度 Dmax 设置为 3。Freebase KG 用作 CWQ、WebQSP、GrailQA、Simple Questions 和 Webquestions 的 KG。在所有数据集的推理提示中每个实体延伸 3 种关系, 每个关系保留 5 个实体, 子图关系修剪保留 3 种。因问答的随机性, 每个实验运行三到四次, 取其平均值作为最终结果。

(5) 实验结果

以 GPT-3.5 作为推理模型进行实验的结果如表 3-1 所示。

表 3-1 GPR 方法以 GPT-3.5 为基础模型的实验结果

Method QA(%)	Multi-Hop KBQA			Single Hop KBQA	Open Domain QA
	cwq	grailqa	webqsp	simpleqa	webquestions
GPT-4	36.40	33.90	69.10	22.90	56.63
GPT-3.5	39.53	33.43	64.10	29.18	60.53
ToG	35.50	59.50	66.00	53.00	59.50
ToG-bm25	26.00	42.00	44.00	19.00	48.00
ToG-sentence	40.00	72.00	66.00	55.00	61.00
GPR-vector	39.65	51.75	65.65	45.25	54.05
GPR-sentence	41.77	74.87	70.43	55.83	61.97

以 Mixtral-8x7B-Instruct-v0.1 作为推理模型进行实验的结果如表 3-2 所示。

表 3-2 GPR 方法以 Mixtral 实验结果

Method QA(%)	Multi-Hop KBQA			Single-Hop -KBQA	Open-Domain -QA
	cwq	grailqa	webqsp	simpleqa	webquestions
Mixtral	34.00	28.00	54.50	20.50	54.00
Mixtral-GPR	38.00	59.50	57.00	51.50	56.00

检索耗时以多次运行的平均时间进行统计，如图 3-4 所示。




图 3-4 耗时统计 (CPU:AMD EPYC 7543 32-Core Processor)

(6) 结果分析

普通文本知识上可知结果在单实体和多实体的问题实验结果中均有较大提升，能够为基础模型提供准确的知识路径供模型进行推理，精准回答出问题答案。而在公开领域的问题中，因为模型自身已经掌握了大量的知识，而检索框架所能提供的信息仅仅更加精确，但不一定能涵盖到最终结果，或者不能推理正确，因此差距微小。

通过实验结果图 3-4 可知，ToG 原有方案耗时较多，使用 bm25 算法进行替代 GPT 进行修剪，节省了大量时间，但是检索精度却下降严重。同样使用 Bert 语义模型进行相似性计算，提出的方法能够大量减少检索时间，主要因为在检索信息时无需关注路径的选择，专注于关系和实体，最终在全局的角度进行修剪路径，保留的路径与问题高度相关，由最终的 GPT 模型进行路径推理，能够在精确检索信息的同时兼顾时间效率，如果将语义相似性计算的模型通过 GPU 进行计算，检索速度将进一步提升。

3.4.2 医疗知识问答

(1) 数据集

将该方案在医疗问答上进行测试，涉及两个问答数据集：GenMedGPT-5k^[57]，CMCQA^[58]。这些数据集的统计数据如表 3-3 所示。此外，使用了两个 KG，EMCKG 和 CMCKG，以支持 KG 增强的方法。对于所有数据集，以 BertScore 作为评估指标。

表 3-3 医疗知识问答实验样本数据

Dataset	Domain	Multi-task	Question	KG	Node	Triple	Relationship
GenMedGPT-5k	English Clinical Q&A	Disease, Drug, Test	714	EMC KG	1122	5802	6
CMCQA	Chinese Long Dialogue	Disease, Drug, Test, Food	468	CMC KG	62282	506490	12

（2）语言模型

为了验证 GPR 方法在大型语言模型上的性能，统一使用 GPT-3.5 作为推理模型。

（3）基准及测试方案

在医疗问答中以 MindMap、GPT3.5、BM25 Retriever、Embedding Retriever、GPT4 及 KG Retriever 方法为基线，探索知识图谱检索增强大语言模型在医疗问答中的可行方法。

（4）评估方案

使用 OpenAI API 来调用 ChatGPT（GPT-3.5-turbo）。其中 temperature 参数对于勘探过程设置为 0.4，医疗问答任务中因输入输出较多，Max Token 需要设置较高数目。将实体关系树深度 Dmax 设置为 2。在所有数据集的推理提示中每个实体延伸 4 种关系，每个关系保留 5 个实体，子图关系修剪保留 4 种，提示词完全按照 MindMap 中的进行设计保证一致性。为能更加全面的回答医疗问题，在子图修剪中我们还可增加了白名单策略，以便保留相关关系及实体。例如在 GenMedGPT 数据集中，添加白名单为：

"has_symptom"

"need_medication"

"possible_cure_disease"

"possible_disease"

在 CMCQA 数据集中，添加白名单为：

"可以治疗疾病"

"可能患有疾病"

"并发症"

"症状"

"诊断检查"。

（5）实验结果

经过对 GenMedGPT-5k 的 714 条数据进行实验分析得到相关的数据如表 3-4。

表 3-4 GenMedGPT 实验数据

Method \ Eval	BERT Score		
	Precision	Recall	F1 Score
MindMap	0.7936	0.7977	0.7954
GPT-3.5	0.7612	0.8003	0.78
GPT4	0.7689	0.7893	0.7786
BM25 Retriever	0.7693	0.7981	0.7831
Embedding Retriever	0.769	0.8038	0.7857
KG Retriever	0.7717	0.8035	0.7868
GPR	0.7799	0.8154	0.7969

经过对 CMCQA 的 468 条数据样本进行实验分析得到相关的数据如表 3-5:

表 3-5 CMCQA 实验数据

Method \ Eval	BERT Score		
	Precision	Recall	F1 Score
MindMap	0.9415	0.9321	0.9367
GPT-3.5	0.9385	0.9361	0.9372
GPT4	0.9355	0.9358	0.9356
BM25 Retriever	0.9365	0.9348	0.9356
Embedding Retriever	0.9357	0.9334	0.9345
KG Retriever	0.9318	0.9348	0.9332
GPR	0.9422	0.9317	0.9369

(6) 结果分析

在医疗知识问答中提出 GPR 方法搜索策略同样有着优势, BERT Score 评估的领先优势表现可知提出的 GPR 方法有着良好的检索性能, 在两数据实验集中与其他方法相对比都处于相对领先优势, 可更加精准的回答患者问题。对比 BM25 等普通检索方案, 其优势明显。在 GenMedGPT 实验中, 其为英文文本, Bert 语义模型的检索精度优势整体显现。而 CMCQA 实验为中文文本, Bert 语义模型表现相对平庸。BERT Score 评估主要是与原语句进行对比, 生成方法中语序的不同也可导致 BERT Score 值的变化, 但从普通文本实验中可知, GPR 方法可提供更加精确的相关知识, 生成内容的相关度也更高。在此处添加的白名单策略可以在全局修剪中能够保留相关关系和实体, 为患者提供更为全面的回答。

3.5 本章小结

提出的 GPR 方法以实体关系搜索树将相关实体进行联系，并从全局视角进行修剪语义相似性较低的实体，并以 LLMs 作为 KG 推理的智能代理来实现更好的决策，从而提高了 LLMs 推理精度。同时加速了检索速度，降低了用户的等待时间。通过多项实验证明了提出的方法相比普通 LLMs 和检索增强生成方法具有显著的提高，GPR 优于现有提示推理方案，并减轻了 LLMs 的幻觉问题，有效提高了在医疗应用中的可行性。

第4章 核查辅助诊断内容事实模型

在事实核查任务中，不同模型的有着各自的优势。通过 RAFTS 发现合理生成的对比论证文本信息可提高模型判断的正确性，但是完全由大语言模型判断不仅速度较慢，通过复杂的提示或 LLMs 的内在知识来提高准确性，导致较小的 LLMs 或领域转移时性能下降。MiniCheck 和标签自适应学习方法通过微调小型模型能够快速完成核查任务，因此本章提出了一种基于多任务学习的高效事实核查方法，旨在通过结合增强证据和原子事实分解来验证声明的正确性。

4.1 多任务学习的事实核查模型

在图 4-1 中展示了多任务学习的高效事实核查模型的整体框架，解释说明该框架的工作流程，主要包含三部分：增强证据模块，声明分解模块，模型预测模块。通过模型对增强的证据及分解的声明进行预测，最终得到基于证据条件下该声明是否正确的推理的结果。

增强证据模块：通过对证据 D 进行分析，获得支持论点 A_s 和反驳论点 A_r 。

声明分解模块：通过对声明 c 进行分析，分割成多个原子事实 c_i 。

微调模型模块：分别从声明到增强证据以及原子事实到证据两个方面进行处理，并通过综合二者结果，获得最终结果。




图 4-1 事实核查模型

4.2 事实核查增强方法

4.2.1 事实核查的证据增强方法

根据给定的声明和增强证据来判断声明的正确性。首先并行创建两个分支，从两个相反的角度生成独立但不同的论点，利用 LLMs 的文本理解和摘要能力，执行指令提示来提取相关事实并生成支持和反驳论点。采用简单的任务描述并对其进行优化，以获得简洁而准确的论点，从而全面地分析该主张及其可信度。

因此基于已检索的证据集合 D 生成支持论点 A_s 和反驳论点 A_r ，该模块将声明 c 及证据集合 D 组合输入 LLMs 进行处理，通过模型的推理生成支持论证和反驳论证。如图 4-2 所示。

$$A_s, A_r = \text{LLMs}_{\text{Generate}}(c, D) \quad (4-1)$$

其中 c 表示输入声明， D 表示检索到的证据。通过生成的支持和反驳论证，可以实现更细粒度的声明分析。将支持论点 A_s 和反驳论点 A_r 通过事实核查模型进行处理。




图 4-2 证据增强

4.2.2 事实核查的声明分解方法

通过分解为原子事实的声明与原有证据的结合判断声明的正确性。声明分解是提升事实核查准确性和效率的重要步骤。大语言模型在生成自然语言文本时，往往通过多个信息片段综合而成。为了确保生成文本的真实性和一致性，必须将复杂的声明分解成简单、独立的原子事实，每个原子事实都可以独立验证，从而提高整个声明验证的可操作性和精确度。

因此面对多组原始证据的支持下生成的声明 c 时进行分解，将声明 c 通过

LLMs 进行分析分解为若干原子事实 $c_1, c_2, \dots, c_n$ 。如图 4-3 所示。

$$c_1, c_2, \dots, c_n = \text{LLMs}_{\text{Generate}}(c, D) \quad (4-2)$$

每一个原子事实 c_i 在证据集合 D 中都可找到对应的点, 将每个原子事实等可进行独立的核查。




图 4-3 声明分解

4.3 事实核查模型

在多任务学习的事实核查模型中, 为获得最终的预测结果, 模型需要将声明和证据增强的核查结果与证据和声明分解的核查结果进行加权融合, 通过多任务学习框架优化模型参数。每个任务的损失会根据其输入数据类型进行计算, 并加权合并以更新模型参数。在增强证据模块, 模型根据声明和增强证据进行判断, 输出分类标签, 计算该模块的损失。声明分解模块, 模型则首先将声明分解为原子事实, 并与原有证据一起输入模型。模型输出一个分类标签, 然后计算损失。损失是模型预测和实际标签之间的误差。多任务学习框架中的损失函数是增强证据模块和声明分解模块损失的加权和:

$$L = \lambda_1 \cdot L_1 + \lambda_2 \cdot L_2 \quad (4-3)$$

其中 L_1 是声明与增强证据验证模块的损失, L_2 是原子事实列表与原有证据验证整个声明模块的损失, λ_1 和 λ_2 是任务权重超参数, 用来平衡两个任务对模型训练的贡献。通过该损失函数, 模型可在训练过程中同时优化两个任务, 从而提升模型性能。对于每个输入样本, 模型分别计算声明与增强证据验证模块和原子事实列表与原有证据验证整个声明模块的损失, 并通过反向传播更新模型参数。在多任务

学习中，模型的底层参数是共享的，因此模型的参数在训练过程中会同时服务于两个任务，提高了训练效率并减少了过拟合的风险。模型能够同时适应声明和增强证据的直接验证以及声明的原子事实与原有证据的结合验证。这使得模型在面对复杂和多变的输入时，具有更高的灵活性和适应性，可以帮助模型全面了解声明的背景信息和细节。具体算法 4-1 所示。

算法 4-1: 事实核查模型 RM

输入：声明、证据、声明分解的结果、证据增强的结果、模型 model

输出：true/neutral/false/mixture

1. 函数 `check_fact_claim(declaration, vidence, decomposed_declaration, enhanced_evidence, model)`
2. 将声明 `declaration` 转换为 `tokens_declaration`
3. 将增强证据 `enhanced_evidence` 转换为 `tokens_enhanced_evidence`
4. 将声明和增强证据合并为一个输入
5. 使用模型 `model` 处理声明和增强证据的组合输入
6. 声明分解的结果 `decomposed_declaration` 转换为 `tokens_decomposed`
7. 将证据 `evidence` 转换为 `tokens_evidence`
8. 将声明分解结果和证据合并为一个输入
9. 使用模型 `model` 处理声明分解结果和证据的组合输入
10. 合并两个处理结果
11. 对合并后的结果进行解码
12. 返回最终的判断结果
13. 结束 函数

4.4 实验及分析

为验证方案的性能，在 GPU: RTX 4090(24GB), CPU16 vCPU Intel(R) Xeon(R) Platinum 8352V, Python3.10, CUDA: 12.1 的平台上进行测试。

4.4.1 实验数据

我们选用与医疗相关的公开数据集进行实验，其中包含结构化和非结构化的声明与其对应的事实核查标注：

(1) AVeriTeC^[59]：包含从各个相关领域网站提取的真实世界声明，支持复杂的多标签标注（支持、反驳、部分正确等）。因 AVeriTeC 原有数据集中测试集缺少 label，因此合并训练集和验证集并重新按照 8: 1: 1 进行划分为训练集验证集及测试集三部分。

(2) PubHealth^[60]: 一个关于医疗声明的事实核查数据集, 提供声明、证据文本以及标签 (支持、反驳、信息不足)。证据由事实检查文章或新闻评论的全文组成, 平均长度超过 600 个单词, 明显比 Averitec 的平均 120 个单词更长。

由于两数据集的 label 并不相同, 因此将两数据集的 label 进行映射合并, 如表 4-1 所示。具体数据集数据如表 4-2 所示。

表 4-1 数据映射

AVeriTeC_label	PubHealth_label	Now_label
Supported	true	true
Not enough evidence	unprovent	neutral
Refuted	false	false
Conflicting evidence/cherry-picking	mixture	mixture

表 4-2 数据集统计

Dataset	AVeriTec			PubHealth		
Label	Train	Dev	Test	Train	Dev	Test
true	1638	215	194	5078	629	599
neutral	767	93	111	3001	380	388
false	259	30	28	1434	164	201
mixture	90	19	24	291	41	45

4.4.2 微调模型

在微调中采用参数高效微调方法 (PEFT, Parameter Efficient Fine-Tuning) 对 Flan-T5-Large 模型进行微调, 以实现事实核查分类任务。因此在微调中使用了 LoRA (Low-Rank Adaptation) 方法, 该方法通过在 Transformer 层的权重矩阵上引入低秩矩阵的可训练参数, 避免了对整个模型进行大规模更新, 从而降低计算成本和存储需求, 同时保持较高的微调效果。

该微调方法中以预训练的 Flan-T5-Large 为基础模型, 保持其大部分参数冻结, 仅在注意力层的部分权重上应用 LoRA 适配器。LoRA 通过在原始权重矩阵上施加可训练的低秩矩阵, 使模型能够学习特定任务的特征, 而不会改变基础模型的整体参数分布。这种方法可有效减少微调过程中所需的参数量, 并提高了模型的泛化能力。

在训练过程中, 采用了标准的自回归序列到序列训练范式, 将输入文本转换为合适的模型输入格式, 并以目标标签文本作为监督信号。输入数据采用 PubHealth

和 AVeriTeC 数据集进行训练，其中 PubHealth 数据集的输入为单一文本，而 AVeriTeC 数据集的输入由多个问答对组成。为了保证模型的输入一致性，对 AVeriTeC 数据集的问答对进行了文本拼接，使其转换为符合 Flan-T5-Large 输入格式的自然语言描述。目标标签则采用标准的四分类标签，包括“false”、“true”、“neutral”和“mixture”。

训练过程中，使用交叉熵损失函数，并采用 AdamW 优化器进行梯度更新。学习率采用线性预热和衰减策略，以缓解训练初期的震荡问题，同时保证后期模型的稳定收敛。批量大小设定为 4，学习率设为 $1e-4$ ，并采用梯度累积策略以适应较大输入长度的情况。AVeriTeC 数据集训练中最大长度设置为 600，PubHealth 设置为 800。训练轮数根据验证集性能进行调整，最终选择收敛性最佳的模型作为最终微调模型。通过微调均获得了良好的效果，可有效分类相关文本到正确的标签。训练 loss 如图 4-4、图 4-5 所示。




图 4-4 AVeriTeC Loss




图 4-5 PubHealth Loss

4.4.3 生成论证和声明分解数据

在事实核查任务中，生成论证和声明分解是确保模型能够准确评估声明真实性的关键步骤。通过生成支持和反驳的论证，模型可以从多个角度对声明进行分析，从而提高判断的准确性和可靠性。同时，将复杂的声明分解为原子事实，可以进一步细化核查过程，确保每个关键点都经过严格的验证。在实验中利用 GPT4 进行生成支持论证和声明分解。数据集属性如表 4-3。

表 4-3 数据集属性

claim	label	main_text	evidence	claim_Atom
原始声明	标签	原始文本	根据原始文本生成的支持和反驳论点	分解的原子事实

4.4.4 事实核查模型训练

按照不同的数据处理方式进行训练模型，首先对两数据集进行模型的微调训练，训练参数保持不变，批量大小设定为 4，学习率设为 $1e-4$ 。AVeriTeC 数据集训练中最大长度设置为 600，PubHealth 设置为 800。训练轮数根据验证集性能进行调整，最终选择收敛性最佳的模型作为最终微调模型。训练 loss 实验结果如图 4-6、4-7 所示。




图 4-6 事实核查模型在数据集 AVeriTeC 的 Loss




图 4-7 事实核查模型在数据集 PubHealth 的 Loss

训练后的模型与 GPT 等大模型进行对比, Flan-T5-FT 为 Flan-T5-Large 微调后的直接应用, RAFTS-T5 为使用 RAFTS 方法的 Flan-T5-FT, MiniCheck-T5 为 MiniCheck 方法的 Flan-T5-FT, RM 为现有方案。评估结果如表 4-3、表 4-4 所示。

表 4-4 AVeriTeC 数据集上的实验结果

Model	Accuracy				Micro-F1
	true	neutral	false	mixture	
GPT-4	83.4	65.6	91.1	45.7	83.0
Flan-T5-FT	26.1	07.1	94.3	12.5	60.8
RAFTS-T5	85.7	69.3	92.8	48.1	84.5
MiniCheck-T5	84.9	68.7	92.6	47.8	84.2
RM	86.5	66.8	93.2	50.2	85.3

表 4-5 PubHealth 数据集上的实验结果

Model	Accuracy				Micro-F1
	true	neutral	false	mixture	
GPT-4	80.6	18.2	73.0	42.0	69.6
Flan-T5-FT	89.9	02.2	69.3	38.8	71.8
RAFTS-T5	82.3	27.4	74.1	40.8	75.6
MiniCheck-T5	81.5	26.3	73.9	40.4	75.2
RM	85.2	30.4	77.2	44.6	77.3

根据实验结果分析可知，微调后的 Flan-T5-FT 在 true 和 false 标签上优势明显，但在 neutral 和 mixture 标签中仍旧效果不佳，经过相关方法处理的微调模型可大幅提升对 neutral、mixture 标签的判断精度。且提出的 RM 在处理声明时对声明的分类把握更为精准，在 neutral、mixture 标签的表现均有提高。在 AVeriTeC 数据集是包含多方面的真实世界的声明，在 true 和 mixture 两种标签提升，其他标签中保持均衡额，而在 PubHealth 数据集是医疗方面的声明，在 neutral、false 和 mixture 三种标签提升，差异的存在主要为领域的不同及声明逻辑的不同。对比方法 GPT-4 在 AVeriTeC 数据集表现优异，但是在 PubHealth 数据集较差，与其训练数据有关，而经过数据集训练的 RAFTS-T5 和 MiniCheck-T5 二者在两个数据集上因此性能相似。但以 Micro-F1 指标中可知 Flan-T5-FT 对声明的事实核查方面进行了整体提升。

4.5 本章小结

本文提出的多任务学习的高效事实核查方法在医疗数据集 PubHealth 和 AVeriTeC 两个数据集上均实现了部分的性能提升，尤其是在处理复杂声明时表现尤为突出。Micro-F1 分数的稳定提升表明了集成策略在不同任务场景下的通用性和适应性。

通过根据声明复杂度调整的权重分配，模型能够在复杂任务中保持高效，同时充分利用模型的推理能力。这种多任务学习方法在复杂声明场景下的宏 F1 分数有提升，证明其对模糊信息的处理能力显著增强，在性能提升的同时具备较高的计算效率。本文方法有效增强了模型对复杂医学声明（如辅助诊断、治疗建议等）事实核查的可靠性。

第5章 检索增强的大语言模型辅助诊断系统

在现有医疗辅助诊断系统中多是依靠预测式的模型，而大语言模型则是生成式模型，可通过对医学语言和概念的深入理解，以及综合分析处理大量的医疗数据生成上下文高度相关的信息，生成更加准确的诊断决策。本文提出了于知识图谱和大语言模型的辅助诊断系统，旨在推进大语言模型在医疗方面的应用。并对其各个模块进行了改进，使得大语言模型能更安全地应用于医疗辅助诊断方面。系统能够为医生提供全面、准确的诊断支持，同时确保诊断的安全性和可靠性。

5.1 系统分析

5.1.1 功能需求分析

医疗辅助诊断系统旨在为医生提供基于患者病历和检查结果的诊断建议，提高诊断的准确性和效率。为了实现这一目标，系统需要具备一系列功能，以满足不同用户的需求。

首先是患者信息端功能，该部分供医生使用，系统通过综合判断患者的病史和目前身体状况进行诊断，诊断生成详细的报告供医生参考决策。主要功能如下：

患者信息端登录：使用者通过输入用户名和密码登录系统，确保系统的信息安全。

患者管理：医生可以选择管理当前需要处理的患者。

患者基本信息：该部分详细记录患者的个人信息，如性别、年龄、患者历史信息、患者当前状况等，应提供一个用户友好的界面，允许医生查看并编辑患者的病历信息、患者的既往病史、既往诊断、既往治疗情况等。

诊断报告生成：根据患者当前状况及病史信息生成报告，并允许医生导出诊断报告。报告应包括患者信息、病历信息、诊断建议等。

诊断建议管理：医生可以查看和管理患者的诊断建议，包括诊断过程、诊断结果、建议的检查项目和治疗方案。

患者随访管理：医生可以记录和管理患者的随访情况，跟踪患者的治疗进展和康复情况。

系统管理端功能部分主要是管理和维护使用，对于系统稳定和安全方面十分重要，管理者应当有权限查看相关操作日志，确保系统的准确诊断并保障系统安全。

系统管理端登录：管理人员通过输入用户名和密码登录系统，确保系统的信息安全。

用户管理：系统应提供用户管理功能，包括用户注册、登录、权限管理和用户管理。用户管理功能应确保系统的安全性和可靠性，防止未经授权访问。

知识图谱查询：系统应提供查询医学知识图谱的功能，以便医生获取更多相关医学知识，包括疾病信息、药物信息、检查方法等。知识图谱查询应支持关键词搜索和实体关系查询。

诊断建议生成：系统应根据输入的病历信息，调用大语言模型和知识图谱等相关功能，生成详细的诊断建议。诊断建议应包括可能的疾病诊断、建议的检查项目和治疗方案。

事实核查证据检索：从不同的医疗数据库中获取相关信息，以支持事实核查过程。

电子护栏事实核查：实时监控诊断建议，确保其符合预定义的安全规则和隐私政策。电子护栏应能够检测和过滤不当内容，保护患者的隐私和安全。

通过以上功能需求分析，医疗辅助诊断系统将能够为医生提供全面、准确、可靠的诊断支持，提高医疗诊断的效率和质量。这些功能需求不仅涵盖了系统的核心功能，还考虑了用户的实际操作需求和系统的安全性、可靠性，确保系统在实际应用中的有效性和实用性。整体功能结构如图 5-1 所示。




图 5-1 功能需求分析

5.1.2 非功能需求分析

非功能需求（Non-functional Requirements, NFRs）是指系统在性能、可用性、安全性、可维护性、可扩展性、用户界面、数据完整性和合规性等方面的要求。这些需求对系统的整体质量和用户体验至关重要。以下是医疗辅助诊断系统的非功能需求分析：

（1）性能需求：系统应在合理的时间内响应使用者的请求，通过快速的响应确保使用者的使用体验，及时提供使用者所需要的信息供其参考。

（2）吞吐量：系统应能够处理高并发请求，在高并发情况下，系统的平均响应时间应当及时，以免长时间的等待。

（3）可用性需求：系统应具备高可用性，系统应具备自动故障恢复机制，能够在发生故障后快速地自动恢复服务。系统应具备数据备份和恢复功能，避免数据丢失。

（4）安全性需求：系统应确保数据在传输和存储过程中的加密，所有数据传输应使用 SSL/TLS 加密，确保数据在客户端和服务端之间的安全传输。所有敏感数据（如患者个人信息、病历信息等）在存储时应使用加密算法进行加密。

（5）可维护性需求：系统代码应具备高可读性和可维护性，代码应遵循统一的编码规范，提高代码的可读性和一致性。代码应进行模块化设计，降低模块之间的耦合度，提高代码的可维护性。

（6）用户界面需求：系统应提供用户友好的界面，界面应简洁明了，操作流程直观易懂，减少用户的认知负担。

通过以上非功能需求分析，医疗辅助诊断系统将具备高性能、高可用性、高安全性、易维护性、可扩展性、用户友好性，确保系统在实际应用中的稳定性和可靠性，提高用户的满意度和信任度。这些非功能需求不仅涵盖了系统的技术要求，还考虑了用户的实际使用体验。

5.2 系统设计

5.2.1 系统整体框架

医疗辅助诊断系统的整体框架设计旨在确保系统的高效性、可靠性和可扩展性。该框架通过模块化设计，将系统分为多个相互协作的组件，每个组件负责特定的功能，从而提高系统的整体性能和可维护性。

前端用户界面是用户与系统交互的主要界面，提供病历信息查看录入、诊断建

议查看、知识图谱查询和用户反馈提交等功能。使用 React 框架构建前端界面，利用其组件化和响应式设计，提高界面的交互性和用户体验。使用 Redux 进行状态管理，确保应用状态的一致性和可预测性。使用 Ant Design UI 组件库，提供丰富的预设组件，加快开发速度，确保界面的一致性和美观性。后端开发框架使用 Spring Boot。Neo4j 图数据库用于存储知识图谱数据，MySQL 用于存储结构化数据，如患者基本信息、诊断报告等，MongoDB 用于存储半结构化数据，如日志、知识图谱的非结构化部分。系统架构图如图 5-2 所示，系统架构具体信息如下：

（1）用户界面层是用户与系统交互的最直接部分，它负责展示信息、接收用户输入，并将用户操作传递给后端系统，同时将后端返回的数据以友好的方式展示给用户。这一层的核心目标是提供良好的用户体验，确保界面简洁、直观且响应迅速。主要包括患者信息端界面和系统管理端界面两部分，患者信息端界面主要是使用者所需要的页面，系统管理端界面是管理者进行控制所需要的页面。

（2）业务逻辑层则是具体功能的实现，从使用者方面的功能到管理者方面的功能都包含在此层。该层需要根据患者的病历信息和当前症状，调用知识图谱和大语言模型生成诊断建议。它还需要处理用户管理、权限控制、数据统计等业务逻辑。

（3）数据访问层主要是与数据库进行交互，实现数据的增删改等查操作。该层需要将业务逻辑层传来的数据映射到数据库中，并将查询结果返回给业务逻辑层。这一层还需要处理数据库连接管理、事务管理和数据缓存等任务，以提高系统的性能和可靠性。




图 5-2 系统架构

5.2.2 系统功能框架

系统功能是医疗辅助诊断系统开发的关键环节，旨在确保系统能够满足医生在实际医疗诊断中的需求。在该系统中主要包括两个模块，分别是患者信息端模块和系统管理端模块。患者信息端模块的主要功能有患者信息端登录、患者管理、患者基本信息、患者历史信息、患者当前状况、诊断建议管理、患者随访管理、患者反馈管理、用户反馈收集等功能，将其分管到患者信息状况和使用反馈部分。系统管理端功能部分主要是系统管理端登录、用户管理、系统设置、知识图谱查询、诊断建议生成、电子护栏事实核查、数据统计与分析、系统集成等功能，将其分管到用户管理、系统及数据设置、系统诊断功能设置部分。具体的功能模块如图 5-3 所示。




图 5-3 系统功能

5.2.3 系统业务流程设计

系统业务流程设计是确保医疗辅助诊断系统高效、准确运行的关键环节。通过详细设计业务流程，可以明确系统各模块之间的交互和数据流动，提高系统的整体性能和用户体验。本节将详细描述系统的业务流程设计，在该系统中主要功能流程为根据患者基本信息、患者历史信息和患者当前状况给出诊断建议。系统业务流程图如图 5-4 所示。

知识图谱查询模块是根据患者信息查找相关专业知识，并将知识提示给诊断模型的模块。包含疾病，并发症，治疗医药等等多方面的专业知识，以增强诊断建议生成模块有足够的正确信息进行推断。

诊断建议生成模块将患者信息和相关的专业知识转化为提示词上输入到

LLMs 中进行推断，并在推断过程中生成推断依据和推理思维过程，并将推理结论输出到电子护栏事实核查模块进行核查。

电子护栏核查模块根据知识图谱的专业知识进行判断输出结论是否符合逻辑和事实，防止 LLMs 在生成诊断建议中出现幻觉问题确保生成内容的准确，保障患者的安全。




图 5-4 系统业务流程

5.3 系统数据库设计

5.3.1 逻辑结构设计

逻辑结构设计是数据库设计的重要环节，定义了数据库中数据的组织方式、数据之间的关系以及数据的完整性约束。逻辑结构设计的目标是确保数据的准确性和一致性，同时优化数据的存储和访问效率。在医疗辅助诊断系统的逻辑结构设计中，E-R 图可以清晰地展示患者、医生——使用者、诊断报告等实体之间的关系。例如，一个患者可以有多个诊断报告，而每个诊断报告只属于一个患者，这体现了一对多（1:N）的关系；一个医生可以生成多个诊断报告，每个诊断报告由一个医生生成，这同样是一对多（1:N）的关系。此外，患者与医生之间还可能存在多对多（M:N）的关系，因为一个患者可以由多个医生诊断，一个医生也可以诊断多个患者。每一个报告都将使用数个知识图谱实体，而每个知识图谱实体又可供数个报告使用，因此诊断报告与知识图谱实体之间存在多对多（M:N）的关系。医疗辅助诊断系统的逻辑结构设计如图 5-5 所示。




图 5-5 E-R 图

5.3.2 存储结构设计

存储结构设计是数据库设计的重要组成部分，合理的存储结构设计可以显著提高数据库的性能，确保数据的高效读写和管理。本节将详细描述医疗辅助诊断系统的存储结构设计。

(1) 用户表：该表中主要包含用户的 ID、姓名、哈希密码、角色、邮箱及联系方式等信息。如表 5-1 所示：

表 5-1 用户表

字段名	数据类型	描述
UserID	INT	用户唯一标识（主键）
Username	VARCHAR(50)	用户名
PasswordHash	VARCHAR(128)	密码哈希值
Role	VARCHAR(20)	用户角色（如医生、管理员）
Email	VARCHAR(100)	用户邮箱
Phone	VARCHAR(20)	用户电话

(2) 患者信息表主要包括患者 ID、用户 ID、姓名、年龄、身高、体重、既往病史、当前状况及过敏史等信息。该部分的信息是患者身体状况的基础信息，如表 5-2 所示：

表 5-2 患者信息表

字段名	数据类型	描述
PatientID	INT	患者唯一标识（主键）
UserID	INT	关联用户表（外键）
Name	VARCHAR(50)	姓名
Gender	CHAR(1)	性别（M/F）
Age	INT	年龄
Height	INT	身高（厘米）
Weight	FLOAT	体重（千克）
MedicalHistory	JSON	既往病史
Allergies	JSON	过敏史
CurrentCondition	JSON	当前状况

(3) 诊断报告表主要包括报告 ID、患者 ID、报告生成日期、诊断结果、诊断过程、诊断依据、治疗方案和生成报告的医生等信息，用于存储诊断结果及生成信息。如表 5-3 所示：

表 5-3 诊断报告表

字段名	数据类型	描述
ReportID	INT	报告唯一标识（主键）
PatientID	INT	关联患者信息表（外键）
ReportDate	DATE	报告生成日期
Diagnosis	TEXT	诊断结果
Diagnosis_Evi	TEXT	诊断依据
Diagnosis_Tract	TEXT	诊断过程
TreatmentPlan	TEXT	治疗方案
DoctorID	INT	生成报告的医生（外键）

(4) 随访表中主要包括随访唯一标识、随访关联患者 ID、随访日期和随访内容等信息。如表 5-4 所示。

表 5-4 随访表

字段名	数据类型	描述
FollowUpID	INT	随访记录唯一标识（主键）
PatientID	INT	关联患者信息表（外键）
FollowUpDate	DATE	随访日期
FollowUpContent	TEXT	随访内容

（5）知识图谱实体表主要包括实体唯一标识、实体名称、实体类型、实体属性等信息。如表 5-5 所示：

表 5-5 知识图谱实体表

字段名	数据类型	描述
EntityID	INT	实体唯一标识（主键）
EntityName	VARCHAR	实体名称
EntityType	VARCHAR	实体类型（如疾病、药物等）
Attributes	JSON	实体属性（JSON 格式）

（6）知识图谱表主要包括关系唯一标识、关系类型、关系起始实体、关系目标实体等信息。如表 5-6 所示：

表 5-6 知识图谱关系表

字段名	数据类型	描述
RelationID	INT	关系唯一标识（主键）
RelationType	VARCHAR	关系类型
FromEntityID	INT	关系起始实体（外键）
ToEntityID	INT	关系目标实体（外键）

5.4 系统实现

医疗辅助诊断模块主要包含患者信息端模块和系统管理端模块，下面将对两模块的实现进行介绍。

5.4.1 患者信息端模块

患者信息端模块主要功能有患者信息端登录、患者基本信息、患者历史信息、

患者当前状况、诊断建议管理和患者随访管理等功能。首先使用者通过登录进入患者信息端模块使用其他功能，用户登录可有效强化系统安全，防止信息外泄。

患者管理页面提供了快速搜索功能，可以通过输入患者姓名、患者 ID 等关键词，快速定位到特定患者选项卡，查询结果以列表形式展示，包括患者的基本信息和关键病情摘要。医生可以点击患者名称或相关信息，进入患者的详细信息页面，查看患者的所有信息，包括病历记录、诊断报告、随访记录等，也可直接进行简单备注。医生还可以根据多个条件进行组合，查询患者信息，对患者进行批量管理和分析。如图 5-6 所示。

The interface displays a sidebar on the left with the title '患者信息端' (Patient Information End). The main area contains search filters for '患者姓名' (Patient Name), '患者证件号' (Patient ID), '科室' (Department), and '患者编号' (Patient Number). Below the filters is a table with columns: '编号' (ID), '姓名' (Name), '证件号' (ID Number), '病情描述' (Medical History), '备注' (Remarks), and a '详情' (Details) button. The table contains two rows of data:

编号	姓名	证件号	病情描述	备注	详情
202503123456	张三	3213215541561321	牙疼		详情
202503123457	李四	1165416512302302	肚子疼		详情

图 5-6 患者管理

在患者基本信息页面，如图 5-7 所示。该页面除了姓名、性别、年龄、联系方式等基本属性外，还包括患者的既往病史、过敏史、家族病史等医疗属性。这些信息通过表格的形式展示，方便医生快速了解患者的医疗背景。

病历记录以列表形式展示，每条病历记录包括就诊日期、诊断结果、治疗方案等关键信息，检查检验结果则以图表或表格的形式展示，方便医生分析和对比。

当前状况展示区，详细描述患者当前的症状，包括发病时间、症状的性质和程度等，并展示患者的当前生命体征，如血压、心率、体温等，通常以实时更新的图表形式展示。

点击诊断报告生成按钮，系统将根据患者的病历信息和当前状况生成详细的诊断报告，包括诊断结果、诊断依据、治疗建议等。随访记录按钮则用于查看和添加患者的随访记录，记录患者的病情变化和治疗进展。

患者随访页面旨在对患者的病情发展、治疗效果以及康复情况进行持续跟踪和记录。随访记录作为患者的医疗档案的重要组成部分，为后续的医疗决策和病情评估提供参考。如图 5-8 所示。

患者信息端

患者管理

患者反馈管理

用户反馈收集

← 搜索 一键诊断 随访记录

🔔 用户名

患者基本信息

患者姓名: 张三

患者证件号: 3213215541561321

科室: -- -- --

患者编号: 202503123456

性别: 男

年龄: ----

身高: -- -- --

体重: -- -- --

过敏史

时间	过敏源	过敏症状
--	--	---
--	--	---

既往病史

就诊日期	诊断结果	治疗方案	检查检验结果
--	--	--	详情
--	--	--	详情

当前状况

时间: 20250302

科室: -- -- --

症状: 前两天牙疼有蛀牙,后来就肿起来了,从脸摸那个肿的地方烫烫的

图 5-7 患者信息

患者信息端

患者管理

患者反馈管理

用户反馈收集

← 搜索

🔔 用户名

随访记录

患者姓名: -- -- --

患者编号: -- -- --

性别: -- -- --

年龄: --

身高: -- -- --

体重: -- -- --

随访日期	随访医生	身体状况	治疗情况	患者或家属的反馈
---	--	---	---	-----

图 5-8 患者随访记录

该页面顶部显示患者的详细信息，包括患者姓名、年龄和性别等基本信息有助于医护人员快速识别患者身份并了解其基本背景情况，为随访工作提供基础依据。

随访结果会以表格的形式展示，包含随访日期、随访医生、身体状况、治疗情况以及患者或家属的反馈等信息。医护人员可以根据需要对查询结果进行筛选和排序，方便对特定时间段或特定医生的随访情况进行查看和分析。

5.4.2 系统管理端模块

系统管理端功能部分主要有系统管理端登录、用户管理、知识图谱查询、诊断建议生成、电子护栏事实核查等功能。用户管理页面允许管理员通过输入用户 ID、姓名或其他关键字来快速定位特定用户，以表格形式展示用户，列出了用户的 ID、姓名、角色、等基本信息。如图 5-9 所示。




图 5-9 用户管理

在用户列表中，管理员可以对用户“编辑”和“删除”。点击“编辑”按钮后，管理员可以在其中修改用户的详细信息，如姓名、密码、角色、邮箱及联系方式等。编辑完成后，点击“保存”按钮即可更新用户信息。同时系统在后台会对用户信息进行加密存储，确保用户数据的安全性。此外，系统还会对管理员的操作进行日志记录，以便在需要时进行审计和追踪。

5.4.3 知识图谱数据库

在网络上等网站包含丰富的疾病信息，包括疾病介绍、症状、治疗方法、预防措施等。医学数据库包含大量的医学文献，可以从中获取疾病的研究成果、临床试

验数据等。使用工具编写脚本从目标网站采集数据或通过调用 API 获取数据。

采集的数据中有大量无用数据，需要去除重复数据、无效数据和错误数据并将不同数据源采集到的数据整合到一起，解决数据冲突和不一致的问题。从文本数据中抽取实体和关系，构建实体和关系数据库。

选择 Neo4j 作为知识图谱的存储工具，Neo4j 具有强大的图查询能力，可高效地处理复杂的图数据查询请求。定义知识图谱的模式，包括实体类型和关系类型。构建脚本将预处理后的数据导入到 Neo4j 数据库中。如图 5-10 所示。

将数据导入到 Neo4j 数据库后，可以使用 Cypher 查询语言对知识图谱进行查询，获取所需的信息。




图 5-10 知识图谱数据库示例

5.4.4 大语言模型诊断建议生成模块

诊断建议生成模块是基于知识图谱和大语言模型（LLMs）的辅助诊断系统中的核心模块之一，它将患者的病历信息和当前状况与知识图谱中的医学知识相结合，利用大语言模型的强大推理能力生成详细的诊断建议，包括可能患有的疾病诊断和治疗方案。

患者信息包括病历文本数据和结构化数据，是诊断建议生成的基础。病历文本包含患者的症状描述、既往病史、实验室检查结果等。这些信息输入系统后，系统会根据这些实体信息通过全局检索方案进行从知识图谱检索通相关的医学知识。例如，如果患者有“胸痛”和“呼吸困难”的症状，系统会查询知识图谱中与这些

症状相关的疾病、检查和治疗方案。这些信息会被整理成一个结构化的知识子图。将子图和患者信息一起提示到大语言模型。大语言模型（LLMs）将对患者信息与知识子图进行推理并生成诊断建议，并结合其自身的医学知识和推理能力，生成一份详细的诊断报告。报告中会包含可能的疾病诊断、疾病的病因分析、建议的检查项目和治疗方案等。

5.4.5 核查证据检索模块

在调用过程中需要将 LLMs 输出的声明进行解析，系统首先将 LLMs 生成的文本转换为结构化声明，利用 NER（Named Entity Recognition）提取出该声明的核心事实，以便进行后续匹配。

为支持事实核查需要保证高效、准确的检索相关证据，需要结合语义搜索和结构化查询方法对 ICD、SNOMED CT、DrugBank 和 PubMed 进行查询。

ICD 和 SNOMED CT 主要是基于标准化编码的医学术语系统，因此可以使用 SPARQL 查询或 SQL 查询直接访问存储的知识库。

对于 DrugBank，由于其包含药物的详细信息，包括适应症、副作用、相互作用等，因此需要基于 API 访问并使用 QL 语句来查询具体的药物信息。当 LLMs 生成的医学建议涉及某种药物时，系统可以调用 DrugBank API，获取该药物的详细信息，并检查是否存在潜在的不合理性，如错误的适应症或药物相互作用风险。

在 PubMed 的检索过程中，由于 PubMed 主要包含医学论文和研究数据，因此使用 Entrez API 进行查询。系统首先对 LLMs 生成的医学建议进行实体识别，提取出疾病、症状、治疗方法等核心内容，然后基于这些关键词构造检索查询并返回最新的研究文献。

由于不同数据库数据各有差异，需要进行实体消歧和术语对齐操作，将不同信息源的相同概念转化为相同实体，以提高数据匹配的准确性。

且不同数据库其返回格式同样各不相同，ICD 和 SNOMED CT 主要基于结构化编码，而 PubMed 的数据则是非结构化文本，因此数据处理需要针对不同来源的数据进行不同的处理。

对于 ICD 和 SNOMED CT，系统会将查询结果转换为三元组（实体-关系-实体）格式，这些数据将被存入知识图谱数据库以支持后续的事实匹配。DrugBank 的数据通常是 JSON 格式，因此需要解析药物的适应症、副作用和相互作用信息并将其转换为结构化数据。PubMed 返回的数据通常是自然语言文本，因此数据处理需要进行文本摘要和关键信息提取。为了提高检索效率，使用基于 BERT 的嵌入匹配方法以确保检索到的论文与查询内容具有较高的语义相关性。

5.4.6 事实核查模块

电子护栏事实核查模块是辅助诊断系统中的关键组件，旨在确保大语言模型（LLMs）生成的诊断建议的真实性和可靠性。该模块通过实时监控并核查诊断建议防止不准确或有害的信息被提供给医生和患者，从而保障医疗决策的安全性和有效性。

电子护栏事实核查模块将对大语言模型（LLMs）生成的诊断建议进行实时监控。当模型生成一段诊断内容后该模块会立即对输出内容进行核查。首先将调用核查证据检索模块将检索其他信息源的医学信息，包括核查诊断内容是否符合医学标准、药物是否合理以及其他额外的证据支持等。将生成内容和检索到的医学知识证据一起输入事实核查模型，事实核查模型分别从增强证据和声明分解两个不同任务进行，核查模型将根据证据核查生成内容的逻辑合理性以及内容一致性确认生成内容被医学资料所支持，最终综合两个任务的结果输出核查结果。

电子护栏事实核查模块会根据核查结果对诊断建议进行反馈。如果诊断建议被标记为不准确或不可靠，模块会提示大语言模型（LLMs）进行重新进行推理修正建议。修正后的建议将再次经过核查，直至内容被确认为准确和可靠，诊断建议将展示给使用者。

最终呈现于诊断页面，顶部会显示报告的基本信息，包括报告 ID 和患者 ID，这些信息有助于医生快速识别和关联患者的其他医疗记录。其后是报告生成日期，这一信息对于追踪患者的病程进展和治疗效果至关重要。如图 5-11 所示。

患者信息端

患者管理

患者反馈管理

用户反馈收集

报告信息

患者姓名: 张三

报告ID: 2025030256

报告生成日期: 20250302

科室: -- --

生成医生: -- --

患者编号: 202503123456

诊断结果

根据患者描述的症状，儿子可能患有龋齿并引发根尖周病。为了确诊疾病，建议进行口腔X光片检查以确认龋齿和根尖周病的情况。

治疗方案

推荐的药物是非甾体抗炎药布洛芬片（布洛芬片），用于缓解疼痛和减轻炎症。

此外，建议避免食用高糖食物和饮料，以帮助控制龋齿的发展。

诊断依据

患者

- 牙疼（基于知识1）
- 可能患有龋齿（基于知识2）
- 引发根尖周病（基于知识3）
- 需要口腔X光片检查（基于知识4）
- 确认龋齿和根尖周病（基于知识5）
- 可以治疗龋齿（基于知识6）
- 使用非甾体抗炎药布洛芬片（基于知识7）
- 用于缓解疼痛和减轻炎症（基于知识7）
- 应避免高糖食物和饮料（基于知识8）

图 5-11 诊断报告

诊断结果显示当前患者的健康状况，包含疾病名称、进一步检查项目等信息。诊断依据部分则更为详细，这部分内容可能包括患者症状的描述、可能的疾病、所需的检查项目、忌口、实验室检查结果、影像学检查发现以及其他相关医疗数据，以便医生能够快速理解诊断的基础。治疗方案则根据诊断结果量身定制，详细列出了药物治疗或其他治疗措施，并可能包括治疗的预期效果和可能的副作用。

5.4.7 系统功能测试

为验证系统的性能和有效性，因此设计并进行了系统功能测试。该测试主要涵盖了包括知识图谱检索、问答和事实核查等三个方面。在知识图谱检索测试中，主要测试系统对于知识图谱中的实体和关系的检索和匹配能力，如从知识图谱中选取的实体和关系与问题的相关性。在事实核查测试中，主要测试事实核查部分的验证能力，通过多个测试样例测试事实核查模块的正确率。在问答测试中，测试系统对于各类医疗问题的回答能力，测试系统在不同问题的回答准确度和实时性。测试结果如表 5-7 所示。

表 5-7 系统功能测试结果

测试项目	操作步骤	预期结果	测试结果
前端界面显示	访问医疗问答系统页面	系统按键、图标等 UI 的样式正常，交互功能正常	测试结果正常
知识图谱检索	在医疗问答系统界面输入问题	系统在 Neo4j 数据库检索，并修剪无关实体	测试结果正常
事实核查	在医疗问答系统界面输入问题	将系统输出与另一数据源进行对比并做出判断	测试结果正常
问答功能	在医疗问答系统界面输入问题	系统可以理解用户输入的问题，并根据检索到的数据回答用户问题	测试结果正常

5.5 本章小结

本章围绕基于知识图谱和大语言模型的医疗辅助诊断系统的实现进行了全面阐述。系统的设计与开发旨在为医生提供一个高效、准确且安全的诊断支持工具，通过整合知识图谱的结构化知识和大语言模型的强大推理能力，提升医疗诊断的

效率和质量。系统功能需求分析涵盖了患者信息端和系统管理端的详细功能。患者信息端主要面向医生，提供患者信息管理、病历记录、诊断报告生成、随访管理等功能，以支持医生对患者进行全面的医疗管理。系统管理端则侧重于系统的维护和管理，包括用户管理、知识图谱查询、诊断建议生成、事实核查等，确保系统的稳定运行和数据安全。通过系统提供简洁明了的用户界面，降低了学习成本，提高了工作效率，增强了用户体验。

结 论

随着医疗数据的爆炸式增长，传统的基于规则引擎的辅助诊断系统已难以满足现代医疗的需求，而大语言模型（LLMs）的出现为医疗辅助诊断带来了新的机遇。然而 LLMs 在医疗应用中也面临着幻觉问题、缺乏可解释性以及计算效率低等挑战。因此提出了全局修剪检索（GPR）方法和高效的事实核查模型以提高系统的诊断准确性、可解释性、内容事实性和计算效率。具体研究内容如下：

（1）提出的一种创新的知识检索方法——全局修剪检索，该方案首先利用广度优先搜索（BFS）算法构建完整的实体关系树，捕捉实体间直接和间接的复杂语义联系。并通过全局修剪策略从整棵树的角度去除语义相似性较低的部分，保留与问题最相关的实体和关系形成精简的实体关系图。此外 GPR 方案特别关注多实体问题的处理，通过融合多个实体关系树为 LLMs 提供更全面的语义信息，使其能够更好地理解多实体间的复杂关系并进行有效推理。

在实验中 GPR 方法展现出显著的优势。它在多个基准数据集上优于现有的检索增强方法，无论是普通文本知识问答还是医疗知识问答任务都能为 LLMs 提供更准确的知识路径，从而生成更精准的答案。GPR 方案的全局修剪策略确保了检索结果的完整性和准确性，同时高效的检索效率显著降低了 LLMs 的推理负担，提高了系统的响应速度。

（2）在事实核查方面提出了一种结合多任务的高效事实核查模型，事实核查模型首先基于检索到的证据生成支持论证和反驳论证，通过语言模型的推理能力从多个角度对声明进行分析。然后将复杂的声明分解为若干原子事实并对每个原子事实进行独立核查，并聚合所有原子事实的核查结果。最终根据两任务的结果综合得出结论从而确保在事实核查任务中充分利用模型的推理能力获得精确结果。

实验部分在公开的数据集 AVeriTeC 和医疗相关的 PubHealth 数据集上进行了测试。这两个数据集分别包含复杂的多标签标注和长篇证据文本能够有效评估模型在不同场景下的表现。模型在医疗和非医疗文本分类任务上都展现出良好的性能，在提升性能的同时保持了较高的计算效率，为大语言模型在医疗领域的安全、可靠应用提供了有力支持。

（3）提出了一种检索增强的大语言模型辅助诊断系统，旨在通过结合知识图谱的结构化知识和大语言模型的强大推理能力解决传统辅助诊断系统在复杂病例处理中的局限性，并通过事实核查模型提升医疗诊断的准确性和效率。

本文通过检索增强和事实核查模型实现了知识图谱增强大语言模型在医疗辅

助诊断中的应用。在未来的 AI 医疗辅助诊断研究中,将进一步提升大模型的能力,同时探索大模型与知识图谱的结合方案。未来将关注以下方面:

(1) 大语言模型自身的能力在辅助诊断中至关重要,是强大的综合分析和逻辑推理能力知识推理的核心,更强大的模型将对知识的推理更精确,对患者情况的把握更精确,从而可给出更可靠的医疗报告。

(2) 知识图谱增强方面,如何检索到更优质的知识并提供给大语言模型。大语言模型可以利用知识图谱中的结构化知识增强其对医疗领域知识的理解和推理能力,提供更有针对性的报告。

(3) 提高事实核查的效率和准确性能力可以确保数据的准确性和研究结论的可靠性,从而提高大语言模型相关系统生成内容的可靠性。

参考文献

- [1] 司锐, 李文秀, 苏俊武. 人工智能在医学领域的应用进展[J]. 中国医药, 2021, 16(6): 957-960.
- [2] 苏尤丽, 胡宣宇, 马世杰, 等. 人工智能在中医诊疗领域的研究综述[J]. 计算机工程与应用, 2024, 60(16): 1-18.
- [3] 张如意, 周运翱, 彭迎春. “医生-医疗人工智能-患者”新型医患关系建构路径探析[J]. 中国医学伦理学, 2025(1): 103-108.
- [4] Wang F, Preininger A. AI in health: state of the art, challenges, and future directions[J]. Yearbook of Medical Informatics, 2019, 28(1): 16-26.
- [5] Joel Prabhod K. Integrating large language models for enhanced clinical decision support systems in modern healthcare[J]. Journal of Machine Learning for Healthcare Decision Support, 2023, 3(1): 18-62.
- [6] Bedi S, Liu Y, Orr-Ewing L, et al. Testing and evaluation of health care applications of large language models: a systematic review[J]. Jama-journal of The American Medical Association, 2025, 333(4): 319.
- [7] Haltaufderheide J, Ranisch R. The ethics of ChatGPT in medicine and healthcare: a systematic review on large language models (LLMs)[J]. npj Digital Medicine, 2024, 7(1): 183.
- [8] Omar M, Nadkarni G N, Klang E, et al. Large language models in medicine: a review of current clinical trials across healthcare applications[J]. PLOS Digital Health, 2024, 3(11): e0000662.
- [9] He K, Mao R, Lin Q, et al. A survey of large language models for healthcare: from data, technology, and applications to accountability and ethics[M]. arXiv, 2024.
- [10] Rao A, Pang M, Kim J, et al. Assessing the utility of ChatGPT throughout the entire clinical workflow[J]. Medrxiv, 2023: 2023-2.
- [11] Sallam M. ChatGPT utility in healthcare education, research, and practice: systematic review on the promising perspectives and valid concerns[J]. Health Care, 2023, 11(6): 887.
- [12] Reddy S. Evaluating large language models for use in healthcare: a framework for translational value assessment[J]. Informatics in Medicine Unlocked, 2023, 41: 101304.
- [13] 中华人民共和国国民经济和社会发展第十四个五年规划和 2035 年远景目标纲要[A]. (2021-01-13).
- [14] Pal A, Umapathi L K, Sankarasubbu M. Med-HALT: medical domain hallucination test for large language models[C]//Proceedings of the 27th Conference on Computational Natural Language Learning, 2023: 314-334.
- [15] Zhao W X, Zhou K, Li J, et al. A survey of large language models[M]. arXiv, 2023.
- [16] Raghu Subramanian C, Yang D A, Khanna R. Enhancing health care communication with large language models—the role, challenges, and future directions[J]. Jama Network Open, 2024, 7(3): e240347.

- [17] Ullah E, Parwani A, Baig M M, et al. Challenges and barriers of using large language models (LLM) such as ChatGPT for diagnostic medicine with a focus on digital pathology – a recent scoping review[J]. *Diagnostic Pathology*, 2024, 19(1): 43.
- [18] Yang R, Tan T F, Lu W, et al. Large language models in health care: development, applications, and challenges[J]. *Health Care Science*, 2023, 2(4): 255-263.
- [19] Nassiri K, Akhloufi M A. Recent advances in large language models for healthcare[J]. *Biomedinformatics*, 2024, 4(2): 1097-1143.
- [20] Suzuki M, Hirano M, Sakaji H. From base to conversational: japanese instruction dataset and tuning large language models[C]//*Proceedings of the 2023 IEEE International Conference on Big Data*, 2023: 5684-5693.
- [21] Sun K, Xu Y E, Zha H, et al. Head-to-tail: how knowledgeable are large language models (LLM)? A.K.A. will LLMs replace knowledge graphs?[M]. *arXiv*, 2023.
- [22] Kang M, Baek J, Hwang S J. KALA: knowledge-augmented language model adaptation[C]//*Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics*, 2022: 5144-5167.
- [23] Zhang Z, Han X, Liu Z, et al. ERNIE: enhanced language representation with informative entities[C]//*Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, 2019: 1441-1451.
- [24] Qiao S, Ou Y, Zhang N, et al. Reasoning with language model prompting: a survey[C]//*Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*, 2023: 5368-5393.
- [25] Wang Y, Wang M, Manzoor M A, et al. Factuality of large language models: a survey[C]//*Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Miami, Florida, USA: Association for Computational Linguistics, 2024: 19519-19529.
- [26] Jiang X, Yan L, Vavekanand R, et al. Large language models in healthcare current development and future directions[C]//*Proceedings of the Generative AI Research*, 2023.
- [27] Peng C, Xia F, Naseriparsa M, et al. Knowledge graphs: opportunities and challenges[J]. *Artificial Intelligence Review*, 2023, 56(11): 13071-13102.
- [28] Dai Y, Wang S, Xiong N N, et al. A survey on knowledge graph embedding: approaches, applications and benchmarks[J]. *Electronics*, 2020, 9(5): 750.
- [29] Pan S, Luo L, Wang Y, et al. Unifying large language models and knowledge graphs: a roadmap[J]. *IEEE Transactions on Knowledge and Data Engineering*, 2024: 1-20.
- [30] Sun Y, Shi Q, Qi L, et al. JointLK: joint reasoning with language models and knowledge graphs for commonsense question answering[C]//*Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics*, 2022: 5049-5060.
- [31] Wang X, Gao T, Zhu Z, et al. KEPLER: a unified model for knowledge embedding and pre-trained language representation[J]. *Transactions of the Association for Computational Linguistics*, 2021, 9: 176-194.

- [32] 李源, 马新宇, 杨国利, 等. 面向知识图谱和大语言模型的因果关系推断综述[J]. 计算机科学与探索, 2023, 17(10): 2358-2376.
- [33] Baek J, Aji A F, Lehmann J, et al. Direct fact retrieval from knowledge graphs without entity linking[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics, 2023: 10038-10055.
- [34] Luo D, Sheng J, Xu H, et al. Improving complex knowledge base question answering with relation-aware subgraph retrieval and reasoning network[C]//Proceedings of the 2023 International Joint Conference on Neural Networks, 2023: 1-8.
- [35] Jiang J, Zhou K, Ye K, et al. StructGPT: a general framework for large language model to reason over structured data[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, 2023.
- [36] Feng C, Zhang X, Fei Z. Knowledge solver: teaching LLMs to search for domain knowledge from knowledge graphs[M]. arXiv, 2023.
- [37] Baek J, Aji A F, Saffari A. Knowledge-augmented language model prompting for zero-shot knowledge graph question answering[C]//Proceedings of the 1st Workshop on Natural Language Reasoning and Structured Explanations, 2023: 78-106.
- [38] Sun J, Xu C, Tang L, et al. Think-on-graph: deep and responsible reasoning of large language model on knowledge graph[C]//Proceedings of the Twelfth International Conference on Learning Representations, 2023.
- [39] Wen Y, Wang Z, Sun J. MindMap: knowledge graph prompting sparks graph of thoughts in large language models[M]. arXiv, 2023.
- [40] Gero Z, Singh C, Cheng H, et al. Self-verification improves few-shot clinical information extraction[C]//Proceedings of the ICML 3rd Workshop on Interpretable Machine Learning in Healthcare, 2023.
- [41] Gupta P, Wu C S, Liu W, et al. DialFact: a benchmark for fact-checking in dialogue[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics, 2022: 3785-3801.
- [42] Chamoun E, Saeidi M, Vlachos A. Automated fact-checking in dialogue: are specialized models needed?[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, 2023: 16009-16020.
- [43] Yang J, Rocha A. Take it easy: label-adaptive self-rationalization for fact verification and explanation generation[C]//Proceedings of the 2024 IEEE International Workshop on Information Forensics and Security, 2024: 1-6.
- [44] Yue Z, Zeng H, Shang L, et al. Retrieval augmented fact verification by synthesizing contrastive arguments[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics, 2024: 10331-10343.
- [45] Tang L, Laban P, Durrett G. MiniCheck: efficient fact-checking of LLMs on grounding documents[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing, 2024: 8818-8847.

- [46] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems, 2017: 6000-6010.
- [47] Elman J L. Finding structure in time[J]. Cognitive Science, 1990, 14(2): 179-211.
- [48] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [49] Talmor A, Berant J. The web as a knowledge-base for answering complex questions[C]//Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2018: 641-651.
- [50] Yih W tau, Richardson M, Meek C, et al. The value of semantic parse labeling for knowledge base question answering[C]//Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics, 2016: 201-206.
- [51] Gu Y, Kase S, Vanni M, et al. Beyond I.I.D.: three levels of generalization for question answering on knowledge bases[C]//Proceedings of the Web Conference 2021, 2021: 3477-3488.
- [52] Bordes A, Usunier N, Chopra S, et al. Large-scale simple question answering with memory networks[J]. Arxiv, 2015, abs/1506.2075.
- [53] Berant J, Chou A, Frostig R, et al. Semantic parsing on freebase from question-answer pairs[C]//Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing, 2013: 1533-1544.
- [54] Bollacker K D, Evans C, Paritosh P K, et al. Freebase: a collaboratively created graph database for structuring human knowledge[C]//Proceedings of the SIGMOD Conference, 2008.
- [55] Brown T B, Mann B, Ryder N, et al. Language models are few-shot learners[C]//Proceedings of the 34th International Conference on Neural Information Processing Systems, 2020.
- [56] Jiang A Q, Sablayrolles A, Roux A, et al. Mixtral of experts[M]. arXiv, 2024.
- [57] Li Y, Li Z, Zhang K, et al. ChatDoctor: a medical chat model fine-tuned on a large language model meta-AI (LLaMA) using medical domain knowledge[J]. Cureus, 2023, 15(6).
- [58] Xia F, Li B, Weng Y, et al. MedConQA: medical conversational question answering system based on knowledge graphs[C]//Proceedings of the the 2022 Conference on Empirical Methods in Natural Language Processing, 2022: 148-158.
- [59] Schlichtkrull M, Guo Z, Vlachos A. AVERITEC: a dataset for real-world claim verification with evidence from the web[C]//Proceedings of the 37th International Conference on Neural Information Processing Systems, 2023.
- [60] Kotonya N, Toni F. Explainable automated fact-checking for public health claims[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing, 2020: 7740-7754.