

电 子 科 技 大 学

UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

专业学位硕士学位论文

MASTER THESIS FOR PROFESSIONAL DEGREE



论文题目

知识图谱与大模型协同的
智能问答方法研究及应用

专业学位类别

电子信息

学 号

202222080715

作者姓名

卿 正

指导教师

胡 旺 教 授

学 院

计算机科学与工程学院
(网络空间安全学院)

分类号 TP181 密级 公开
UDC 注 1 004.8

学 位 论 文

知识图谱与大模型协同的智能问答方法研究及应用

(题名和副题名)

卿 正

(作者姓名)

指导教师 胡 旺 教 授
电子科技大学 成 都

申请学位级别 硕士 学科专业 电子信息
专业学位领域 计算机技术
提交论文日期 2025 年 3 月 16 日 论文答辩日期 2025 年 5 月 16 日
学位授予单位和日期 电子科技大学 2025 年 6 月
答辩委员会主席
评阅人

注 1: 注明《国际十进分类法 UDC》的类号。

Research and Application of Intelligent Question Answering Methods Based on Collaboration between Knowledge Graphs and Large Language Models

A Master Thesis Submitted to

University of Electronic Science and Technology of China

Discipline	Electronic Information
Student ID	202222080715
Author	Qing Zheng
Supervisor	Prof. Hu Wang
School	School of Computer Science and Engineering (School of Cyber Security)

摘要

智能问答技术作为人机交互的核心，能够精准理解用户提出的自然语言问题，并提供简洁、高效的答案。在自然灾害领域，该技术可用于实时获取灾害相关信息、辅助灾害应急决策，并提高获取灾害信息的效率。在这一过程中，知识图谱通过结构化的知识支持，提升回答的准确性和可解释性，而大模型凭借强大的自然语言理解与生成能力，使智能问答系统具备更深层次的语境理解和复杂推理能力。二者结合不仅能提升智能问答系统的效率和准确性，还能增强其可信度，为自然灾害的信息获取、应急响应和救援调度提供智能化支持。

本研究围绕自然灾害智能问答技术展开，重点探讨知识图谱与大模型的协同机制，以提升问答方法在准确性和可解释性方面的表现。本研究主要完成了以下工作：

1.自然灾害知识图谱构建：引入 SENet 机制，提出基于 BERT-SENet-BiLSTM-CRF (BSBC) 的实体抽取模型，实验结果表明该模型在多个数据集上表现优越。此外，优化本体、实体和关系构建策略，提高数据一致性和规范性。

2.自然灾害多通道智能问答模型 (MultiPathQA)：结合图卷积网络与 BERT 计算问题语句复杂度，并通过智能决策机制选择最优问答通道。系统采用知识图谱问答负责简单难度精准匹配问题、检索增强生成负责中等难度跨领域问题和大模型负责复杂难度推理问题的三类问答通道协同机制，以提升智能问答的准确性和适应性。

3.自然灾害情景构建智能问答系统：融合知识图谱与多通道问答技术，支持地震事件查询、灾害情景构建、智能问答等功能，提供高效、精准的信息服务，在地震应急响应及防灾减灾领域具有重要应用价值。

本研究通过融合知识图谱与大模型，构建了高效、精准的自然灾害智能问答系统，提升了问答的准确性和可解释性。研究成果不仅为自然灾害信息获取与应急响应提供了智能化支持，也推动了智能问答技术在自然灾害领域的应用与发展。

关键词：知识图谱，大语言模型，检索增强生成，智能问答，自然灾害

ABSTRACT

Intelligent Question Answering technology, as the core of human-machine interaction, can accurately understand users' natural language questions and provide concise, efficient answers. In the field of earthquake disasters, this technology is used to obtain real-time earthquake-related information, assist in emergency decision-making, and improve the efficiency of accessing disaster information. In this process, knowledge graphs enhance the accuracy and interpretability of responses through structured knowledge support, while large models, with their powerful natural language understanding and generation capabilities, enable the Question Answering system to achieve deeper contextual understanding and complex reasoning. The combination of these two not only enhances the efficiency and accuracy of the Intelligent Question Answering system but also strengthens its reliability, providing intelligent support for information acquisition, emergency response, and rescue dispatch in earthquake disaster scenarios.

This study focuses on Intelligent Question Answering technology for earthquake disasters, with an emphasis on integrating knowledge graphs and large models to enhance the system's accuracy and interpretability. The following work has been completed in this thesis:

1. Construction of a Seismic Disaster Knowledge Graph: This study introduces the SEnet mechanism and proposes the BERT-SEnet-BiLSTM-CRF (BSBC) entity extraction model. Experimental results demonstrate that this model outperforms existing approaches across multiple datasets. Additionally, strategies for optimizing ontology, entity, and relationship construction have been implemented to improve data consistency and standardization.

2. Multi-Path Intelligent Question Answering Model for Seismic Disasters (MultiPathQA): Incorporates Graph Convolutional Networks and BERT to assess question complexity and employs an intelligent decision mechanism to select the optimal answering path. Establishes a collaborative mechanism among three Question Answering channels. Knowledge Graph Question Answering for precise matching of simple questions. Retrieval-Augmented Generation (RAG) for moderate-difficulty cross-domain questions. Large Language Model for complex inference questions. This multi-path

framework enhances the accuracy and adaptability of the Intelligent Question Answering system.

3. Intelligent Question Answering System for Seismic Disaster Scenario Construction: By integrating knowledge graphs and multi-path Question Answering technologies, the system supports earthquake event queries, disaster scenario construction, and intelligent Question Answering functionalities. It delivers efficient and precise information services, playing a crucial role in earthquake emergency response and disaster prevention and mitigation.

This study integrates knowledge graphs and large models to construct an efficient and accurate Intelligent Question Answering technology for earthquake disasters, enhancing the accuracy and interpretability of Question Answering. The research results not only provide intelligent support for earthquake information retrieval and emergency response but also promote the application and development of intelligent Question Answering technology in the field of earthquake disaster management.

Keywords: Knowledge Graph, Large Language Model, Retrieval-Augmented Generation, Intelligent Question Answering, Seismic Disaster

目 录

第一章 绪论.....	1
1.1 课题背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 地震灾害知识图谱构建研究现状.....	2
1.2.2 基于知识图谱的问答方法研究现状	3
1.2.3 基于大模型的问答方法研究现状.....	4
1.2.4 基于检索增强生成的问答方法研究现状	5
1.2.5 地震灾害情景构建研究现状.....	5
1.3 课题主要研究内容.....	6
1.4 课题来源.....	7
1.5 论文结构.....	7
第二章 课题相关技术基础	9
2.1 知识图谱.....	9
2.2 深度学习.....	11
2.2.1 SENet 网络	11
2.2.2 BiLSTM	12
2.2.3 BERT 模型.....	15
2.2.4 图卷积网络.....	17
2.3 大语言模型.....	18
2.4 检索增强生成.....	19
2.5 本章小结.....	19
第三章 地震灾害知识图谱构建	21
3.1 引言.....	21
3.2 地震灾害实体抽取模型.....	22
3.2.1 模型描述.....	22
3.2.2 数据预处理.....	23
3.2.3 BERT-BiLSTM-CRF 实体抽取模型	24
3.2.4 基于 BERT-SENet 的编码方法	25
3.3 实验数据集、评价指标和参数设置	27
3.3.1 实验数据集.....	27
3.3.2 评价指标.....	28
3.3.3 参数选择.....	29
3.3.4 实验和结果分析.....	31
3.4 地震灾害知识图谱结构设计及实现	33

3.4.1 地震灾害知识图谱本体构建.....	33
3.4.2 地震灾害知识图谱实体构建.....	35
3.4.3 地震灾害知识图谱关系构建.....	37
3.5 地震灾害知识图谱展示与质量评估	38
3.6 本章小结.....	41
第四章 地震灾害多通道智能问答模型	42
4.1 引言.....	42
4.2 模型描述.....	43
4.2.1 模型总体结构.....	43
4.2.2 知识图谱问答通道.....	44
4.2.3 检索增强生成通道.....	45
4.2.4 大语言模型通道.....	46
4.2.5 智能路由决策模块.....	48
4.3 实验数据集、评价指标和参数设置	51
4.3.1 实验数据集.....	51
4.3.2 评价指标.....	51
4.3.3 参数设置.....	53
4.3.4 实验和结果分析.....	53
4.4 本章小结.....	54
第五章 地震灾害情景构建智能问答系统	55
5.1 引言.....	55
5.2 系统分析与设计.....	56
5.2.1 需求分析.....	56
5.2.2 概要设计.....	57
5.2.3 数据库设计	59
5.3 系统实现.....	63
5.3.1 系统开发环境.....	63
5.3.2 系统实现方案.....	64
5.4 系统展示.....	65
5.5 本章小结.....	69
第六章 总结与展望	70
6.1 全文总结.....	70
6.2 未来展望.....	70
参考文献.....	72

第一章 绪论

1.1 课题背景及意义

随着信息时代的快速发展,全球数据和知识的规模呈指数级增长,使得知识的存储、管理与获取变得愈发复杂^[1]。在此背景下,人工智能(Artificial Intelligence, AI)技术的飞速进步为智能问答系统的研究与应用带来了前所未有的机遇。智能问答系统旨在理解用户的自然语言问题,并提供精准、高效的答案。与此同时,人工智能技术的进步为智能问答系统的发展提供了新机遇。然而,随着数据的增长,传统的问答系统在处理复杂的、专业性较强的问题时,仍然面临诸多挑战,包括知识碎片化、数据结构不统一、信息检索效率低下等问题^[2],难以满足高精度、深层次的信息需求。因此,如何构建一个精准、高效、可解释的智能问答系统,已成为人工智能与知识管理领域的重要研究方向。

在应对这些挑战的过程中,知识图谱(Knowledge Graph, KG)与大语言模型(Large Language Model, LLM)逐渐成为智能问答技术的两大核心支柱。知识图谱以结构化的方式组织和关联知识,使问答系统具备更强的逻辑推理能力^[3],从而提供精准、可验证的回答。而大语言模型(如 Generative Pre-trained Transformer 4, GPT-4^[4])凭借卓越的自然语言理解和生成能力,能够解析复杂语境并生成连贯、流畅的答案。然而,大模型的训练数据存在一定局限性,可能会产生幻觉现象,即生成与事实不符的回答,尤其在专业问答领域,这一问题尤为突出^[5]。

近年来,知识图谱与大语言模型的融合逐渐成为智能问答技术的新趋势^[6]。知识图谱能够提供结构化、可追溯的知识来源,而大语言模型则具有强大的自然语言处理能力,二者相结合,有望构建更加精准、可靠的智能问答系统,并在医疗、金融、法律、地震灾害等专业领域发挥重要作用^[7]。

本研究围绕知识图谱与大模型协同的智能问答方法展开,旨在解决地震灾害情景构建领域的复杂知识问题,构建一套高效、可解释的地震灾害智能问答系统。与传统问答系统相比,该系统不仅能依靠关键字匹配和信息检索来回答问题,还能基于知识图谱进行实体链接与关系推理,从而提供更精准的答案。同时,融合大模型的自然语言理解能力,使得问答系统能够更流畅地解析用户问题^[8],进一步提高回答的准确性。此外,针对大模型的“黑箱”问题,本研究利用知识图谱的可溯源性,为智能问答系统提供推理路径和知识证据,增强用户信任度。

本研究的成果将推动智能问答技术在专业领域的深度应用，助力知识管理与智能服务的升级，同时为人工智能在复杂知识体系下的推理与问答研究提供新的思路。

1.2 国内外研究现状

1.2.1 地震灾害知识图谱构建研究现状

地震灾害知识图谱是一种基于语义网络的知识表示方式，用于整合和组织分散的地震灾害信息。它由本体、实体、关系等基本组成部分构成，用于表达地震相关事件、灾害影响、应急措施等信息。知识图谱的构建不仅包括知识的抽取、融合、存储，还包括推理和可视化，从而为地震灾害管理和研究提供更智能的支持。

近年来，国内外学者围绕地震灾害知识图谱的构建方法、知识抽取与融合等方面展开了深入研究，取得了一定成果。陶坤旺等人^[9]基于知识抽取和信息融合等技术，构建构建了一套面向一体化综合减灾的知识图谱，Usländer 等人^[10]提出了基于语义网络技术的地震知识管理框架，该框架使用 Resource Description Framework 和 Web Ontology Language 构建地震领域的本体模型，以提供更精确的地震知识表示和查询能力。Deng 等人^[11]研究了地震灾害知识的本体构建方法，建立了地震术语本体，实现了跨领域地震知识的标准化表达和共享。Zhang 等人^[12]构建了一个地震术语词典，并基于模式匹配方法识别地震相关信息，主要适用于结构化和半结构化文本数据，如地震报告和灾害预警信息。Kim 等人^[13]利用正则表达式结合命名实体识别（Named Entity Recognition, NER）方法，对地震新闻文本进行实体抽取，主要识别地震发生时间、地点、震级等关键信息。Liu 等人^[14]提出了一种基于句法分析的地震实体识别方法，结合依存句法树和规则匹配，从灾害报告中提取地震损失信息，如房屋损毁程度、受灾人口等。Wang 等人^[15]采用 Conditional Random Field (CRF) 模型进行地震文本的实体识别，结合地震术语特征、词性标注特征和上下文窗口特征，取得了较好的效果。Matsuo 等人^[16]提出了一种基于支持向量机的地震实体分类模型，通过提取 Term Frequency-Inverse Document Frequency 特征和文本嵌入特征，提高了对地震相关实体（如震源位置、震级、烈度等）的识别能力。Zhao 等人^[17]使用隐马尔可夫模型模型进行地震事件抽取，在多个地震报告数据集上取得了较高的准确率。

尽管现有研究在地震灾害知识图谱构建方面取得了一定成果，但当前对地震灾害知识图谱构建领域仍存在数据源的知识的异构性导致概念的定义和层级关系

难以统一、非结构化文本提取实体精度不够和高质量地震语料数据集较少导致模型泛化能力不足等问题，对地震灾害知识图谱构建的研究还有待进一步深化。

1.2.2 基于知识图谱的问答方法研究现状

基于知识图谱的问答方法致力于利用结构化知识库实现自然语言问题的语义解析与逻辑推理。与传统的搜索引擎相比，基于知识图谱的问答方法不仅通过实体之间的直接联系进行推理，还能够挖掘隐含关系，使得信息检索不再局限于简单的文档排序，而是通过智能语义分析提供更接近用户需求的答案^[18]。这种方法能够提高问答的准确性和可解释性，在各类智能应用中具有广泛的应用价值。

当前，基于知识图谱的问答方法主要分为三大类：基于语义图的问句解析方法、基于神经网络的问答方法和基于深度学习的答案排序方法^[18]。基于语义图的问句解析方法通过构建语义图，将问句解析成知识图谱的子图，再通过图匹配进行问答；Reddy 等人^[19]提出了与传统词典-文法方法不同的解析方法，即利用依存树转换为语义图，使得问题的语义映射更加精确；Yih^[20]进一步优化了语义图的构建方式，提高了其可解释性和解析准确性；此外，Bast 等人^[21]采用模板匹配方式生成语义图，使得系统能够处理更复杂的问句。该方法的优势在于其较强的逻辑可解释性，但同时依赖启发式方法构建语义图，通用性较弱，难以适应不同领域的多样化问题。基于神经网络的方法将问答任务视为机器翻译任务，利用端到端模型将自然语言转换为结构化的语义表示。Dong 等人^[22]和 Jia 等人^[23]采用注意力（Attention）机制的编码器-解码器（Encoder-Decoder）架构，实现了端到端的语义解析；Chen 等人^[24]提出了 Sequence-to-Action 模型，结合知识图谱信息进行语义解析，提高了问答的准确性；此外，Lukovnikov 等人^[25]设计了一种字符级编码器，使系统能够处理未知词汇问题（Out of Vocabulary, OOV）。尽管神经网络方法在大规模数据集上表现良好，但其可解释性较弱，训练过程耗时且对标注数据的依赖较大。最后，基于深度学习的答案排序方法通过将问题和知识图谱中的实体、关系投射到高维向量空间，并利用深度学习模型计算相似度，实现答案的智能排序。丁斌^[26]构建了基于汽车领域的智能问答系统，针对原有问答模板方法进行了改进，结合汽车领域知识库提出模板自动生成方法，提前将复杂自然语言处理，预备在模板库构建中取得较好效果。Bordes 等人^[27]提出了基于实体链接和路径匹配的问答方法，在多个数据集上取得了良好的效果；Hao 等人^[28]进一步提出 Cross-Attention 机制，在训练过程中充分利用知识库的全局信息，有效缓解了 OOV 问题；Qu 等人^[29]设计了一种基于注意力机制的递归神经网络，捕获问句与答案之间的交互信息，提高了问答

的准确性。然而，该方法仍然存在泛化性不足的问题，在处理时序性较强的问句时表现有限。

综上所述，基于知识图谱的问答方法在提供结构化信息和精确答案方面具有显著优势。然而，在实际应用中仍然面临诸多挑战，如知识图谱的构建和维护成本高、多跳推理的复杂度大、数据的更新和覆盖范围有限等。此外，不同领域的问答需求差异较大，如何增强系统的适应性和可扩展性仍然是当前研究的重点方向。未来，基于知识图谱的问答方法需要结合更多的数据驱动方法以提升问答系统的智能性和适应性，为各类专业领域提供更高效率的智能问答服务。

1.2.3 基于大模型的问答方法研究现状

随着深度学习的快速发展，基于大语言模型的问答方法已经成为当前研究的核心方向^[30]。大模型在知识理解、信息提取和答案生成方面展现出强大的能力，并在各行业的问答任务中取得突破性进展。OpenAI^[31]推出的 Generative Pre-trained Transformer (GPT) 系列（如 GPT-3、GPT-4）和 Google 开发的 Bidirectional Encoder Representations from Transformers (BERT)、Text-to-Text Transfer Transformer (T5) 等模型，极大地提升了问答系统的准确性和泛化能力。GPT-3 被用于开放域问答，并在 SQuAD、TriviaQA 等数据集上表现出色。中国 DeepSeek-AI^[32]近日发布了 DeepSeek-R1 智能问答模型，这一突破性成果凭借其在编程、数学计算和逻辑推理方面的卓越表现，展现了极高的智能水平，迅速在全球科技领域引发广泛关注。Google^[33]的 T5 模型采用 Text-to-Text 架构，对问答任务进行了统一建模，在多种问答任务中表现出极高的灵活性。此外，Facebook AI Research^[34]推出的 Large Language Model Meta AI (LLaMA) 模型在多任务学习中进一步优化了问答能力。由于大模型的训练数据存在时间滞后性，研究者提出了结合外部知识库的知识增强问答方法。例如，Lewis 等人^[35]提出的检索增强生成 (Retrieval-Augmented Generation, RAG) 模型，将 RAG 机制与大模型相结合，提高了对事实性问题的回答能力。Google Research^[36]的 Retrieval-Augmented Language Model (RALM) 通过主动检索知识库，提高了问答系统对新知识的适应性。开放域问答是当前大模型问答研究的重要方向。Karpukhin 等人^[37]提出的 Dense Passage Retrieval 模型利用双编码器架构，实现了高效的文档检索和答案生成。此外，GPT-4^[38]在开放域问答任务上的表现进一步优化，使其能够回答复杂推理问题。大模型问答方法已经广泛应用于医疗、法律、金融等领域。Hua 等人^[39]提出 Med-PaLM 模型，在医学知识问答任务中表现优异。Yao 等人^[40]提出 ChatLaw，专注于法律领域的问答应用。Wu 等人^[41]开发的 FinGPT，在金融数据分析和市场预测中展现出强大能力。百度的文

心一言、阿里的 Qwen、华为的盘古大模型等，均在大模型问答方面进行了深入探索。文心一言 3.0 Titan^[42]在知识增强和问答准确性方面进行了优化，Qwen^[43]则通过大规模预训练和高效微调，提高了中文问答系统的性能。近年来，多模态问答成为研究热点。国内学者尝试结合视觉、文本等多模态信息，提升问答系统的综合能力。

1.2.4 基于检索增强生成的问答方法研究现状

大语言模型在语言理解和生成方面展现了显著的能力，但仍然具有局限性，如幻觉和无法有效检索到关键信息，在预训练大模型时，并没有明确使 LLM 学习到如何高质量利用检索文本完成生成任务，对于长而复杂的检索文本，LLM 无法准确提取到关键信息^[44]。检索增强生成 (Retrieval-Augmented Generation, RAG) 技术通过整合外部数据源的信息来丰富和细化 LLM 的生成能力，允许 LLM 在处理查询或生成文本时，动态地从外部数据库中检索相关内容。Shi W 等人^[45]提出了 Retrieval-Augmented Black-Box Tuning，是一种检索增强的语言建模框架，直接将检索到的文档作为输入添加到冻结的语言模型中。Ram O^[46]等人提出了一种简化版的检索增强语言建模方法 In-Context RALM，通过将相关文档直接添加到输入中，无需修改 LLM 架构或进一步训练，来提升语言建模性能。Yu W 等人^[47]提出了一个解决知识密集型任务的新视角，利用 LLM 取代文档检索器。Sun Z^[48]等人提出了 Retrieval-Augmented Commit-to-Recall for Faithful Generation，通过采样从 LLM 记忆中背诵一个或多个相关段落，然后产生最终答案。Feng Z^[49]等人提出了 Iterative Retrieval-Generation，一个迭代检索生成协同框架，用于增强大型语言模型解决知识密集型任务的能力。Shao Z^[50]等人提出了 ITER-RETGEN，将检索和生成过程迭代进行，利用上一轮生成的输出作为检索的上下文，从而获取更相关的知识，进而生成更好的输出。检索增强生成的问答方法在处理需要多步推理的问题时可能表现不足。

由于检索过程通常是单轮的，系统可能无法有效地关联多个相关信息片段，从而难以回答需要跨越多个文档或信息源的问题。此外，RAG 系统的性能对检索模块的质量高度依赖。如果检索阶段未能找到与查询高度相关的文档，生成模型可能基于不相关或错误的信息生成回答，导致回答的准确性下降。

1.2.5 地震灾害情景构建研究现状

地震灾害情景构建是地震灾害防御和应急管理的重要组成部分。该技术通过对历史地震数据、地震预测模型、城市基础设施和人口分布等因素的分析，模拟可

能发生的地震情境，以辅助政府和相关机构制定应急预案和减灾对策。近年来，国内外学者围绕地震灾害情景构建展开了深入研究，逐步形成了一系列理论与实践成果。Zhang 等人^[51]提出了一种基于情景推演的地震应急管理模型，该模型能够有效模拟不同震级下的灾害影响，并评估应急响应的有效性。Tian 等人^[52]研究了基于虚拟仿真的地震灾害场景构建方法，利用 3D 建模和 GIS 技术模拟真实地震情景，并结合历史数据进行推演。此方法为灾害应急管理提供了更加直观的风险评估工具。此外，Spence 等人^[53]研究了城市区域地震灾害的情景预测和损失建模，提出了一套用于震害评估的计算框架，该框架基于地震灾害场景推演，可以评估建筑损坏、人员伤亡和经济损失。Tang 和 We^[54]开发了一种智能地震灾害评估仿真系统，该系统能够在特定城市的地震场景中进行推演，并提供地震灾害的实时评估结果。该方法被应用于地震应急管理的演练中，提高了防灾减灾的决策效率。同时，Hori 等人^[55]提出了一种地震灾害模拟的集成系统，该系统结合高性能计算和人工智能，实现了对地震发生后的建筑物损坏和次生灾害的自动化预测。Babayev 和 Ismail-Zadeh^[56]基于情景模拟方法，评估了阿塞拜疆巴库市的地震灾害风险，并采用峰值地面加速度（Peak Ground Acceleration, PGA）等参数计算可能的损失。Zhuang 等人^[57]在中国固原地区开展了基于地震情景的风险评估研究，综合考虑了坡度位移、PGA 和人口密度等因素，以提高地震灾害评估的准确性。Karimzadeh 等人^[58]结合遥感数据和 GIS，评估了伊朗大不里士的地震灾害情景，并分析了建筑脆弱性和人员伤亡情况。Mendes-Victor 等人^[64]提出了一种基于深度学习的地震灾害预测模型，该模型能够通过对历史地震数据进行学习，提高对未来地震灾害的预测精度。

然而当前，地震灾害情景构建技术与人工智能和深度学习的结合方面还有待加强。在数据管理方面，由于知识图谱等图数据库结构化的数据存储方式，如果地震灾害情景构建与知识图谱结合，能够使得地震灾害情景构建的情景解释能力得到增强，但目前地震灾害情景构建与知识图谱的结合尚属空白。并且地震灾害情景构建需要得到与地震灾害有关的风险评估报告生成，由于大模型强大的语言生成能力，使用大模型能够使得地震灾害风险评估报告的生成如鱼得水，而在这方面的研究还有待深化。

1.3 课题主要研究内容

本课题主要围绕智能问答技术在地震灾害情景构建中的应用展开研究，重点探讨知识图谱与大模型的融合，以提升问答系统的准确性、可解释性和推理能力。研究构建了地震灾害知识图谱，并创新性地引入 Squeeze-and-Excitation Network

(SENet) 机制, 提出基于 BERT-SENet-BiLSTM-CRF (BSBC) 的实体抽取模型, 同时优化本体、实体和关系的构建策略, 以提高数据一致性和知识表达的规范性。研究提出了一种多通道智能问答模型 (Multi-Path Intelligent Question Answering Model, MultiPathQA), 结合图卷积网络 (Graph Convolutional Network, GCN) 与 BERT 计算问题语句复杂度, 并设计智能决策机制, 根据不同问题类型选择最优问答通道, 包括知识图谱问答通道进行精准匹配问答、检索增强生成通道进行向量检索来进行中长文本问题问答和大模型推理通道进行复杂推理任务问答。研究构建了一套地震灾害智能问答系统, 集成知识图谱与多通道问答技术, 实现地震事件查询、灾害情景构建及智能问答等功能, 为用户提供高效、精准的灾害信息服务, 助力地震应急响应和防灾减灾工作的智能化发展。

1.4 课题来源

本课题来源于国家重点研发项目“特大城市和城市群重特大地震灾害风险情景构建技术研发与应用示范”中的专题“城市和区域地震灾害风险评估及情景构建软件系统平台”(项目编号 2022YFC3003605)、宜宾大学城与宜宾市科技创新城共建协议项目“地质灾害知识图谱的构建与应用”(项目编号 YBSCXY2024010004) 和四川省重点实验室开放基金“战略性关键矿产资源知识图谱构建与智能问答关键技术研究”(项目编号 SCSXDZ2025-1)。

1.5 论文结构

本论文共分为六个章节, 按照逻辑性和研究重点展开, 具体如下:

第一章为绪论, 介绍研究背景、研究意义, 并综述国内外在地震灾害知识图谱构建、基于知识图谱、大模型和检索增强生成的问答方法以及地震灾害情景构建等方面的研究现状, 明确论文的研究目标和技术路线。

第二章为课题相关技术基础, 阐述本研究涉及的核心技术, 包括知识图谱的构建方法、深度学习、大语言模型、检索增强生成等内容, 为后续研究奠定理论基础。

第三章为地震灾害知识图谱构建研究, 提出基于 BERT-SENet-BiLSTM-CRF (BSBC) 的实体抽取模型, 并对地震灾害知识图谱的本体构建、实体构建、关系构建进行优化, 确保知识表示的规范性和数据的一致性。

第四章为地震灾害多通道智能问答模型, 构建多通道智能问答模型 (MultiPathQA), 结合图卷积网络和 BERT 计算问题的语句复杂度, 并采用智能决策机制, 根据不同问题类型从知识图谱问答、检索增强生成、大语言模型中选择最优问答通道。

第五章为地震灾害情景构建智能问答系统，基于前述技术，设计并实现地震灾害情景构建智能问答系统，支持地震事件查询、灾害情景构建、智能问答等核心功能，并分析其在地震应急管理中的应用价值。

第六章为总结与展望：总结本研究的主要贡献，并探讨研究中的不足与未来发展方向。

第二章 课题相关技术基础

2.1 知识图谱

知识图谱（Knowledge Graph, KG）是一种用于表示和组织结构化知识的图数据库模型，它将现实世界中的实体（如人物、地点、事件等）及其之间的关系（如属性、关联、联系等）以图的形式呈现。其核心目标是构建一个完整、精准且可扩展的知识库，以模拟人类的知识组织方式，使机器能够理解和推理信息，从而在语义搜索、智能问答、推荐系统等领域提供支持。通过结构化的方式，知识图谱能够将海量的知识进行统一管理和表示，使得复杂的关系推理和语义计算成为可能。

知识图谱主要由本体（Ontology）、实体（Entity）和关系（Relation）三个核心元素组成。本体是用于描述领域知识的形式化模型，它定义了该领域的概念、实体、属性、关系及其逻辑约束，形成知识的语义框架。本体的设计能够帮助知识的系统化管理和推理，使知识的表示更加标准化和一致性。本体通常包括概念层次结构、属性类型（如数据属性、对象属性）以及类与类之间的关联规则（如继承、互斥、传递性等），这使得知识图谱具备一定的语义推理能力。另一方面，实体则是本体的具体实例，它代表现实世界中的对象，并通过属性和关系与其他实体相连接。实体是知识图谱的基本构成单元，表示现实世界中的具体事物，如人、组织、产品、地点等，每个实体都具有唯一的标识符，以便在知识图谱中进行识别和检索。关系是用于连接本体、实体中节点与节点之间的逻辑关联，这些关联通常以有向边的方式构建，使得知识网络得以形成，图 2-1 展示了一个知识图谱的片段来对本体、实体以及关系进行说明。




图 2-1 知识图谱片段

在地震灾害领域中“地震”属于一个概念，定义为：“地壳快速释放能量过程中造成的振动，期间会产生地震波的一种自然现象。”当说起“地震”时它不是指某一次特定的地震，而是指一类自然现象，这一类自然现象有着相同的描述模板，构成一个类或者概念，将符合该定义的自然现象都称为“地震”，所以“地震”就定义为知识图谱本体网络中的一个节点，而“余震”属于“地震”的一个子类，所以将其作为关联与“地震”的一个本体节点，而“地震”发生的地点称为“震中”，“震中”所在的位置位于“断裂带”上，这些概念都是本体网络的一个节点，通过边的关系关联起来，所有的这些节点和边形成一个概念的集合，即为本体网络。而“汶川 8.0 级地震”是在“地震”范围下的一个实例，这就是一个实体节点，而与其关联的实体节点则构成一个实体网络。本体网络与实体网络中节点与节点意见连接的有向边就称为关系。

知识图谱的构建是一个复杂而系统的过程，涉及多个关键环节，包括实体抽取、本体构建、实体构建和关系构建等。其中实体抽取是知识图谱构建的基础步骤，主要是从海量的非结构化文本数据中识别并提取出具有明确含义的对象或概念，利用深度学习模型自动从文本中识别出地震事件、震源深度、震中地区、地震发生日期等专有名词。本体构建是知识图谱构建的骨架和核心框架，明确定义了领域内实体的类别、属性以及实体之间关系的规范化结构，该过程通过领域专家知识或文本挖掘技术，定义领域的核心概念、类别以及分类层次结构，并明确每个实体类别应包含的属性、属性的数据类型和取值范围，建立统一的术语体系与标准，确定好实体之间的关系类型，如层级关系、关联关系、因果关系等，确保实体关系定义的规范性和一致性。在明确本体体系后，需要对抽取到的实体进行融合和构建，以确保实体的唯一性和一致性，该过程针对多源数据中实体的名称异构和歧义，使用实体链接或实体对齐技术，进行同一实体的合并，通过数据挖掘或融合外部权威数据源，进一步完善实体的属性信息，以提高实体的完整性和准确性，在实体构建过程中，涉及多个来源知识的融合，确保知识图谱中实体信息的质量和统一性。关系构建是知识图谱中的关键环节，明确表示实体之间的关联与互动。利用模式匹配，自动从文本数据中提取出实体之间的关系，并借助知识推理技术和规则推导，补充图谱中隐含的知识关系，丰富关系层次和扩展关系网络。

通过以上环节的协同作用，可以构建一个结构完善、语义丰富、具有广泛应用价值的高质量知识图谱。

2.2 深度学习

2.2.1 SENet 网络

Squeeze-and-Excitation Networks (SENet) 是一种改进卷积神经网络 (Convolutional Neural Network, CNN) 结构的深度神经网络, 其中 CNN 是一种专门用于处理结构化网格数据的深度学习模型。CNN 之所以能够高效处理自然语言等感官数据, 得益于其独特的网络结构和特定的技术方法。




图 2-2 卷积神经网络结构示意图

CNN 主要由卷积层、池化层和全连接层三个关键层组成, 其结构如图 2-2 所示。

卷积层是 CNN 的核心部分。它的主要作用是通过卷积核提取输入数据的特征。卷积运算如公式(2-1)所示。

$$Y(i, j) = \sum_m \sum_n X(i + m, j + n) \cdot K(m, n) + b \quad (2-1)$$

其中 $X(i + m, j + n)$ 代表输入特征图, $K(m, n)$ 代表卷积核, b 代表偏置, $Y(i, j)$ 代表输出特征图。

池化层用于降低数据的维度, 同时保留关键特征常见的池化操作有最大池化和平均池化。最大池化选取局部区域内的最大值, 增强特征的显著性。平均池化计算局部区域内的平均值, 减少数据的变化。

全连接层用于对特征进行整合, 最终输出分类或回归结果。全连接层的计算如公式(2-2)所示。

$$Y = WX + b \quad (2-2)$$

其中 W 是权重矩阵, X 是输入向量, b 是偏置项。

SENet 基于 CNN 网络而进行改进,旨在提升特征表示能力。SENet 由 Hu 等人在 2017 年提出,并在 ILSVRC 2017 中取得冠军。

SENet 核心思想是通过注意力机制自适应地调整通道间的特征重要性,从而增强有用特征并抑制无关特征。SENet 的结构如图 2-3 所示,SENet 的核心模块称为 Squeeze-and-Excitation(SE)块,它主要由特征压缩(Squeeze)、权重激励(Excitation)和权重融合(Reweighting)三个步骤组成。




图 2-3 SENet 结构示意图^[63]

特征压缩的目的是对输入特征进行全局信息整合,从而减少空间维度的影响,对于一个输入特征矩阵,应用全局平均池化来获得每个通道的全局特征。在特征压缩之后,SENet 使用两个全连接层构成的注意力机制来计算通道的重要性分数,这个过程类似于一个自适应的门控机制。通过权重激励计算得到的通道权重之后,对原始特征进行通道级的加权,每个通道的特征会根据其重要性进行自适应缩放,从而增强有效特征、抑制无用特征。SENet 的核心是通道注意力机制,它通过全局池化和全连接层来计算每个通道的重要性,使网络能够更有效地聚焦于有用的信息。尽管 SENet 额外引入了全连接层,但由于 SE 块作用于通道维度,其计算开销较低。同时,通过降低全连接层的维度,可以进一步减少参数量。

SENet 通过通道注意力机制增强了 CNN 的特征表达能力,具有较好的通用性和可插拔性。它在语义编码增强、图像分类等任务上取得了显著的提升,并且可以与多种深度网络架构结合,进一步提高深度学习模型的性能。

2.2.2 BiLSTM

双向长短时记忆网络(Bidirectional Long Short-Term Memory, BiLSTM)是循环神经网络(Recurrent Neural Network, RNN)的一种改进形式,是长短时记忆网络(Long Short-Term Memory, LSTM)的扩展版本,其中 RNN 是一类专门用于处理序列数据的神经网络,在自然语言处理、时间序列预测、语音识别等领域有着广泛的应用,RNN 的结构如图 2-4 所示。




图 2-4 RNN 结构示意图

与传统的前馈神经网络（如 CNN）不同，RNN 能够利用隐藏状态存储和传递过去的信息，从而具备“记忆”能力。RNN 通过在每个时间步共享权重，并利用隐藏状态存储历史信息，使得它可以处理变长序列，其核心计算如公式(2-3)和公式(2-4)所示。

$$S_t = f(UX_t + WS_{t-1}) \quad (2-3)$$

$$O_t = VS_t \quad (2-4)$$

其中 X_t 是输入向量，表示某个字或词的特征向量， U 是输入层到隐藏层的参数矩阵， S_t 是当前时间步的隐藏状态向量， S_{t-1} 是上一时间步的隐藏状态向量， W 是隐藏层的状态转换矩阵， V 是隐藏层到输出层的参数矩阵， O_t 是输出向量， f 为非线性激活函数（通常采用 $\tanh$ 或 ReLU ）。

RNN 采用反向传播通过时间进行参数优化，即在整个序列上展开计算梯度。但由于梯度在多个时间步之间传播，RNN 容易遇到梯度消问题，影响长期依赖关系的学习。为了缓解 RNN 在长序列学习中的梯度消失问题，Hochreiter 和 Schmidhuber 提出了 LSTM。LSTM 网络的结构如图 2-5 所示，其通过引入 Input Gate、Forget Gate 和 Output Gate 控制信息的流动。




图 2-5 LSTM 结构示意图

其中 Forget Gate 决定当前时刻是否保留上一时刻的细胞状态信息，计算过程如公式(2-5)所示。

$$f_t = \sigma(U_f X_t + W_f S_{t-1} + b_f) \quad (2-5)$$

如果 f_t 近似 0，表示遗忘上一时刻的信息。如果 f_t 近似 1，表示完全保留上一时刻的信息。

Input Gate 决定当前时刻新的信息有多少需要写入细胞状态，计算过程如公式(2-6)和公式(2-7)所示。

$$i_t = \sigma(U_i X_t + W_i S_{t-1} + b_i) \quad (2-6)$$

$$\tilde{C}_t = \tanh(U_c X_t + W_c S_{t-1} + b_c) \quad (2-7)$$

其中 i_t 控制新信息写入的比例， $\tilde{C}_t$ 是当前时刻新的候选细胞状态。

Output Gate 决定当前时刻的隐藏状态，即 LSTM 的输出，其计算如公式(2-8)和公式(2-9)所示。

$$o_t = \sigma(U_o X_t + W_o S_{t-1} + b_o) \quad (2-8)$$

$$S_t = o_t \odot \tanh(C_t) \quad (2-9)$$

其中 o_t 控制当前细胞状态 C_t 经过非线性变换后的信息传递到下一层， S_t 作为当前时间步的隐藏状态，传递给下一时刻。LSTM 通过门控机制改进了信息流，解决了原始 RNN 存在梯度消失的问题使其能够更好地学习长期依赖关系。

BiLSTM 通过两个方向的 LSTM 处理同一序列数据，以更全面地捕捉上下文信息。传统 LSTM 只能利用过去的信息，而 BiLSTM 在处理数据时，不仅从序列的起点到终点进行计算，还反向处理数据，从终点到起点进行计算。这种双向机制使得 BiLSTM 能够在序列的任意位置同时利用过去和未来的信息，从而增强对全局上下文的理解。




图 2-6 BiLSTM 结构示意图

BiLSTM 的结构如图 2-6 所示,与单向 LSTM 只使用过去的信息不同,BiLSTM 结合了前向 LSTM 和后向 LSTM,使得网络在每个时间步都能利用完整的上下文信息。由于同时考虑了前后信息,BiLSTM 在文本理解、语音处理等任务中表现更优。在许多自然语言处理和语音识别任务中,BiLSTM 能够比单向 LSTM 更好地理解句子结构,提高模型的预测能力。

在自然语言处理中,BiLSTM 适用于实体抽取、机器翻译、情感分析等任务,能够更全面地理解句子结构。在实体抽取任务中,BiLSTM 能够分析文本特征向量的前后联系,提高实体抽取的准确性。BiLSTM 进一步提高了信息表达能力,在自然语言处理、语音识别、时间序列预测等任务中表现出色,在低计算资源和特定任务上具有竞争力。

2.2.3 BERT 模型

Google 研究团队革新性地提出 BERT (Bidirectional Encoder Representations from Transformers) 预训练模型,该架构基于多层双向 Transformer 编码器构建,通过全词掩码机制和双向上下文建模,实现深度语义表征学习。其中 Transformer 模型采用编码器-解码器双栈架构,其核心结构如图 2-7 所示。编码器与解码器分别由 N 个结构相同的层级模块堆叠构成,每个层级内部包含两个核心子组件:多头自注意力机制和前馈神经网络。各子组件间通过层归一化与残差连接实现深度网络的高效训练,该设计可有效抑制梯度消失问题。




图 2-7 Transformer 结构示意图^[59]

Transformer 在编码器/解码器单层结构中,多头注意力子层首先对输入序列进行并行化语义关系建模,通过多组独立的 (Q, K, V) 投影空间捕捉长程语义依赖,其输出经层归一化后与原始输入进行残差融合。前馈子层则由两层全连接网络构成,

使用 GELU 激活函数实现高阶非线性特征变换能力，该组件经归一化与残差连接后输出至下一层级。

其中多头注意力的作用是为了让模型在不同位置分别捕捉 h 个头的子空间信息，每个头 $head_i$ 使用 $Q_i = QW_i^Q$, $K_i = KW_i^K$, $V_i = VW_i^V$ 作为它的输出。多头的计算如公式(2-10)和公式(2-11)所示。

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h)W^O, \quad (2-10)$$

$$where head_i = Attention(QW_i^Q, KW_i^K, VW_i^V), \quad (2-11)$$

其中 $\{W_i^Q, W_i^K, W_i^V\} \in \mathbb{R}^{N \times d_k}$ 是可学习的参数， W^O 是一个可学习的映射矩阵。在公式(2-10)中使用的注意力被称为“缩放点积注意力”。它可以将查询值(Q)和一组键值对(K, V)映射到一个输出上，映射的公式为如公式(2-12)所示。

$$Attention(Q, K, V) = softmax(QK^T / \sqrt{d_k}) \quad (2-12)$$

BERT 与传统单向语言模型不同，BERT 采用遮蔽语言模型和下一句预测双任务预训练范式，通过对输入语句中 15% 的词汇进行动态遮蔽处理，强制模型依据双向语境重建被遮蔽单元，从而捕捉词汇间的深层语义关联。




图 2-8 BERT 模型结构示意图^[66]

BERT 模型结构如图 2-8 所示，它没有使用 Transformer 模型中的解码器部分，只使用双向 Transformer 中的编码器，并且主要运用 Transformer 模型中的注意力机制，每层包含多头自注意力机制和前馈神经网络。自注意力机制通过计算查询(Q)、键(K)和值(V)之间的加权关系，捕捉序列中各个位置之间的依赖关系。

在 BERT 模块中,首先采用 WordPiece 分词方法,将输入文本拆分为子词单元,对输入句子 $S = \{w_1, w_2, \dots, w_n\}$,通过分词器转换为子词序列 $T = \{t_1, t_2, \dots, t_n\}$,并添加特殊标记: $T' = \{[CLS], t_1, t_2, \dots, t_n, [SEP]\}$,其中, $[CLS]$ 表示分类标记, $[SEP]$ 为句子分隔标记。输入序列经过预训练的深度双向编码器,通过嵌入矩阵查找与正弦位置编码融合,生成带有绝对位置信息的初始表示;通过三个不同的线性变换得到查询(Query, Q)、键(Key, K)和值(Value, V) 向量 $Q = XW^Q$, $K = XW^K$, $V = XW^V$, X 是输入嵌入矩阵, W^Q , W^K , W^V 是可学习的参数矩阵,继而通过多层自注意力机制编码器进行全局语义建模,自注意力机制如公式(2-12)所示。

BERT 模型采用缩放点积注意力机制实现语义建模,其中键向量维度 d_k 作为归一化因子参与计算,该设计通过抑制点积值的量级膨胀,保障数值稳定性。进一步扩展的多头自注意力机制将输入向量投影至 12 个独立参数空间,每个注意力头聚焦不同语义子空间的特征模式,最终通过拼接和线性变换实现多粒度语义融合。

在 BERT 模型的预训练环节,没有采用传统的单向单词预测任务,而是在 BERT 模型下游加入了遮蔽语言模型和下一句预测。整个预训练过程中,同一段文本会进行多次参数学习,这样做是为了避免文本中某个词一直未被训练,从而在微调阶段影响整个模型的效果。通过以上操作后即可同时获得被遮挡部分的双向特征,学习到了句子中词语和词语之间的关系。

2.2.4 图卷积网络

图卷积网络(Graph Convolutional Network, GCN)是一种用于处理图结构数据的神经网络模型,广泛应用于社交网络分析、推荐系统、生物信息学、知识图谱等领域。它的核心思想是利用图的拓扑结构和节点特征来进行信息传播和特征提取其流程如图 2-9 所示。




图 2-9 GCN 示意图^[60]

GCN 的核心思想是利用图的邻接信息进行特征更新,使得节点能够融合其邻居的特征,其基本公式如公式(2-13)所示。

$$H^{(l+1)} = \sigma \left(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)} \right) \quad (2-13)$$

其中, $H^{(l+1)}$ 是第 l 层的节点特征矩阵, $H^{(0)} = X$, 即初始输入特征, $\tilde{A} = A + I$, 是邻接矩阵加上自环, 确保每个节点包括自身信息, $\tilde{D}$ 是 $\tilde{A}$ 的度矩阵, 对应的归一化因子用于稳定训练, $W^{(l)}$ 是第 l 层的可训练权重矩阵, $\sigma(\cdot)$ 是激活函数, 每个节点的特征是其邻居特征的加权和, 从而实现局部信息融合。

2.3 大语言模型

大语言模型 (Large Language Model, LLM) 是基于深度学习技术的人工智能模型, 旨在处理和生成自然语言文本。这些模型通过在海量数据集上进行训练, 学习语言中的模式和规则, 从而具备理解、生成和翻译文本的能力。大语言模型的核心架构通常采用 Transformer 神经网络, 该网络利用自注意力机制, 能够高效地捕捉序列数据中的长程依赖关系。与传统的 RNN 不同, Transformer 可以并行处理整个序列, 从而大幅提升训练速度和效果。

近年来, 随着模型参数规模的不断扩大, 大语言模型展现出了强大的通用语言处理能力。例如, OpenAI 开发的 Generative Pre-trained Transformer (GPT) 系列模型, 通过在大规模未标记文本数据上进行预训练, 能够生成类似人类的自然语言文本。GPT 模型在各种自然语言处理任务中表现出色, 如文本分类、问答系统、文本摘要和代码生成等。除了 GPT 之外, Meta 开发的 Large Language Model Meta AI (LLaMA) 系列模型在开放研究社区中也受到广泛关注。LLaMA 采用高效的架构设计, 优化了计算资源的使用, 使得中小型实验室和个人开发者也能够使用高性能的语言模型。此外, LLaMA 在多语言理解和少样本学习方面具有较强的能力, 适用于学术研究和实际应用。DeepSeek 是另一款新兴的国产大语言模型, 专注于提升中文及多语言处理能力。DeepSeek 结合了先进的训练方法和高效的数据采集策略, 在文本理解、对话生成、代码生成等任务上展现了竞争力。相比于传统的大语言模型, DeepSeek 侧重于增强推理能力和知识整合, 从而提高模型的可靠性和实用性。

尽管大语言模型具有广泛的通用能力, 但在实际应用中, 通常需要进行微调以适应特定任务或领域。微调方法主要包括全参数微调、适配器微调、提示学习和提示学习等方式, 其中全参数微调对模型的全部参数进行训练调整, 适用于数据量丰富的场景, 但计算开销较大; 适配器微调在原有模型架构上添加额外的适配层, 仅

训练这些适配层的参数，从而减少计算资源消耗；提示学习通过优化输入提示来引导模型生成更符合预期的结果，而无需修改模型内部参数；低秩适配通过低秩矩阵的方式调整部分参数，提高微调的效率，适用于资源有限的场景。微调技术使得大模型能够在医疗、法律、金融和地震灾害等专业领域展现更好的表现，同时减少训练成本，提高模型的可用性。然而，尽管大语言模型具有强大的能力，仍存在数据隐私、模型偏见和高计算资源需求等挑战，需要在实际应用中加以关注和解决。

2.4 检索增强生成

检索增强生成（Retrieval-Augmented Generation, RAG）是一种结合信息检索与文本生成技术的方法，旨在提升生成式人工智能模型的准确性和上下文相关性。其核心在于将检索器和生成器两个组件协同工作。

检索器负责从大型知识库和知识图谱中检索与输入查询相关的文档、信息或结构化知识。当用户提出查询时，检索器不仅在预先构建的文本索引中搜索，还可利用知识图谱进行精确的语义检索。知识图谱中的实体、属性和关系能够提供更加结构化和规范化的信息，帮助检索器识别和定位精确的知识点，减少歧义，提高信息检索的准确性和相关性。

生成器利用检索器提供的上下文信息与结构化的知识图谱数据，结合原始输入，生成连贯且信息丰富的文本输出。这使得生成器不仅依赖于自身的训练数据，还能动态获取外部知识库和结构化知识，从而提高响应的准确性、权威性和实用性。

通过结合知识图谱，检索增强生成模型能够在不重新训练的情况下，实时访问和利用外部结构化和非结构化信息源，生成更贴近实际需求的回答。这对于需要最新信息、准确的领域知识或复杂关系推理的应用场景，如智能问答系统、客户服务和内容生成等，具有重要意义。此外，这种架构也允许分别对检索器和生成器进行精细化的评估和优化，进一步提升整体系统的性能与效果。

2.5 本章小结

本章介绍了与本研究相关的核心技术，为后续章节的研究奠定理论技术基础。系统首先阐述了知识图谱的基本概念、构建方法及其在智能问答系统中的应用价值。接着，详细讨论了深度学习的关键技术，包括 SENet、BiLSTM、BERT 和 GCN，并分析了其在自然语言处理任务中的优势。随后介绍了大语言模型的演进及其在问答系统中的作用，同时探讨了检索增强生成技术如何结合知识图谱与大模型，提高问答系统的准确性和可解释性。通过本章的内容，研究构建了智能问答系统所需

的理论框架，并为后续章节关于地震灾害知识图谱构建和智能问答模型的设计提供了必要的背景支持。

第三章 地震灾害知识图谱构建

3.1 引言

地震灾害是全球最具破坏性的自然灾害之一，对人类社会与生态环境造成严重冲击。随着地震监测、预测及应急管理技术的不断发展，如何高效组织和利用海量的地震相关数据，提升灾害响应的智能化水平，成为当前研究的关键课题。作为一种新兴的知识管理与表示技术，知识图谱通过结构化、语义化的方式整合复杂的地震灾害信息，为地震灾害的预警、响应和决策支持提供了有力支撑。因此，构建高质量的地震灾害知识图谱，不仅对提升地震灾害的智能管理能力具有重要的理论价值，同时在防灾减灾与应急救援等实际应用中也具备广泛前景。

然而，当前知识图谱的构建方法仍存在诸多挑战。由于数据来源的多样性，不同数据源的知识组织方式存在异构性，导致概念定义与层级关系难以统一。大量地震相关数据以非结构化文本的形式存储，如何从中精准提取实体仍是知识图谱构建的关键难题。传统基于规则或词典的方法，在面对数据多样性和复杂上下文时，存在泛化能力不足的问题。实体之间的关联关系往往未在文本中显式呈现，而是需要借助推理技术进行自动识别，这对关系构建提出了更高要求。

针对上述问题，本章重点研究地震灾害知识图谱的构建方法，并提出了一种基于 BERT-SENet-BiLSTM-CRF (BSBC) 的实体抽取模型。该模型创新性地引入 SENet 机制以优化 BERT 编码过程，充分利用 BERT 的中低层特征信息，从而提升实体抽取的准确性。

随后，本章围绕本体构建、实体构建和关系构建三个核心环节展开研究，构建地震灾害领域的概念体系，明确核心概念及其层次关系，确保知识组织的严谨性和逻辑一致性。在实体构建过程中，采用数据清洗与实体融合技术，提高知识的准确性与一致性；在关系构建阶段，运用语义模式驱动方法识别实体间关系，并构建高质量的知识三元组。

此外，为确保知识图谱的应用价值，本章还从完整性、准确性、一致性、时效性和相关性五个维度对知识图谱质量进行评估，并提出优化方向。本研究为地震灾害知识的智能化组织与应用提供了有效的技术支撑，同时也为未来智能问答系统的构建和地震灾害应急管理的优化奠定了坚实基础。

3.2 地震灾害实体抽取模型

3.2.1 模型描述

知识图谱的构建涉及从海量的非结构化或半结构化数据中提取本体、实体和关系，在实际应用中，知识数据往往来自不同的来源，如文本、数据库、网页等，不同来源的数据格式、结构和语义存在较大差异，难以直接统一处理。为了应对这些挑战，实体抽取模型被引入到知识图谱构建过程中，以高效地从文本数据中提取构建知识图谱所需的实体信息。目前主流的知识抽取模型主要包括基于规则的方法、基于机器学习的方法和基于深度学习的方法，然而，但它们都存在一定的局限性，基于规则的方法虽然在特定领域中可以取得较高的准确率，但规则的设计和维护成本较高，并且难以适应开放域和复杂语境的变化；基于机器学习的方法在面对复杂语境时难以捕获深层语义信息，泛化能力有限；当前主流的基于 BiLSTM-CRF 的深度学习的方法虽然可以自动学习特征并适应不同的文本环境，捕获序列信息，但难以建模远程依赖关系，且容易受到序列长度的限制影响实体抽取的准确性。




图 3-1 BERT-SENet-BiLSTM-CRF 模型示意图

针对上述问题，本文提出了一种适用于地震灾害领域的 BERT-SENet-BiLSTM-CRF (BSBC) 实体抽取模型，实体抽取模型的模型示意图如图 3-1 所示。该模型基于 BERT-BiLSTM-CRF 实体抽取模型，BERT 作为新兴的自注意力编码模型，能够很好地捕捉到文本中的深层次语义信息，对文本进行特征编码；BiLSTM 作为特征提取层，通过双向循环神经网络能够更好地捕捉上下文信息；CRF 作为解码层，

通过标签之间的条件依赖关系来解析出提取的特征，生成实体的标签。使用 BERT-BiLSTM-CRF 模型进行实体抽取可以有效地识别出如地震地点、地震时间、震级和震源深度等地震事件相关的实体，对 BERT-BiLSTM-CRF 实体抽取模型描述将在本章 3.2.3 小结详细展开。

然而在实际的使用过程中，编码层 BERT 进行编码操作时会在 12 个层级逐级迭代后只选用最后一个层级的迭代结果作为文本的向量表述，而忽略了前面 11 个层级的迭代结果在语义表示过程中同样具有相当重要的作用。本课题创新性地将 SENet 网络结构引入 BERT 编码过程中，把 BERT 编码过程中所有层级迭代的信息进行加权融合，最终将加权融合的向量结果输出给 BiLSTM 特征提取层，进行特征提取，使输出给特征提取层的文本语义编码具有更精准的语义表示，对 BERT-SENet 编码方法的描述将在本章 3.2.4 小结详细展开。

3.2.2 数据预处理

确保实体抽取的关键在于选择高质量的数据。为了进行实体抽取数据的真实性和可靠性以及在一定程度上保证数据的时效性，本课题选用地震灾害相关的专业文献、风险评估报告和领域专家知识等作为模型训练的数据来源。

数据清洗是数据预处理过程中的第一步，它的主要目的是提升原始数据的质量，确保后续的实体抽取能够顺利进行。在数据清洗阶段，首先要处理文本数据中的噪声数据，例如去除无关的符号、特殊字符、空格、重复信息等，这些无用的部分会干扰实体抽取模型的训练和推理。接下来，还需要对文本数据中的错别字、拼写错误进行纠正，以避免因数据质量问题导致的实体抽取错误。此外，还要进行文本数据规范化处理，包括统一日期格式、单位换算等，确保数据的一致性和标准化。同时，数据清洗还包括去除冗余数据，即去除重复的记录和无效信息，以确保后续模型能够专注于有价值的文本内容。通过这一系列清理工作，原本混乱、不规范的文本数据得以整理成高质量的输入数据。




图 3-2 BIO 标注模式示意图

接下来对清洗过后的文本数据进行 BIO 标注。在实体抽取任务中，为了让模型更好地识别实体的边界，通常采用 BIO 标注模式对数据进行标注，其中 Begin (B)：表示实体的开始部分，Inside (I)：表示实体的内部部分，Outside (O)：表示非实体部分。各个标签与实体的对应关系如图 3-2 所示。

3.2.3 BERT-BiLSTM-CRF 实体抽取模型

BERT-BiLSTM-CRF 实体抽取模型使用 BERT 作为编码层，BiLSTM 作为特征提取层，CRF 作为解码层，其示意图如图 3-3 所示。




图 3-3 BERT-BiLSTM-CRF 模型示意图

该模型中 BERT 作为编码层，利用多层双向 Transformer 编码器进行特征提取，每层包含多头自注意力机制。设输入文本序列为 $T = \{t_1, t_2, \dots, t_n\}$ ，其中每个词 t_i 经过 BERT 处理后，得到对应的词向量表示 $H = \{h_1, h_2, \dots, h_n\}$ 。BERT 的 12 层 Encoder 网络利用自注意力机制计算每个词的注意力分数，其计算过程如公式(3-1)所示。

$$Attention(Q, K, V) = softmax(QK^T / \sqrt{d_k}) \quad (3-1)$$

其中， Q, K, V 分别表示查询 (Query)、键 (Key) 和值 (Value) 矩阵， d_k 是键的维度。多头自注意力机制进一步计算多个独立的注意力头，并将其拼接后投影，以增强模型对不同语义信息的建模能力。然后将第 12 层的特征向量表示输出给特征提取层。

BiLSTM 作为特征提取层，通过同时考虑序列的前向和后向信息，以双向 LSTM 网络捕捉局部与全局依赖关系。具体而言，输入序列首先被映射为词向量，然后传递给双向 LSTM 层，分别处理前向和后向的上下文信息。设 x_i 为第 i 个词的

输入特征向量, BiLSTM 计算前向隐状态 $\vec{h}_i$ 和后向隐状态 $\overleftarrow{h}_i$, 其计算过程如公式(3-2)和公式(3-3)所示。

$$\vec{h}_i = LSTM(\vec{h}_{i-1}, x_i) \quad (3-2)$$

$$\overleftarrow{h}_i = LSTM(\overleftarrow{h}_{i+1}, x_i) \quad (3-3)$$

最终, 每个词的综合表示为拼接后的隐状态向量: $h_i = [\vec{h}_i, \overleftarrow{h}_i]$ 。然而, BiLSTM 在对每个词进行标注时是独立的, 未考虑标签之间的相互依赖性。为了解决这一问题, 模型引入了解码层 CRF。CRF 通过学习标签之间的转移概率, 确保输出的标签序列合法且符合预期模式。设 $Y = \{y_1, y_2, \dots, y_n\}$ 为预测的标签序列, CRF 通过评分函数计算整个序列的评分, 评分函数如公式(3-4)所示。

$$S(X, Y) = \sum_{i=1}^n P_{i, y_i} + \sum_{i=1}^{n-1} T_{y_i, y_{i+1}} \quad (3-4)$$

其中, P_{i, y_i} 是 BiLSTM 提供的特征表示, $T_{y_i, y_{i+1}}$ 是标签 y_i 转移到 y_{i+1} 的概率。CRF 层在解码阶段利用维特比算法进行全局最优序列搜索, 其计算过程如公式(3-5)所示。

$$\hat{Y} = \arg \max_Y S(X, Y) \quad (3-5)$$

在实体抽取任务中, CRF 层作为解码层, 根据 BiLSTM 的标签转移分数, 提取头实体 *head* 和尾实体 *tail*, 然后对实体进行 BIO 标注, 完成实体抽取。这种结构结合了 BERT 的深层次语义信息分析能力、BiLSTM 的序列建模能力和 CRF 的标签依赖解析能力, 使得模型不仅能捕捉上下文信息, 还能考虑标签之间的依赖关系, 从而有效提升了实体抽取任务的准确性和鲁棒性。

3.2.4 基于 BERT-SENet 的编码方法

BERT 作为实体抽取编码器的层级结构在特征提取方面呈现出显著的层次化特性。以经典的中文编码器架构 BERT-Base-Chinese 为例, 该模型包含 12 个堆叠的 Transformer 编码层, 通过实验观察发现不同深度的网络层在语义表征学习上具有明显的差异化倾向^[62]。具体而言, 网络层级与语义粒度的对应关系可划分为三个层次: 低层网络 (1-4 层) 主要捕获局部短语级别的语言特征; 中间层 (5-8 层) 逐步建立句子层面的语义关联, 能够解析句法结构及中程语义关系; 而高层网络

(9-12 层) 则专注于学习全局性的上下文语义表征, 擅长捕捉长距离依赖关系。这种层次化的特征学习机制使得不同深度的网络层形成了互补的语义理解体系。

BERT 模型通过多层网络架构实现了文本表征的多粒度学习, 但实际应用中存在显著的语义利用不充分现象。当前使用 BERT 作为编码器的主流研究仍习惯性采用顶层网络(第 12 层) 输出作为词向量表征。这种单一的层次选择策略忽视了注意力机制中分层语义贡献度的动态特性, 及中低层网络更擅长捕捉词形与短语结构, 高层网络则在篇章级语义关联方面具有优势, 大部分的实体抽取文本仍然以中短文本为主, 低层网络的短语级别特征在实体抽取过程中依然扮演着极为重要的角色。




图 3-4 BERT-SENet 编码方法结构示意图

为提升语义表征编码的质量, 本研究选用 SENet 结构对 BERT 的编码结果进行特征增强融合, 并提出基于 SENet 改进的 BERT 加权融合方法 (BERT-SENet 编码方法)。该方法的结构如图 3-4 所示, 由于 SENet 结构能够增强通道特征选择能力^[63], 于是把 BERT 的各层特征向量视作通道将赋予 BERT 的特征向量中更有价值的向量更高的权重。具体而言, 该方法首先利用 BERT 进行特征提取, 输入文本 $T = \{t_1, t_2, \dots, t_n\}$ 经过 BERT 的 12 层 Encoder 层处理, 每 token t_i 被编码为一个特征向量, 得到 BERT 向量表示 $O = (Output_1, Output_2, \dots, Output_{12})$, 其中, 每个 $Output_i$ 为 BERT 的每个 encoder 层的特征向量输出。接下来, 为了充分利用 BERT 的层次信息, 将各层 BERT 特征向量转换为通道, 进行通道特征堆叠并卷积处理, 即将 BERT 输出的特征向量进行堆叠组合, 形成特征矩阵 $M = [Output_1; Output_2; \dots; Output_{12}]$, 随后, 采用卷积操作提取局部特征, 设卷积核为 W , 经过卷积后的特征表示为 $C = Conv(M, W)$, 卷积后的特征 C 将用于后续的注意力机制处理, 其中 SENet 通过全局平均池化提取每个通道的全局信息, 从而衡量各个通道的整体重要性, 全局池化过程如公式(3-6)如示。

$$S_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W C_{i,j,c} \quad (3-6)$$

其中, S_c 表示通道 C 的全局池化值, H , W 分别表示特征图的高度和宽度。接下来, SENet 进行特征权重生成, 将卷积得到的特征通过特征压缩操作作为一个低维向量 S , 然后进行激励操作, 通过两个全连接层对压缩后的向量进行非线性变换, 从而计算出每个通道的重要性权重, 计算过程如公式(3-7)所示。

$$Z = \sigma(W_2 \cdot \delta(W_1 \cdot S)) \quad (3-7)$$

其中, W_1 进行降维操作, $\delta(\cdot)$ 为 ReLU 激活函数, W_2 进行升维操作, $\sigma(\cdot)$ 为 Sigmoid 归一化, 确保权重值归一化到 $(0, 1)$ 之间, 从而得到最终的通道权重 A_c , 其计算过程如公式(3-8)所示。

$$A_c = \frac{e^{Z_c}}{\sum_{i=1}^C e^{Z_i}} \quad (3-8)$$

权重融合与特征重标定通过逐通道乘法操作对卷积特征进行加权, 加权过程如公式(3-9)所示。

$$F = A \odot C \quad (3-9)$$

其中, $\odot$ 表示通道权重的逐元素乘法, 从而对原始特征进行特征重校准。在经过两个全连接层进行非线性变换后, 通过 Sigmoid 归一化, SENet 学习到不同通道的重要性, 并为更有价值的通道赋予更高的权重, 赋权过程如公式(3-10)所示。

$$F' = A \times C \quad (3-10)$$

这样, 原始特征中更重要的通道会被赋予更高的权重, 从而更有效地表达实体相关的特征信息, 强化重要特征, 同时抑制无关信息, 最终使得特征表示更加精准和有针对性, 提升实体抽取任务的性能。

3.3 实验数据集、评价指标和参数设置

3.3.1 实验数据集

为全面验证 BERT-SENet-BiLSTM-CRF 实体抽取模型的性能, 实验采用以下数据集:

人民日报命名实体抽取数据集是中文自然语言处理领域的重要资源, 广泛应用于命名实体抽取任务。该数据集主要来源于《人民日报》1998 年和 2014 年的语

料，包含了丰富的标注信息。在这些数据中，实体类型主要分为人名（PER）、地名（LOC）和机构名（ORG）三类，采用 BIO 标注格式。数据集经过预处理，生成了适合模型训练的格式，保留了分词信息和词性标注信息。研究者可以利用该数据集训练和评估中文命名实体抽取模型，以提升模型在实际应用中的性能。

DuIE（百度关系抽取数据集）由百度公司于 2018 年发布，作为中文实体抽取任务的标准化评测数据，支持从非结构化文本中提取实体。该数据集数据主要来自中文百科、新闻文章及网络公开文本，涵盖人物、机构、地点、事件等多领域内容，包含总句子数：约 21 万条，关系类型：48 种预定义关系实体对数量，每条句子平均包含 1-2 个有效实体对。其中训练集 16 万条句子。验证集 2 万条句子。测试集包含 3 万条句子。该数据集旨在推动中文实体抽取技术的研究与应用。该数据集覆盖广泛的实体类型，标注质量高，广泛应用于学术界和工业界的实体抽取模型训练与评估。

EarthquakeNER 为自建数据集，运用 3.2.2 节数据预处理的方法，对包含地震灾害相关文章句子片段和所对应的实体信息进行处理：相关文章片段是实体信息的来源，涵盖了多种地震灾害类型的相关信息，相关文章片段的来源为地震灾害领域相关的专业文献、风险评估报告和领域专家知识等。该数据集包括 16267 条篇地震灾害的相关文章句子片段及其所对应的实体等内容，句子与实体的组合类似于人民日报命名实体抽取数据集和 DuIE 的形式。

3.3.2 评价指标

在知识抽取任务的性能量化评估中，通常选用精确率（Precision）、召回率（Recall）以及 F1 score 三个指标来评估答案的生成质量。

其计算基于表 3-1 所示的混淆矩阵。以下是对这四个指标的详细介绍：

表 3-1 混淆矩阵

真实 \ 预测	正例	反例
正例	TP	FN
反例	FP	TN

精确率反映模型预测正类样本的可信度，其计算方法如公式(3-11)所示。

$$precision = \frac{TP}{TP + FP} \quad (3-11)$$

召回率表征模型对真实正类样本的覆盖能力，其计算方法如公式(3-12)所示。

$$recall = \frac{TP}{TP + FN} \quad (3-12)$$

从公式(3-11)和公式(3-12)中揭示两者的固有矛盾：提高决策阈值可提升精确率（减少 FP），但会导致召回率下降（FN 增加）；降低阈值则扩大召回范围（FN 减少），但可能引入更多误报（FP 上升）为平衡精确率与召回率，提出了一个新的度量指标—— F_β ，其计算方式如公式(3-13)所示。

$$F_\beta = \frac{(1 + \beta^2) \times precision \times recall}{(\beta^2 \times precision) + recall} \quad (3-13)$$

其中， β 为一个人为指定的权重参数，表示了精确率和召回率之间的相对重要性。 $\beta > 1$ 时强调召回率重要性， $\beta < 1$ 时侧重精确率优先，当 $\beta = 1$ 时， F_β 退化为标准 F1 值，实现调和平均，其计算如公式(3-14)所示。

$$F1 = \frac{2 \times precision \times recall}{precision + recall} \quad (3-14)$$

3.3.3 参数选择

在模型构建与训练过程中，参数的选择对模型性能有着至关重要的影响。为深入了解 BSBC 模型中各参数对实体抽取性能的影响程度，本研究开展了参数敏感性分析。通过系统地改变模型中的关键参数，并观察模型在实验数据集上性能指标的变化，以确定各参数的敏感程度，为模型的进一步优化提供依据。

本研究主要对 BERT 隐藏层维度、SENet 的降维因子、BiLSTM 隐藏层维度这几个关键参数进行敏感性分析。在进行单一参数调整时，保持其他参数为默认设置不变。实验数据集选用 EarthquakeNER 数据集，评价指标采用精确率（Precision）、召回率（Recall）和 F1 值。

编码层 BERT 的隐藏层维度决定了模型对文本特征的表示能力。本研究将 BERT 隐藏层维度分别设置为 256、512、768 和 1024，其他参数保持不变，实验结果如表 3-2 所示。实验结果显示，当隐藏层维度为 256 时，模型的精确率为 0.8925，召回率为 0.9132，F1 值为 0.9027；维度提升至 512 时，精确率达到 0.9012，召回率为 0.9205，F1 值为 0.9108；当隐藏层维度为 768 维度时，精确率为 0.9145，召回率为 0.9427，F1 值为 0.9234；而当维度增加到 1024 时，精确率为 0.9103，召回率为 0.9358，F1 值为 0.9227。可以看出，随着隐藏层维度的增加，模型性能先提升后略有下降，在 BERT 隐藏层维度为 768 时达到最佳，表明该维度下模型能较好地平衡特征表示能力和计算复杂度。

表 3-2 BERT 隐藏层维度参数敏感性分析

参数	取值	Precision ↑	Recall ↑	F1 ↑
BERT 隐藏层维度	256	0.8925	0.9132	0.9027
	512	0.9012	0.9205	0.9108
	768	0.9145	0.9427	0.9234
	1024	0.9103	0.9358	0.9227

SENet 的降维因子影响着通道注意力机制的效果。分别将降维因子设置为 8、16、32 和 64 进行实验，实验结果如表 3-3 所示。当降维因子为 8 时，模型精确率为 0.9056，召回率为 0.9301，F1 值为 0.9177；降维因子为 16 时，精确率为 0.9145，召回率为 0.9427，F1 值为 0.9234；降维因子为 32 时，精确率为 0.9082，召回率为 0.9254，F1 值为 0.9167；降维因子为 64 时，精确率为 0.8984，召回率为 0.9183，F1 值为 0.9082。由此可见，降维因子为 16 时模型性能最佳，过大或过小的降维因子都会导致模型性能下降，说明合适的降维因子能够有效调整通道间特征的重要性，提升模型性能。

表 3-3 SENet 降维因子参数敏感性分析

参数	取值	Precision ↑	Recall ↑	F1 ↑
SENet 降维因子	8	0.9056	0.9301	0.9177
	16	0.9145	0.9427	0.9234
	32	0.9082	0.9254	0.9167
	64	0.8984	0.9183	0.9082

BiLSTM 的 LSTM 单元数对模型捕捉上下文信息的能力有重要作用。将 LSTM 单元数分别设为 128、256、512 和 1024 进行实验，实验结果如表 3-4 所示。当 LSTM 单元数为 128 时，精确率为 0.8834，召回率为 0.9025，F1 值为 0.8928；单元数为 256 时，精确率为 0.9145，召回率为 0.9427，F1 值为 0.9234；单元数为 512 时，精确率为 0.9078，召回率为 0.9312，F1 值为 0.9193；单元数为 1024 时，精确率为 0.9011，召回率为 0.9267，F1 值为 0.9138。结果表明，增加 LSTM 单元数在一定程度上能提升模型性能，但超过一定值后，性能提升不再明显，甚至可能因模型复杂度增加导致过拟合，256 个单元数在当前实验设置下表现最优。

表 3-4 BiLSTM 的 LSTM 单元数参数敏感性分析

参数	取值	Precision ↑	Recall ↑	F1 ↑
BiLSTM 的 LSTM 单元数	128	0.8834	0.9025	0.8928
	256	0.9145	0.9427	0.9234
	512	0.9078	0.9312	0.9193
	1024	0.9011	0.9267	0.9138

训练轮数决定了模型学习的程度。分别设置训练轮数为 5、10、15 和 20 进行实验，实验结果如表 3-5 所示。训练轮数为 5 时，模型精确率为 0.8856，召回率为 0.9102，F1 值为 0.8977；训练轮数为 10 时，精确率为 0.9145，召回率为 0.9427，F1 值为 0.9234；训练轮数为 15 时，精确率为 0.9054，召回率为 0.9281，F1 值为 0.9166；训练轮数为 20 时，精确率为 0.8987，召回率为 0.9213，F1 值为 0.9100。这表明，在一定范围内增加训练轮数有助于模型学习，但过多的训练轮数可能导致模型过拟合，使得性能下降，本模型在训练轮数为 10 时达到较好的平衡。

表 3-5 训练轮数参数敏感性分析

参数	取值	Precision ↑	Recall ↑	F1 ↑
训练轮数	5	0.8856	0.9102	0.8977
	10	0.9145	0.9427	0.9234
	15	0.9054	0.9281	0.9166
	20	0.8987	0.9213	0.9100

通过对 BSBC 模型关键参数的敏感性分析可知，各参数对模型性能均有不同程度的影响。BERT 隐藏层维度、SENet 的降维因子、BiLSTM 的 LSTM 单元数和训练轮数在各自的默认设置下能使模型取得较好的性能表现。在实际应用和进一步优化模型时，需综合考虑这些参数的影响，根据具体任务需求和数据特点进行合理调整，以实现模型性能的最优化。

3.3.4 实验和结果分析

为了验证本章提出的 BERT-SENet-BiLSTM-CRF 模型的有效性，本节选择了实体抽取的五个模型，在三个数据集上进行实验，在本研究中，采用精确率（Precision）、召回率（Recall）、F1-score 来衡量模型的实体抽取性能，实验中 BSBC 模型使用参数敏感性实验中得到的最优参数。以下是详细介绍：

BERT-Softmax^[66]：该模型使用 BERT 作为特征提取器，并在输出层使用 Softmax 进行分类，预测每个 token 的实体类别。

BiLSTM-Softmax^[65]：该模型采用双向长短时记忆网络（BiLSTM）进行序列建模，并在输出层使用 Softmax 进行分类，预测每个词的实体类别。

BERT-CRF^[69]：该模型使用 BERT 作为特征提取器，并结合 CRF 层进行实体识别。结合了 BERT 的深层语义建模能力和 CRF 的标签依赖建模能力。

BiLSTM-CRF^[68]：该模型使用 BiLSTM 进行序列建模，并结合 CRF（条件随机场）作为解码层，以捕捉标签之间的依赖关系。

BERT-BiLSTM-CRF^[61]: 该模型使用 BERT 模型作为编码层, 生成词向量, 输入特征提取层 BiLSTM 提取语义特征, 并结合解码层 CRF 解码得到标注序列。

表 3-6 人民日报数据集上的实验结果

模型	Precision ↑	Recall ↑	F1 ↑
BERT-Softmax	0.8217	0.8013	0.8114
BiLSTM-Softmax	0.8542	0.8287	0.8413
BERT-CRF	0.8625	0.8143	0.8377
BiLSTM-CRF	0.8724	0.8621	0.8672
BERT-BiLSTM-CRF	0.8932	<u>0.8825</u>	<u>0.8878</u>
BSBC (Ours)	<u>0.8906</u>	0.9283	0.9089

表 3-7 DuIE 数据集上的实验结果

模型	Precision ↑	Recall ↑	F1 ↑
BERT-Softmax	0.8338	0.7872	0.8098
BiLSTM-Softmax	0.8621	0.8315	0.8466
BERT-CRF	0.8583	0.8136	0.8353
BiLSTM-CRF	0.8652	0.8524	0.8588
BERT-BiLSTM-CRF	<u>0.8824</u>	<u>0.8948</u>	<u>0.8886</u>
BSBC (Ours)	0.8831	0.9310	0.9054

表 3-8 EarthquakeNER 数据集上的实验结果

模型	Precision ↑	Recall ↑	F1 ↑
BERT-Softmax	0.8234	0.8121	0.8177
BiLSTM-Softmax	0.8665	0.8342	0.8501
BERT-CRF	0.8427	0.8283	0.8354
BiLSTM-CRF	0.8721	0.8614	0.8667
BERT-BiLSTM-CRF	<u>0.8923</u>	<u>0.8856</u>	<u>0.8889</u>
BSBC (Ours)	0.9145	0.9427	0.9234

表 3-6、表 3-7 和表 3-8 分别展示了各模型在人民日报数据集、DuIE 数据集和 EarthquakeNER 数据集上的实验结果。其中, 各指标最高分以加粗字体显示, 次高分以下划线字体显示。

从以上各表中可以看出, BiLSTM-CRF 和 BERT-BiLSTM-CRF 在多个数据集上均表现优越, 证明 CRF 对实体边界识别的重要性。BERT-BiLSTM-CRF 结合了 BERT 的深度语义建模能力、BiLSTM 的上下文序列学习能力和 CRF 的标签依赖建模能力, 在所有实验中均比 BiLSTM-CRF 提高了约 2%-3%。

BSBC 在所有实验中都取得最优 F1 值，尤其是在召回率方面，相比 BERT-BiLSTM-CRF 提升了 4%-6%，特别是在地震领域数据集上取得了最好的表现，说明 SENet 结构对 BERT 的特征增强作用有效，提高了在通用领域和地震灾害专业领域的实体抽取能力，实体抽取实例如表 3-9 所示。

表 3-9 抽取实例展示

原始文本片段	抽取实体	文本片段包含的三元组
2008 年 5 月 12 日 14 时 28 分，四川汶川县发生 8.0 级强烈地震。	2008 年 5 月 12 日、汶川县、8.0 级地震	(地震-发生时间-2008 年 5 月 12 日); (地震-发生地点-汶川县)
震中位于北纬 31.0 度、东经 103.4 度，震源深度 14 公里。	北纬 31.0 度、东经 103.4 度、14 公里	(地震-震中坐标-北纬 31.0 度/东经 103.4 度); (地震-震源深度-14 公里)
地震共造成 69227 人遇难，374643 人受伤，17923 人失踪。	69227 人、374643 人、17923 人	(地震-导致-伤亡人数)
汶川地震波及四川、甘肃、陕西等地，约 4600 万人受灾。	四川、甘肃、陕西、4600 万人	(地震-波及地区-四川); (地震-波及地区-甘肃); (地震-波及地区-陕西); (地震-受灾人数-4600 万人)
地震由龙门山断裂带活动引发，是一次逆断层型地震。	龙门山断裂带、逆断层	(地震-成因-龙门山断裂带); (地震-类型-逆断层)

3.4 地震灾害知识图谱结构设计及实现

3.4.1 地震灾害知识图谱本体构建

本体构建是知识图谱的基础工作，其目的在于通过对领域知识进行形式化描述，建立一个清晰的、逻辑一致的实体关系网络，从而为知识的组织、管理和应用提供支持。在地震灾害领域，本体构建尤为重要，因为该领域的知识内容复杂、涉及面广，既包括地震成因、预测等自然科学内容，又涉及灾后救援、应急管理 etc 社会科学内容。通过本体构建，可以将这些跨学科的知识要素有机整合，为地震灾害知识图谱的构建奠定坚实的基础。本体构建不仅是知识图谱构建的前提，也是实现地震灾害知识的智能化管理和服务的关键技术手段。

在本节中,要构造一个概念层面的本体网络,采用 Extract-Transform-Load(ETL)的方法进行数据的提取、转换和加载。地震灾害领域本体的构建方法主要包括本体要素的定义与分类、领域本体设计的关键步骤以及本体构建中采用的具体技术和工具。在本体要素的定义与分类方面,地震灾害领域涉及众多概念和关系,需要对这些要素进行分类和层次化组织。

通过 3.2 节阐述的实体抽取模型,提取地震灾害相关的实体数据。在这之后,人工提取出其中的地震灾害领域核心概念,这些数据源于地震灾害相关的专业文献、风险评估报告等,该工作由地震灾害领域的专家完成,保证了这项工作的真实性和可靠性以及在一定程度上保证数据的时效性。

在提取到核心实体概念数据后,为确保数据质量和一致性,需要对数据进行转换定义。在本体中定义地震灾害类型、地点、时间等顶级类,其下再细分为构造地震、火山地震、陷落地震和诱发地震等子类,以及震中、震源深度和震级等属性。这种层次化组织方式有助于明确各个实体之间的语义关系,提升知识图谱的结构严谨性。在领域本体设计的关键步骤方面,需要经历需求分析、概念抽取、关系定义和属性定义等过程。例如在本体节点的定义中,定义一个类为地震,则其父类为自然事件,其子类则为余震,并且定义一个公理,余震必须关联一个主震(主震与余震为同一类实例),而地震的属性则为震级和发震时间,其关系为:触发(地震→余震)、位于(地震→发震时间)定义好“地震灾害”这一顶层概念后,其下可细分为“构造地震”、“火山地震”、“陷落地震和“陷落地震””等具体类型。并且地震灾害领域存在许多同义词,需要把不同形式的词语转换统一为一个意思,对定义进行标准化。比如“余震”和“后续地震”这些不同术语实际上表达的是同一概念,即“在主震发生之后的一定时间内,在主震附近区域发生的一系列地震活动”,为了实现知识图谱中的概念和术语标准化,需要定义标准术语,将上述同义术语统一为标准概念“余震”。每种地震灾害类型可进一步关联其诱发因素、影响范围、防治措施等属性,通过关系定义明确这些概念之间的关联方式。在构建本体时,需要结合领域专家的经验,确定各概念之间的层次结构和关联关系。例如,“构造地震”可能由“地壳运动”引发,其影响对象包括“居民区”、“交通设施”等。通过定义这些概念和关系,构建出地震灾害领域的本体模型,为后续的知识图谱构建提供结构化的框架。在实际应用中,这样的本体网络有助于提高地震灾害信息的组织和检索效率,支持灾害预警、应急响应等工作。

最后通过属性定义完善实体的具体信息,将处理后的数据加载到目标数据仓库(Neo4j)中,以支持后续的实体融合阶段。

本体构建对地震灾害知识图谱的质量和后续智能问答系统的实现具有重要意义。一方面,本体设计的严谨性和一致性直接影响到知识图谱的结构完整性和语义准确性。通过本体构建,可以确保知识图谱中的实体和关系能够真实反映地震灾害领域的复杂知识结构,从而为地震灾害的智能化管理和服务提供可靠的知识支持。另一方面,本体构建也为地震灾害多通道智能问答模型中的知识图谱通道奠定了基础。在地震灾害知识图谱中,可以通过本体定义的实体和关系进行精确的知识定位和推理,从而提升系统对复杂问题的理解能力和回答质量。通过本体构建,还可以实现知识图谱的可视化展示,便于用户直观理解地震灾害知识的组织方式,从而提高系统的易用性和用户体验。

综上所述,地震灾害领域本体的构建是知识图谱构建的关键环节,其设计原则和方法对知识图谱的结构严谨性和逻辑一致性具有决定性作用。通过层次化的设计和逻辑关系的明确化,本体不仅为地震灾害知识的组织和管理提供支持,还为智能问答系统的实现奠定了坚实的基础。在未来的研究中,可以进一步探索本体的动态更新机制和跨领域知识融合方法,以提升地震灾害知识管理的智能化水平和应用价值。

3.4.2 地震灾害知识图谱实体构建

在构建好本体网络后,就要将实体抽取环节中的实体用于进行实体网络的构建,实体构建是知识图谱构建的核心环节之一,旨在从大规模的文本数据中提取并组织关键信息,从而为后续的知识管理和应用提供支持。在地震灾害领域,实体构建的质量直接影响到知识图谱的准确性和实用性。

实体抽取作为第一步,负责从非结构化文本中提取灾害相关实体。运用 3.2 节所提到的 BERT-SENet-BiLSTM-CRF 地震灾害实体抽取模型进行实体抽取。由于地震灾害数据的专业性和复杂性,采用基于深度学习的方法,在处理领域特定实体时表现出色。

在经过实体抽取的一系列步骤过后,原本零散的文本信息被提炼成清晰的结构化知识,为知识图谱的构建提供了基础数据。而各三元组中可能存在同一个实体以不同名字在不同的三元组中,如果重复进行构建则会影响知识图谱的质量,于是需要进行实体融合的操作。实体融合则是将提取的实体与已有知识图谱中的实体进行匹配,消除歧义并丰富知识库。

实体融合,又称实体解析或实体对齐,是知识图谱构建与数据集成中的核心任务,旨在解决多源异构数据中同一现实对象的不同表示的识别与合并问题。其目标

是通过消除冗余、解决冲突，生成全局唯一的规范化实体，构建高质量、一致性的知识库。

在本研究中，实体融合的具体方法是通过计算两个实体之间的相似度来衡量是否进行实体融合。而相似度的计算分为字符相似度和语法相似度，再运用一个加权公式得到两实体的最终相似度计算结果。首先采用 Jaccard 系数来衡量实体间的字符相似度，具体计算方式如公式(3-15)所示。

$$sim_t(A, B) = \frac{|A \cap B|}{|A \cup B|} = \frac{|A \cap B|}{|A + B + A \cap B|} \quad (3-15)$$

其中其中 $sim_t(A, B)$ 代表两个实体之间的相似性， $|A \cap B|$ 表示 A、B 两个实体中相同的字符， $|A \cup B|$ 指实体 A 和实体 B 的字符总量。

通过计算在原句子中的自注意力编码的余弦相似度来表示两实体间的语义相似度。其中将原句子输入到共享权重的 BERT 模型中进行实体嵌入表示成向量，对输入句子 $S = \{w_1, w_2, \dots, w_n\}$, $S' = \{w'_1, w'_2, \dots, w'_n\}$ ，通过分词器转换为子词序列 $T = \{t_1, t_2, \dots, t_n\}$ ， $T' = \{t'_1, t'_2, \dots, t'_n\}$ ，并添加特殊标记 $A = \{[CLS], t_1, t_2, \dots, t_n, [SEP]\}$, $B = \{[CLS], t'_1, t'_2, \dots, t'_n, [SEP]\}$ ，其中， $[CLS]$ 表示分类标记， $[SEP]$ 为句子分隔标记。然后将两实体属性拼接为文本序列两个向量中的夹角越小，则两个实体越相似。其计算方式如公式(3-16)所示。

$$sim_s(A, B) = \frac{|A \times B|}{|A| \times |B|} = \frac{\sum_n^i A_i B_i}{\sqrt{\sum_n^i (A_i)^2} \times \sqrt{\sum_n^i (B_i)^2}} \quad (3-16)$$

其中 $sim_s(A, B)$ 代表 A 和 B 的语义相似性。

在计算实体间的字符相似度和语义相似度后，再对以上两个参数赋予不同权重计算综合相似度，具体计算公式如公式(3-17)所示。

$$sim(A, B) = \alpha sim_t(A, B) + (1 - \alpha) sim_s(A, B) \quad (3-17)$$

考虑到地震灾害领域的文本数据存在一定相似性，将字符相似度的权重设置为 0.4。经过计算分析，对综合相似度超过 0.8 的实体进行融合。这种技术的应用不仅提高了知识图谱的覆盖率，还增强了其实用性。综上所述，实体构建是地震灾害知识图谱构建的重要组成部分，其技术实现对于提升知识图谱的质量至关重要。未来，随着算法的进步和计算资源的生长，实体构建有望在实时性和自动化方面取得更大突破，为地震灾害领域的智能化管理和服务提供更多可能性。

3.4.3 地震灾害知识图谱关系构建

关系构建是知识图谱构建的核心环节之一，其目标是通过抽取和定义实体之间的语义关系，确保知识图谱的结构完整性和语义一致性。在地震灾害领域，关系构建尤为重要，因为该领域的知识具有多学科交叉、覆盖范围广等特点，需要通过关系构建反映地震灾害防治中复杂的因果关系、空间关系和时间关系。

关系的完整性和语义一致性直接影响到知识图谱的实用性和智能问答系统的性能。在地震灾害领域，关系抽取的任务是从文本中识别实体之间的语义关系并将其转换为三元组形式。关系定义则是在抽取的基础上，对关系类型进行规范和分类，以确保知识图谱的逻辑一致性和语义深度，这一步是要识别文本中实体之间的预定义的语义关系。

然后通过三元组表示将实体及其关系转化为(*head*, *relation*, *tail*)的形式，其中*head*表示三元组中的头实体，*relation*表示三元组中的关系，*tail*表示三元组中的尾实体，这种结构化的数据格式便于后续存储、处理和分析。

通过这一系列的步骤，原本零散的文本信息被提炼成清晰的结构化知识，为知识图谱的构建提供了基础数据，两个部分协同作用以提升知识抽取的准确率和鲁棒性。

在关系抽取环节，由于在地震灾害领域，大量关系属于同义词，比如“引发”、“导致”、“诱发”这一组关系在地震灾害关系上属于同义，因此在以语义模式驱动的关系提取中，先收集大量与地震灾害相关的文本资料，通过这些文本资料中再基于专家经验，预定义一些在地震灾害领域中可能存在的关系类型模版，在这些类型中填充属于这些类型的词语，该模版如表 3-10 所示。

表 3-10 关系类型对应表

类型	定义	关系词
因果关系	描述灾害事件引发灾害。	“引发”、“导致”、“诱发”、“造成”等
空间关系	描述灾害事件与地理位置之间关联。	“位于”、“分布”、“邻近”“覆盖”等
时间关系	灾害事件发生的时间顺序和周期性。	“期间”、“持续”、“开始于”、“结束于”、“同时”等
影响关系	灾害对环境、生态和人类社会的影响程度和范围。	“影响”、“危害”、“破坏”、“威胁”、“损害”、“干扰”等

在地震灾害领域，关系定义需要综合考虑灾害防治的多层次需求，明确灾害成因、影响因素、应对措施等之间的语义联系。例如“地震发生在汶川”中“地震”与“汶川”之间的关系为“发生”。以语义模式驱动的关系提取，抽取出实体间的关联。通过本体指导，可以定义灾害类型与灾害影响之间的“因果”关系，震中与

震区之间的“空间”关系，以及灾害对环境、生态和人类社会的影响程度和范围的“影响”关系等，这种精细化的关系定义方式能够更好地反映地震灾害领域的复杂性。设计好关系类型模版后，将设计的模式和模板转化为具体的规则，这些规则运用正则表达式、依存句法分析等技术手段，将编写好的规则应用于预处理后的文本数据，自动识别并抽取实体之间的关系，生成结构化的关系数据。

图 3-5 展示了地震灾害知识图谱子数据集中不同类型关系的数量统计。从图中可以看出，“导致”和“影响”等关系类型在知识图谱中占据较高比例，这表明地震灾害的核心知识集中在因果关系和影响分析上。




图 3-5 子图关系数量统计

下一步是将这些信息整合为三元组，将实体与关系对齐，即每句话中的关系及其对应的实体进行拼接，并带入原文中进行验证，验证完成后组合成三元组的形式，即(head, relation, tail)的形式。

综上所述，关系构建是地震灾害知识图谱构建的重要环节，其关系抽取与定义方法直接决定了知识图谱的质量和 application 价值。通过综合应用先进的抽取技术与规范化的定义策略，可以有效提升知识图谱的语义一致性和结构完整性，为地震灾害领域的智能化管理和服务提供可靠支持。

3.5 地震灾害知识图谱展示与质量评估

经过上述 BSBC 模型进行实体抽取，并完成本体构建、实体构建和关系构建后，地震灾害领域的知识图谱正式构建完成。该知识图谱共包含总节点 234600 个，

其中本体节点 600 个, 实体节点 234000 个; 总关系 773640 条, 其中本体关系 358174 条, 实体关系 3415466 条。知识图谱的本体网络及实体网络的部分内容如图 3-6 和图 3-7 所示, 展现了地震灾害领域各类本体、实体及其关联关系的整体框架。由于知识图谱的构建涉及多种数据来源, 并经过实体抽取、本体构建、实体构建和关系构建, 在数据处理过程中可能会引入不准确、不完整、冗余或过时的信息。此外, 某些实体关系可能因数据噪声或不一致性而产生偏差, 影响推理和智能问答的准确性。因此, 需要开展知识图谱质量评估工作, 包括实体一致性检测、关系完整性分析、数据去重、事实验证等, 以保障知识图谱的高效性、可靠性和可解释性, 从而更好地支撑地震灾害智能问答系统的情景构建、应急响应和智能问答等应用。

图 3-6 地震灾害知识图谱本体网络节选展示



图 3-7 地震灾害知识图谱实体网络节选展示

为了科学、系统地评估地震灾害知识图谱的质量，本研究采用多维度评分方法，综合考虑完整性、准确性、一致性、时效性和相关性五个关键维度，并结合行业标准和改进方向建议，对知识图谱的实际表现进行量化分析。评分过程首先针对完整性维度，通过计算知识图谱中实体、属性和关系的覆盖率，衡量其在地震成因、预测、应对措施等方面的知识涵盖程度，并与行业基准进行对比，最终根据覆盖率计算得分。在准确性评估中，采用人工校验与自动化错误检测工具相结合的方法，随机抽取一定数量的实体、属性和关系，计算其准确率，并通过加权平均方式计算整体准确性得分。

同时，在一致性评分过程中，利用实体和关系矛盾检测技术，分析知识图谱中是否存在语义冲突，并结合规则约束检查，确保逻辑一致性。对于时效性维度，则基于知识更新频率进行评分，考察知识图谱是否能及时反映地震预警信息和最新研究进展，并通过计算数据更新间隔时间、知识条目增长速率等指标进行量化评估。最后，在相关性评估过程中，采用查询匹配度分析方法，通过构建测试查询集，计算知识图谱返回结果的精准度，并结合用户反馈数据优化评分。最终，将各维度评分汇总，并与行业标准对比，以提供全面、客观的质量评估报告，同时依据评分结果制定改进方向，包括引入更多权威数据源、优化数据更新机制、加强语义约束以及建立用户反馈系统等措施，以确保地震灾害知识图谱在智能问答系统和灾害应急响应中的可靠性和有效性。

在地震灾害领域的知识图谱质量评估中，可以结合表 3-11 所示的评估结果表，对各项指标进行具体分析。

表 3-11 知识图谱质量评估结果表

评估维度	评分（满分 5 分）	评价说明	行业标准对比	改进方向建议
完整性	4.5	覆盖地震成因、预测和应对措施等核心知识，但在部分细分领域仍有扩展空间	4.2	引入科研机构和政府部门的最新数据源
准确性	4.3	实体准确率为 92%，属性准确率为 89%，关系准确率为 90%；少量信息需进一步核实	4.1	使用自动化错误检测工具与人工校验相结合
一致性	4.7	实体和关系矛盾检测显示高语义一致性，未发现明显逻辑冲突	4.4	持续优化关系定义规则，加强语义约束检查
时效性	4.1	更新频率较低，特别是地震预警数据未能完全实现实时更新	4.0	建立动态更新机制，定期整合新数据
相关性	4.2	查询匹配度较高，但部分边缘知识点的相关性仍需提升	4.0	引入用户反馈机制，调整权重以优化查询结果

表 3-11 汇总了知识图谱在完整性、准确性、一致性、时效性和相关性等维度上的评分和评价说明，同时提供了与行业标准或其他类似知识图谱的对比数据。从表中可以看到，地震灾害知识图谱在完整性维度上得分较高，反映了其在覆盖地震成因、预测和应对措施等核心知识方面的全面性。而在一致性评估中，知识图谱中实体和关系的矛盾检测结果显示较高的语义一致性，这对支持智能问答系统的推理能力具有重要意义。然而在时效性评估中，知识图谱的更新频率略显不足，特别是在地震预警数据的实时更新方面存在改进空间。这些评估结果为知识图谱的质量优化提供了明确的方向。

为了确保地震灾害知识图谱的质量持续提升，可以采取多种方法。针对完整性评估中的不足，可以通过引入更多来源的数据，尤其是科研机构和政府部门发布的最新研究成果，扩展知识图谱的覆盖范围。为了提高知识图谱的准确性，可以采用迭代的评估框架，通过随机抽样的方式对知识图谱中的信息进行人工校验，同时结合自动化的错误检测工具，确保信息的真实性和可靠性。此外，针对时效性评估中的不足，可以建立动态更新机制，定期采集和整合地震灾害相关的新数据，确保知识图谱能够及时反映现实世界的动态变化。通过引入用户反馈机制，可以进一步提升知识图谱的相关性，确保其提供的信息与用户的需求高度吻合。

综上所述，地震灾害知识图谱的质量评估是一项多维度、系统化的过程。通过综合运用完整性、准确性、一致性、时效性和相关性等评估维度，结合表 3-11 的质量评估结果，可以全面了解知识图谱的实际表现，并为进一步的优化提供依据。这些优化措施不仅能够提升知识图谱在地震灾害防治中的应用价值，还为智能问答系统的性能提升奠定了坚实基础。

3.6 本章小结

本章围绕地震灾害知识图谱的构建展开研究，针对地震灾害领域的知识组织问题，提出了一种 BERT-SENet-BiLSTM-CRF 实体抽取模型，以提升实体抽取的准确性。分析了地震灾害知识图谱的构建需求，明确了本体构建、实体构建和关系构建三大核心环节。引入 SENet 机制对 BERT 编码进行优化，增强不同层级语义特征的融合能力，从而提升知识抽取的效果。利用语义模式驱动方法进行关系构建，形成高质量的知识三元组。对构建的知识图谱进行了完整性、准确性、一致性、时效性和相关性评估，结果表明本章方法能够有效提高知识图谱的质量，为后续地震灾害智能问答系统的构建奠定了坚实基础。下一步研究将进一步优化知识融合策略，提高知识图谱的自动化构建能力，并探索知识推理技术的应用，以增强问答系统的推理深度和可解释性。

第四章 地震灾害多通道智能问答模型

在第三章中,研究并构建了一套地震灾害知识图谱,在本章提出一个多通道模型,使用第三章构建的知识图谱在知识图谱问答通道中进行问答辅助。

4.1 引言

在传统智能问答模型中,单一的问答方式难以满足不同类型、不同复杂度问答的需求,如面对低复杂度需要精确查询的问题时,知识图谱问答可以给出高效、可解释的答案;在面对半结构化、知识图谱未覆盖的问题时,检索增强生成问答结合文本检索与生成,可以从非结构化数据(如新闻、科研论文)中补充信息进行回答;而面对开放性、需要复杂推理类的问题时,大语言模型问答能够进行语义理解与推理,提供专业化的综合答案。目前,不同的问答任务的复杂性差异较大,简单查询与跨领域推理问题需要不同的处理方式,同时直接使用大语言模型处理所有问题计算成本高昂,且某些问题并不需要复杂推理,迫切需要一种问答方法能够满足地震灾害知识领域内不同类型的问答需求。通过融合知识图谱、检索增强生成和大语言模型,以面对不同难度的问题采用不同的方法进行回答的方式,从而赋予问答更深层的语境理解和更完善的问答机制,以便能够更准确地理解用户提出的问题。

在这种方法中,需要通过知识图谱通道通过对实体的抽取直接对知识图谱进行匹配用以对专业领域问题进行最准确的回答,知识图谱问答在面对垂直领域场景中具有精确性和可解释性的优势,但也面临知识覆盖不完备、复杂语义理解不足和答案生成僵化的挑战。而检索增强生成通过向量检索从知识图谱和外部文档中检索相关信息进行补充回答,提高了回答的准确性和时效性,又利用知识图谱其自身的结构化信息弥补了大语言模型在垂直领域的幻觉问题。但面对复杂开放性问题时,知识图谱问答和检索增强生成问答的表现仍稍显逊色,通过领域知识微调的大语言模型具备强大的语言理解和生成能力,能够解析复杂语义,处理高难度复杂的问答推理,提供更深入的专业分析。同时,通过分析问句的句式特征与语义深度,筛选问题复杂度,自适应选择最优的处理路径,为回答用户问题选择适合的答案生成方式。将简单查询交给知识图谱,减少大语言模型的调用次数,降低计算成本。检索增强生成通道结合向量检索与轻量级生成,避免大语言模型计算过载,提高问答系统的整体吞吐量。因此,融合知识图谱问答、检索增强生成和大语言模型的问答模型,可以提供更全面、准确和可靠的问答服务。

4.2 模型描述

4.2.1 模型总体结构

为满足地震灾害知识领域内不同类型的问答需求，本研究提出了一个地震灾害多通道智能问答模型（Multi-Path Intelligent Question Answering Model，MultiPathQA），MultiPathQA 如图 4-1 所示由知识图谱问答通道、检索增强生成通道、大语言模型通道和智能路由决策模块四部分组成。在地震灾害知识图谱的智能问答系统中，采用多通道架构以确保不同类型问题的精准解答，并通过智能路由决策模块进行高效分配。该系统主要由知识图谱问答通道、检索增强生成通道和大语言模型通道组成，每个通道针对不同复杂度和类型的问题进行处理，以提供高准确性、可解释性和动态性的答案。




图 4-1 MultiPathQA 模型结构示意图

知识图谱问答通道负责处理简要查询式问题，该通道通过信息抽取技术从用户问句中识别关键实体、关系和属性，构建三元组 (subject,predicate,object)，并在

知识图谱中匹配对应事实,进而得出精准答案。由于知识图谱结构化程度高,数据经过严格验证,该通道能够确保回答的精准性和可解释性,特别适用于事实型问题,如“某次地震的震级是多少?”或“某地区的主要断层有哪些?”。

检索增强生成通道主要用于处理中等难度的问题,该通道结合向量检索技术,从非结构化文档(如地震灾害报告、科研论文、新闻数据等)中提取相关知识,补充知识图谱未完全覆盖的内容。该通道特别适用于涉及最新动态、长尾知识或跨领域专业信息的问题,如“2023 年全球发生了哪些大地震?”或“某个研究机构对地震预测的最新研究进展如何?”。通过结合检索与生成,该通道在保证一定可解释性的同时,也能够适应专业领域内的知识动态更新。

大语言模型通道依托大规模预训练语言模型的自然语言理解能力,用于处理复杂问题,生成更专业、推理性强的答案。该通道适用于需要跨领域知识整合、推理或主观判断的问题,如“地震活动的长期趋势如何影响建筑抗震设计?”或“地震预警系统如何与其他灾害管理体系协同工作?”。大语言模型通过上下文理解、语义推理和知识扩展,能够在信息不完全或需要深度分析的情况下,提供符合逻辑的专业答案。

为了优化问答流程,提高回答的准确性和效率,系统设计了智能路由决策模块,该模块在问题进入问答系统后,首先对问句进行预处理,分析其语义结构、复杂度、领域特征等关键要素,进而决策将问题投入最适合的通道。例如,若问题涉及明确的实体查询,则优先使用知识图谱通道;若问题涉及知识图谱未涵盖的信息,则通过检索增强生成通道补充答案;若问题需要综合推理或语义理解,则交由大语言模型通道处理。通过动态决策和多通道协同,该系统能够在精准性、时效性和可解释性之间取得良好平衡,为地震灾害领域的智能问答提供高效可靠的支持。

4.2.2 知识图谱问答通道

知识图谱问答通道分为三个主要阶段:三元组抽取、图谱匹配和答案生成。每个阶段的目标是确保系统能够准确、全面地理解并回答用户提出的领域相关问题。

在三元组抽取阶段,首先提出与领域相关的问题,并进行实体和关系的抽取。运用在 3.2 节设计的 BERT-SENet-BiLSTM-CRF 实体抽取模型,抽取出实体,并运用在 3.4.3 小节中设计的关系抽取工具,对实体和关系进行匹配,如 Q: 地壳运动会引发地震吗? Triple: (地壳运动,引发,地震)。

在图谱融合阶段,将文本中抽取的原始三元组(*head, relation, tail*)与知识图谱 $G=(E,R,T)$ 中的实体和关系进行快速匹配,判断其是否已存在于图谱中,由于在知识图谱通道中多为简要查询式问题,抽取的三元组可能不完整,所需要的答案为

三元组中的尾实体,且所需要查询的尾实体可能为多个,因此需要为文本三元组中的头实体 $head$ 或尾实体 $tail$ 在图谱中寻找潜在匹配的实体 $eKG \in E$, 将文本关系 $relation$ 映射到图谱关系 $rKG \in R$ 。其匹配方式如公式(4-1)所示。:

$$Match_{exact}(etext, eKG) = \begin{cases} 1, & \text{if } etext.name = eKG.name \\ 0, & \text{otherwise} \end{cases} \quad (4-1)$$

在图数据库中执行结构化查询(如 Neo4j 的 Cypher 语句),用以验证 $(head, relation, tail)$ 、 $(head, relation, ?)$ 或 $(head, ?, tail)$ 是否已存在于图谱三元组集合 T 中。如存在则进入答案生成阶段,如不存在则转入检索增强生成通道。

在答案生成阶段,输入检索到的三元组,并输出符合语法且信息完整的自然语言句子 S ,在此过程中预定义句式模板,动态插入实体和关系,按关系类型选择模板,将实体列表转换为自然语言。

4.2.3 检索增强生成通道

检索增强生成通道(Retrieval-Augmented Generation, RAG)是一种将信息检索技术与生成模型相结合的技术框架,旨在通过动态引入外部知识库(如知识图谱、文档集合等)提升生成内容的事实准确性和语义相关性,以解决知识图谱问答通道覆盖不到的问题。具体步骤如图 4-2 所示:




图 4-2 检索生成通道示意图

检索增强生成通道通常由检索器(Retriever)和生成器(Generator)构成。在检索器中,外部参考文档被预先分割成文本块,这些文本块可能包含与问题或任务相关的段落或部分。知识图谱包含有关实体及其关系的结构化信息,这些信息预先都以三元组的形式存储起来。之后,文本块和三元组都被向量化为向量表示,存储在向量库中便于后续处理和相似度比较。在用户提出问题后,对问题中涉及的三元

组进行抽取,所用的技术为前文所介绍的三元组抽取技术,并将问题中所涉及的三元组也进行向量化表示,将其转化为易于与知识图谱或参考文档所生成的向量库进行匹配的形式。生成器的主要功能是利用检索到的相关信息生成流畅、准确且上下文相关的自然语言答案。从信息检索阶段获取的相关信息,经过适当的处理后,会被合并为一个统一的提示信息,传入生成模型进行处理。生成器通常使用大型预训练语言模型作为生成模型来生成答案。这些模型基于大量的文本数据进行训练,能够生成自然流畅的语言文本。为了适应特定领域的知识,模型会利用相关领域的文本数据进行微调,使其能够生成更专业和相关的回答。生成模型需要理解输入的用户查询和检索到的信息的上下文关系。生成器通过分析查询中的关键实体、关系以及与检索信息的关系,来确保生成的答案与问题相关。生成模型有效地融合检索到的提示信息,确保答案中包含相关的实体、关系及其他背景信息。生成模型基于输入信息生成连贯的自然语言文本。生成的答案不仅需要回答用户的提问,还应当符合语言的语法和语义逻辑,使得答案更加自然。

4.2.4 大语言模型通道

当面对提出的问题涉及的领域超出了现有知识库的覆盖范围、问题包含了模糊未定义的实体和关系、问题文本过于复杂,涉及了过多的信息导致进行三元组提取等困难时,检索器和知识图谱无法提供足够的信息,无法通过知识图谱问答通道和大语言模型解决,则问答模型进入大语言模型通道。此时,模型会依赖其在大量语料中学习到的常识、推理能力和语言生成能力来回答问题。

生成的答案是基于一个领域知识微调的大语言模型,用其在预训练阶段所学到的知识和信息进行回答,因此,这种方式的回答更为灵活且能处理各种不同类型的查询。

领域知识微调是指在预训练的大型语言模型基础上,通过在特定领域的文本数据上进一步训练微调,使模型更好地适应该领域的特定任务。与通用模型相比,微调后的大模型能更精准地处理该领域的专业术语、领域知识和特殊需求。

领域知识微调通常从一个大型预训练模型开始,这些模型已经在大规模语料库(如通用语料、新闻、维基百科等)上进行了预训练,具备了基本的语言理解能力和生成能力。微调模型需要特定领域的语料库,因此在数据准备阶段,运用数据清洗的手段来构建知识注入样本语料库。构建好语料库后进入核心微调技术阶段,运用低秩适配技术^[70](Low-Rank Adaptation, LORA),将前述选择的大模型与精心构建的知识注入样本数据集结合,模型在注入知识后还需要经过细致的微调,经

过知识图谱应用反馈后,将未注入大模型中的知识进行反馈微调,并对模型进行监督学习,提高模型的质量,LORA 的技术路线该技术的示意图如图 4-3 所示。




图 4-3 LORA 技术示意图^[70]

结合领域的通用大语言模型,在这里选用 DeepSeek-V1:7b^[32]模型为基准模型,将文本信息转化为问答集,输入到模型中进行低秩适配微调,该问答集包含历史灾害案例库中的灾害信息(如时间、地点、灾害类型、损失数据等)和学术文献与专家规则,经过数据整理后,将问答集进行基于 LoRA 的知识注入。

对于基准预训练模型的原始权重矩阵 $W_0 \in \mathbb{R}^{d \times k}$, 它具有 d 行 k 列, 这个矩阵通常由模型在大规模语料库上训练而得, 包含了通用的语言表示能力, 在 LoRA 微调过程中, 不直接修改这个矩阵, 而是添加一个小的调整项(即低秩更新矩阵)。

LoRA 技术的核心思想是用两个低秩矩阵 A 和 B 近似更新权重, 而不是直接调整整个 W_0 , 更新计算过程如公式(4-2)所示。

$$\Delta W = BA \quad (4-2)$$

其中 $B \in \mathbb{R}^{d \times r}$, 这是一个小矩阵, 行数为 d (与原始权重矩阵 W_0 的行数相同), 列数为低秩维度 r , 这个矩阵的作用是对输入特征进行降维, 减少计算量。 $A \in \mathbb{R}^{r \times k}$, 这是另一个小矩阵, 行数为 r (低秩维度), 列数为 k (与原始权重矩阵 W_0 的列数相同)。这个矩阵的作用是恢复降维后的特征, 使其匹配原始模型的输出维度。由于 $r \ll \min(d, k)$, 矩阵 A 和 B 的参数总量远小于直接训练一个 $d \times k$ 的全参数矩阵, 因此可以显著减少计算和存储成本。

在推理过程中, 神经网络对输入数据进行计算时, 使用更新后的权重, 其计算过程如公式(4-3)所示。

$$h = W_0 x + \Delta W x = W_0 x + BAx \quad (4-3)$$

其中 x 为输入向量,表示当前层接收到的输入数据, h 为前向传播的计算结果,即当前层的输出, W_0x 为原始模型的计算结果(不含 LoRA), BAx 为 LoRA 低秩更新部分,增加了领域知识的微调效果。LoRA 在前向传播时,仅通过额外的 BAx 进行计算,而不改变原始的 W_0x ,这样能够保持原始模型的知识,同时增强地震灾害领域的表现。

4.2.5 智能路由决策模块

之前提出了智能问答模型的三个通道,并详细介绍了各通道的详细情况以及在模型工作和各通道之间的协同机制,然而在此模型中,通常会串行处理多个信息通道以获取更全面的答案,在选择最优路径时缺乏智能决策能力,这种情况,可能导致在获取信息时导致信息冗余或遗漏,从而影响回答的准确性和效率。为了解决这一问题,提出了智能路由决策模型。

智能路由决策作为智能问答模型的核心组件,其核心思想在于通过分析问句的句式特征与语义深度,自适应选择最优处理路径,为回答用户问题选择适合的答案生成方式,以实现知识可信性与生成灵活性的平衡。算法需要对简单短问句与复杂长问句的处理需求截然不同,前者需轻量级快速响应,进入知识图谱问答通道,后者则需要依赖深度的语义推理,进入检索增强生成通道或者大模型通道。目前固定的流程无法根据语句结构动态调整,传统方法通常采用固定处理流程,难以动态适配不同复杂度的语言结构,对简单问句的冗余计算和对复杂问句的浅层处理,导致计算资源的浪费和答案的生成不够全面。

为此,本章提出一种智能路由决策模块,通过综合量化语句的句法-语义复杂度,实现动态路径选择与资源优化,从而在效率与精度间达到平衡。智能路由决策模块旨在通过融合句法和语义两大层面的复杂度信息,为后续的答案生成提供决策依据。

本模型的总体框架如图 4-4 所示,具体分为以下三个组件:句法复杂度分析组件,语义复杂度分析组件和语句复杂度融合组件。模块首先利用分词工具对输入语句进行预处理,获取词语及其词性信息,并进一步通过依存句法分析构建出语句的成分语法树。该语法树通过图卷积网络(GCN)的作用,将词与词之间的依存关系进行建模,从而提取出反映句法复杂度的关键信息,最终以语法树的最大深度作为句法复杂度的量化指标。同时,模型采用 BERT 模型对语句进行语义编码,通过遮蔽语言模型技术计算每个词的困惑度(Perplexity),从而评估语句的语义复杂度。两种复杂度指标由于在尺度和含义上存在差异,因此在进一步处理之前,需要对其进行归一化处理。模型采用线性加权的方式将句法复杂度与语义复杂度融合,得到

一个综合的语句复杂度评分。该评分反映了语句在结构和语义两方面的总体难度，并作为判断语句质量的重要依据。根据综合复杂度与预设阈值的匹配情况，模型将选择不同的答案生成策略，以实现输入语句的差异化处理和优化答案的生成效果。模块支持模块化替换组件，兼具自适应资源分配与可视化解释能力，在效率与精度间实现动态平衡。下面，将详细介绍这三个组件。




图 4-4 智能路由决策模型架构示意图

句法结构的复杂度是衡量语言表达难度的重要指标，对语言学研究、语言教学以及自然语言处理应用具有重要意义。传统的复杂度评估方法主要依赖于人工规则或浅层统计特征，难以全面捕捉句子中深层次的句法关系。近年来，图卷积网络（GCN）在处理图结构数据方面展现出强大的能力，被广泛应用于社交网络分析、分子结构建模等领域。然而，将 GCN 应用于句法结构复杂度评估的研究尚属空白。本文提出了一种新的方法，将句子解析为依存句法图，并利用 GCN 对其进行建模，以自动评估句法结构的复杂度。

句法复杂度组件利用 GCN 评估句法结构复杂度的新方法。该方法首先使用自然语言处理工具将句子解析为依存句法树，然后将其转换为图结构数据。在此基础上，设计了一个包含边特征编码、图卷积层和注意力机制的 GCN 模型，以捕获句子中词汇和句法关系的深层次特征。对于给定输入句子 $S = \{w_1, w_2, \dots, w_n\}$ ，使用自然语言处理工具对输入句子进行依存句法解析，获取每个词的词性（POS）标签、词向量表示以及词之间的依存关系，将句子表示为图结构，其中节点表示词，边表示词之间的依存关系。每个词 w_i 的特征向量由三部分拼接组成， $h_i(0) = \text{Concat}(e_{word}(w_i), e_{pos}(p_i), e_{dep}(d_i))$ ，其中 $e_{word}(w_i)$ 为词向量，可通过自然语言处理工具获得， $e_{pos}(p_i)$ 为词性（POS）标签， $e_{dep}(d_i)$ 为依存关系类型的嵌入向量，

这三部分拼接起来，形成一个包含词、词性和依存关系信息的综合特征向量，该特征向量如图 4-5 所示。




图 4-5 GCN 节点特征示意图

边的特征代表了词与词之间的依存关系类型及其方向信息。对于每条依存关系边（连接 $w_i w_j$ ）的特征 f_{ij} ，其编码过程如公式(4-4)所示。

$$f_{ij} = W_e f_{ij} + b_e \quad (4-4)$$

其中 W_e 为可学习的权重矩阵,此矩阵负责从边的特征（如关系类型、方向等）中学习表示。 b_e 为偏置项，表示在学习边特征时的平移。

GCN 会根据上述节点和边的特征对图进行操作。在 GCN 中，节点的特征会随着网络的层数逐步更新，通过与邻域节点的信息进行聚合，从而得到一个新的表示。具体计算方式如公式(4-5)所示。

$$h_i^{l+1} = \sigma \left(\sum_{j \in N(i)} \frac{W^{(l)} h_j^{(l)}}{c_{ij}} + b^{(l)} \right) \quad (4-5)$$

其中 $h_j^{(l)}$ 为第 l 层时，节点 i 的特征表示， $N(i)$ 为节点 i 的邻居节点集合。 c_{ij} 是归一化系数，通常用来调整节点间的权重， $W^{(l)}$ 和 $b^{(l)}$ 为第 l 层的可学习权重和偏置，通过线性变换将边特征映射到隐藏空间，将其映射到与节点特征相同的维度，以便在图卷积层中融合节点和边的信息。该模块包含两层 GCNConv 层，分别对输入的节点特征进行变换和聚合，以捕获局部的句法结构信息。在第二层图卷积之后，加入 GATConv 层，引入注意力机制，以捕获全局的句法关系和重要性差异。通过线性层计算图中节点特征的最大深度和跨度方差，作为句法结构的全局特征。将图卷积层和结构化特征提取得到的特征拼接后，经过全连接层和激活函数，最终输出句法复杂度分数 f_{syntax} 。

语义复杂度组件利用 BERT 评估困惑度的方法，本方法采用预训练 BERT 模型进行语义编码，对输入句子 $S = \{w_1, w_2, \dots, w_n\}$ ，首先通过分词器转换为子词序列 $T = \{t_1, t_2, \dots, t_n\}$ ，并添加特殊标记： $T' = \{[CLS], t_1, t_2, \dots, t_n, [SEP]\}$ ，其中， $[CLS]$ 表示分类标记， $[SEP]$ 为句子分隔标记。将输入序列输入 L 层 Transformer 编码器，获得上下文相关表征，再进行遮蔽语言模型（MLM）的困惑度计算流程：对每个位置 $i \in \{1, \dots, M\}$ ， $T_{mask(i)} = [t_1, \dots, [MASK], \dots, t_M]$ ，通过 BERT 模型计算被遮蔽位置的词表分布，生成整体的句子困惑度归一化为语义复杂度 $f_{semantics}$ 。

最后使用加权平均的方式将两者的特征结合通过一个加权系数 α 将句法复杂度和语法复杂度的评分结合起来： $f_{complexity} = \alpha f_{syntax} + (1 - \alpha) f_{semantics}$ 。

4.3 实验数据集、评价指标和参数设置

4.3.1 实验数据集

为全面验证多通道问答模型的性能，实验采用以下数据集：

Stanford Question Answering Dataset 1.1 (SQuAD1.1)^[71]：是斯坦福大学于 2016 年发布的阅读理解数据集，包含来自 536 篇维基百科文章的 107,785 个问答对，包括艺术、科学、历史、文学等方面。对于每个问题，都有对应的答案，答案是从相关的文章中直接获取的。该数据集中的问题由众包工人提出，答案直接取自相应文章中的一段文本。SQuAD1.1 的推出为问答系统的研究提供了重要的基准测试资源。

EarthquakeQA：为本研究自建数据集，包含地震灾害相关文章片段和问答对两种类型：相关文章片段作为检索增强生成通道的外部文档和一部分问答对的来源，涵盖了多种地震灾害类型的相关信息，来源为地震灾害领域相关的专业文献、风险评估报告和领域专家知识等。问答对大部分来源于相关文章片段中，其余部分来源于网络论坛和地方性地震灾害监测数据等。该数据集包括以下内容：115 篇地震灾害的相关文章片段和 3115 个问题和答案，问题与答案的组合类似于 SQuAD1.1 的形式。

4.3.2 评价指标

在智能问答任务中，通常选用 Exact Match (EM)、Bilingual Evaluation Understudy (BLEU)、Recall-Oriented Understudy for Gisting Evaluation (ROUGE-N) 和 Metric for Evaluation of Translation with Explicit Ordering (Meteor) 四个指标来评估答案的生成质量。以下是对这四个指标的详细介绍：

EM 指标用于评估生成的答案是否与参考答案完全一致。EM 衡量的是模型生成的答案与标准答案之间的精确匹配程度，其计算方式如公式(4-6)，如果生成的答案和参考答案在字面上的字符完全一致，包括标点、大小写和词语顺序等才算完全匹配，如果生成的答案与参考答案有任何不同，即使只有一个字符的差异，也会被视为不匹配。该指标适用于需要精确匹配的垂直领域问答任务。

$$EM = \frac{\text{Number of exact matches}}{\text{Total number of questions}} \quad (4-6)$$

BLEU-N 通过计算 $n-gram$ (n 个连续单词) 的精确度来衡量生成答案与参考答案之间的相似度以评估生成答案的质量，其计算方式如公式(4-7)所示。其中， W_n 指 $n-gram$ 的权重，一般设为均匀权重，即对于任意 n 都有 $W_n = 1/n$ 。 BP 是惩罚因子，其计算方式如公式(4-7)所示，如果生成答案的长度小于最短的参考答案，则 BP 小于 1。 lc 为生成答案的长度， lr 为参考答案的有效长度（即与生成答案长度最接近的参考答案的长度）。

$$BLEU = BP \times \exp\left(\sum_{n=1}^N W_n \times \log P_n\right) \quad (4-7)$$

$$BP = \begin{cases} 1 & , lc > lr \\ \exp\left(1 - \frac{lr}{lc}\right) & , lc \leq lr \end{cases} \quad (4-8)$$

ROUGE-N 通过计算 $n-gram$ 的召回率来衡量生成答案与参考答案之间的相似度以评估生成答案的质量。ROUGE-N 计算生成文本与参考文本之间 $n-gram$ 的重叠情况，其计算方式如公式(4-9)所示，其中， $Count_{match}(n-gram)$ 表示生成文本 $n-gram$ 的数量， $Count_{reference}(n-gram)$ 表示参考文本中 $n-gram$ 的总数量，分子表示生成文本和参考文本匹配的 $n-gram$ 总数量。

$$ROUGE - N = \frac{\sum_{S \in \{ReferenceAnswer\}} \sum_{n-gram \in S} Count_{match}(n-gram)}{\sum_{S \in \{ReferenceAnswer\}} \sum_{n-gram \in S} Count_{reference}(n-gram)} \quad (4-9)$$

Meteor (Metric for Evaluation of Translation with Explicit ORdering) 是一种综合考虑精确度和召回率的评估指标，使用精确度和召回率的调和平均来平衡两者的影响，其计算方式如公式(4-10)所示，其中， P 是精确度，在这里将 BLEU 值看作精确度， R 是召回率，在这里将 ROUGE-N 值看作召回率， α 是平衡因子，由于在垂直领域的问答更侧重于精确度层面，所以通常取值为 0.9。

$$Meteor = \frac{P \times R}{\alpha \times P + (1 - \alpha)R} \quad (4 - 10)$$

4.3.3 参数设置

知识图谱通道使用 BSBC 实体抽取模型使用的主要参数在 3.3.3 小节中有过详细介绍, 检索增强生成通道和大语言模型通道使用的领域微调大模型模块使用的主要参数为训练轮数 (Epochs) 为 100, epoch 批处理大小 (Batch_size) 为 1, 最大文本长度 (Max_len) 为 300, 初始学习率为 5e-3, 丢弃比例 (Dropout) 为 0.1, 梯度累计 (Gradient_accumulation_steps) 为 16。

此外, 模型在配备 NVIDIA RTX 3090 GPU 和 Intel i9-10900K CPU 的服务器上使用软件库 PyTorch 实现。

4.3.4 实验和结果分析

为了验证本章提出的多通道问答模型的有效性, 本节选择了智能问答领域的五个基线模型进行对比, 以下是详细介绍:

(1) RODQA^[72]: 一种基于预定义的规则和模板的检索问答模型, 该方法能够回答来自各个领域的问题, 方法通过规则框架来从上下文中提取答案。

(2) BERTQA^[66]: 一种基于 BERT 算法构建的问答模型, 可以根据给定的问题和上下文段落, 抽取出答案的起始和结束位置, 将问题和上下文拼接在一起, 生成问题答案。

(3) BART^[73]: 一种生成式的问答模型, 结合了 BERT 的双向编码器和 GPT 的自回归解码器, 它能够理解输入上下文并生成高质量的回答或文本。

(4) T5^[33]: 一种通用文本到文本转换模型, 具有处理多种自然语言处理任务的能力, 将所有输入和输出都视为文本序列, 简化了问答任务的处理流程, 并且能够高效地利用预训练模型, 提供强大的语言理解和答案生成能力。

(5) GPT-3^[38]: 的一种基于 GPT 架构的对话生成模型, 专为人类语言交互设计。它基于 GPT-3 模型, 能够进行上下文感知的对话答案生成。

为了验证 MultiPathQA 模型能够进行更优秀的问答表现, 本节进行了智能问答任务实验, 并于基线模型进行对比。在智能问答任务中, 本节采用 EM、BLEU、Rogue-4 以及 Meteor 来综合衡量模型智能问答的性能。

在 SQuAD1.1 数据集上的实验结果如表 4-1 所示, 在 EarthquakeQA 数据集上, 进行了智能问答实验, 结果如表 4-2 所示。表中最高分以加粗显示, 次高分以下划线显示。

表 4-1 SQuAD1.1 数据集上的实验结果

模型	EM ↑	BLEU-2 ↑	ROUGE-2 ↑	Meteor ↑
RODQA	0.273	0.361	0.453	0.441
BERTQA	0.305	0.396	0.649	0.611
BART	<u>0.568</u>	<u>0.529</u>	<u>0.714</u>	<u>0.689</u>
T5	0.541	0.473	0.537	0.516
GPT-3	0.526	0.436	0.662	0.629
MultiPathQA	0.665	0.557	0.795	0.762

表 4-2 EarthquakeQA 数据集上的实验结果

模型	EM ↑	BLEU-2 ↑	ROUGE-2 ↑	Meteor ↑
RODQA	0.391	0.457	0.537	0.528
BERTQA	0.434	0.761	0.736	0.738
BART	<u>0.691</u>	<u>0.793</u>	<u>0.854</u>	<u>0.847</u>
T5	0.651	0.744	0.774	0.771
GPT-3	0.637	0.713	0.793	0.784
MultiPathQA	0.834	0.894	0.914	0.912

从整体上看,同时利用多通道问答模型的问答模型比仅使用一种信息的模型表现出更好的性能。从表 4-1 和表 4-2 可以看出,MultiPathQA 优于其他模型,取得了最好的成绩。具体而言,MultiPathQA 在 SQuAD1.1 数据集上的 EM 值为 0.665,在 EarthquakeQA 数据集上的 EM 值为 0.834。与次高分的 BART 相比,SFFGE 在 SQuAD1.1 和 EarthquakeQA 数据集上的 meteor 分别实现了 10.5%和 7.67%的提升,这证明了本章提出的 MultiPathQA 模型的有效性。

4.4 本章小结

本章提出了一种地震灾害多通道智能问答模型(MultiPathQA),旨在融合知识图谱问答、检索增强生成(RAG)和大语言模型(LLM)三种问答方式,以提高问答系统的准确性、可解释性和推理能力。介绍了模型的总体架构,包括知识图谱问答通道进行精准匹配问答、检索增强生成通道进行向量检索来进行中长文本问题问答和大模型推理通道进行复杂推理任务问答。设计了智能路由决策模块,结合图卷积网络与 BERT 计算问题语句复杂度,并动态选择最优问答路径。通过实验验证了本模型的有效性,结果表明 MultiPathQA 在准确率和答案质量方面均优于单一问答方式。综上所述,本章研究为地震灾害智能问答系统的构建提供了关键技术支持,下一步将进一步优化模型参数,提高系统在多模态数据融合和复杂推理任务中的适应能力。

第五章 地震灾害情景构建智能问答系统

5.1 引言

地震灾害是一种突发性极强、破坏力巨大的自然灾害，其危害直接体现在人员的伤亡、基础设施的损坏、次生灾害的触发、经济的损失、社会秩序的混乱以及生态环境的破坏等多个方面。地震所引发的建筑物倒塌、交通系统瘫痪、供水供电设施中断以及滑坡、崩塌、海啸、火灾等次生灾害，不仅对人民的生命安全构成严重的威胁，而且还会造成长期的经济以及社会影响，甚至会引发群体心理创伤和生态系统的退化。

在地震灾害发生以后，如何快速、准确地获取地震灾害相关的信息对地震灾害的应急响应和决策支持至关重要。然而传统的信息获取方式常常依赖于人工检索和专家咨询，存在信息获取效率低、专业性要求高以及实时性不足等问题。因此，为了提升地震灾害应急管理的科学性和效率，地震灾害情景构建系统的应用显得尤为必要。该系统依托知识图谱与人工智能技术，能够整合地震的多源监测数据，模拟地震灾害的具体情景，预防潜在的威胁，并且提供应急处置建议以及评估报告，从而辅助政府决策者、应急管理人员和公众在灾前做好防范措施，在灾中做到快速响应，在灾后实施高效恢复。通过构建智能化的地震灾害情景分析和问答系统，不仅可以提高应急响应措施的精准度，减少灾害带来的损失，还能为防灾减灾体系的建设提供科学依据，进一步增强社会的抗震减灾能力。随着人工智能技术的快速发展，基于知识图谱和大模型的智能问答方法为地震灾害情景构建智能问答系统提供了一种高效且智能的解决方案。

本研究实现了一套基于知识图谱与大模型协同工作的地震灾害情景构建智能问答系统。该系统依托于地震灾害相关的知识图谱，整合地震监测数据、历史灾害案例、建筑抗震能力评估及应急处置预案等多源信息，并且利用大模型进行自然语言的理解和推理，提供高质量的问答服务。系统的主要功能包括地震事件查询、应急处置建议及多轮交互问答等，以满足不同用户群体的信息需求。

本章将详细介绍该智能问答系统的整体架构、核心技术、功能模块及实际应用案例并介绍系统的需求粉丝以及设计思路。对地质灾害情景构建智能问答系统的具体实现进行阐述。通过实际案例对地震灾害情景构建智能问答系统进行展示，验证系统的有效性，展示其在地震灾害应急管理中的应用价值。

本研究的智能问答系统不仅提升了地震灾害情景构建的智能化水平，也为防灾减灾领域的智能化信息服务提供了新的技术路径，为政府和公众在面对地震灾害时提供了更高效、准确的信息支持。

5.2 系统分析与设计

5.2.1 需求分析

需求分析是系统开发过程中的关键环节，通过需求分析，能够清晰地了解到用户的实际需求，明确系统的目标和范围，避免在开发过程中出现需求模糊或不一致的问题，以提高系统开发的效率，在系统开发中扮演着至关重要的角色，需求分析的好坏直接影响项目的成功与否。




图 5-1 地震灾害情景构建智能问答系统用例图

图 5-1 给出了本系统的用户用例图。用户在本系统中能够进行包括对地震灾害情景构建知识图谱的相关操作、进行地震灾害情景构建、通过系统进行智能问答以及对用户基本信息的操作。用户需通过注册功能创建账号，在系统中注册过后，用户才能够获取系统的服务并进行登录，以确保用户身份的安全性和系统信息交互的可控性。用户注册完成之后，在系统中输入正确的用户名和密码，即可登录系统，

获取服务。在系统中，用户能够根据特定的地震事件触发情景构建模块，通过输入地震灾害信息，自动生成地震灾害的情景模拟，来进行地震灾害的场景模拟与动态展示，以帮助用户理解地震灾害的发展过程，便于预判灾情且能够及时采取相应的措施。并且用户可以通过节点搜索，输入节点的名称以及关键词，快速地定位到所需要的地震灾害的相关信息，同时系统支持知识图谱的子图展示，使得用户能够清晰直观地理解到节点与节点之间的关系和结构。此外，系统基于已构建的地震灾害知识图谱和多通道智能问答模型，提供了高效、精准的地震灾害情景构建智能问答服务，包括对地震灾害信息的问答和地震灾害情景构建出的地震事件的评估，其中地震灾害情景构建出的地震事件的评估包含地震灾害构建事件的详细信息、影响的范围以及潜在风险评估等，并依据情景定制详细准确的应急预案和应急措施，以满足灾前预警、灾中响应和灾后恢复等不同阶段的信息需求。

5.2.2 概要设计

B/S 架构（Browser/Server，浏览器/服务器）是一种网络结构模式，客户端主要依赖浏览器，而服务器主要负责处理业务逻辑、数据存储与客户端通信。图 5-2 为此网络结构请求响应示意图。这种网络结构模式把系统的功能实现核心部分集中到了服务器上面，简化了系统的开发与维护。客户端只需要安装一个浏览器，通过 Web 服务器与数据库服务器进行数据的交互。



图 5-2 B/S 请求响应示意图

B/S 架构利用了 Web 浏览器技术和 Internet 协议，实现了异构系统连接和信息共享。这种架构下，客户端无需安装专用的软件，只需要使用浏览器即可访问应用程序，降低了部署的复杂性，并且跨平台兼容性强，应用程序可以在多个平台上正常运行，只要求服务器端适配即可，此外这种网络结构模式易于集中管理，应用核心逻辑和数据处理均集中在服务器端，便于统一的管理和维护，也便于快速升级系统功能，还支持分布式的架构，可以通过服务器集群、负载均衡等技术来扩展性能，能够适应大规模用户并发访问。B/S 架构将应用程序的业务逻辑集中在服务器端来

进行处理,简化了客户端的需求,使应用程序更易于维护和扩展,适用于需要跨平台访问、易于维护和升级,且用户群体广泛的应用场景,能够满足地震灾害情景构建智能问答系统的需求。

为构建地震灾害情景构建智能问答系统,采用 B/S 架构的分层设计,其架构设计如图 5-3 所示其中包括数据知识层、模型服务层和知识应用层。




图 5-3 地震灾害情景构建智能问答系统架构图

数据知识层主要负责多源异构的地震灾害数据的收集、存储和管理,包括地震灾害报告、网络资源、地震灾害学术论文及其他专业信息系统的数据。该层通过图存储实现知识图谱数据的存储,通过多模态存储方式支持不同类型的数据存储,同时设置索引管理以提高数据查询的效率,采用备份管理的机制,保障地震灾害数据的安全与稳定。

模型服务层是该系统智能化的核心,分为地震灾害知识图谱模块、地震灾害大模型模块和多通道智能问答模块三个部分。知识图谱模块包括地震灾害本体网络和地震灾害实体网络,用于知识的结构化表示。地震灾害大模型模块则将专业领域知识引入大模型中,通过知识注入和 LoRA 微调提高了模型的泛化能力与专业性,保障地震灾害问答和地震灾害评估的准确性。多通道智能问答模块则包含知识图谱问答通道、检索增强生成问答通道和大模型问答通道,分别针对结构化知识、非结构化数据以及需要深层语义理解等不同需求的问题提供综合性智能问答服务,实现用户多样化的信息需求。

知识应用层为用户提供直接的应用界面,主要实现地震灾害知识图谱的管理维护、地震灾害情景构建的展示以及地震灾害智能问答服务。用户可以通过该层直观方便地查看和管理知识图谱信息,快速地进行情景模拟和灾情分析,以及获得准确专业的灾害信息以及应急决策支持。

整体设计通过清晰明了的层次划分，明确了各层的职责，增强了系统的可维护性、扩展性与响应速度，从而显著提升了地震灾害管理的智能化与精准性。

5.2.3 数据库设计

为了更全面地满足地震灾害情景构建智能问答系统在数据存储、管理与高效检索方面的需求，本系统设计中同时采用关系型数据库 MySQL 和图数据库 Neo4j，充分考虑地震灾害情景构建的特殊性和应用需求，进行了详细的数据库表结构设计。

关系型数据库 MySQL 主要负责存储结构化数据，具体包括用户基础信息、地震事件元数据、系统操作日志以及情景构建所需的基础数据。

表 5-1 关系型数据库设计

表名称	核心字段	功能定位
情景参数配置表	情景 ID（主键）、震源机制（走滑/逆冲）、断层破裂速度、土壤液化概率、建筑群脆弱性分级、人口热力图编码	定义情景构建的输入规则，支持通过地震参数、工程参数与社会参数组合生成灾害演化基线场景
灾害链推演表	链式 ID、触发事件类型（主震/余震/滑坡）、级联强度系数、传播时间延迟、阻断措施有效性评分	量化次生灾害的级联逻辑，为动态应急预案生成提供数据支撑
实时监测数据表	数据 ID、传感器类型（地震波/倾斜仪）、采集时间戳、地理网格坐标、物理量值（加速度/位移）、数据置信度	集成多源传感器数据，通过地理网格坐标与时间戳对齐，支持情景模拟的实时校准与动态修正
应急资源调度表	资源 ID、资源类型（医疗队/物资库）、可用容量、调度优先级、路径拓扑关系、绑定情景 ID	基于情景 ID 关联资源分布与灾害影响范围，结合路径拓扑关系优化灾中资源调度效率

关系型数据库设计如表 5-1 所示。其中用户信息表记录用户基本信息，包括用户 ID、用户名、密码（加密存储）、权限级别和用户注册时间，以实现用户身份验证及权限管理；地震事件基本信息表记录地震事件的核心数据，包括事件 ID、发生时间、地震震级、震中位置、影响范围、灾害类型以及初步损失估算；系统日志表记录系统运行和用户操作相关的日志信息，包括日志 ID、操作类型、操作用户、操作时间、描述信息，以便对系统运行状态进行有效追踪和维护，以下是对各关系型数据库表的具体设计。

表 5-2 和表 5-3 展示了地震灾害知识图谱智能问答的核心用户与系统信息。

表 5-2 用户信息表

字段名	数据类型	描述
user_id	INT	用户唯一标识 ID
username	VARCHAR(50)	用户名
password_hash	VARCHAR(255)	密码哈希（加密存储）
role	VARCHAR(20)	权限级别（管理员/普通用户）
register_time	DATETIME	用户注册时间

表 5-3 系统日志表

字段名	数据类型	描述
og_id	INT	日志记录唯一 ID
operation_type	VARCHAR(50)	操作类型（登录/查询/修改）
user_id	INT (FK)	操作用户 ID
operation_time	DATETIME	操作时间
description	TEXT	操作描述详细信息

表 5-4 展示了数据库中地震事件的基本信息存储设计。

表 5-4 地震事件基本信息表

字段名	数据类型	描述
event_id	INT	地震事件唯一 ID
event_time	DATETIME	地震发生时间
magnitude	FLOAT	地震震级
epicenter	VARCHAR(255)	震中位置
influence_area	TEXT	影响区域空间描述
disaster_type	VARCHAR(50)	灾害类型
loss_estimation	FLOAT	初步损失估算（万元）

表 5-5 至表 5-8 展示了地震灾害情景功能数据库构建中需要的关键参数。

表 5-5 情景参数配置表

字段名	数据类型	描述
scenario_id	INT	情景唯一标识
source_mechanism	VARCHAR(50)	震源机制
fault_rupture_speed	FLOAT	断层破裂速度（m/s）
liquefaction_probability	FLOAT	土壤液化概率（%）
building_vulnerability	INT	建筑群脆弱性分级
population_heatmap_code	VARCHAR(255)	人口热力图编码

表 5-6 灾害链推演表

字段名	数据类型	描述
chain_id	INT	灾害链唯一标识
trigger_event_type	VARCHAR(50)	触发事件类型
cascade_strength	FLOAT	级联强度系数
propagation_delay	FLOAT	传播时间延迟
mitigation_score	FLOAT	阻断措施有效评分

表 5-7 监测数据表

字段名	数据类型	描述
data_id	INT	监测数据唯一标识
sensor_type	VARCHAR(50)	传感器类型
timestamp	DATETIME	数据采集时间戳
grid_coordinates	VARCHAR(100)	地理网格坐标
physical_value	FLOAT	物理量值

表 5-8 应急资源调度表

字段名	数据类型	描述
resource_id	INT	资源唯一标识
resource_type	VARCHAR(50)	资源类型
scenario_id	INT (FK)	绑定的情景 ID
dispatch_priority	INT	调度优先级

表 5-9 图数据库设计

节点/关系类型	属性/特征	功能定位
地震事件节点	事件 ID、震源深度、矩震级、烈度等值线空间数据、能量释放频谱、历史案例相似度哈希值	通过烈度等值线与能量频谱构建物理特征向量，关联历史案例库实现情景模式匹配与灾害影响类比推理
次生灾害节点	灾害类型（滑坡/火灾/危化品泄漏）、发生概率、时空扩散模型参数、环境依赖变量（降雨量/风速）	定义次生灾害的触发条件与演化规则
基础设施关系边	关系类型（依赖/脆弱性/阻断）、连接强度权重、失效阈值、修复时间成本	描述交通网、供电网等基础设施的级联失效机制
应急决策关系边	决策类型（疏散/封路/物资投放）、触发情景 ID、生效时间窗、执行效果评估指标（覆盖率/响应延迟）	将预案措施与具体情景绑定，通过效果评估指标反馈优化决策逻辑

Neo4j 图数据库用于存储地震灾害知识图谱相关的数据,充分突出情景构建特性,建立高度结构化的图形化数据存储与查询模式。图数据库设计如表 5-9 所示。具体而言,包括地震灾害节点,用于表示不同地震事件的详细信息,包括节点 ID、灾害名称、发生时间、灾害波及范围、人员伤亡及经济损失估算;灾害影响关系边,用以展示灾害节点间的关联及影响路径,包括边 ID、影响类型、影响程度、路径描述;应急预案节点,储存与特定灾害事件相关的应急预案信息,包括预案 ID、对应的灾害类型、响应级别和具体的应对措施。通过这些明确的节点与关系边设计,使知识图谱能够实现精准的知识检索、情景推理与智能分析,以下是对各关系型数据库表的具体设计。

表 5-10 至表 5-12 展示了地震灾害知识图谱图数据库中的节点数据设定。

表 5-10 地震事件节点

属性名	描述
event_id	地震事件唯一标识
depth	震源深度 (km)
magnitude	矩震级
intensity_contour	烈度等值线空间数据
energy_spectrum	能量释放频谱数据
historical_similarity_hash	历史案例相似度哈希值

表 5-11 次生灾害节点

属性名	描述
disaster_type	类型 (滑坡/火灾/危化品泄漏等)
occurrence_probability	发生概率 (%)
diffusion_parameters	时空扩散模型参数
environmental_dependencies	环境依赖变量 (如降雨量、风速)

表 5-12 应急预案节点

属性名	描述
plan_id	预案唯一标识
disaster_type	对应的灾害类型
response_level	响应级别 (I 级、II 级等)
response_measures	具体应对措施描述

表 5-13 至表 5-15 展示了地震灾害知识图谱图数据库中的关系边数据的设定。

表 5-13 灾害影响关系边

属性名	描述
impact_type	影响类型（触发/传播）
severity	影响程度（权重系数）
path_description	影响路径描述

表 5-14 基础设施关系边

属性名	描述
relationship_type	关系类型（依赖/脆弱性/阻断）
weight	连接强度权重
failure_threshold	失效阈值（临界点）
recovery_time_cost	修复所需时间成本

表 5-15 应急决策关系边

属性名	描述
decision_type	决策类型（疏散/封路/物资投放）
trigger_scenario_id	触发情景 ID
valid_time_window	生效时间窗（开始-结束）
effectiveness_metrics	执行效果指标

整体数据库设计通过融合关系型和图形化数据存储技术，有效地支持地震灾害情景构建的多样化数据需求，提升数据的查询效率、分析能力与系统的响应速度，进而为地震灾害情景构建智能问答系统的可靠运行提供全面而高效的数据基础支持。

5.3 系统实现

5.3.1 系统开发环境

为支撑地震灾害情景构建智能问答系统的情景构建、推演展示与智能问答协同需求，系统采用混合技术栈开发环境，具体配置如表 5-16 所示。

通过采用上述混合技术栈覆盖了数据存储、深度学习模型开发、智能问答服务搭建与前端交互设计，明确了前后端分离架构，各模块解耦易于开发和运维，可扩展性强，支持未来技术扩展，如新模型开发、知识图谱扩充、新数据类型整合等。

整体上，该配置方案充分满足了地震灾害情景智能问答系统在开发效率、数据管理、高效检索、智能分析与用户体验等多方面需求。

表 5-16 系统开发配置表

类型	名称/工具	版本
操作系统	Ubuntu	22.04 LTS
开发平台	VSCode	1.82.0
编程语言	Python/Java/TypeScript	3.10/17.0/4.9.5
数据库	MySQL/Neo4j	8.0.33/5.12.0
深度学习框架	PyTorch/Transformers	2.0.1/4.30.0
后端框架	Flask	2.2.5
前端框架	React.js	18.2.0

5.3.2 系统实现方案

该系统要保障长期稳定运行，拥有丰富的机器学习和数据科学库，并且需要稳定可靠，适用于复杂业务逻辑实现，高效稳定，适合构建高性能的后端服务，提升前端代码的可维护性与稳定性且提供更好的用户交互体验，通过数据知识层、模型服务层与知识应用层的深度协同，实现地震灾害情景构建的全流程智能化管理。

在数据知识层，系统采用 MySQL 与 Neo4j 混合存储架构，针对结构化与非结构化数据进行差异化处理：MySQL 数据库通过分表策略存储用户权限信息、地震事件元数据（如震级、震中经纬度、发震时间戳）及传感器监测流数据（包括加速度计、倾斜仪等设备的秒级采样值），并建立索引来加速地理范围查询；Neo4j 图数据库则构建以第三章中构建好的地震灾害知识图谱为蓝本，其中地震事件节点嵌入烈度等特征，灾害影响关系边定义级联传播模型参数（如滑坡触发概率与扩散速度），应急预案节点关联多维度响应指标（如疏散路线覆盖率、物资投放时效性阈值）。数据层通过 Kafka 流处理平台实时接入多源异构数据，利用地理网格编码对齐遥感影像、社交媒体舆情与监测数据，并基于动态贝叶斯网络实现灾害链推演，当用户输入地震参数时，系统自动调用历史案例库匹配相似情景，结合建筑脆弱性分级模型与人口热力图，生成包含建筑物倒塌热区、交通网络中断概率、次生火灾风险分布的三维动态影响场。

模型服务层深度融合了知识图谱与大语言模型的能力，构建多模态智能计算框架。通过对地震事件节点进行嵌入表示，计算当前情景与历史案例的特征相似度，从知识图谱中提取关联应急预案并注入大模型进行决策优化；智能问答引擎采用混合推理机制，结构化查询直接通过 Cypher 语句在图数据库检索，复杂语义问题则触发检索增强生成（RAG）流程，先提取知识图谱中的建筑抗震等级、医疗资源分布数据，再驱动经 LoRA 微调的 DeepSeek-V1.7b 模型生成多维度分析报告；同

时建立知识图谱动态更新机制,当新增传感器检测到土壤液化概率异常时,系统自动修正次生滑坡节点的环境依赖参数,并通过对比学习算法优化图嵌入表示。

知识应用层提供可视化交互界面与决策支持工具,用户在地图界面标注震中位置并设置震源参数后,系统实时渲染烈度分布等值面与基础设施脆弱性热力图,叠加历史相似案例的应急处置路径作为参考;智能问答模块支持多轮对话,当用户追问“如何优化震后 48 小时救援路线”时,系统结合实时路况数据与知识图谱中的路径拓扑关系,并将计算结果以交互式沙盘形式展示;知识图谱管理界面允许用户通过自然语言指令触发子图检索,关联的应急预案、资源调度方案及其执行效果评估指标以决策树形式可视化,支持拖拽式节点关系重构与影响推演模拟。全系统通过 Docker 容器化部署,实现模型推理服务的动态负载均衡,确保在千级并发访问下仍能保持亚秒级响应速度。

5.4 系统展示

新用户首次访问系统时,可在注册界面(图 5-4)通过填写自定义用户名、密码及验证邮箱完成身份认证,点击“立即注册”提交表单后即完成账户创建流程。



图 5-4 用户注册



图 5-5 用户登录

已注册用户则通过登录入口(图 5-5)输入凭证信息实现系统鉴权。完成身份验证后,系统将自动跳转至主界面(图 5-6),默认加载知识图谱中的本体网络的核心节点及其关联子图的可视化图谱。用户可通过顶部搜索栏输入地震事件关键词(如“震级”、“烈度”等)进行精准图谱检索,亦可直接点击可视化界面中的节点(如标注为“地震”的节点),系统将动态触发节点详情弹窗(图 5-7)。




图 5-6 系统首页




图 5-7 节点详细信息展示框

用户可在系统的右边部分进行智能问答交互，在提问文本框中输入问题后，点击文本框右边的问答按钮，系统即可为用户提供答案，（图 5-8），同时系统会在知识图谱展示界面显示与问题匹配相关的实体节点以及与其相关联的实体节点子图，（图 5-9）。



图 5-8 智能问答展示




图 5-9 匹配节点展示

在情景构建功能中用户可以通过输入经纬度以及震级等信息，新增地震事件（图 5-10），之后系统即可生成该新增地震的影响场信息，展示给用户，并且该地震事件的相关信息也随之更新至知识图谱系统中（图 5-11）。

新增地震事件

录入方式

参数录入

外部影响场

勾绘录入

* 经度

请输入经度

* 纬度

请输入纬度

* 震级

4.5

(MS)

* 震源深度

12

(KM)

* 震中位置

请输入震中位置

* 发震时刻

2024-04-01 17:31:28

* 破裂方向

请输入破裂方向(破裂方向为0~360°)

计算

* 计算公式

请选择计算公式

地震类型

测试地震

真实地震

演练地震

* 评估名称

请输入评估名称

粒度

区县

乡镇

保存

取消

图 5-10 新增地震事件



图 5-11 地震影响场展示

新增地震事件后，用户可以在系统中就本次新增地震灾害新增事件进行提问，并通过问答的方式给出相似的历史地震以及生成该情景构建事件的灾害评估报告和应急预案（图 5-12）。



图 5-12 评估报告生成

5.5 本章小结

本章围绕地震灾害情景构建智能问答系统展开研究，结合地震灾害知识图谱与地震灾害多通道智能问答模型，构建了一套集地震事件查询、灾害情景构建、智能问答于一体的智能化系统。分析了系统的功能需求，并在此基础上进行概要设计，明确了系统架构、数据库结构及核心模块。详细介绍了系统的实现过程，包括数据处理、知识图谱集成、多通道问答机制的应用，以及前端交互设计。通过系统展示验证了本研究方法的可行性和有效性，表明该系统在地震应急响应、灾害评估及防灾减灾领域具有重要的应用价值。下一步研究将进一步优化系统性能，提升问答准确性，并探索多模态数据融合，以增强系统的实用性和智能化水平。

第六章 总结与展望

6.1 全文总结

本研究围绕智能问答技术展开，重点探讨了知识图谱与大模型的融合，以提升问答方法的准确性和可解释性。本研究开展了一系列创新性研究，主要包括以下三个方面：

构建了地震灾害知识图谱，并在其构建过程中创新性地引入 SENet 机制，提出了一种基于 BERT-SENet-BiLSTM-CRF (BSBC) 的实体抽取模型，实验结果表明该模型在多个数据集上的表现优越。此外，本研究优化了知识图谱的本体、实体和关系构建策略，以提高数据的一致性和规范性。

提出了一种多通道智能问答模型 (MultiPathQA)，结合图卷积网络 (GCN) 与 BERT 计算问题语句复杂度，并引入智能决策机制，根据不同问题类型选择最优问答通道。本研究设计了三种问答通道，分别为知识图谱问答负责简单难度精准匹配问题、检索增强生成负责中等难度跨领域问题和大模型负责复杂难度推理问题，以增强答案的准确性和适应性。

构建了一套面向地震灾害情景构建的智能问答系统，融合知识图谱与多通道问答技术，实现了地震事件查询、地震灾害情景构建和智能问答等核心功能。该系统能够为用户提供高效、精准的灾害信息服务，并在地震应急响应及防灾减灾领域具有重要的应用价值。

总体而言，本研究通过构建知识图谱与大模型协同的问答方法，有效提升了地震灾害领域问答系统的智能化水平，提供了一种高效且可靠的专业问答解决方案。未来的研究可以进一步探索知识图谱与大模型的深度融合，优化问答系统的实时性和可扩展性，以提升在实际应用中的适应性和普及度。

6.2 未来展望

尽管本文在知识图谱构建和智能问答技术方面取得了一定成果，但仍存在以下值得进一步研究的方向：

1. 动态知识图谱构建：当前的知识图谱主要针对静态数据构建，未来可以研究如何将知识图谱扩展到动态环境，以支持随时间变化的知识更新和推理。

2.用户行为数据融合：目前的问答系统主要依赖知识图谱和大模型，尚未充分利用用户与系统的交互行为数据。未来可以结合用户行为数据，优化个性化推荐策略，提高问答系统的响应质量。

通过上述研究方向的进一步探索，有望提升基于知识图谱和大模型的智能问答系统的智能化水平，并推动其在更广泛的应用场景中落地实践。

参考文献

- [1] 刘正伟, 文中领, 张海涛. 云计算和云数据管理技术[J]. 计算机研究与发展, 2012, 49(S1): 26-31.
- [2] Liu X, Wu Y, Zheng K, et al. A survey on knowledge graphs: Representation, acquisition, and applications[J]. Artificial Intelligence Review, 2021, 54(5): 3701-3745.
- [3] Dong X, Gabrilovich E, Heitz G, et al. Knowledge vault: A web-scale approach to probabilistic knowledge fusion[C]//Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining. 2014: 601-610.
- [4] Brown T, Mann B, Ryder N, et al. Language models are few-shot learners[C]. //Proceedings of the Advances in Neural Information Processing Systems, 2020, 33: 1877-1901.
- [5] Zhang H, Li T, Fang B, et al. A review on knowledge graph-based question answering[J]. Future Generation Computer Systems, 2021, 117: 347-370.
- [6] 张鹤译, 王鑫, 韩立帆, 等. 大语言模型融合知识图谱的问答系统研究[J]. 计算机科学与探索, 2023, 17(10): 2377-2388.
- [7] Wu J, Zhang Y, Feng J, et al. A hybrid knowledge graph and deep learning-based approach for intelligent question answering[J]. Expert Systems with Applications, 2022, 187: 115947.
- [8] Lin H, Gao J, Wang Y. Enhancing explainability in question answering with knowledge graphs[J]. Knowledge-Based Systems, 2022, 235: 107617.
- [9] 陶坤旺, 赵阳阳, 朱鹏, 等. 面向一体化综合减灾的知识图谱构建方法[J]. 武汉大学学报(信息科学版), 2020, 45(08): 1296-1302.
- [10] Uslander T. Foundations and trends in knowledge graphs[J]. Semantic Web, 2020, 11(3): 471-504.
- [11] Deng Y, Han R, Zhou J. Earthquake terminology ontology: A new approach to knowledge representation[J]. Journal of Geophysical Research, 2019, 124(6): 1345-1361.
- [12] Zhang Y, Wang X, Liu Z. A rule-based approach for earthquake-related entity recognition[J]. Natural Hazards, 2018, 93(2): 675-689.
- [13] Kim J, Park J, Choi S. Named entity recognition for earthquake reports using rule-based patterns[C]. Proceedings of ACL 2019, 2019: 221-228.
- [14] Liu Q, Sun Y, Wang P. Syntax-aware entity extraction for earthquake disaster reports[J]. Information Processing & Management, 2020, 57(5): 102341.

- [15] Wang L, Zhang M, Li H. Conditional random fields for seismic event extraction[J]. Expert Systems with Applications, 2017, 90: 179-188.
- [16] Matsuo Y, Ishikawa T. Earthquake entity classification using support vector machines[C]. Proceedings of ICML 2020, 2020: 789-798.
- [17] Zhao H, Xu J, Liu Y. Hidden Markov models for earthquake damage assessment[C]. AAAI 2021, 2021: 541-548.
- [18] 王智悦, 于清, 王楠, 等. 基于知识图谱的智能问答研究综述[J]. 计算机工程与应用, 2020,56(23):1-11.
- [19] Reddy S, Lapata M, Steedman M, et al. Large- scale semantic parsing without question-answer pairs[J]. Transactions of the Association for Computational Linguistics, 2014, 2(1): 377-392.
- [20] Yih S W, Chang M W, He X, et al. Semantic parsing via staged query graph generation: Question answering with knowledge base[C]//Proceedings of the Joint Conference of the 53rd Annual Meeting of the ACL and the 7th International Joint Conference on Natural Language Processing of the AFNLP. 2015.
- [21] Bast H, Haussmann E. More accurate question answering on freebase[C]//Proceedings of the 24th ACM international on conference on information and knowledge management. 2015: 1431-1440.
- [22] Dong L, Lapata M. Language to logical form with neural attention[C]//In Meeting of the Association for Computational Linguistics, 2016:33-43.
- [23] Jia R, Liang P. Data recombination for neural semantic parsing[C]// In Meeting of the Association for Computational Linguistics, 2016:12-22.
- [24] Chen B, Sun L, Han X, et al. Sequence-to-action:end-toend semantic graph generation for semantic parsing[C]// In Meeting of the Association for Computational Linguistics, 2018:766-777.
- [25] Lukovnikov D, Fischer A, Lehmann J, et al. Neural networkbased question answering over knowledge graphs on word and character level[C]//2024 IEEE 24th International Conference on Software Quality, Reliability, and Security Companion (QRS-C). IEEE, 2024: 926-933.
- [26] 丁斌. 汽车领域智能问答系统中模板库自动生成方法的研究[D]. 上海: 上海交通大学, 2017.
- [27] Bordes A, Chopra, Weston J. Question answering with subgraph embeddings[J]. arXiv:1406.3676,2014.

- [28] Hao Y, Zhang Y, Liu K, et al. An end-to-end model for question answering over knowledge base with cross-attention combining global knowledge[C]//Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2017: 221-231.
- [29] Qu Y, Liu J, Kang L, et al. Question answering over freebase via attentive RNN with similarity matrix based CNN[J]. arXiv:1804.03317, 2018.
- [30] 任海玉, 刘建平, 王健, 等. 基于大语言模型的智能问答系统研究综述[J]. 计算机工程与应用, 2025, 61(7): 1-24.
- [31] OpenAI. ChatGPT: Optimizing Language Models for Dialogue[EB/OL]. OpenAI Blog, 2022. Available: <https://openai.com/research/chatgpt>.
- [32] DeepSeek-AI, Daya Guo, Dejian Yang, et al. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning[EB/OL]. arXiv, 2025. Available: <https://arxiv.org/abs/2501.12948>.
- [33] Raffel C, Shazeer N, Roberts A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. Journal of machine learning research, 2020, 21(140): 1-67.
- [34] Touvron H, Lavril T, Izacard G, et al. LLaMA: Open and Efficient Foundation Language Models [J]. arXiv:2302.13971, 2023.
- [35] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks [J]. arXiv:2005.11401, 2020.
- [36] Guu K, Lee K, Tung Z, et al. REALM: Retrieval-Augmented Language Model Pre-training [C]. International Conference on Machine Learning, 2020.
- [37] Karpukhin V, Oguz B, Min S, et al. Dense Passage Retrieval for Open-Domain Question Answering [C]. Empirical Methods in Natural Language Processing, 2020.
- [38] Gallifant J, Fiske A, Levites Strekalova Y A, et al. Peer review of GPT-4 technical report and systems card[J]. PLOS digital health, 2024, 3(1): 1-15.
- [39] Hua R, Dong X, Wei Y, et al. Lingdan: enhancing encoding of traditional Chinese medicine knowledge for clinical reasoning tasks with large language models[J]. Journal of the American Medical Informatics Association, 2024, 31(9): 2019-2029.
- [40] Yao S, Ke Q, Wang Q, et al. Lawyer GPT: A legal large language model with enhanced domain knowledge and reasoning capabilities[C]//Proceedings of the 2024 3rd International Symposium on Robotics, Artificial Intelligence and Information Engineering. 2024: 108-112.
- [41] Wu T, Zhang J, Wu X, et al. FinGPT: Open-source financial large language model [C]. FinTech Conference, 2023.

- [42] Sun Y, Wang S, Li Y, et al. ERNIE 3.0 Titan [C]. Meeting of the Association for Computational Linguistics, 2021.
- [43] Qian Y, Bai M, Zhao X, et al. Qwen: Alibaba's Large Language Model [J]. arXiv:2311.06420, 2023.
- [44] 文森, 钱力, 胡懋地, 等. 基于大语言模型的问答技术研究进展综述[J]. 数据分析与知识发现, 2024, 8(06): 16-29.
- [45] SHI W, MIN S, YASUNAGA M, et al. Replug: Retrieval-augmented black-box language models[J]. arxiv preprint arxiv:2301.12652, 2023.
- [46] RAM O, LEVINE Y, DALMEDIGOS I, et al. In-context retrieval-augmented language models[J]. Transactions of the Association for Computational Linguistics, 2023, 11:1316-1331.
- [47] YU W, ITER D, WANG S, et al. Generate rather than retrieve: Large language models are strong context generators[J]. arxiv preprint arxiv:2209.10063, 2022.
- [48] SUN Z, WANG X, TAY Y, et al. Recitation-augmented language models[J]. arxiv preprint arxiv:2210.01296, 2022.
- [49] FENG Z, FENG X, ZHAO D, et al. Retrieval-generation synergy augmented large language models[C]//ICASSP2024-2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2024.
- [50] SHAO Z, GONG Y, SHEN Y, et al. Enhancing retrieval-augmented large language models with iterative retrieval-generation synergy[J]. arxiv preprint arxiv:2305.15294, 2023.
- [51] Zhang Y, Weng W G, Huang Z L. A scenario-based model for earthquake emergency management effectiveness evaluation[J]. Technological Forecasting and Social Change, 2018, 128: 197-207.
- [52] Tian D, Song W, Qu T, et al. Constructions of earthquake scenarios based on virtual simulations[C]//IOP Conference Series: Earth and Environmental Science. IOP Publishing, 2021, 669(1): 1-6.
- [53] Spence R, So E, Ameri G, et al. Earthquake disaster scenario prediction and loss modelling for urban areas[J]. Less loss report, 2007, 7: 1-165.
- [54] Tang A, Wen A. An intelligent simulation system for earthquake disaster assessment[J]. Computers & Geosciences, 2009, 35(5): 871-879.
- [55] Hori M, Ichimura T. Current state of integrated earthquake simulation for earthquake hazard and disaster[J]. Journal of seismology, 2008, 12: 307-321.

- [56] Babayev G, Ismail-Zadeh A, Le Mouél J L. Scenario-based earthquake hazard and risk assessment for Baku (Azerbaijan)[J]. *Natural Hazards and Earth System Sciences*, 2010, 10(12): 2697-2712.
- [57] Zhuang J, Peng J, Zhu X, et al. Scenario-based risk assessment of earthquake disaster using slope displacement, PGA, and population density in the guyuan region, China[J]. *ISPRS International Journal of Geo-Information*, 2019, 8(2): 1-16.
- [58] Karimzadeh S, Miyajima M, Hassanzadeh R, et al. A GIS-based seismic hazard, building vulnerability and human loss assessment for the earthquake scenario in Tabriz[J]. *Soil Dynamics and Earthquake Engineering*, 2014, 66: 263-280.
- [59] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need [J]. *Advances in neural information processing systems*, 2017, 30.
- [60] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[J]. *arXiv preprint arXiv: 1609.02907*, 2016.
- [61] Yang N, Pun S H, Vai M I, et al. A Unified Knowledge Extraction Method Based on BERT and Handshaking Tagging Scheme[J]. *Applied Sciences*, 2022, 12(13): 6543-6557.
- [62] Jawahar G, Sagot B, Seddah D. What Does BERT Learn about the Structure of Language?[C]//*ACL 2019-57th Annual Meeting of the Association for Computational Linguistics*. 2019.
- [63] HU J, SHEN L, SUN G. Squeeze-and-Excitation Networks [C]// *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2018: 7132-7141.
- [64] Mendes-Victor L, Oliveira C S, Pais I, et al. Earthquake damage scenarios in Lisbon for disaster preparedness[J]. *Issues in urban earthquake risk*, 1994: 265-289.
- [65] Chiu J P C, Nichols E. Named entity recognition with bidirectional LSTM-CNNs[J]. *Transactions of the Association for Computational Linguistics*, 2016, 4: 357-370.
- [66] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//*Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*. 2019: 4171-4186.
- [67] Li X, Feng J, Meng Y, et al. A Unified MRC Framework for Named Entity Recognition[C]//*Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. 2020: 5849-5859.
- [68] Huang Z, Xu W, Yu K. Bidirectional LSTM-CRF models for sequence tagging[J]. *arXiv preprint arXiv:1508.01991*, 2015.

- [69] Souza F, Nogueira R, Lotufo R. Portuguese Named Entity Recognition using BERT-CRF[J]. arXiv preprint arXiv:1909.10649, 2019.
- [70] Hu E J, Shen Y, Wallis P, et al. Lora: Low-rank adaptation of large language models[J]. ICLR, 2022, 1(2): 1-20.
- [71] Rajpurkar P, Zhang J, Lopyrev K, et al. SQuAD: 100,000+ Questions for Machine Comprehension of Text[C]//Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2016: 2383-2392.
- [72] Dasigi P, Gardner M, Murty S, et al. RODQA: A Rule-based Open-Domain Question Answering Model[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). Association for Computational Linguistics, 2020: 5678-5689.
- [73] Lewis M, Liu Y, Goyal N, et al. BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL). Association for Computational Linguistics, 2020: 7871-7880.